DataFun.

数据科学
典藏版合集

DataFunTalk系列技术合集：数据科学篇

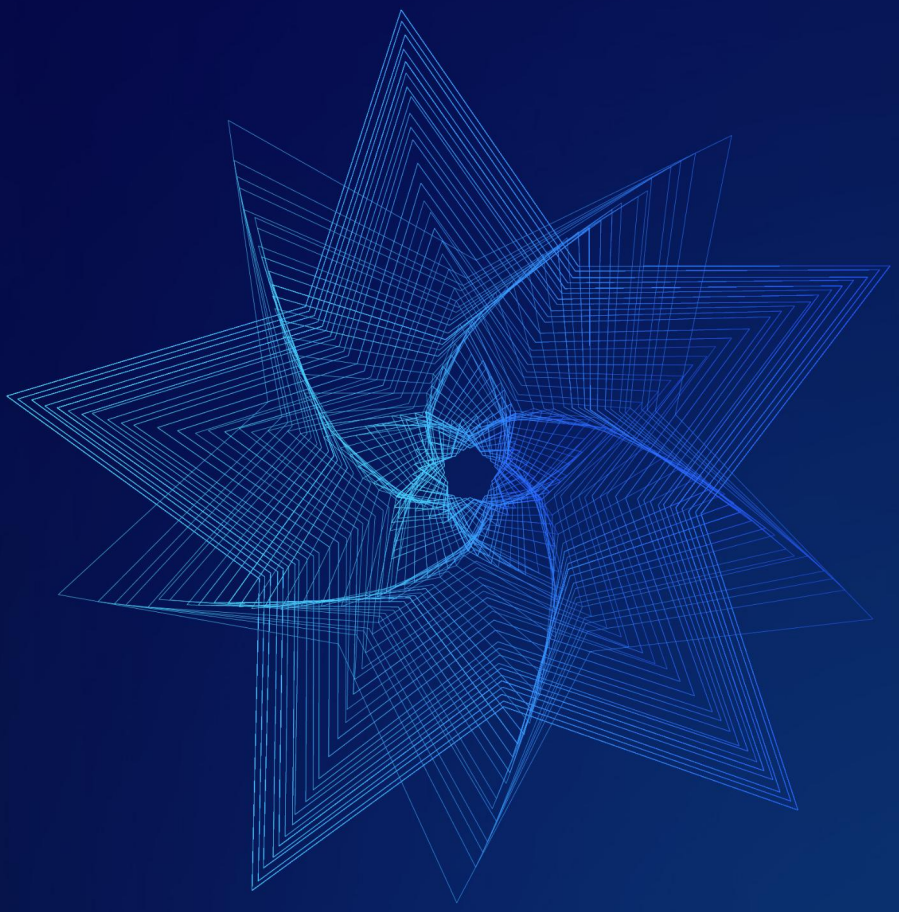

本书内含：

DataFunTalk精选最新数据科学技术文章合集
20篇，400+页，10W字

DataFun
视频回看年卡

-视频涵盖大数据和算法技术实践，干货满满

-近4年，积攒400+精选案例视频，免费回看

-每1年，至少200+新增案例分享，免费回看

扫码查看历史视频

目录

数据驱动的京东精细化消费者运营平台……4
因果推断在阿里飞猪广告算法中的实践……27
腾讯增长技术：智能投放篇……52
信息流推荐的用户增长机制……69
滴滴数据指标体系建设实践……85
因果推断在阿里文娱用户增长中的应用……112
推荐系统衡量：ABtest 框架……123
联邦学习与安全多方计算……136
京东超大规模联邦学习探索实践……159
微众银行在联邦推荐算法上的探索及应用……180
新一代联邦学习技术及应用实战……210
阿里文娱智能营销增益模型（Uplift Model）技术实践……243
爱奇艺数据中台的建设实践……260
金融资管数据中台体系探索实践……287
增强分析技术原理与实践……310
贝壳商业化算法中台架构实践……331
网易大数据用户画像实践……367
用户画像在阅文的探索与实践……387
用户画像实践：神策标签生产引擎架构……408

数据驱动的京东精细化消费者运营平台

分享嘉宾：王成栋 京东 产品总监
编辑整理：刘博文
出品平台：DataFunTalk

导读：互联网下半场，随着互联网渗透率提升，人口红利消失，传统的以流量为中心的营销方式难以支撑品牌在电商平台的高速增长，新形势下，品牌该如何寻找新的增长动力？以大数据和 AI 算法驱动的消费者精细化运营，是京东平台为品牌提供的新答案。在本次分享中，将介绍京东在构建品牌消费者精细化运营平台的过程中，相关行业思考、技术应用和产品形态，为听众解码品牌在互联网下半场的新增长动力。

围绕以下三方面进行介绍：

- 互联网下半场的营销生态
- 消费者精细化运营重新定义营销
- 京东消费者精细化运营平台的三次进阶

01

互联网下半场的营销生态

1．伴随互联网成长的在线营销生态

在过去 20 年期间，中国互联网基本上可以分为两个时代，一个是 PC 时代，一个 Mobile 时代。简单可以看下图所示的三条轴，前两条轴代表在营销环境下整个信息传播的一些媒介形式变化和这种商业流动的形式变化。随着移动端的出现，人们在移动互联网上花费的时间越来越多，从信息流动层面上，媒体形式越来越多样化、碎片化；从商品流动这个层面上，出现很多新的电商形态，比如说去中心化的社交电商，依托于新媒体形式的直播电商等；伴随信息和商品流动形式的改变，在线营销生态也相应发生改变，从 2012 年左右兴起的 AdTech 到近几年的 MarTech，在 AdTech 时代，DSP、DMP 和 Ad Exchange 等类型的独立公司出现，很多大厂也在做这类产品的建设，这段时间行业在集中的精力攻克的一个事情，是怎么样通过数据的应用去直接提升广告的效果。随着互联网进入下半场，营销生态逐步进入到 MarTech 时代，随之又产生了一系列新的产品形态，我们本次分享试图探讨这些演进背后的逻辑。

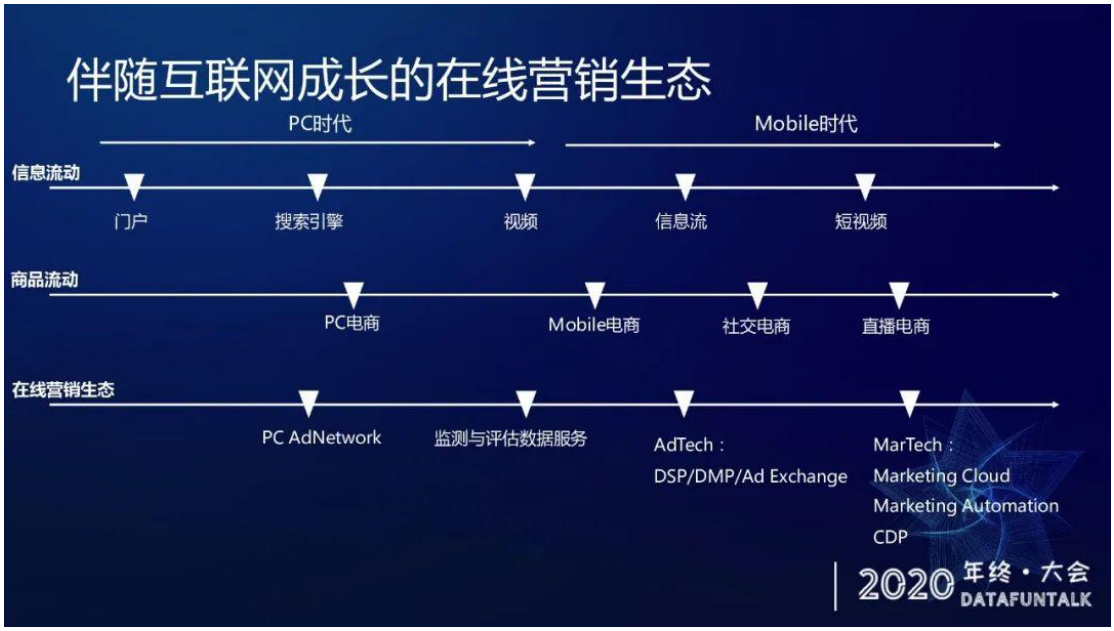

2. 互联网下半场的营销挑战

互联网下半场，可以归结为两个特征，一是互联网市场人口和流量的红利逐渐消失，二是随着整个互联网渗透率提高，量变带来的质变，互联网成为商业社会的基础设施。这两个因素叠加，我们能看到很有意思的现象，虽然表面上增速趋缓，但是创新和变化依然活跃，互联网行业在不停开辟新的战场，比如下沉市场的各种产品和服务形态出现，电商的线上线下一体化，还有就是国际化，我们中国的先进的这些产品和技术去向国外输出，以及一个大的趋势就是从 toC 互联网，向 toB 产业互联网的发展。简单的总结一下，今天的互联网，虽然我们号称属于下半场，但是它依然变化很多很快，在这样的一个时点下，对于品牌的在线商业营销带来以下三方面挑战。

① 流量红利消失带来营销效果提升难

以前出现一个新 app，或者一个新渠道，我们去做一波投放，销售、转化就会有一个明显的提升，但在今天的环境下，大家都聚集在一些头部媒体上，怎样去进一步的提高效果，是一个比较有挑战的事情。

② 如何快速应对变化

互联网上的新媒体形态和新商业形态依然在快速变化，比如短视频、直播电商，在这种歌情况下，品牌一方面要去应对效果提升难的挑战，另一方面，还需要去快速的去应对这些变化，否则的话就要落后更多。

③ 原营销方法论不再适用

从营销 4P 要素的角度看，品牌提供商品（Product），设定价格（Price）后，通过推广渠道（Promotion）和销售渠道（Place）进行消费者触达，曾经互联网只是对 Promotion 和 Place 的一个补充。当下，互联网成为商业社会的新基础设施，我们所有的品牌消费者都连接到互联网上，4P 已经完全融入到互联网中。这样的话原来的营销方法论不再适用，我们需要一个全新的营销方法论去帮助应对现在的互联网新环境，这个从未有过的新环境。从这个角度上来讲，整个互联网市场无论是平台方，还是说其中的各个品牌企业都面临着这个挑战：在这样的一个范式转换的时刻，我们该如何应对。京东作为一个平台，平台上有很多品牌商家在上面做生意，做营销，我们怎么样去利用我们的技术、数据和能力的优势来帮助品牌去应对这个挑战，这是我们思考的起点。

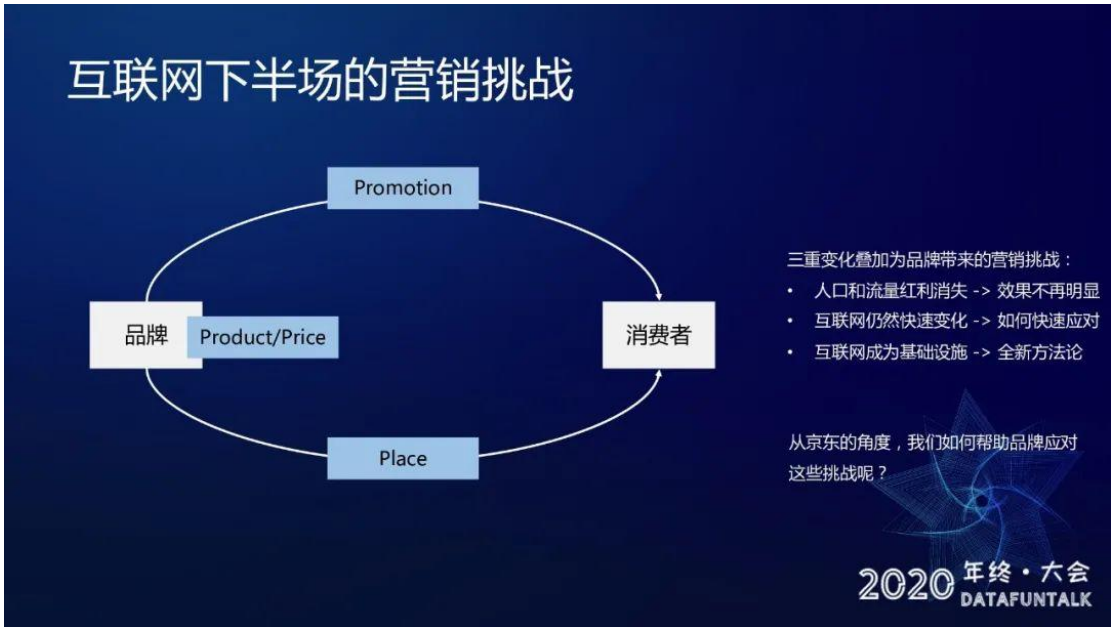

02

消费者精细化运营重新定义营销

这部分是我们初步思考的一个结论，希望通过我们的能力向品牌提供消费者精细化运营的能力，通过重新定义营销的方式来帮助品牌去更好地获得成长。

1．寻找变化中的不变量

首先，回到我们现在所处的环境，整个互联网从媒介层面上来讲，它的碎片化和多元化依然非常严重，并且新的形式无论是媒介上还是商业上是一直在层出不穷，不停变化。面对这样一个变化的环境，我们应该怎么样去更好的去做好营销，是一个很大的问题。我们可以想象一个场景，某个晚上在没有指南针的情况下，要找到方向，我们要怎么做？我们肯定不会去研究那些在不同季节里出现的星座，我们最快的捷径是找到在任何夜晚都不变的那颗星，也就是北极星。回到营销也

是一样的，整个环境在不停的变化，在变化过程中，我们需要抓住不变量，然后围绕不变量去更好的设计我们的营销策略，这可能是一个更有效的方法。在营销里面，不管互联网怎么变，在互联网的另一端，消费者和用户其实都是同一拨人，也许他们上网的方式，购买的渠道，购买的方式会发生的变化，但是他们本身是不变的。我们如果能够去捕捉到他们，对他们有持续的关注，那我们就可能找到一个新的方式去更好的做营销增长。

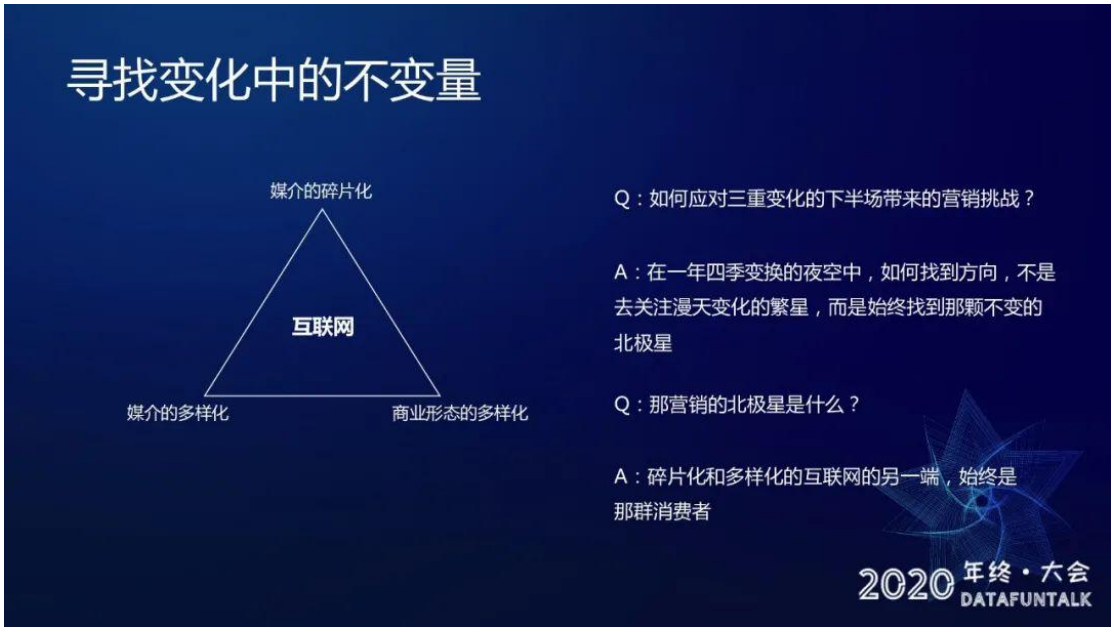

2. 重新定义营销

怎么样去重新定义营销？我们希望在互联网成为商业社会的基础设施后，营销能升级为品牌对消费者的持续运营。它具有以下的特征，首先它是真正以消费者为中心的运营。其实营销的传统理念也是以消费者为中心，但是由于数据条件和技术条件的限制，传统营销不能真正的跟消费者产生直接的联系，以及关注消费者的利益。而在互联网环境下，我们是可以实现这种真正以消费者为中心的跟踪和

持续沟通。通过对消费者做数字化管理和干预实现真正的精细化运营，以及通过对用户的持续关注实现真正的品效无界营销。我们希望这种消费者的精细化运营，能够给新时代营销提供新的解法和打法。

3. 数字化+智能化双引擎驱动消费者精细化运营

如何实现消费者精细化运营，本质上需要两个核心的驱动引擎：一个是数据化引擎，一个是智能化引擎。

数据化引擎，是把真实世界里的消费者做一个数字化映射，这离不开整个网络对消费者提供的服务，以及对沉淀下来的消费者特征做的挖掘和补充。在这些数据的基础上构建智能的分析算法和用户转化算法，帮助我们理解消费者，针对不同消费者，制定不同的沟通策略和转化策略，优化营销效果，以及通过科学的方式去评估营销效果。所以在这个系统里，核心的是数据化+智能化这两个引擎。

4. 构建兼顾营销的品牌消费者运营模型

为了构建整个双引擎体系，我们需要做以下三方面的工作。第一方面是构建一个兼顾营销的消费者运营模型，这将提供一个新的可以遵循的方法论路径。第二方面是构建一个消费者运营的一站式平台。第三个是在生态层面上构建一个共同增长的运营平台。接下来对这三个方面做一个简单的展开。

① 构建一个兼顾营销目标的品牌消费者运营模型

首先，回归本质，营销的目标是什么？从大的层面来讲，营销目标可以定义为两个方面，一个是销量提升，一个是品牌建设。销量的提升，也就是建立品牌的动能，让品牌直接走向消费者，让消费者购买这个品牌，是我们把产品推到消费者面前。品牌建设是建立品牌的势能，也就是建立消费者对品牌的认知和喜好，这样消费者会主动的关注了解我们的品牌，在产生需要的时候主动购买我们的品牌，这样一推一拉的结合才是最终要达到治标治本的方案。

以这个为目标，首先需要一个消费者运营模型，并基于这个模型去推演后面的一些体系化的运营方法论。增长黑客是现在一个非常火热的概念，增长黑客 AARRR 模型是其中的核心模型，它更适用于 APP 层面或者网站应用层面的用户的增长，因为它更偏向于效果类的视角。怎样做一个能兼顾品效结合的营销消费者运营模型，是我们首先需要解决的问题，这也是我们整个营销方法论的基础。

② 构建一个消费者运营的一站式平台

消费者运营是一个非常体系化的事情，它会贯穿洞察现状，分析原因，制定策略，执行策略，评估效果到优化提升的全流程。以上的工作，是一个很长的链条，会联动整个链条上各种各样的系统。而完成这些不同工作的产品和能力可能是散落在不同部门或者不同的生态角色里，从这个角度来讲，我们就非常有必要提供一个一站式工具，能够去简化操作和降低使用成本，否则这个方法论在落地时就会遇到很大的挑战。

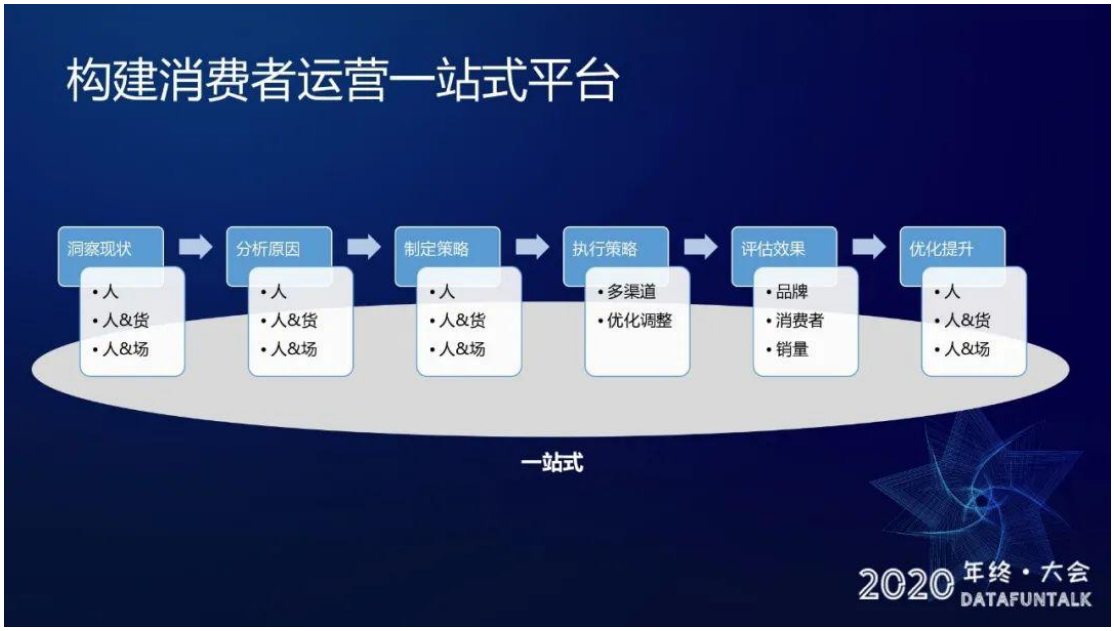

③ 构建共同增长的消费者运营生态

在京东平台上，存在很多角色，比如消费者、品牌商家、服务商等。我们一定要保证在整个生态里，新方法论能够实现共同增长或者共赢，这样才能保证生态比较平稳的落地。从消费者的角度来说，通过消费者运营的一些举措，我们能够跟品牌一起为消费者提升购物体验，让消费者能够多快好省的找到商品。但同时也需要特别关注消费者的数据安全、隐私安全问题，让消费者既保障了自己的数据安全，又能提升购物体验。从品牌的角度来说，我们给品牌提供一个新的武器，让品牌能够依托互联网更好增长生意，在流量红利消失的现状下实现品牌销量和消费者多重的增长。从服务商的角度来说，我们推行一种新的营销思路和方法，需要服务商给品牌做方法论的导入和相应的解决方案的打造，最终通过平台的建设让整个生态获得共同增长。

03

京东消费者精细化运营平台的三次进阶

接下来对京东的消费者精细化运营平台的三次重要进阶以及我们相应做了哪些的工作，跟大家做一些分享。

1．进阶一：构建京东生态内的消费者运营能力

第一个阶段：借助我们的产品和工具帮助品牌构建在京东生态内的消费者运营能力。下图是简单罗列的京东生态上各种营销触点，可以分成全域、公域和私域。通过和媒体的京 X 合作，基本上实现了对中国互联网网民的百分之百覆盖，比如我们跟腾讯合作的京腾计划，跟头条合作的京条计划等等。京 X 计划覆盖了很多种类型的媒体。通过这些触点，为品牌构建了一个全域的流量场和用户场。同样，我们也为品牌构建了公域和私域场。在这三个不同层次的用户场里，怎样让品牌

开展品效结合的消费者运营，进而帮助品牌实现增长，是我们希望第一阶段通过产品达到的目标。

① 品牌 4A 消费者运营模型

针对第一个问题，我们提出了 4A 消费者资产运营模型。首先，我们从品牌的角度，根据京东生态内消费者跟品牌之间的互动关系，将消费者状态切分为四个阶段，分别是认知、吸引、行动和拥护。前两个人群认知和吸引帮助品牌提升品牌力。后两个人群行动和拥护的人群帮助品牌提升销售力。通过这个简化模型，品牌不仅能看到购买自己商品的用户，而且能看到跟品牌产生主动和被动接触的用户。我们实际上完成了一个转换，即原来电商的效果类营销更集中在收割层面，通过 4A 模型拓展到了品牌的消费者心智打造，拓展到消费者的长期培育，依托于此，我们可以探索真正的品效结合。

② 京东营销 360-全方位消费者运营，4E 营销方法论

在 4A 的消费者运营模型基础上，我们推出了京东营销 360 的全方位消费者运营的 4E 营销方法论。4E 其实对应的是在不同的阶段需要做哪些重点的工作，在这些重点工作背后，我们会开发相应的数据产品和技术能力来支撑这个阶段的效果最终达成，从而实现数据驱动闭环消费者运营提效。

③ 推出一站式消费者运营平台-数坊

基于以上这些消费者运营模型和方法论，第一阶段我们推出整个京东面向品牌侧的一站式消费者运营平台——数坊。从底层来讲，基于京东全渠道触点行为，统一用户 ID、用户全渠道行为标签以及品牌一方数据等底层数据，构建了品牌的 4A 消费者资产，围绕着 4A 消费者资产，我们建设了相应的 4E 能力。在开发营销策略环节，我们会构建两种能力，针对品牌整体消费者的洞察分析能力和针对于人货场的分析能力，通过这些能力帮助品牌实现对消费者的深度洞察，支持开发营销策略。在执行环节，通过目标人群挖掘和构建全链路自动化营销的能力，帮助我们精准锁定目标人群，提升营销转化效果。在效果评估层面上，结合 4A 模型从品、效两个层面来评估营销效果。最后通过一些跨渠道优化和智能投放优化的实时调整来改善营销效果。

在最终的能力展示层面上来讲，我们会提供两种能力。一种是标准化的产品能力，通过提供一些简单应用的 UI 界面，让业务人员可以更方便的进行全流程的操作。同时我们开放 DataLab，将底层能力进行封装，让有数据科学能力的品牌参与进来，做更高度定制化的自定义分析，从而更深入地挖掘数据。

④ 数据+算法驱动的消费者深度洞察

接下来简单讲下，我们如何通过数据和算法的结合，对消费者进行的深入洞察。从人的层面上，我们会通过底层的算法分析模型，帮助我们看到消费者不同维度的特征分析与洞察，帮助品牌更好的定位目标人群；在人和场层面上，这些模型可以帮品牌发现哪些触点对流转贡献是更高的。针对这些触点，购物路径是怎么样的，哪些关键触点更值得品牌去做投入；在人和货层面上，通过人和货品的关系洞察，针对不同的消费者群，匹配不同的货品策略，借助这些货品来更好的运营消费者。

⑤ DataLab - 定制化数据应用能力

DataLab 我们开放的定制化数据分析和应用能力，通过对品牌开放我们底层的引擎，使很多有数据科学能力的品牌能够运用这个能力。我们把很多平台底层成熟的 AI 算法模型集成进一个简单易用的点选式建模页面，使品牌的数据分析师可以对数据做定制化挖掘和分析。我们也更进一步提供了在线代码编辑环境，为品牌的数据科学家提供了更高自由度的数据处理能力。这样在标准化能力基础上，通过这种定制化能力的开放，让品牌能够更加灵活的将数据应用到自身的消费者运营中。

2. 进阶二：GOAL 方法论-为消费者运营寻找指示器

第二个阶段，我们推出了 4A 模型以后，品牌经常会问，应该将那些消费者拉进 4A 循环呢？新的消费者进了 4A 循环以后，如何进一步运营，有哪些可以遵循的规则和明确的方向呢？针对这些问题，我们今年推出了能够给品牌提供有效指引的 GOAL 方法论，以帮助品牌更有目标性的进行消费者运营。GOAL，代表四个不同的增长方向。第一个增长方向我们定义为靶群，可以理解为营销中的目标人群。在电商环境下，基于丰富的用户标签（不局限于传统的性别，年龄的用户标签去做用户区分）把消费者做更精细化切分，定义不同的核心人群作为我们需要做运营的人群。在每个需要运营的人群中，我们提炼三个增长方向，分别是渗透增长，价值增长和忠诚增长，分别对应的是让这些人来买我、多买我、只买我。相应的在每个方向上我们提供了很多运营分析指标，来帮我们看我们的品牌相对于平台，相对于其他品牌存在的差距，以及怎么样更好的和一些工具联动起来，做相应的用户增长。

① 寻找增量靶群

在 GOAL 方法论中，一个核心的理念是去寻找增量靶群。随着品牌越来越多，很容易出现大家都去盯着一些同质化用户群去做竞争，这会导致品牌营销成本不断升高。是否能够利用电商丰富的数据发现蓝海人群，通过蓝海人群有效的运营来降低拉新成本，提升营销 ROI 呢？为了帮助品牌更好的寻找增量靶群，我们做了一个靶群挖掘的功能。基于底层维度丰富的标签帮助品牌识别出潜在的消费者族群特征，再通过客群放大能力，帮助品牌进行靶群拓展。通过这个功能，我们计算机去帮助品牌，发掘蓝海人群。

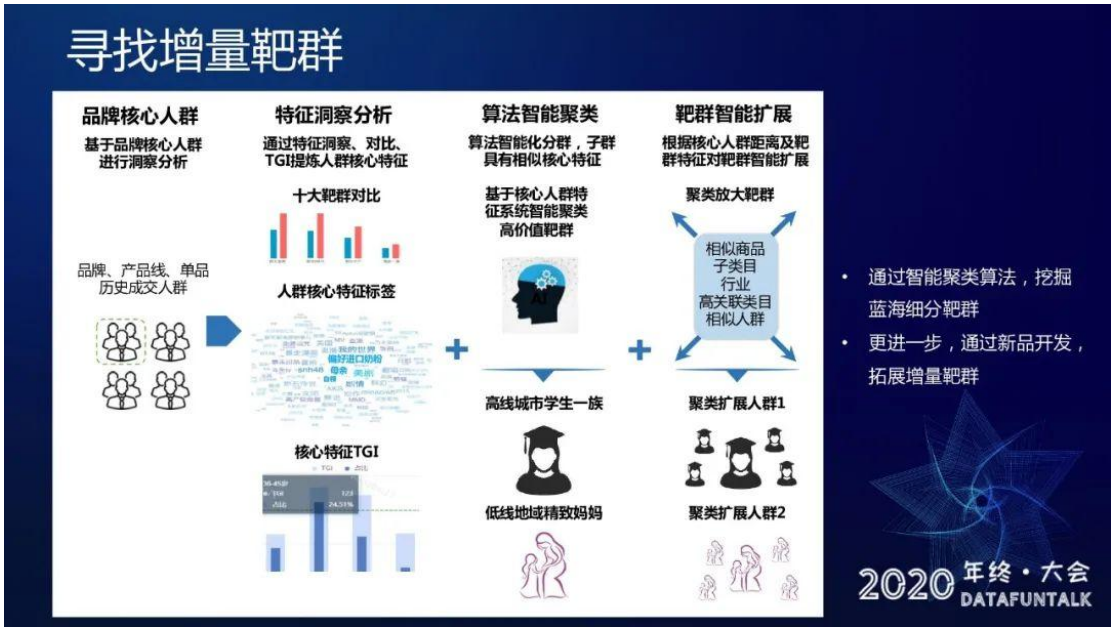

② 靶群全链路自动化触达

当我们细分靶群以后，怎样有效地提升靶群的渗透也是非常关键的环节。这里我们也打造了针对靶群的营销自动化和全链路触达的功能——数坊的营销画布工具。针对品牌关注的靶群，通过制定营销链路，比如前期心智打造的广告、提升转化的优惠券和提升召回的短信营销方式，做一个全链路的串联。通过全链路的方式实现对消费者多波次的触达，来实现持续的消费者运营。

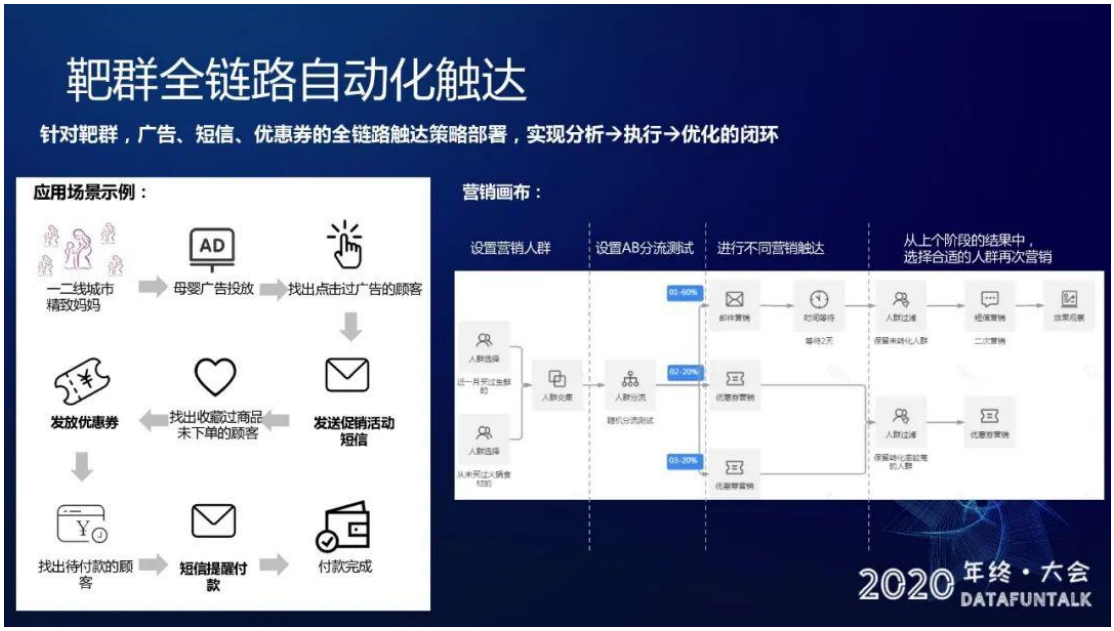

3. 进阶三：从京东生态到品牌全域消费者运营

第三个阶段，从企业的角度来讲，品牌拥有丰富的第一方消费者数据，我们能否帮助品牌建立自己的消费者运营能力，实现品牌第一方数据+生态方数据的全域消费者运营？

① 品牌第一方消费者数据的应用痛点

从品牌的角度来讲，品牌的第一方消费者数据的应用痛点首先在于缺乏一个成熟和好用的工具，其次是消费者数据维度单一，最后是针对消费者激活渠道单一。针对这三个痛点，我们可以通过数坊来帮助企业针对性解决。首先，我们希望能够复制数坊的产品和技术，为企业搭建自己的消费者运营中心。第二，通过数坊的第一方数据融合能力，丰富企业对自有用户的理解，提升运营能力。第三通过

数坊连接企业生态和京东的全域触达生态，让企业有更多渠道去实现消费者的全域激活。

② 京东数坊企业版 - Audience Engine

我们近期推出了京东数坊的企业版产品，叫做 Audience Engine。我们复制京东数坊的能力，使企业去做他自己第一方的用户数据治理，在此基础上构建一个他自己的全域用户的运营能力。在这个平台上，我们为企业构建了私域打通能力，第三方广告渠道对接能力，实现了营销自动化能力。

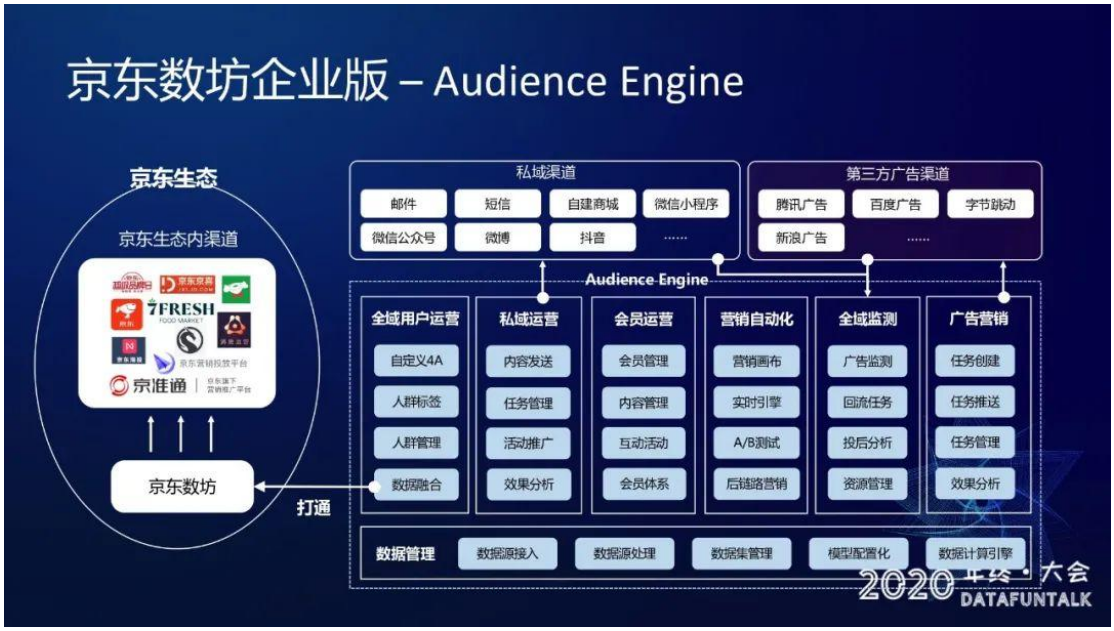

③ 连接京东生态的品牌自有消费者数据价值激活

通过 Audience Engine 跟数坊的紧密联动，借助京东生态的能力，企业激活自身数据价值，构建全渠道消费者运营能力。从效果评估层面上，帮助品牌评估自有流量的投放效果，实现品效结合的效果评估；然后通过京东数据跟企业数据融合，帮助企业深入理解和洞察自己的消费者，以及进一步实现全渠道的营销触达。我们通过这些技术来帮助企业构建新的营销能力以应对互联网新形势的挑战。

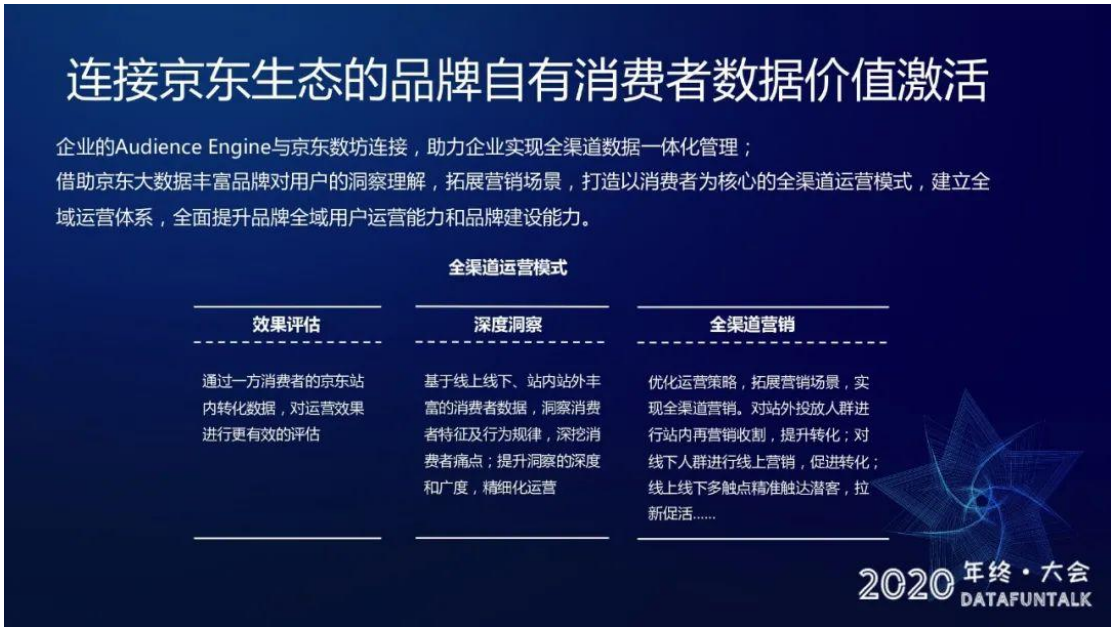

最后，回到消费运营生态角度，作为一个平台，我们一直在努力进步，以帮助平台上的各方都能获益，通过产品数据与技术的建设，创建一个共赢和共同增长的生态。

今天的分享就到这里，谢谢大家。

因果推断在阿里飞猪广告算法中的实践

分享嘉宾：观宙 阿里飞猪 算法专家
编辑整理：王吉东
出品平台：DataFunTalk

导读：在飞猪搜索 CPC 广告业务中，广告策略不仅需要考虑 CPC 消耗和广告主 ROI，平台整体营收（即 CPC 消耗+自然交易抽佣）也是不能忽略的优化目标。传统上基于广告 pCTR、pCVR、bid 等因子的策略算法仅仅从广告曝光本身来对广告主、平台和用户的利益进行优化，难以准确调优这一平台整体目标。我们通过引入因果推断技术，将广告投放建模为对搜索产品的干预（intervention），直接预测广告投放与否对业务目标产生的 uplift 效应，作为下游优化问题的线性奖励（rewards）或约束（constraints），以支持各类线上策略。在本文，我们从其中预算分配策略的视角，介绍飞猪广告算法如何利用广告效应模型进行业务目标优化，同时也介绍模型底层特征（如 CTR、CVR）的一些建模经验。主要内容包括：

- 平台视角下的广告预算分配
- 因果推断技术

- 因果推断在广告策略中的实践
- 未来思考

01

平台视角下的广告预算分配

1. 预算分配：多目标优化问题

广告策略（或者说预算分配），本质上是一个多目标优化的问题。下面结合一个示例简述一下这类优化问题的目标和约束。

预算分配：多目标优化问题

$$max.\ X_{ij} * KPI(ecpm, ctr_{ad}, cvr_{ad}, gmv_{ad}, revenue_{ad})$$

$$s.t.\ \sum_j X_{ij} * ctr_{ij} * bid_{ij} <= budget_i$$

$$\frac{\sum_j X_{ij} * gmv_{ij}}{\sum_j X_{ij} * ctr_{ij} * bid_{ij}} >= ROI_i$$

$$\frac{\sum_{ij} ctr_{ij}}{\sum_{ij} 1} > ctr_{thres}$$

$$\sum_{ij} gmv_{ij} > gmv_{thres}$$

$$\sum_{ij} revenue_{ij} > revenue_{thres}$$

$$X_{ij} := I(delivery\ ad\ i\ on\ pv\ j)$$

从平台角度上来讲，预算分配的优化目标往往是包含多种复杂的因素的函数：

- 平台变现效率（即 ecpm）
- 广告点击率（ctr_{ad}）

- 广告转化率（cvr_{ad}）
- 广告主收入（gmv_{ad}）
- 平台利润（$revenue_{ad}$）

同理，从约束角度看，主要包含以下约束：

- 广告主总预算（budget）
- 投放计划的投资回收率（ROI）
- 点击率下限（ctr_{thres}）
- 广告主收入下限（gmv_{thres}）
- 平台利润下限（$revenue_{thres}$）

另一方面，对于平台中的不同的业务，不同的用户，甚至不同产品不同的投放单元，具体的目标和约束也会存在较大差异。针对不同的目标和约束，需要使用不同的因子加以控制。

2. 常用控制方法和控制对象

常用的控制算法包括：

- PID：最常用的一种传统的工程方法

- 对偶法：基于线性规划求解拉格朗日系数，得到影子成本，通过影子成本进行线上控制

- 线性插值法：通过历史数据拟合控制变量与目标变量的关系

以上提到的几种方法有一个共同的特点：都基于线性模型，因此，要想达到有效的控制，就需要线性因子。

常用的控制对象包括：

- 广告主的出价（bidding）
- CTR/CVR 准入下限
- 参竞概率

3. 使用因果推断的语言建模

广告策略问题，常用的策略因子包括：

- CTR 预估（pCTR）
- CVR 预估（pCVR）
- 出价胜出概率分布（Bidding Landscape）

然而，以上的策略因子具备局限性。以 GMV 为例，对平台 GMV 进行控制，仅使用 pCTR、pCVR 等策略因子是不够的。因为从业务角度看，在电商领域，原生广告和产品（包括搜索、信息流等）的相似度很高，因此广告投放的分布和对应原生产品的分布是相似的；这样带来的结果就是，当广告的 CTR/CVR 高的时候，自然产品的 CTR/CVR 往往也会很高；我们不能基于较高的 CTR/CVR 预估结果推测广告投放的真实效果。

基于此，引入本文的主题——使用因果推断建模。

$$effect_{ad} = GMV(T=1|X) - GMV(T=0|X)$$
$$T := I(deliver\ ad)$$

- 公式中的参数 T 可定义成是否投放广告的 indicator 变量

- 模型控制目标是平台的收入（即 GMV）

- 建模问题定义为广告投放对平台 KPI 的影响，即在给定特征的前提下，投放广告的 GMV 减去不投放广告的 GMV 得到的收益

只有通过建立上述模型，才能优化广告投放的真实效果，实现平台和广告主的共赢。该模型涉及到的因果推断技术，将在下一章节详细阐述。

02

因果推断技术

1．基本问题

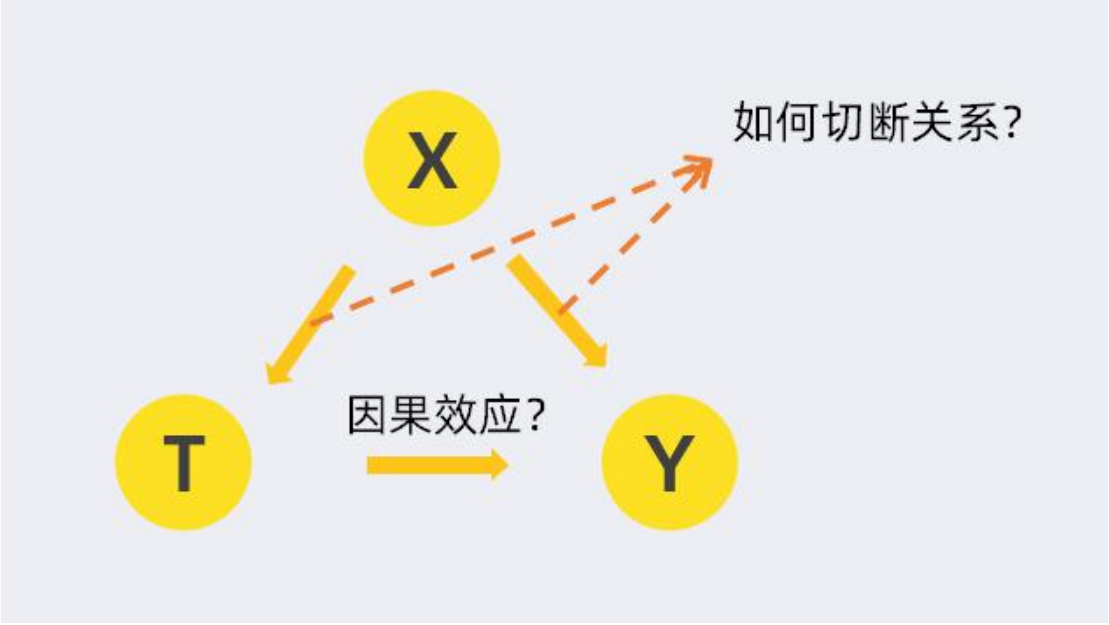

将前文所述的模型抽象成上图所示：我们需要建模的是 T 对 Y 的影响（T 即是否投放广告这个动作；Y 是平台的某项 KPI，如 GMV）。

然而影响平台建模的因素很多，比如不同活跃度的用户、不同的时间段、不同的行业等，都会影响广告在搜索推荐中的转化效率。

2. 影响因素的控制和约束

如何在这种复杂的数据关系中提取出广告投放对平台的 GMV 产生的影响？一个较为朴素的方法就是控制变量法，即人为控制和约束除了广告投放之外的其他相关因子。

具体来说，有两类实现路径：

① 随机实验（切断 X->T）：假设 T 是随机分配的，即 T 与任何变量独立；

② 特征工程（切断 X->T，X->Y）：假设 X 包含所有的 confounders。

- 定义 confounders：同时影响 T 和 Y 的变量

- 若给定 X，则不同 treatment group 下影响 Y 的协变量分布相同，即 X->Y 是天然的随机分配

基于以上这两条假设，从数学上理解，其核心是比较投放广告与否的前提下，平台 KPI 的期望：

$$E(Y(T=t)|X=x) = E(Y(T=t)|T=t, X=x) = E(Y^F|T=t, X=x)$$

由于 X 与 Y/T 独立，故添加条件概率不影响最终的期望值；这样，待求解的期望值等同于实际样本分布的期望。从因果推断角度看，这是个比较理想的情况：从观察数据上得到的模型，和我们期望的因果效应相等的时候，就可以直接使用机器学习模型解决问题。

抛开数学公式，从常识角度也能解释以上假设：每组特征下可视为随机实验，得到局部的无偏估计；那么任意样本上的效应，可以在相应的 X 的分布上积分得到。

3. 从机器学习视角审视

前文简述了一些因果推断领域的技术背景，下面从机器学习视角审视这个问题，将会遇到两个挑战：

从机器学习视角审视

$$effect_{ad} = GMV(T=1|X) - GMV(T=0|X)$$
$$T := I(deliver\ ad)$$

挑战1：样本结构上，两组样本分布需相近，否则存在误差累计效应
--- 一般预测问题上，只需样本整体无偏即可

挑战2：对变量 T 的推断需准确，这并不是机器学习擅长的工作
--- 传统的统计模型，我们通过对数据引入假设，可以推断参数分布
--- 大数据时代的算法模型，往往关注预测精度而非统计推断能力

样本结构方面，对两组样本（T=0 和 T=1）的分布要求更加严格：

- 对于一般的预测问题，只需要保证样本整体无偏，即可预估
- 对于因果推断问题，除了样本整体无偏，还需要要求两组样本的结构相近；

  否则会存在误差累计效应

对变量 T 的推断准确度要求更高，这并不是机器学习所擅长的工作：

- 传统的统计模型，通过对数据引入假设，可推断参数分布
- 大数据时代的算法模型，往往关注预测精度而非统计推断能力

4. 样本结构问题

基于前文提到的两个挑战，首先讲述样本结构问题的处理办法。

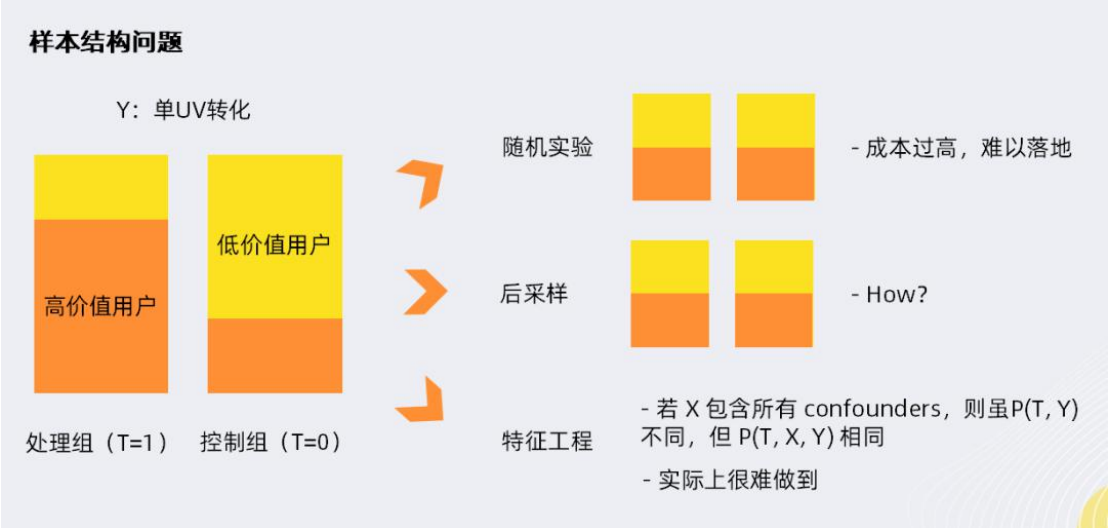

从业务角度列举一个简单示例：控制目标 Y 是归一化（即单 UV 转化）后的平台 GMV；处理组和控制组的用户分布有明显差别（处理组的用户价值较高，控制组的用户价值较低）。

有 3 种方法可以解决这类问题：

① 随机实验

- 选取部分流量，线上广告随机投放，不采用任何策略

- 成本过高，难以落地

② 后采样

通过重采样方法，使两组样本分布一致

③ 特征工程

- 机器学习常用方法

- 假设 X 包含所有的 confounders，则虽然两组样本的 P(T,Y)不相同，但 P(T,X,Y)相同

- 实际很难做到，且对样本也有较高要求

在后面的章节中会详细介绍以上方法在广告策略实践中的具体应用。

5. 变量的统计推断问题

第二个问题是变量的统计推断问题：在大数据时代常用的复杂模型中，如何精准推断某一个变量的效应？具体到我们的广告策略场景上，就是如何推断广告是否投放这个干预变量对平台的 KPI 产生的影响。

这类问题其实是很多学科里面临的一个终极问题，很难得到真正解决。具体到工程实践上，我们可以通过一个模型结构先验和 loss 设计，促使模型对这一单变量学习到正确的效应。

03

因果推断在广告策略中的实践

1．特征工程

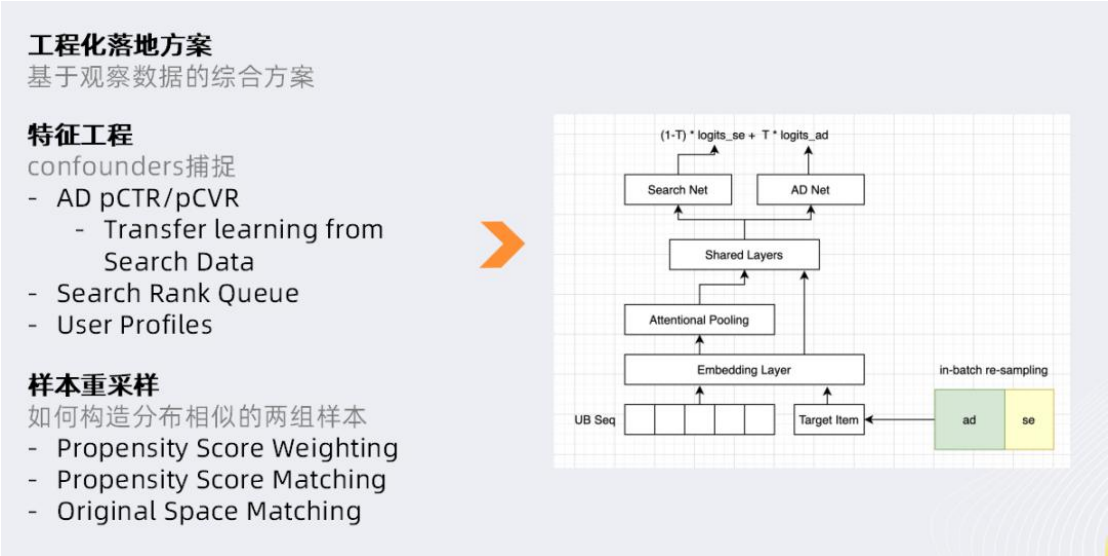

先从前文提到的两大分支（特征工程，样本重采样）入手，具体讲述工程落地的方法。

特征工程方面，目标是捕捉到所有的 confounders（即影响到广告是否投放，以及影响到我们的平台效率的所有特征）。

首先参考广告系统里其他常见工作，例如广告的 CTR/CVR 预估模型；该类模型对广告效率的预估，会预先将原始的复杂特征做汇总。基于此，整体的思想就是基于原生的广告搜索模型做迁移学习。

然而，搜索推荐的信息流和广告策略的数据，两者的分布往往存在差异；因此会涉及到模型的泛化性能问题，需要对模型的拟合精度和泛化能力做权衡。具体来讲，通过策略采样的方式（模型结构类似 CTR/CVR 多任务模型，但是样本和模

型训练方式完全不同于 CTR/CVR），将原生信息流样本和广告样本作为两个任务分别学习，最后通过 loss 融合实现多任务学习。

对于刚刚提到的模型精度和泛化能力的权衡的问题，我们采用 in-batchre-sampling 的方式，对于每个训练 batch，通过超参去动态调整原生样本和广告样本的占比。

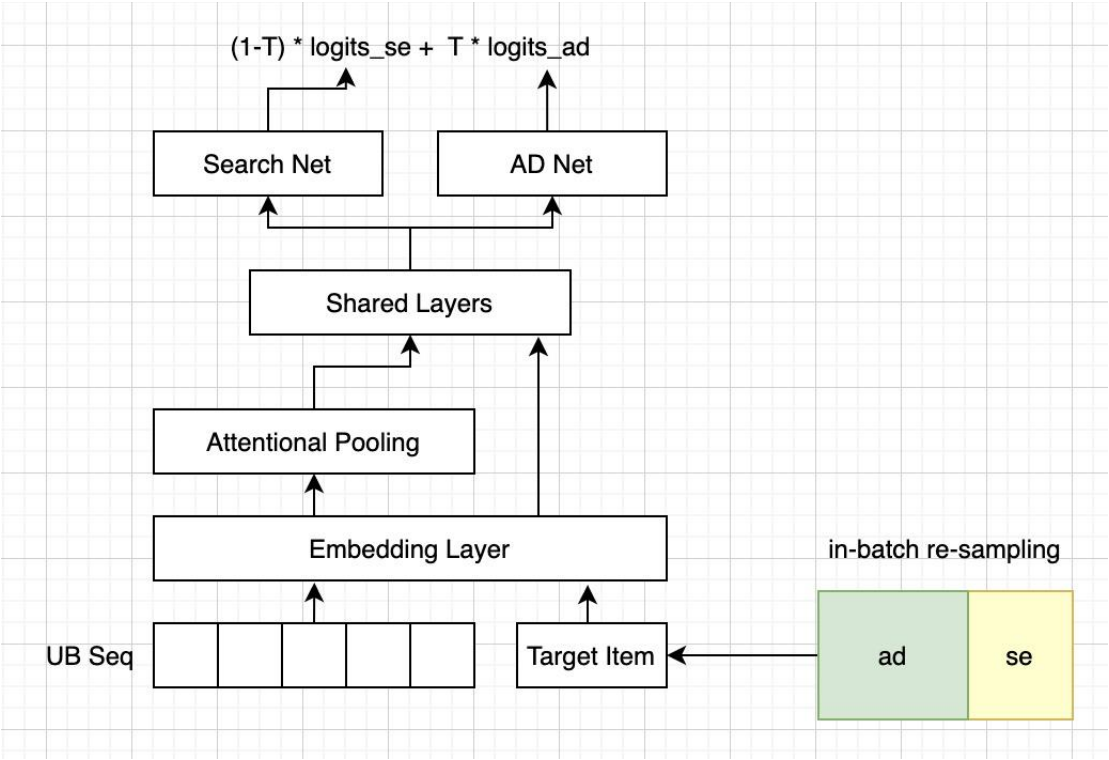

除了刚刚详细介绍的 CTR/CVR,特征工程还包括广告系统中常用的 Search Rank Queue（原生产品队列）、用户画像等，在此不做赘述。

2. 样本重采样

除了特征工程，另外一部分就是样本的重采样。对于纯观察数据，如何在避免 AB 实验的前提下，通过重采样方法在投放广告和不投放广告这两组的样本中构造相似的分布。

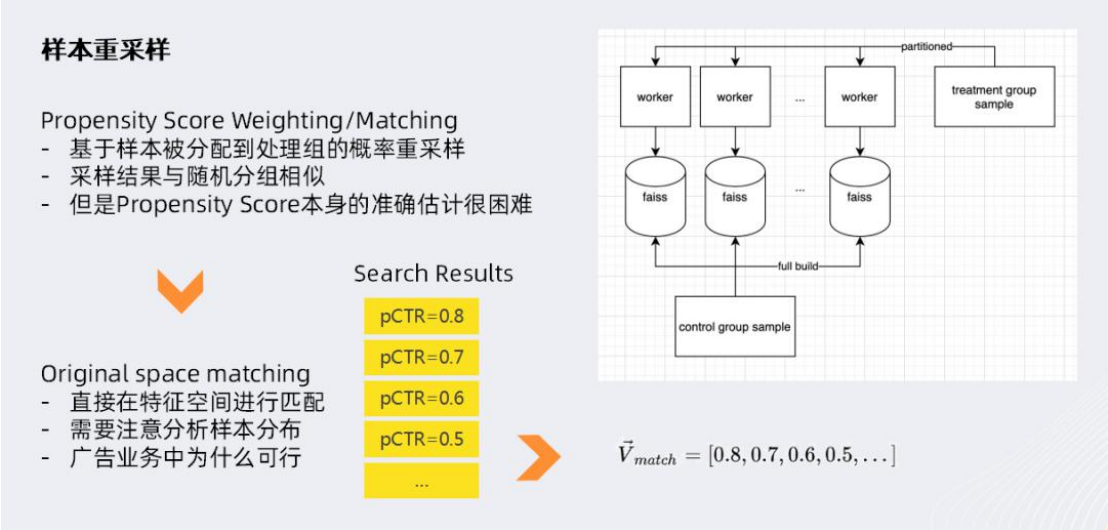

样本重采样常用的方法包括：

① Propensity Score Weighting/Matching（倾向评分加权/配比法）：

- 基于样本被分配到处理组的概率进行重采样
- 采样结果与随机分组相似
- Propensity Score 本身的准确度难以估计，不仅是用户行为用户偏好的高维分布，还受到广告本身的很多策略甚至一些产品业务规则的影响，较难进行机器学习建模，因此实际应用很难

② Original Space Matching（原始空间匹配法）等：

- 避免预估 Propensity Score，直接在特征空间进行匹配
- 需要注意分析样本分布
- 实际应用可行

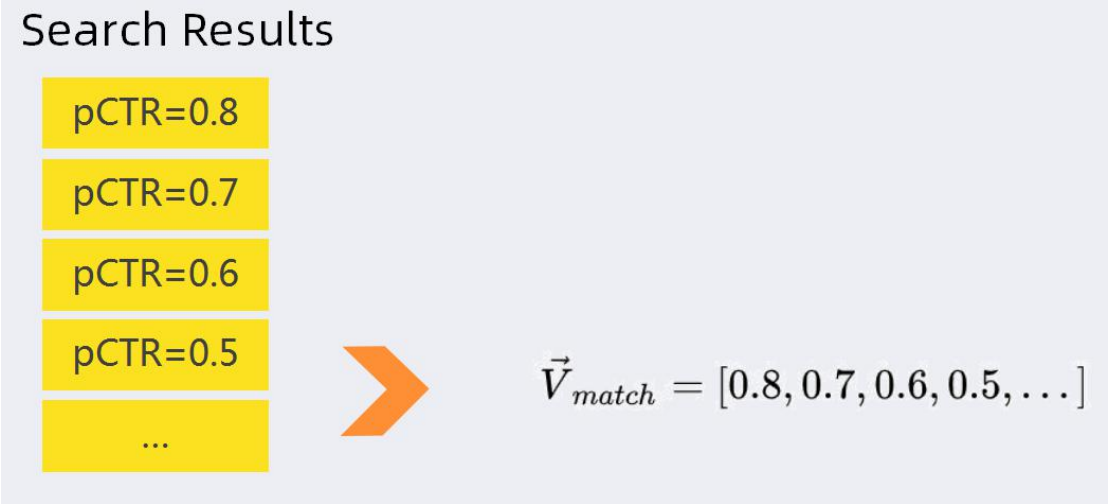

以上述搜索结果页为例，每个商品都可以得到一个模型预估值（pCTR）。可以将整个页面 pCTR 的分布作为特征，用特征向量 Vmatch 表示；

首先对控制组（即未投放广告）的样本进行全量的索引构建；接着对处理组（即有投放广告），按照控制组的向量索引，使用 KNN 方法查找最相似的 K 个没有广告投放样本，进行配对。将控制组样本和处理组样本进行两两配对以后，很容易通过对比两组对应样本的转化率或 GMV 来描述广告投放与否对平台 KPI 产生的影响。

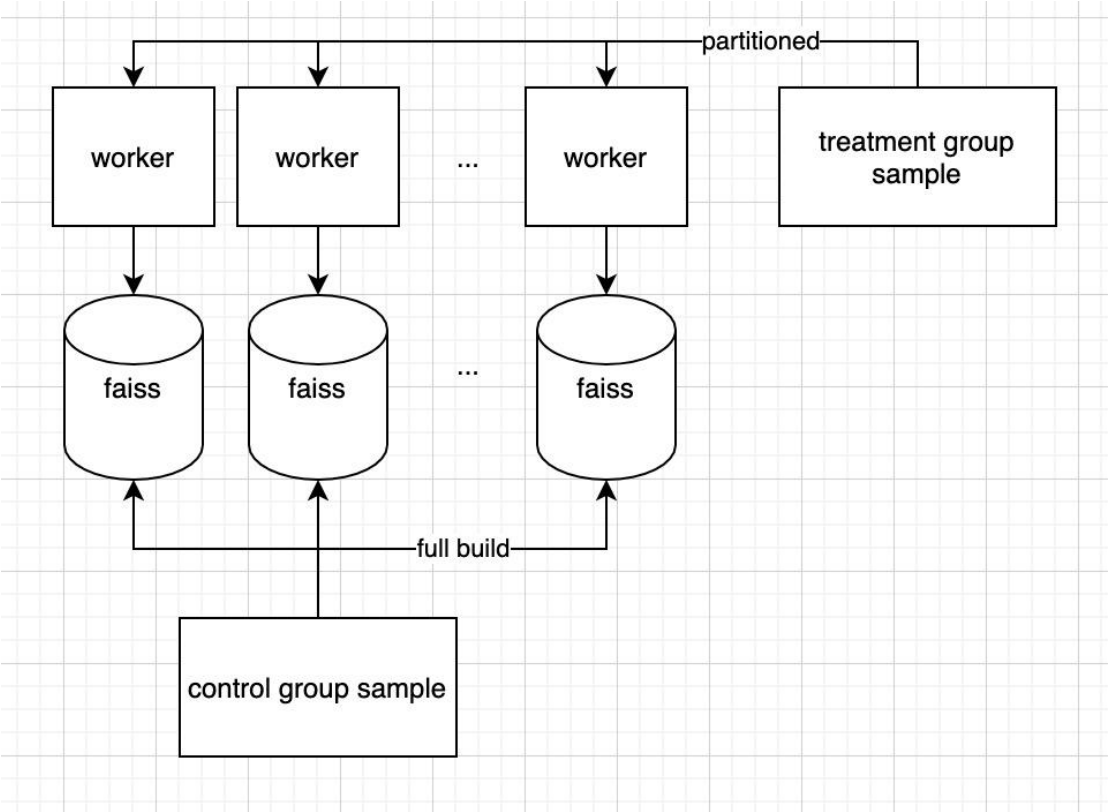

3. 模型设计

从模型设计角度，如何捕捉单变量的影响效应？前面提到过，这个问题很难得到真正的解决；但是我们有几个启发式的方法可以得到落地应用：

- 借鉴 ResNet 思想，通过单变量 embedding，结合深度网络短接（shortcut connection）将其接入到网络的最后一层，从而避免复杂的非线性因素的干扰

- 借助迁移学习中的领域自适应技术（Domain Adaption），通过多任务学习来实现。具体来说，是将两组样本的投放广告与否，当作 Multi-task 的方式处理

- 引入正则项（包括 Structure Regularization、Task Regularization 等），借助对业务的先验知识，对任务的 loss 加入正则项，促使模型学习到广告投放的效果

4. Uplift Evaluation 简介

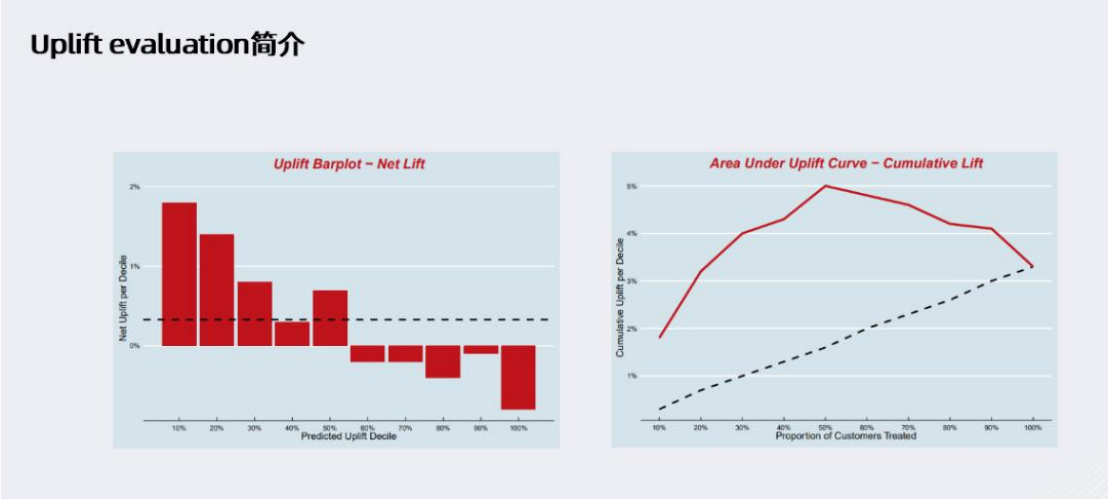

因果效应模型的评估，和常见其他用户模型的评估相比，最大的难点在于，每个样本都没有相反 label。对于这类问题，业界常用分位数分析法进行评估，即对于每一类样本，按照广告效应的预测值，从大到小来进行分桶（上图左侧，分了十个桶）；每个桶内聚集广告效应的预测值相近的样本（包含不同的 label）；将每组样本内的 label 的平均值相减，得到该组样本的 uplift。

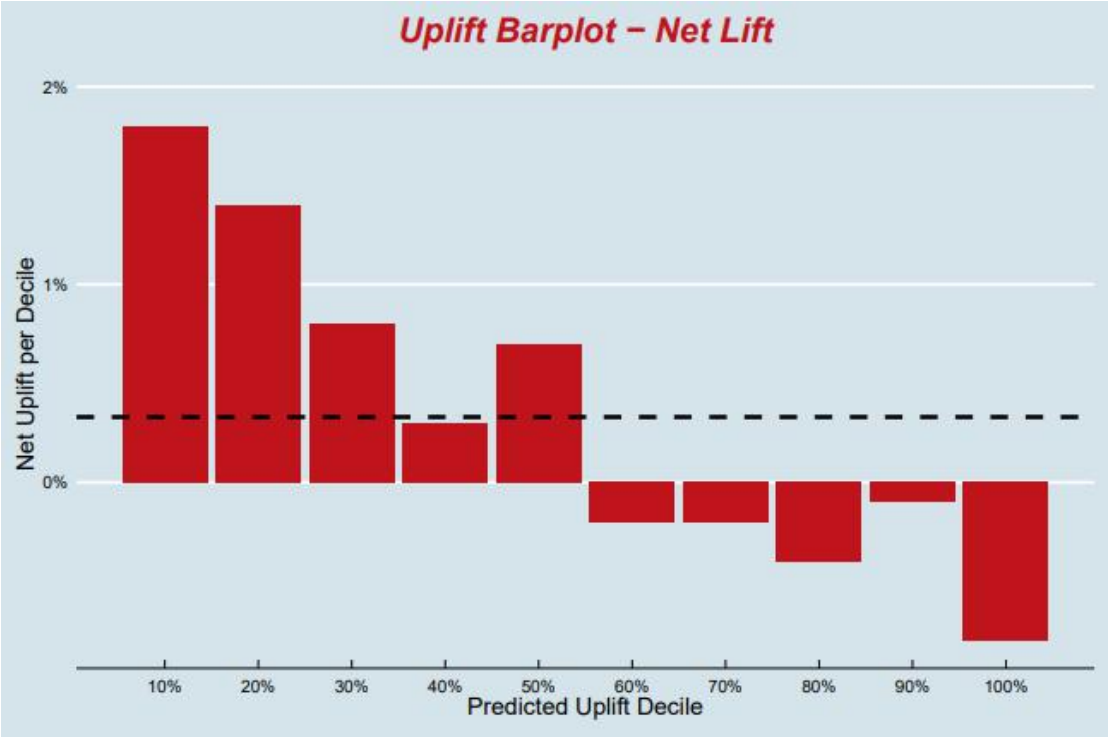

上图是个理想的情况：左侧贡献比较大，右侧贡献比较小，甚至是负的。基于柱状图做累计分布计算，得到下图：

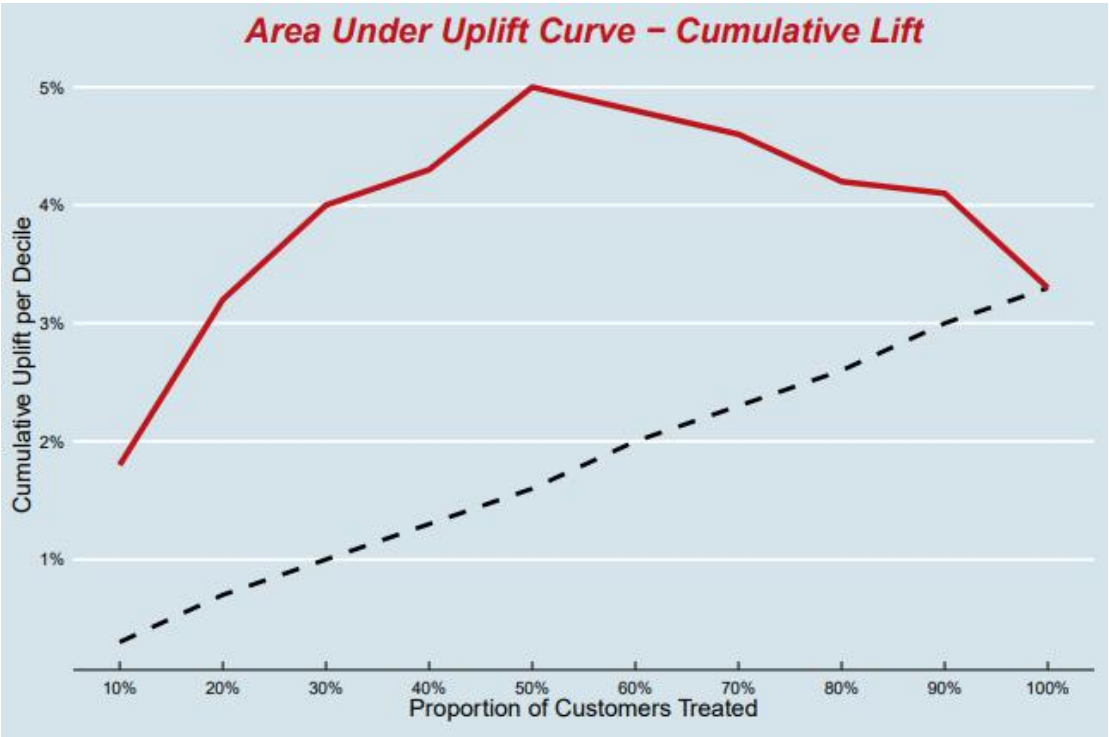

这个图和常规预估模型中的 ROC 曲线形似；同样，曲线下的面积（AUC）越大，模型预估效果越好。

5. 模型 baseline：

Direct Method

假如我们直接做预估模型，选取 SRP（结果搜索页，一部分是广告，一部分是非广告）的特征，和广告本身的特征（包括 pCTR、pCVR，以及单个 treatment 的 embedding）；模型预测某一条用户请求是否产生订单（listing to order）的概率。

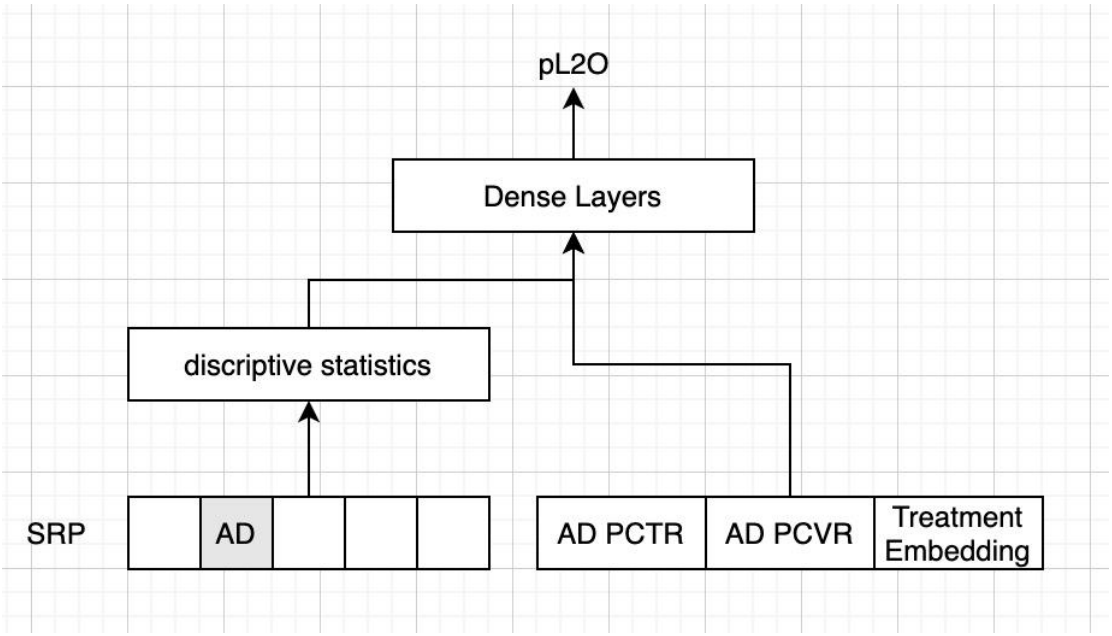

这类常用的预估模型，是将“广告是否投放”这一 treatment 作为一般特征。模型的 baseline 是基于 pCTR/pCVR（包括最好商品的 CTR/CVR，以及广告商品

的 CTR/CVR 和最好商品的 CTR/CVR 的差距）进行预估，预估任务的 AUC 还算理想（0.736），但是评价广告效应的 Uplift Qini 指数是负值；增加 DNN 后 AUC 有所提升，但是 Uplift 指数会变得更差。

由此可见，预估任务的预测能力和对广告效应的评价能力并非正相关。

模型加入样本匹配后（表格最后一行），将样本调整成近似随机实验的样本，可以看出广告效应的预测能力就变成正向了。以上实验说明了针对 Uplift 进行建模优化的必要性。

Method	L20 AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
DM w/o matching	0.744	-0.06
DM	0.740	+0.03

6. 模型改进思路一：

Direct Method with shortcuts

Direct Method with Shortcuts

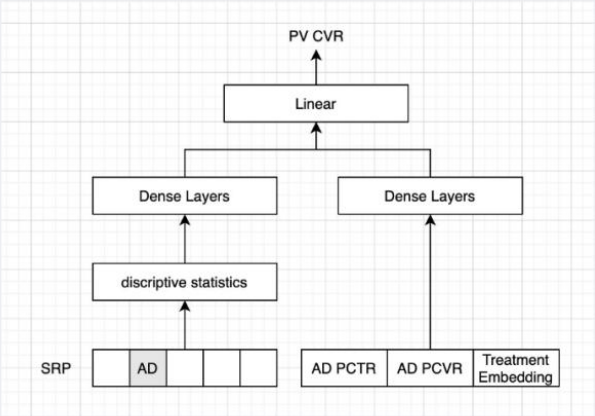

Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
DMS w/o matching	0.742	-0.01
DMS	0.739	+0.06

将所有特征都连到一个 DNN 里面，采用了 ResNets 的思想，如上图所示：左侧网络对用户搜索请求预期的转换效率进行建模，右侧网络对“广告是否投放”产生的影响进行建模，最后通过线性模型加以合并。对于广告效应的推断方面，这种模型相比于 DNN 会有一定的提升（uplift Qini 指数提升至 0.6）。

7. 模型改进思路二：

Dimain-Adaption: Multi-task Learning

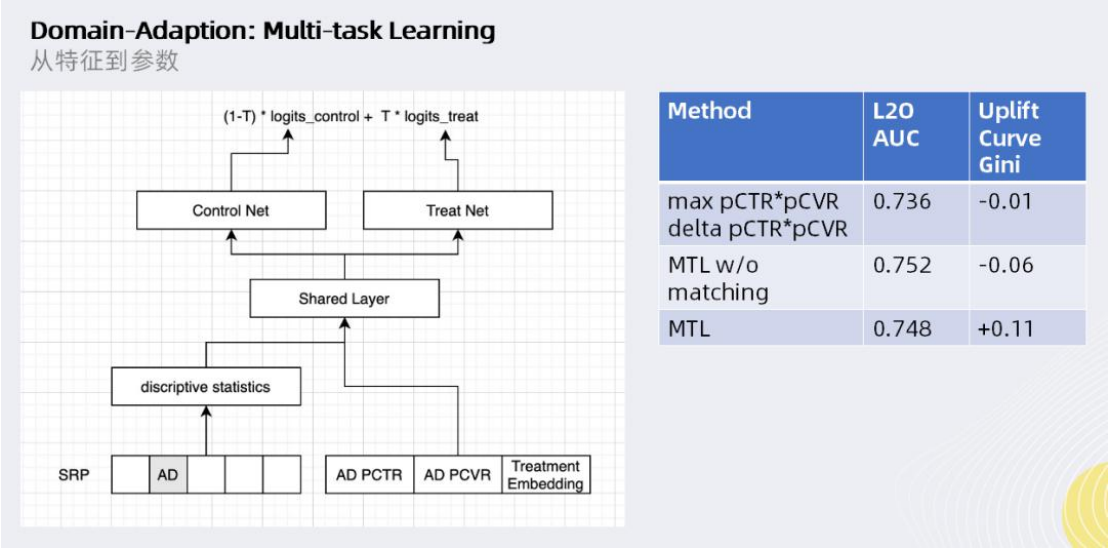

前文提到的建模方法都是将单变量 treatment 当作一种特征，建立基于网络结构的模型，这类基于网络结构的模型在特征权重拟合方面会受到模型结构以及数据的限制。

这里尝试换了一个思路方向，借助领域自适应中的多任务学习方法，将“是否投放广告”作为两个不同的任务（而不是一个任务中的二级特征）进行分别预估，通过建立完全不同的网络来学习“是否投放广告”产生的效果。在重采样后的样本拟合后，uplift 指数可提升至 0.11。然而这种方法更容易对数据分布过拟合，从上图的右表也可以看出，对于未重采样的原始样本，uplift 指数反而会更差。

8. 模型改进思路三：

Effect-Net

Effect-Net

显式建模 treatment effect，使其与原生搜索pv的转化预估构成加性的先验关系

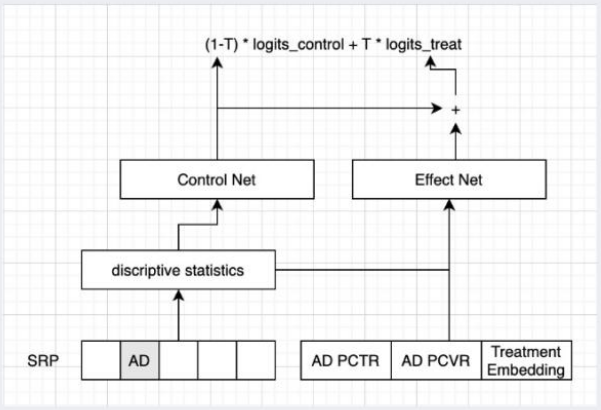

Method	L2O AUC	Uplift Curve Gini
max pCTR*pCVR delta pCTR*pCVR	0.736	-0.01
EN w/o matching	0.749	+0.08
EN	0.745	+0.10

最后一个就是显式建模单变量 treatment 效应，即从模型的结构上体现目标效应的作用方式。类似于前文所述的改进思路一，使用两个网络分别对预测效果和广告投放相应；与思路一不同的是，在模型结构上可以显式地体现出业务理解的先验，即最后一层的模型融合部分，显示地将控制组的输出与 uplift 相加，得到最终的预测值。使用 Effect-Net 方法，由于强先验知识的引入，在原始样本（即未重采样的有偏样本）的表现效果最好。

04 未来思考

1. 因果推理与深度表示学习之间的关系

基于已有的工作，学界提出了以下几点思考：

- 怎样的表征是有利于因果效应的估计的？
- 怎样理解表征与 confounder 的关系？

- 表征学习在 debiasing、模型泛化等问题中的应用

基于以上几点，目前对于表征学习和因果推理方面的前沿研究方向主要是 Balanced Representation Learning。

相关研究方向：Balanced Representation Learning

- F. Johansson, U. Shalit, and D. Sontag, "Learning representations for counterfactual inference," in *International conference on machine learning*, 2016, pp. 3020-3029.
- U. Shalit, F. D. Johansson, and D. Sontag, "Estimating individual treatment effect: generalization bounds and algorithms," in *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, 2017: JMLR. org, pp. 3076-3085.
- L. Yao, S. Li, Y. Li, M. Huai, J. Gao, and A. Zhang, "Representation learning for treatment effect estimation from observational data," in *Advances in Neural Information Processing Systems*, 2018, pp. 2633-2643.
- H. Liu, Y. Li, Q. Cao, G. Qiu, and J. Chen, "Estimating Individual Advertising Effect in E-Commerce," *arXiv preprint arXiv:1903.04149*, 2019.

2. Balanced Representation Learning

Balanced Representation Learning

促使两组样本中学习到的 representation 分布相似

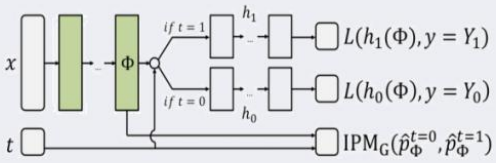

思考

好的方向，但是现有的工作仍有很大改进空间

- IPM as a treatment ...
- Low IPM -> missing confounder

$$\epsilon_{PEHE}(h,\Phi) \leq$$
$$2\left(\epsilon_{CF}(h,\Phi) + \epsilon_F(h,\Phi) - 2\sigma_Y^2\right) \leq \quad (2)$$
$$2\left(\epsilon_F^{t=0}(h,\Phi) + \epsilon_F^{t=1}(h,\Phi) + B_\Phi IPM_G\left(p_\Phi^{t=1}, p_\Phi^{t=0}\right) - 2\sigma_Y^2\right),$$

U. Shalit, F. D. Johansson, and D. Sontag, "Estimating individual treatment effect: generalization bounds and algorithms," in *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, 2017: JMLR. org, pp. 3076-3085.

Balanced Representation Learning 本质上仍然是一种多任务学习，将投放广告组和未投放广告组进行分别建模，进而将两个数字相减，得到因果效应。之所以

称之为 balanced，其实是在目标上加了一个约束，促使两组样本上学习到的表征分布相似。

然而实际情况中，两组样本的分布是存在分布差异的。主动约束 IPM 的做法存在方法论上因果倒置的问题：随机或自然实验中，正是因为实验分组与协变量的独立性，带来了各组样本分布的相似性，而反过来在模型训练中通过目标函数的构造来获取分布相似的表征，能够带来准确的因果效应估计，是值得怀疑的。

从另一个方面看，在学习相似分布的过程中，必然要求模型忽略掉部分 confounder 的效应,这又进一步违背了因果推断中条件独立的假设。类似的工作，现有的改进方法和改进思路或多或少存在不足，这一方向存在很大的改进空间；团队也在着手这一方向的深入研究。

今天的分享就到这里，谢谢大家。

腾讯增长技术：智能投放篇

分享嘉宾：吴超 腾讯 技术专家

编辑整理：李萧萧

出品平台：DataFunTalk

导读："互联网的下半场"流量红利增长进入瓶颈，"用户增长"成为了互联网产品热门话题。不同形态产品随着业务发展对用户增长诉求会改变，相应 AARRR 增长模型下各层指标要求也不一样。增长业务中，需要抽象业务的共性，沉淀增长能力，敏捷支持不同增长需求。增长中台通过物料挖掘，智能投放，RTA/DPA 等技术聚焦增长 AA 环节，帮助业务获量，实现业务增长。今天主要分享增长技术领域的智能投放模块，介绍下腾讯在增长中台方面的工作。本文的主要内容包括：

- 增长与增长中台
- 投放系统与策略
- 增长系统与策略

01

增长与增长中台

1．增长与增长中台面临的挑战

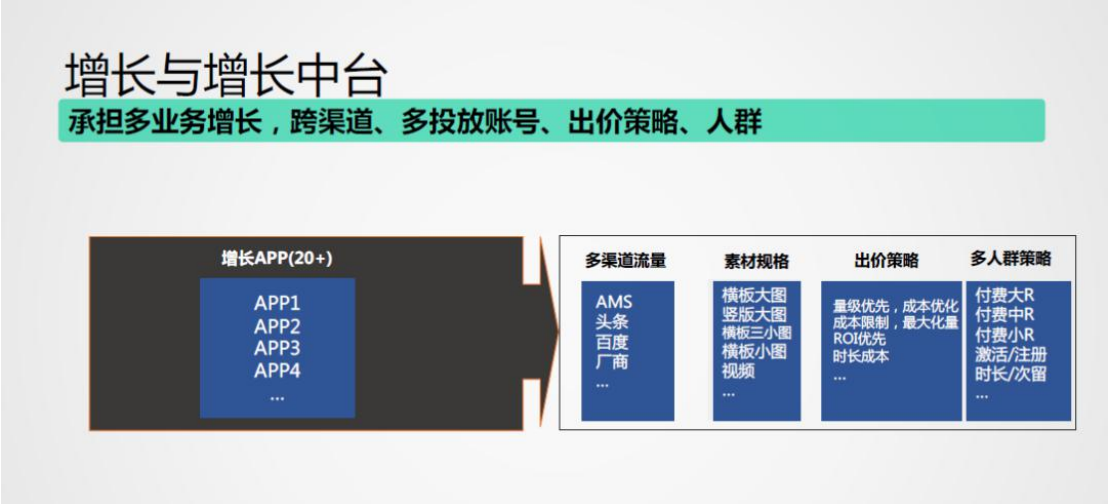

增长中台承接各大产品的增长，需要更频繁的跟产品侧同学沟通。在对接多个 APP 的增长过程中，主要面临以下挑战：

多渠道流量：中台负责每个 APP 在各大厂商各个流量的采买。

素材规格：每个 APP 对素材的要求不一样，互相之间不认同。导致素材方面会变的更复杂。

出价策略：不同 APP 由于所处的产品的生命周期不一样，不同周期里的要求也会不一样。处于增长期的 APP 会优先考虑产品用户量级增长；成熟期的 APP 会权

衡成本；直播、游戏类的 APP 则要求付费类用户，ROI 增值优先。不同 APP 的目标不一样，会导致增长的策略不一样。

多人群策略：不用 APP 的目标不一样，可能侧重大 R 付费、中 R 付费、小 R 付费、或者追求用户激活、注册、时长、次留等，会导致投放的人群策略需要随之改变。

2. 增长与增长中台的背景

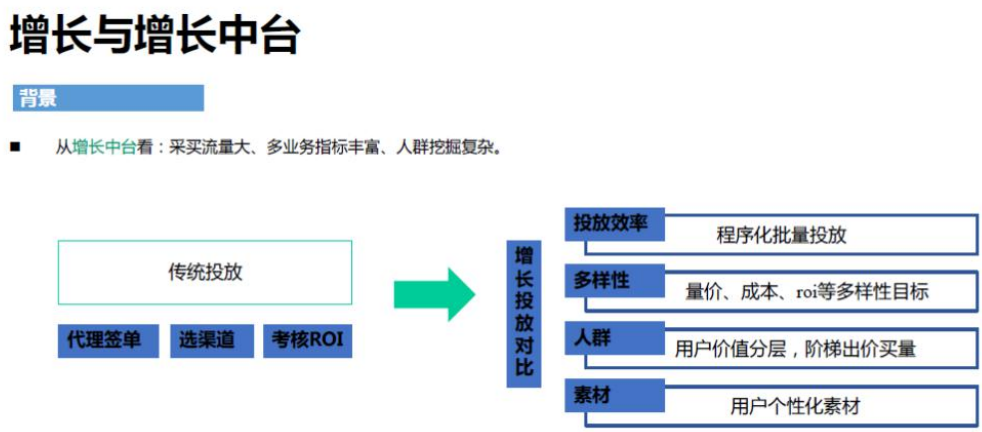

传统的增长买量过程，一般会联系多个代理商，通过代理商联系不同的渠道，根据不同的渠道设定考核 ROI 和预算。对于增长中台，会有更丰富的产品流量、业务指标和精细化的人群挖掘。投放效率方面，能够程序化的投放。业务目标，支持复杂业务在不同的阶段设定不同的考核目标。人群方面：根据前面提到的不同的大 R、小 R、激活、注册等，对人群进行价值分层，实现阶梯出价精细化买量。素材方面也实现个性化素材自动生成。

02

投放系统与策略

1. 投放公式

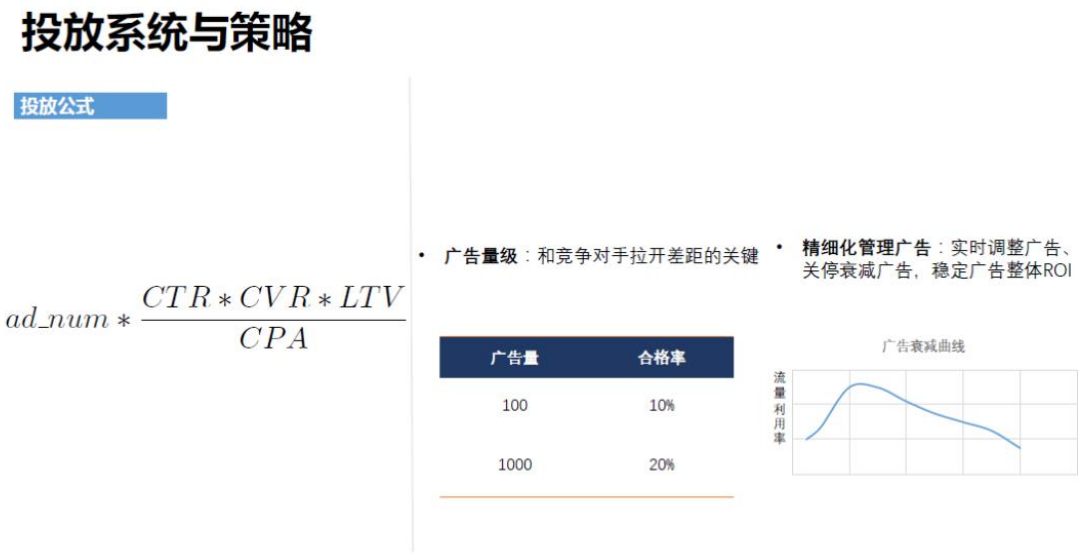

投放系统与策略这块主要介绍如何解决上面提到的投放效率、多样性、人群、素材这些问题。左边的是投放获量的公式。其中，ad_num 是一段时间能够获得的广告量。CTR、CVR 决定了获量，LTV 决定了获量之后的用户价值，CPA 决定了成本。广告量级是和对手差异的关键，在通过媒体平台获量时，如果我们管理的广告量级是别人的 n 倍，那么在获取的用户量级基本上也是 n 倍，基本成线性关系。同时在管理广告时引入合格率的指标。在广告数量和合格率达标的情况下，我们再进行精细化管理广告。广告在媒体渠道进行投放时，都有一个自然生命周期，从冷启动、稳定获量到衰减期。由于不同阶段对 ROI 等指标的要求不一样。

在这个阶段，做到实时的调控指标、关停衰减广告、调整广告预算、广告估价，从而在管理端每天管理十万个广告时做到投放广告的最合理的 ROI 的安排。

2. 投放系统与策略

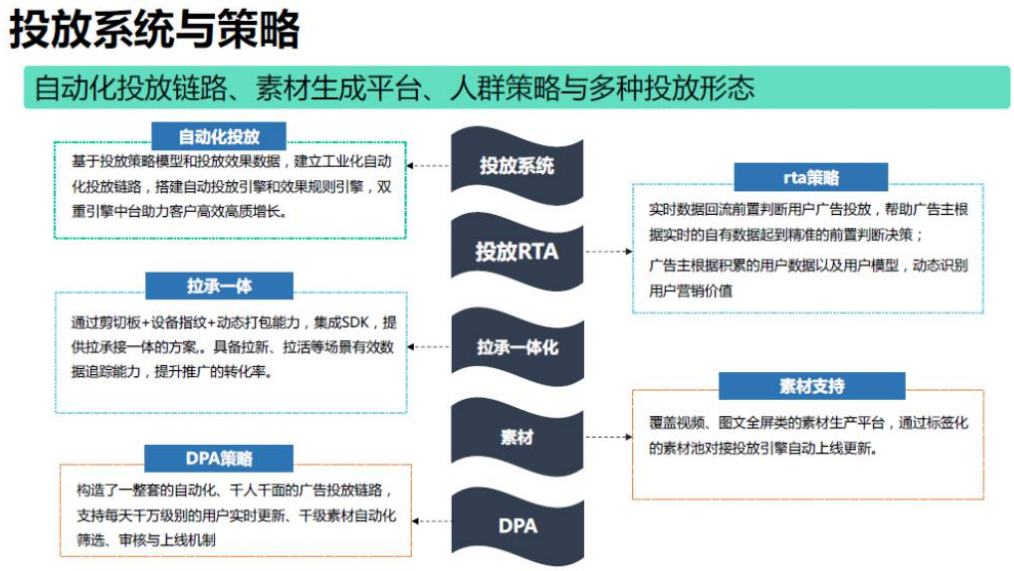

投放系统主要是解决自动化投放和扩量的投放过程。基于投放策略模型、投放效果数据，构建了自动化投放链路。通过模型拟合自动化规则引擎，管理和运营投放的广告，达到了客户获量的水平，以及合格率的水平。

- 投放素材方面，我们搭建了一个覆盖视频、图文全屏类的素材生产平台，通过标签化的素材池、以及结合投放效果自动化优选素材的过程，来做到更大投放量的承载。

- 拉承一体化，负责把用户从外部的自然流量，拉到运营流量中，做到可见即可承接的效果。目前是通过剪切板、设置指纹、动态打包等一系列方法来实现拉承一体。

- 投放效率中更进一步的优化，RTA 策略和 DPA 策略。RTA 策略通过前置判断用户的价值来优化用户的 ROI 模型，DPA 策略借助转化好的素材和后端的数据挖掘能力实现投放广告的千人千面，提升 CTR，进而提升获量的能力。

3. 投放系统

① 投放时

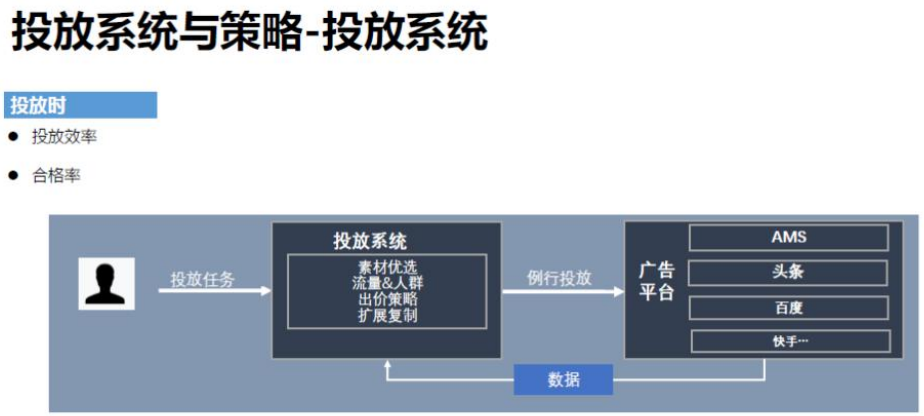

首先介绍下我们的投放系统。一个用户的投放过程一般是请代理，然后代理在各个广告平台操作，我们在这个投放过程中新增了投放系统。投手在投放系统中选择投放策略，然后通过例行化投放，投放到各大平台。具体流程：

素材优选：投放系统的核心是根据回流的数据，结合后端转化数据、ROI 等整体数据，根据历史数据和模型，进行素材的多层目标的分解和优选，推荐给投手，由投手自动或者人工的进行选择素材。

流量&人群的选择：在投放系统中，我们会进行渠道流量和人群的推荐。系统会提示各个渠道的 ROI 达成率、人群选择、量级等。

出价策略：出价时，根据历史信息，计算各个渠道不同人群的竞价状态，在进行素材和人群选择后，推荐较优的出价策略，避免人工出价摸索。

扩展复制：系统的扩展和复制功能。当投手发现某些素材在某些渠道有很好的效果时，可以进行复制和微调，批量化的进行投放。同时，投放系统支持自动化的投放扩展复制。比如，投放系统识别到某些策略在 AMS 平台的投放效果比较好，能够自动化的扩展到其他账号中，解决拿量问题，实现效果最大化。同时，也支持跨渠道、跨平台的扩展。

② 运行时

例行调度：

投放系统与策略-投放系统

运行时

- 例行调度

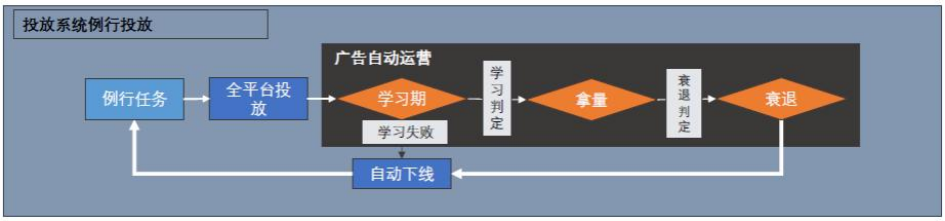

简单介绍下投放引擎在管理线上所有广告时的生命周期策略。当例行任务把全平台的广告投放出去，广告在投放平台中的运行周期主要分三个：学习期，稳定拿量期，衰退期。投放引擎会根据后台的转化数据，建立转化模型，模型会定期检测在线广告的状态。如果处于学习期学习失败时，投放系统会自动将广告下线，从而节约人工操作的成本。如果在稳定拿量期，系统会保持广告的例行更新状态；如果处于衰退期，会将广告置于自动下线的状态。部分广告的自动下线，会驱动新一轮的例行投放，同时新增更多的广告。

效果优化：

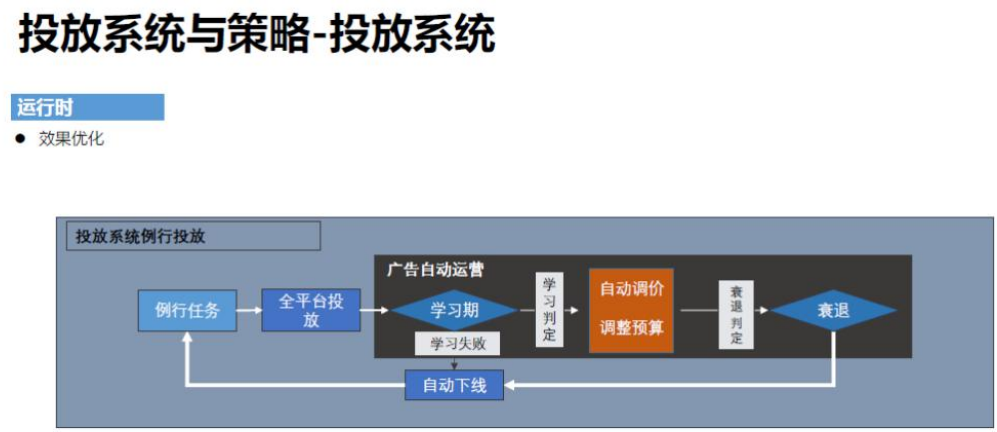

在拿量期，有两种不同的模型，自动调价和调整预算。当有一个业务有很多个广告在稳定拿量时，通过后台的数据发现不同的广告拿量能力会有差别。引擎会根据不同广告的拿量能力、数据和用户质量、媒体平台的竞争状态，对不同的广告进行不同的调价。另一方面，引擎会在广告级别调整预算。根据不同广告的拿量能力进行预算调整，从而达到所有广告的良好的获量状态。

目标优化：

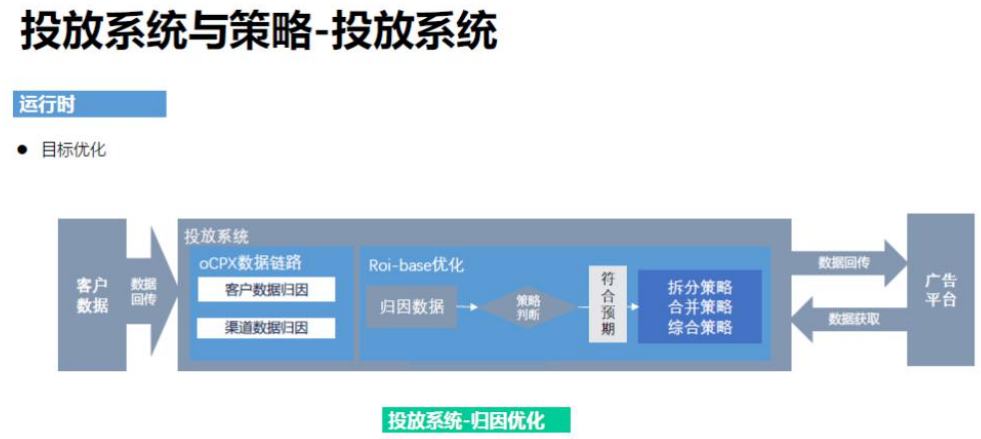

投放系统-归因优化

接下来，介绍我们在归因方面的策略。大部分的广告主投放方式是 oCPX 方式。oCPX 数据链路会涉及客户数据归因和渠道数据归因。在归因方面，也有很多策略工作。我们会驱动媒体平台挑选指定的数据回传到广告平台，从而驱使广告平台的模型学习我们想要的用户特点。比如，在目标 ROI 的归因过程中，会对大 R 用户会进行拆分的策略，小 R 用户会进行合并的策略，对于在同一个媒体平台不同地方有多个点击归因的用户，会根据策略选择归并到不同的点击中。通过不同的归因策略，帮助媒体平台寻找到想要的用户。

03

增长系统与策略

1. RTA 投放场景

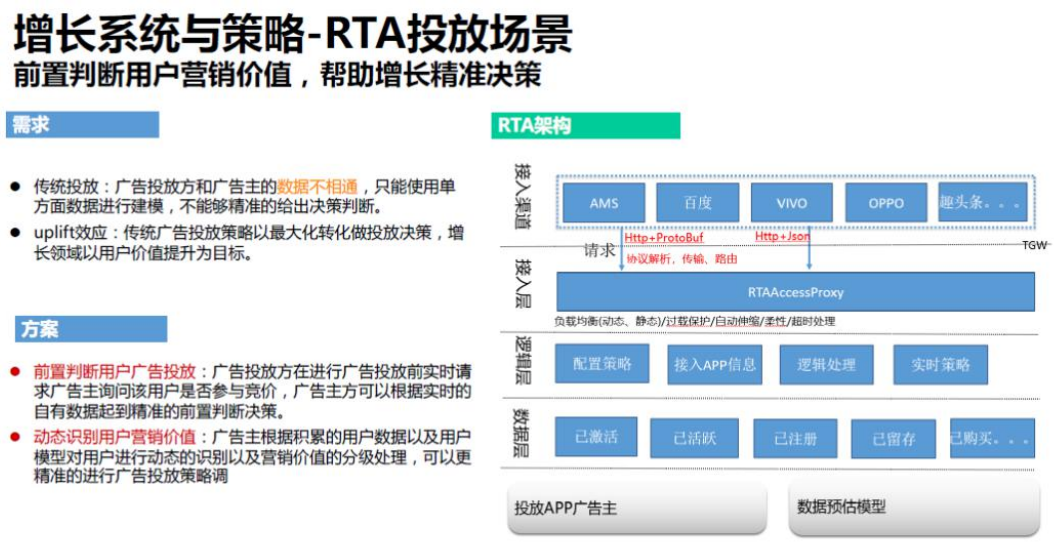

刚才主要是介绍了广告投放平台，以及一些自动化运营策略。接下来介绍 RTA 的投放策略。RTA 的存在主要是由于媒体平台和广告主的数据处于割裂状态，双方

的数据互不相通；除了 oCPX 有一些标准化的数据回传，对于一些高付费用户和高质量用户，广告主方和媒体方处于互不信任的状态。RTA 是通过接口的形式，在广告投放过程中，对用户建模，决策用户是否进行投放。在我们的场景中，首先通过 RTA 实现共同建模；其次，有别于传统投放倾向于获量，增长场景中更倾向于 uplift 效应。

2. RTA 拉活模型

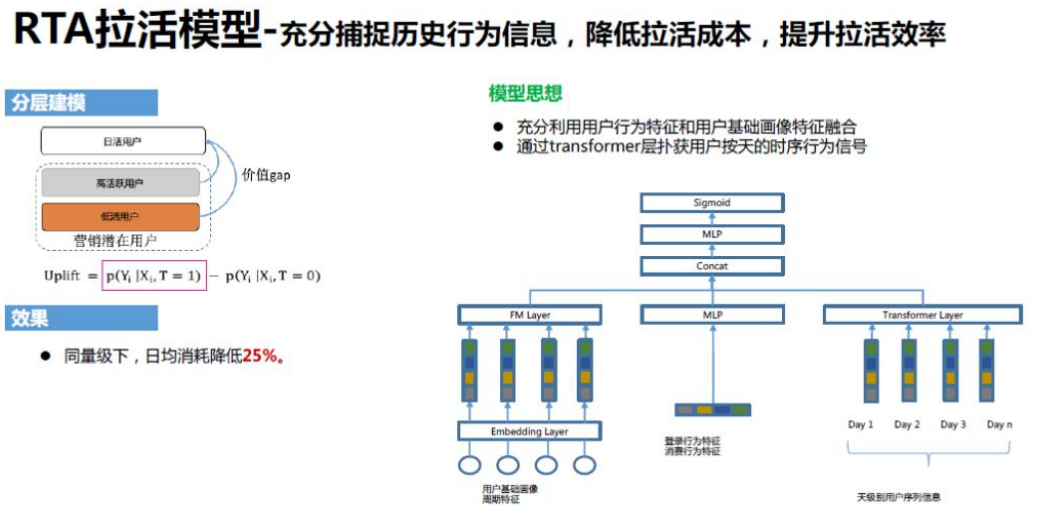

我们在对用户进行拉活增长时，对用户进行分层：营销潜在用户、低活用户、高活用户、日活用户。拉取用户时，考虑到广告的本身投放成本，我们更倾向于拉起业务的低活用户，而不是业务本身已经高活的用户，这样广告的投放价值才最大。uplift 公式的定义是"进行广告投放后的用户拉起概率"和"不进行营销活动的用户拉起概率"的差值。通过这样的 uplift model 在 DPA 中进行拉活的操作，在同一个场景下，消耗降低 25%。

3. 素材策略

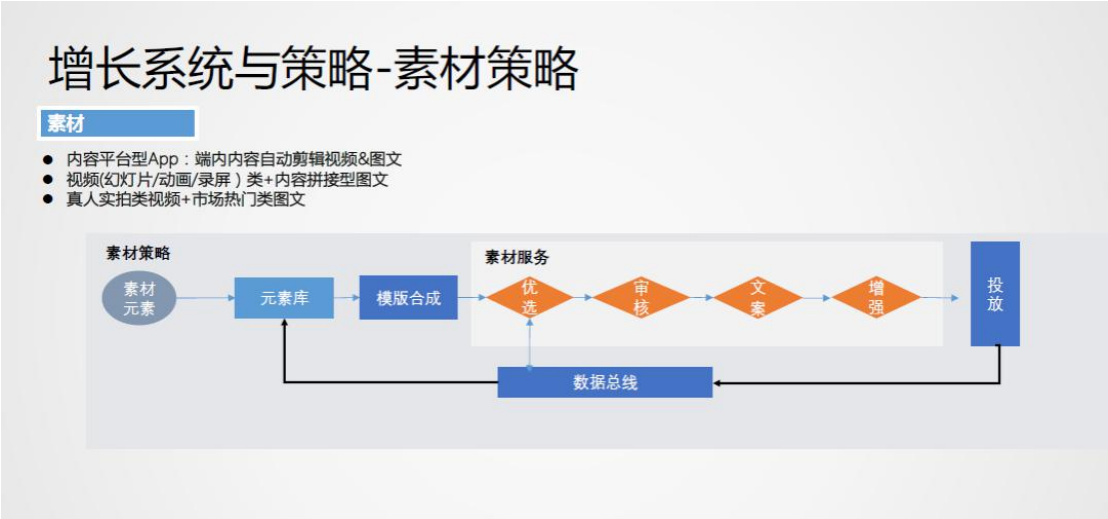

这一块主要是素材方面的策略。素材主要面临的挑战是不同 APP、不同业务的投放素材形态都不太一致，有内容类的、视频类的等等。对于不同业务提供的几十、几百万素材，如何进行素材的申请、挑选、匹配、投放，效率上面临很大的挑战。我们将素材解构成素材元素池，解构完后，每个素材都有对应的标签体系。通过素材库中的元素，和策略投放引擎和媒体平台的模板进行合成，通过模板合成引擎把元素合成为最终要投放的素材。如何挑选元素进行合成，如何挑选合成后的素材进行投放呢？我们是通过优选、审核、文案、增强这四层投放模块的策略进行整体投放的拉通。

在优选和合成的环节，进行素材的挑选时，我们将投放效果归因到素材元素级别，而不仅仅是广告级别；从而对每天投放的素材进行优选，再结合审核的积累、文案的生成、元素库信息的增强，最后进行投放，整体构成了我们素材方面的策略。

4. 拉承一体

介绍完投放和素材的策略后，再介绍下拉承一体的策略。投放需求主要是通过 H5 落地页进行拉新、拉活时，无法有效进行数据追踪分析。同时投放过程中，用户的兴趣点到落地页承接的时候，行为信息是否一致。为了做到广告环节和承接环节的打通。业内主要的做法有用户标识、etag、apk 包等方式。

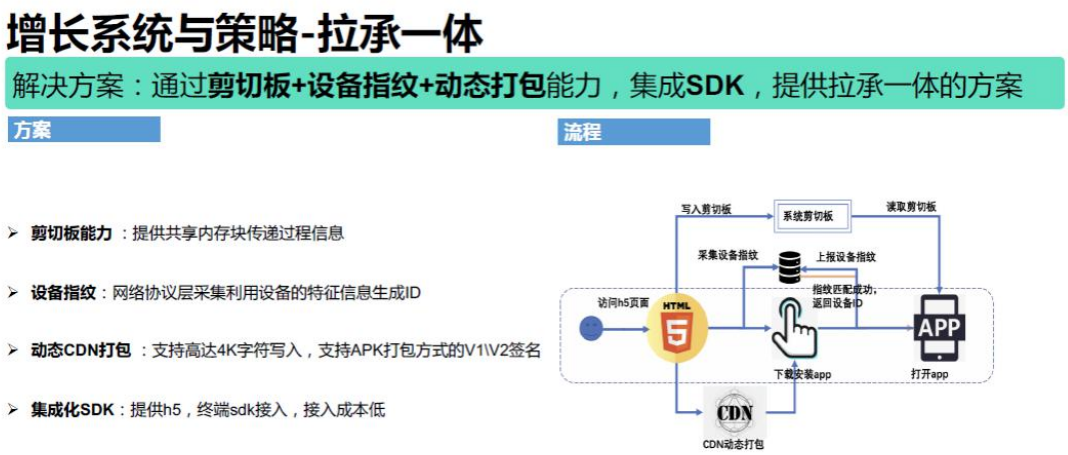

我们的做法主要是通过剪切板+设备指纹+动态打包能力，集成 SDK，提供拉承一体的策略。剪切板通过端上的内存块共享技术传递过程信息；设备指纹的识别是在广告主回传的设备指纹，通过设备指纹和后端的缓存获取呈现给该用户的内容元素，实现在拉起用户时，自动化激活特定素材；动态 CDN 打包是在用户下载激活的过程中，把拉取用户的具体的投放素材通过 APK 打包方式进行动态打包，从而在用户拉起激活的过程中，能够获取这个信息，实现自动化的承接。最后通过提供 h5、终端 sdk 接入，实现集成化 SDK，提供更可靠保障。整体来说，拉承一体的效果比较明显，特别是激活留存等方面取得了不错的效果。

5. DPA 投放场景

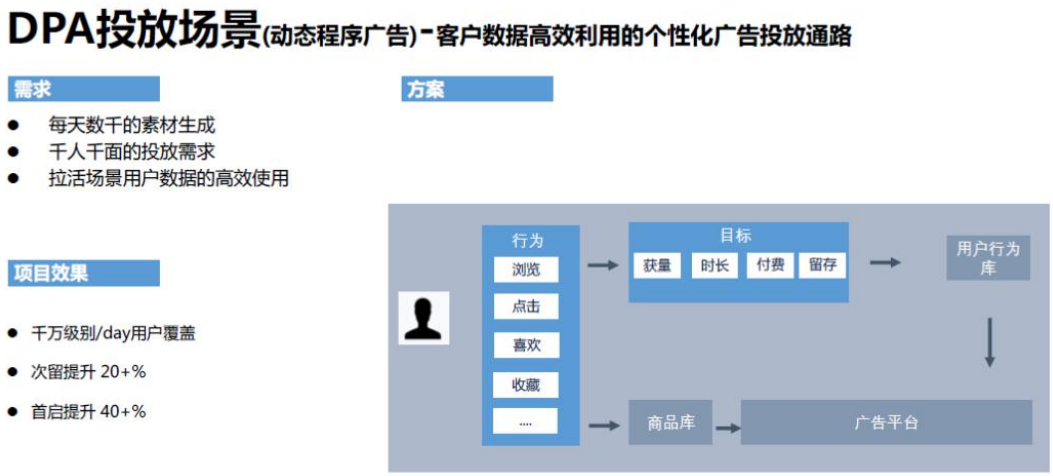

DPA投放

在买量和投放广告的过程中，素材的投放和编辑其实是比较个性化的环节。广告主每天会生成数千的素材，同时有千人千面的投放需求。DPA 的场景是这样的，用户对一些 APP 会产生很多历史行为（浏览、点击、喜欢、收藏等），通过对这

些行为的挖掘形成了一套商品库的体系；然后广告主设置投放目标（获量、时长、付费、留存等）后，会基于这些目标挖掘素材 APP 相关的用户行为库。不同的行为会对应不同的目标；商品库和行为库打通之后，可以做到不同的用户、不同的目标有个性化的素材呈现。在 DPA 投放场景中，做到了千万级别用户覆盖。主要是提高了用户的次留、时长和留存率。

04

总结

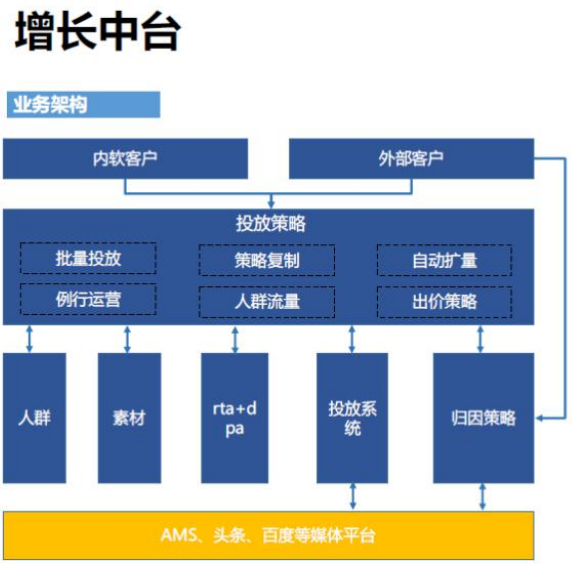

$$ad_num * \frac{CTR * CVR * LTV}{CPA}$$

刚刚介绍了我们的增长中台在承接业务、用户增长、素材挖掘等方面的工作。回过头来总结下，我们的增长中台的大致业务框架如图。最上面主要是批量投放、策略的自动化复制以及自动扩量，从而提升广告的获量、获取外部的优质的流量。在模块例行运营、人群流量、出价策略、rta+dpa 中，介绍了我们在 CTR、CVR、LTV 等价值增长中，ROI 价值目标的达成策略。

总体来说，我们的增长中台目前对接了 8+国内主要媒体平台，实现了广告的程序化、批量投放能力，承接 30W+QPS、每天 240 亿+的流量，20+APP 投放的效果。

05

问答环节

1．如何通过素材库进行模板生成？

其实在不同的业务场景中，生成模板的脚本会不一样。举个例子，在素材生产方面，首先在元素库里做素材元素的解构。由于素材是分广告场景的，比如图片中可能包含人物、道具、标记物广告等等，在不同的 APP 中会进行不同的解构，在模板合成的过程中，进行动态的组合，不一样的业务会拆分成不同的 item、进行不同的组合。

2．广告的自动运营中，会对学习期失败的广告进行自动下线，会不会导致媒体平台中的广告趋近于单一、且对下线的广告不友好，如何评估学习失败的广告对于平台的损失？

广告投放过程中必然会经过三个时期：学习期、拿量期、衰减期。一个广告在学习期学习失败，拿不到量、拿不到激活转化数据是需要进行强制下线。我们对广告进行下线也不是完全的下线，会通过例行化更新的策略，分析历史的投放数据，复制效果好的策略投放到广告平台中，来补充广告的拿量能力。我们没有担心广

告下线对媒体平台的损失，我们考虑的是对于用户增长有没有损失。目前来看对于用户业务增长是没有损失，也说明是一个比较好的策略。

3. DPA 拉活相比 RTB 拉活有什么优劣势？

DPA 主要是解决触达用户多样性的问题。广告在媒体平台进行投放时，呈现给用户的素材不一定是用户想要的。即使是爆品素材，可能在后续的留存、时长等方面效果会比较差。DPA 呈现给用户的是通过后端数据挖掘出来的。比如根据时长标签挖掘的用户，必然是对该内容有很好的停留时长的特点。通过对目标用户的引导，引导到目标广告或商品中。这个是 DPA 的优势，对不同的人群、不同的目标呈现不一样的素材。

理论上，如果外部的流量非常好，从系统上讲，RTB 是一个非常好的广告呈现方式，因为 RTB 能够控制用户所有的行为、模型。平台只需要进行价格成本上的交付，RTB 自己控制模型。从功能上，RTB 更灵活，也能做更多的事情，但是从国内的流量生态上讲，DPA 是跟广告媒体平台结合的更紧密的方式，能够保证媒体流量的优质性。RTB 目前主要是一些边边角角的流量，这部分流量对于很多 APP 不适合。我们以前也尝试过利用 RTB 做一些游戏高质量人群的增长，发现用户的付费意图、留存意图比较低，整体流量质量比较差。从流量角度上讲，是属于不太一样的流量生态。

今天的分享就到这里，谢谢大家。

信息流推荐的用户增长机制

分享嘉宾：天师 阿里巴巴 高级算法专家

编辑整理：王洪达

出品平台：DataFunTalk

导读：本文主要从偏向底层的推荐算法角度来阐述信息流推荐系统升级如何助力用户增长。我们知道，内容信息流实际上已经算是信息流中比较小的概念，其中包含图文信息流、短视频信息流和内容+电商信息流，而对于用户来讲实际上是一个消费时间的产品体验，从而对内容生态产生很大的助力（包括 PGC、UGC 的短内容生态），这就是本文主要的问题——内容信息流。本文旨在解决的问题是：基于推荐算法视角，来解决信息流产品用户增长的问题。其中，主要问题就是如何提升留存率。

01

关于用户增长

做过推荐系统方面工作的同学应该清楚的知道，推荐工程里面主要包含推荐算法和搜索算法。而我们往往关注的是 Stoptime 这样的指标，使用有监督的模型来解决一系列问题，例如点击率、单次时长等。对于留存问题和大盘规模问题在机制上，有很大的不足，比如：推荐新的篇章，从用户方面和生态方面都存在着双边的幸存者偏差问题。

1. 问题分析

首先看下大的背景，目前是移动互联网进入下半场的大趋势，过去粗放式的买量、厂商合作等模式越来越受到掣肘，未来将更加依赖精细化的用户增长策略、产品和用户体验的细致打磨。经典的 AARRR 模式会逐步转向 RARRA 模式，提升产品留存、拉活、分享传播等方式是构建增长的主要战场，对于一个内容型产品来说，个性化算法对于用户留存、拉活起到了决定性的作用。在信息流产品增长上，有三种比较成功的模式：

头部内容模式：一种比较"重"的模式，该类产品利用精准的内容采买，引入优质的头部内容创作者，利用头部内容的流量聚焦效应，迅速圈定大批用户，并形成内容 APP 特有的用户心智；但是由于内容头部化，个性化算法在其中发挥的空间和作用较小，产品模式趋于同质化。

下沉/激励模式：该类产品参考了网络游戏模式，从各个环节设计用户里程碑和激励，不断引导新用户一步步完成点击、下刷、完整阅读、分享、关注等目标里程碑，并给予虚拟货币和真实货币的激励，在短时间内可以获取大量下沉用户。

生态构建模式：该类产品构建了完善的内容生产和消费生态，旨在通过推荐系统同时刺激生产和消费，实现两端的同时增长。

因此，个性化的核心问题主要分为两个：

- 用户状态建模：深度建模用户状态和行为，通过对于大数据集中分析，找到使用户从低阶状态到高阶状态转化的干预因子。也就是如何把新用户转化成低阶用户，然后从低阶用户转化到高阶用户，用户流失后如何召回，类似这样的用户状态转化。
- 个性化分发的升级：将用户行为建模后，在多个场景下将这些干预动作转化为个性化推荐和营销，满足用户的消费需求。

2. 增长要素

什么样的内容会让用户觉得好？我们来看看用户增长的要素：

- 优质内容/时效性：内容的更新频率以及内容的质量是用户增长的关键。

- 个性化体验：千人千面，推荐的内容符合当下的需求。

- 多渠道获客：多渠道获客的能力也是增长的一个关键因素。

- CPC vs LTV：维持 CPC（按点击收费）和 LTV（用户对系统的长期价值）的一个平衡。

算法如何助力增长呢？主要有以下几点：

- 精细化买量/外投；

- 提升留存；

- 衡量推荐这样 Action 的效用；

- 消除幸存者偏差。

02

关于推荐算法

推荐系统在国内大概已经有十多年的应用，模型架构和算法都有很大的升级。

1. 推荐系统回顾

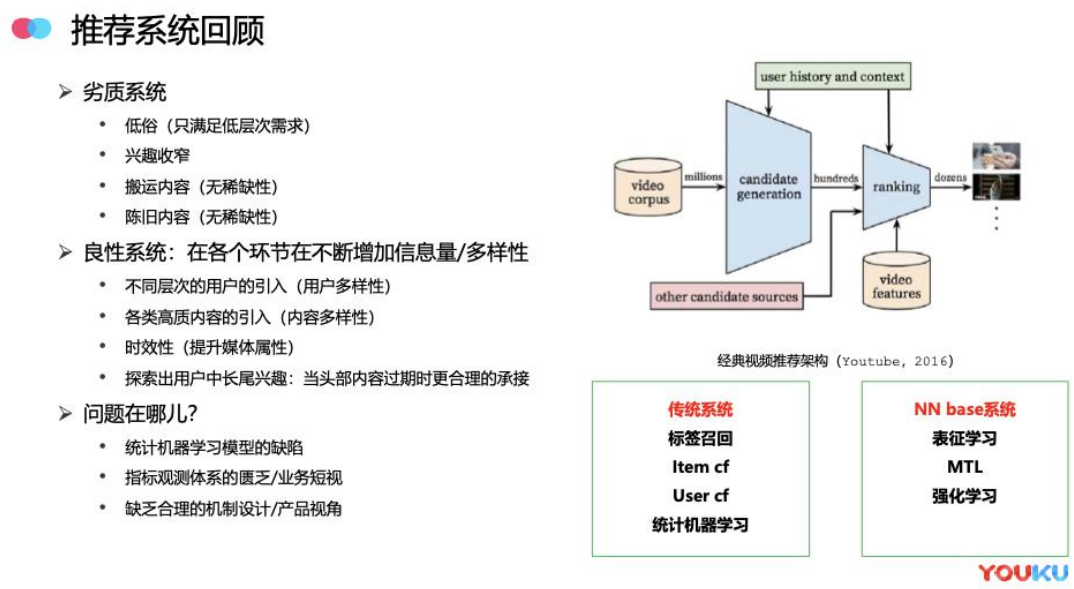

首先回顾下推荐系统：

- 劣质系统：只会推荐一些低俗（只满足低层次需求）、兴趣受窄、搬运内容（无稀缺性）、陈旧内容的信息。
- 良性系统：区别于劣质系统，在各个环节都会不断增加信息量（多样性），不同层次的用户引入（用户多样性），各类高质量内容的引入（内容多样性），内容更具时效性（提升媒体属性），探索出用户中长尾兴趣：当头部内容过期时从而更合理的承接。
- 问题在哪儿？主要存在以下问题：统计机器学习模型存在缺陷；长期的指标观测体系匮乏以及业务短视；缺乏合理的机制设计和产品视角。

2. 信息流推荐的增长目标

用户满意度的衡量：

- 衡量用户满意度的指标有很多，但主要集中在三大方面：内容相关性、内容质量和内容时效性，时效性一定程度上代表内容的稀缺性。
- ctr 代表什么：一定需要 ctr 吗？对内容无认知的用户需要衡量用户对列表页素材的满意度，对内容有认知的用户还需要衡量用户对内容本身的满意度。
- 用户对内容真正的认可是通过点赞、分享、评论这种互动的方式来表现的，目前很多产品注重对互动的引导。

信息流推荐的增长目标，主要包括：

- 提升用户留存、LTV
- 通过分发筛选出优质内容、优质生产者：在传统的认知中，喜欢什么就给什么；但是更新后的认知是创造需求和玩法，持续优质内容生产
- 构建内容生态：提高分发时效性；增加对 upgc 主的激励（曝光、点击、粉丝、分成）；通过准入、扶持打压、激励这种机制维持一个好的生态和增

长。只有通过用户和生态两端的同时增长，才能让产品得到一个飞轮效应，良性发展。

03

核心增长机制

1. 双边冷启动与流转机制① 概述

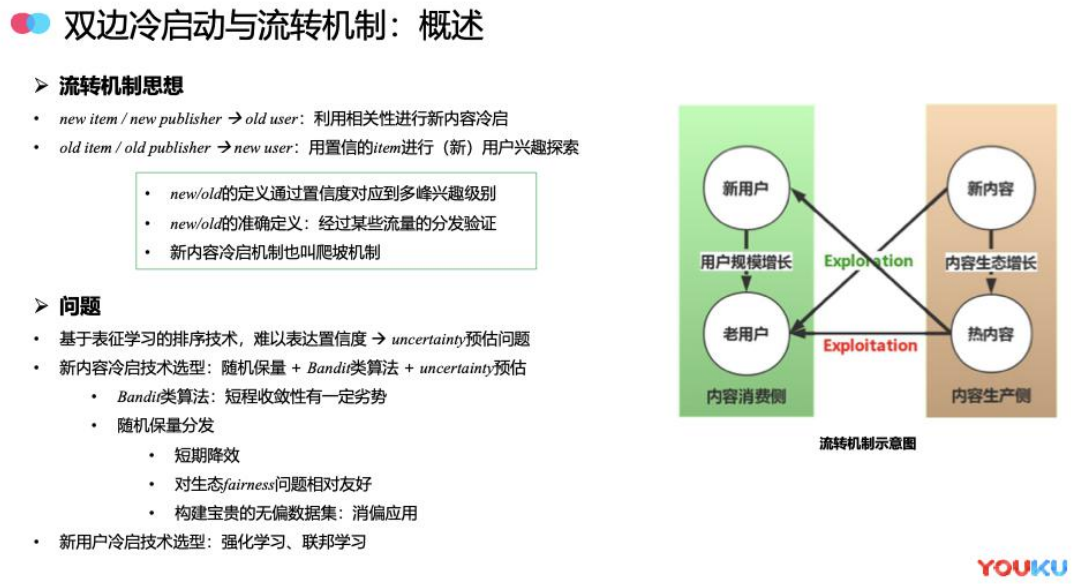

在管理上也有这样的一种思想，就是新人做老事、老人做新事，促进事情稳定向前推进，这就是流转机制设计的主要思想。因此，如何对新用户和新内容做双边冷启动就成了核心的问题。从算法来看，这是两个不太相同的问题，但从整体设计思想来讲，两者又比较相近。新内容通过相关性分析可以达到探索、分发、推广的效果。进而新用户如何探索他的兴趣？比如推荐股票，一定会先推荐近期走势最好的股票；推荐科幻片，大概也是这样，推荐评分最高的，这样就可以实现新用户规模本身的增长。对于新内容来讲，通过老用户面对热内容的探索分析，也可以逐步推进内容生态的增长，其实这并不完全是算法的问题，这同样是贯穿从内容运营到产品设计整个体系的一个哲学思想。对于新和

旧的定义是通过置信度对应到多峰兴趣级别，同时对应到 topic 兴趣的级别；对于新和老的准确定义应该是经过某些流量的分发验证，而不是简单通过来的早晚；新内容冷启机制也叫爬坡机制。这里面带来的技术问题包含：

- 基于表征学习的排序技术，难以表达置信度；神经网络技术很难表达最重要的概念。
- 新内容冷启动技术选型业内有很多的方案：随机保量（短期降效、对生态 fairness 问题相对友好、构建宝贵的无偏数据集，消偏应用）+Bandit 类算法（短程收敛性有一定劣势）+uncertainty 预估（个人推荐）
- 新用户冷启动的技术选型和新内容还是有很大差别的，其主要是通过强化学习、联邦学习这种人工智能的方式进行分析，而通过统计学，很难分析出人的偏好。

② 详细实现

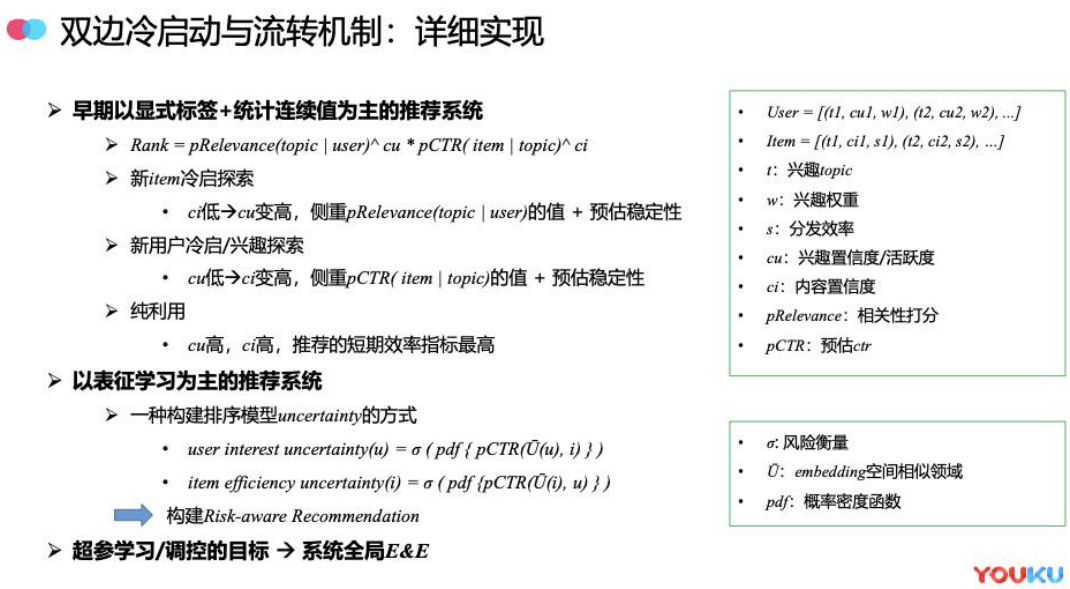

双边冷启动与流转机制的实现，主要包括：a. 早期以显式标签+统计连续值为主的推荐系统

Rank = pRelevance(topic | user)^ cu * pCTR(item | topic)^ ci　一方面用主题到用户的相关性，另一方面用 item 到主题的统计值或者模型的估分，这里面会有两个置信的概念，一个是用户兴趣的置信度，一个是 item 本身的置信度；

新 item 冷启探索：ci 低会提高 cu，侧重主题到用户的相关性值以及预估稳定性；

新用户冷启/兴趣探索：cu 低会提高 ci，侧重 item 到主题的统计值以及预估稳定性；

纯利用：对于老人做老事，ci 高，cu 也高，推荐的短期效率指标是最高的，但是长期来看，如果只注重这种推荐的短期效率指标，不对新用户和新内容进行探索，那长期就很难发展下去。

b. 以表征学习为主的推荐系统，这块主要是思考如何做成 Risk-aware recommendation，目前构建排序模型 uncertainty 的一种方式如下：

- $user\ interest\ uncertainty(u) = \sigma\ (\ pdf\ \{\ pCTR(\bar{U}(u),\ i)\ \}\ )$
- $item\ efficiency\ uncertainty(i) = \sigma\ (\ pdf\ \{pCTR(\bar{U}(i),\ u)\ \}\ )$

c. 超参学习/调控的目标→系统全局 E&E

3. 消偏与因果推断：背景介绍

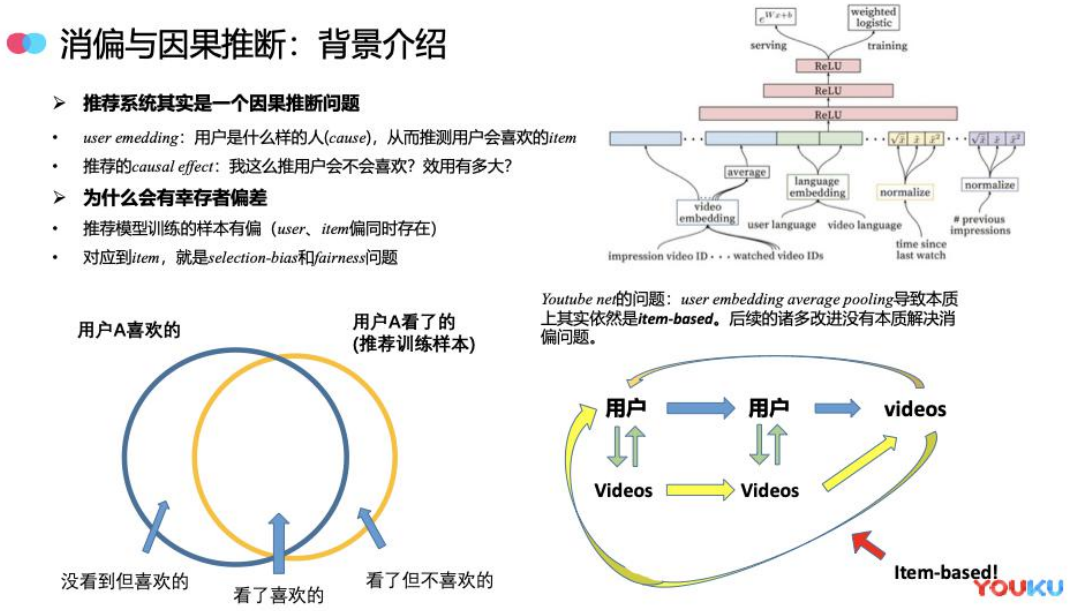

对于幸存者偏差问题，我们是通过因果推断的方式解决的。推荐系统其实是一个因果推断的问题，通过用户是什么样的人，从而推测用户会喜欢什么样的 item；对于推荐的 causal effect，用户会不会喜欢？效用有多大？会不会成为高价值客户？如果推荐后，用户会有 hot moment，我们可以判定，推荐效果是好的。为什么会存在幸存者偏差呢？

推荐模型本身的样本就是有偏的，user 和 item 偏同时存在，比如用户没看喜欢的部分没有参与到模型训练中。

对应到 item，就是 selection-bias 和 fairness 问题。比较典型的案例是 youtube net，user embedding average pooling 本质上，依然是 item-embased，后续诸多改进没有本质的解决消偏问题。这样就会导致后续推的东西比较类似，如果第一次推的好就会留下用户，推得不好用户就会很快流失。

4. 消除幸存者偏差：Casual Inference 推荐框架

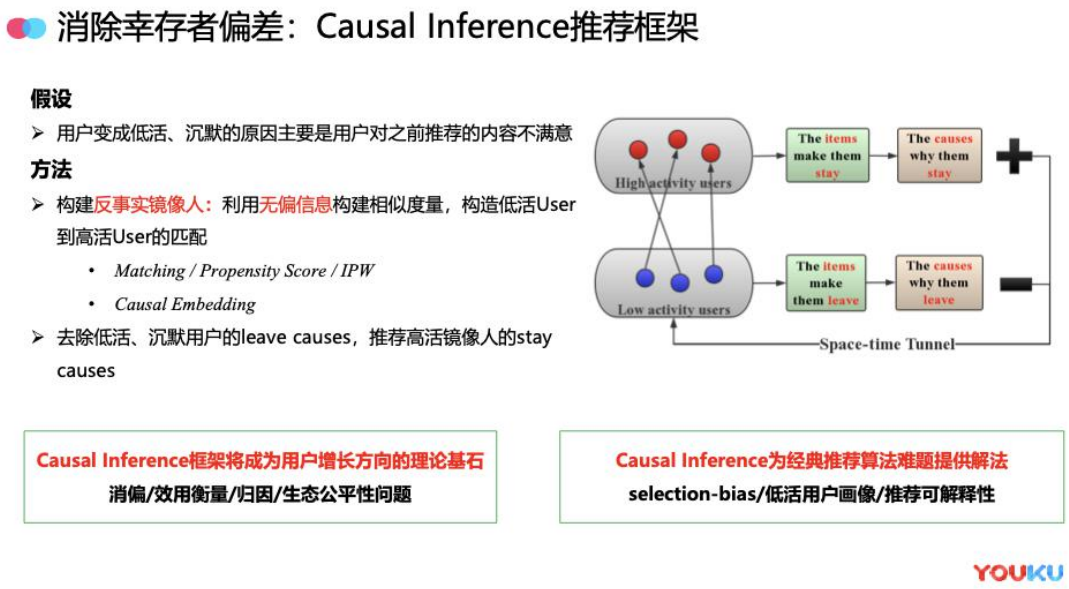

假设：在因果推断的推荐框架中，假设用户变成低活、沉默的原因主要是用户对之前推荐的内容不满意。**方法：**

构建反事实镜像人：利用无偏信息构建相似度量，构建低活 user 到高活 user 的匹配（Matching / Propensity Score / IPW，Causal Embedding）

去除低活、沉默用户的 leavecause，推荐高活镜像人的 stay causes

经过实践探索后发现，causal inference 框架将成为用户增长方向的理论基石，对于消偏、效用衡量、归因和生态公平性问题都有解法；同时，causal inference 也为经典推荐算法难题提供解法，如 selection-bias、低活用户画像和推荐可解释性等问题。

5. 面向增长的用户画像

① 状态里程碑表示法

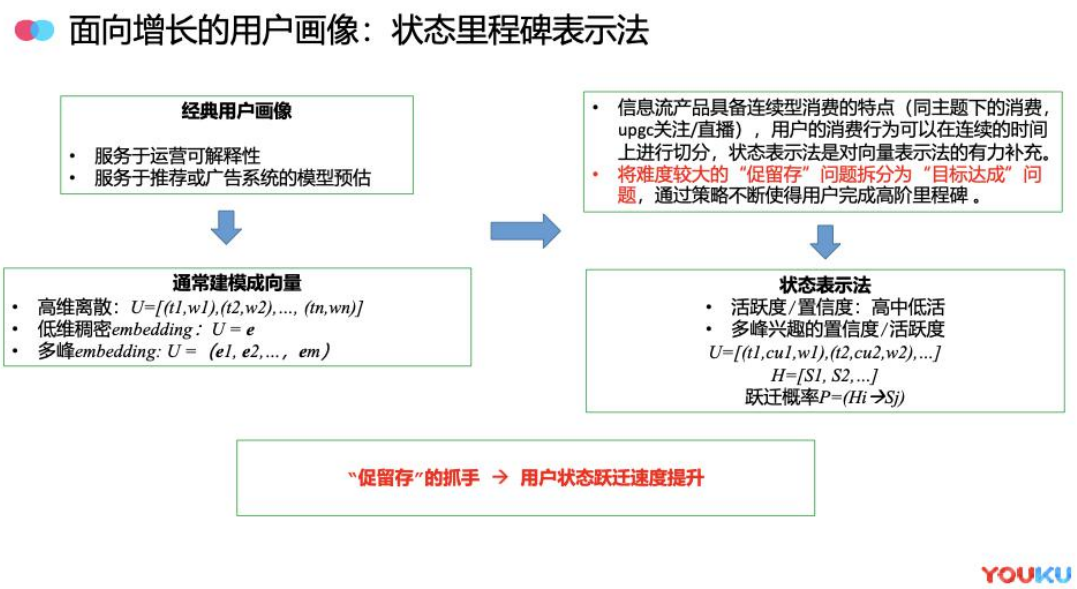

经典用户画像，主要要服务于运营的可解释性、推荐或广告系统的模型预估；通常建模成向量：高维离散、低维稠密以及多峰 embedding。由于信息流产品具备连续型消费的特点（同主题下的消费，upgc 关注、直播），用户消费行为可以在连续的时间上进行切分，因此状态表示法是对向量表示法的有力补充，状态表示法主要包含活跃度、置信度，多峰兴趣的置信度、活跃度；这样将难度较大的"促留存"问题拆分为"目标达成"问题，通过策略不断使得用户完成高阶里程碑，将"促留存"的抓手聚焦在用户状态跃迁速度的提升上。

② 全生命周期因果推断

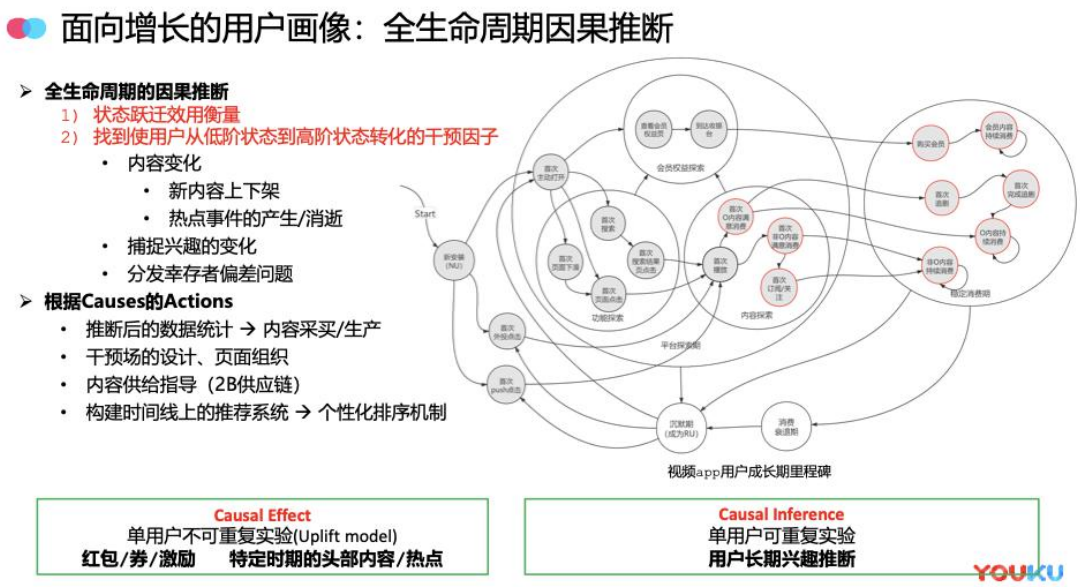

全生命周期的因果推断：在构建面向增长的用户画像时，需要采用全生命周期因果推断：

- 状态跃迁效用衡量
- 找到使用户从低阶到高阶状态转化的干预因子：
  - 内容变化：新内容上下架、热点事件的产生和消逝
  - 捕捉兴趣的变化
  - 分发幸存者偏差问题

根据 causes 的 actions：

- 推断后的数据统计到内容采买和生产
- 干预场的设计和页面组织
- 内容供给指导（2b 供应链）

- 构建时间线上的的推荐系统来推断个性化排序机制

6. 效用理论应用

① 个性化排序机制

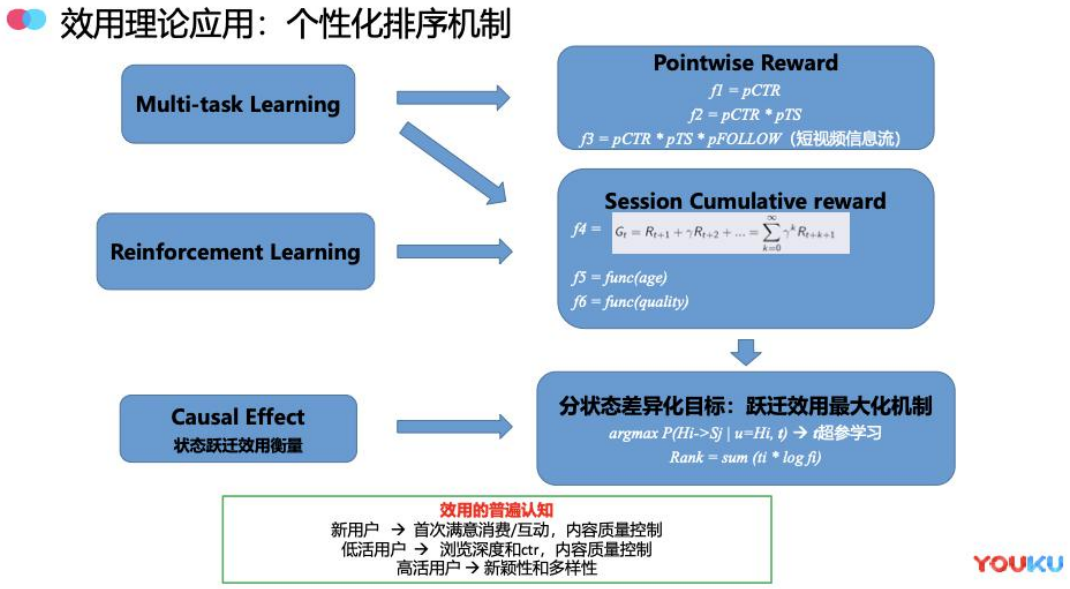

对于效用的普遍认知是：

- 新用户首次满意消费和活动（内容质量控制）
- 低活用户浏览深度和 ctr（内容质量控制）
- 高活用户要增加新颖性和多样性

个性化排序机制通过 multi-task learning、强化学习和 causal effect 的方式，来进行分状态差异化的对用户进行跃迁效用最大化地排序推荐，无论是新用户、低活还是各个细分状态的用户，都会让用户在平台中觉得不是兴趣收窄的，承担着各自的职责。这些内容在阿里都有落地并取得了很大的收益。② **生态效用技术**

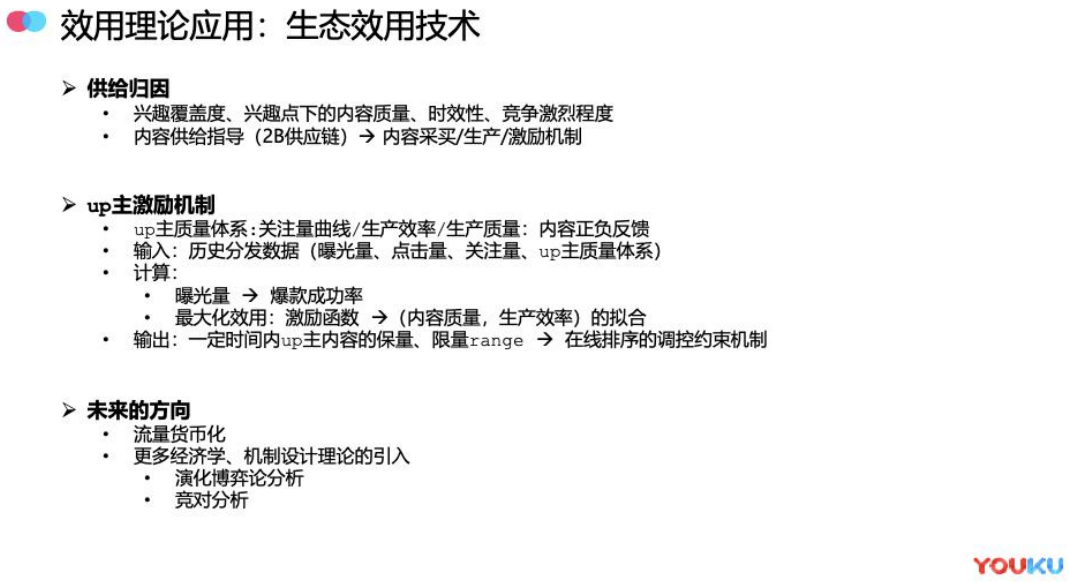

效用理论应用是一个比较开放的课题，对于电商、短内容的生态是不一样的。

供给归因：

- 兴趣覆盖度、兴趣点下的内容质量、时效性、竞争激烈程度
- 内容供给知道（2B 供应链->内容采买/生产/激励机制）

up 主激励机制：

- up 主质量体系：关注量曲线、生产效率、生产质量，内容正负反馈
- 输入就是历史分发数据（曝光量、点击量、关注量、up 主质量体系）
- 计算：

· 曝光量->爆款成功率

· 最大化效用：激励函数->内容质量和生产效率的拟合

- 输出就是一定时间内 up 主内容的保量、限量 range->在线排序的调控约束机制

未来方向：

- 流量货币化
- 更多经济学、机制设计理论的引入
- 演化博弈论分析
- 竞对分析

以上就是针对面向用户增长的信息流分发机制的分享，特别是短内容领域利用推荐算法推动用户增长的思考，分享比较偏技术，是在阿里多年积累所沉淀下来的东西，没有太多强调推荐算法模型的部分，更多是以整体的算法架构和算法机制设计角度考量生态和用户增长，里面很多问题也是特别难、特别开放的，欢迎大家一起交流探讨。

今天的分享就到这里，谢谢大家。

滴滴数据指标体系建设实践

文章作者：曹雷 滴滴 高级专家工程师
编辑整理：Charlotte
内容来源：公众号“滴滴技术”

导读：指标体系是什么？如何使用 OSM 模型和 AARRR 模型搭建指标体系？如何统一流程、规范化、工具化管理指标体系？本文会对建设的方法论结合滴滴数据指标体系建设实践进行解答分析。

01

什么是指标体系

1. 指标体系定义

指标体系是将零散单点的具有相互联系的指标，系统化的组织起来，通过单点看全局，通过全局解决单点的问题。它主要由指标和体系两部分组成。

指标是指将业务单元细分后量化的度量值，它使得业务目标可描述、可度量、可拆解，它是业务和数据的结合，是统计的基础，也是量化效果的重要依据。

指标主要分为结果型和过程型：

结果型指标

用于衡量用户发生某个动作后所产生的结果，通常是延后知道的，很难进行干预。结果型指标更多的是监控数据异常，或者是监控某个场景下用户需求是否被满足

过程型指标

用户在做某个动作时候所产生的指标，可以通过某些运营策略来影响这个过程指标，从而影响最终的结果，过程型指标更加关注用户的需求为什么被满足或没被满足

体系是由不同的维度组成，而维度是指用户观察、思考与表述某事物的“思维角度”，维度是指标体系的核心，没有维度，单纯说指标是没有任何意义的。

维度主要分为定性维度和定量维度，定性维度，主要是偏文字描述类如城市、性别、职业等;定量维度，主要是数值类描述如收入、年龄等，对定量维度需要做数值分组处理。

2. 指标体系生命周期

生命周期主要包含定义、生产、消费、下线四个阶段。针对整个生命周期要持续做指标运维、质量保障，同时为了提高指标数据复用度，降低用户使用成本需要做对应的数据运营工作。

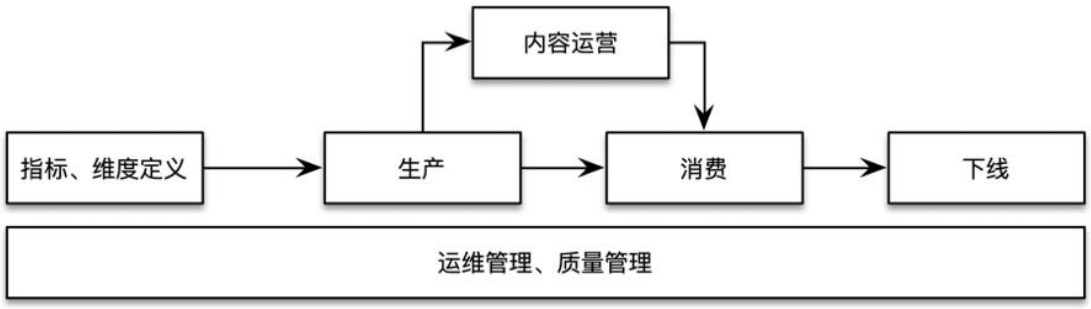

3. 综合使用场景

指标体系主要是结合用户的业务场景来进行使用，多个不同的指标和维度可以组合起来进行业务的综合分析，用户可通过指标的变化看到整体业务的变化，并能够快速发现问题、定位问题。常用的场景一种是决策分析的场景，通过数据看清业务现状进行战略决策支持，另一种是运营分析场景，无论是做用户运营、产品运营还是活动运营都需要各类指标数据的支撑去看清问题、分析问题和指导解决问题。

02

为什么搭建指标体系

衡量业务发展质量：

指标体系可以反映业务客观事实，看清业务发展现状，通过指标对业务质量进行衡量，把控业务发展情况，针对发现的业务问题聚焦解决，促进业务有序增长

建立指标因果关系：

主要明确结果型指标和过程型指标关系，通过结果指标回溯过程指标，找到解决问题的核心原因

指导用户分析工作：目的建立产品评估体系、活动效果评估体系、智能运营分析体系**指导基础数据建设：**明确基础数据建设方向，集中资源，避免过程和结果分析指标数据的遗漏或缺失**指导内容产品建设：**结合用户的业务场景来进行使用，多个不同的指标和维度可以组合起来进行业务的综合分析，用户可通过指标的变化看到整体业务的变化，并能够快速发现问题、定位问题**统一指标消费口径：**企业内统一关键指标业务口径及计算口径，统一企业业务目标，实现自上而下目标驱动

03

如何搭建指标体系

指标体系建设的常用方法是通过场景化进行指标体系的搭建，以用户的视角场景化思考，自上而下业务驱动指标体系建设，所以要在特定场景下做好指标体系建设，需要先选好指标，然后用科学的方法搭建指标体系。

1．科学方法选指标

选指标常用方法是指标分级方法和 OSM 模型。

指标分级主要是指标内容纵向的思考，根据企业战略目标、组织及业务过程进行自上而下的指标分级，对指标进行层层剖析，主要分为三级 T1、T2、T3。

T1 指标：公司战略层面指标

用于衡量公司整体目标达成情况的指标，主要是决策类指标，T1 指标使用通常服务于公司战略决策层

T2 指标：业务策略层面指标

为达成 T1 指标的目标，公司会对目标拆解到业务线或事业群，并有针对性做出一系列运营策略，T2 指标通常反映的是策略结果属于支持性指标同时也是业务线或事业群的核心指标。T2 指标是 T1 指标的纵向的路径拆解，便于 T1 指标的问题定位，T2 指标使用通常服务业务线或事业群

T3 指标：业务执行层面指标

T3 指标是对 T2 指标的拆解，用于定位 T2 指标的问题。T3 指标通常也是业务过程中最多的指标。根据各职能部门目标的不同，其关注的指标也各有差异。T3 指

标的使用通常可以指导一线运营或分析人员开展工作，内容偏过程性指标，可以快速引导一线人员做出相应的动作。

例如：成交率的指标分级

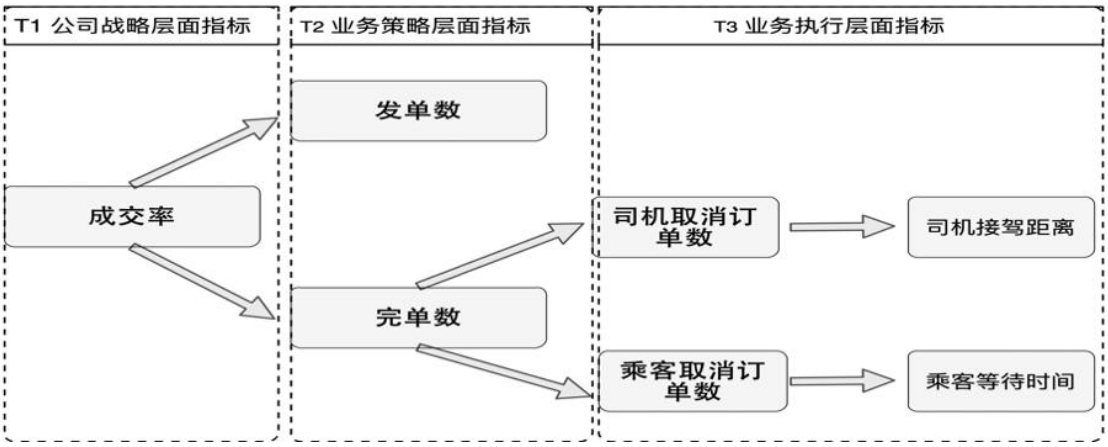

OSM 模型（Obejective，Strategy，Measurement）是指标体系建设过程中辅助确定核心的重要方法，包含业务目标、业务策略、业务度量，是指标内容横向的思考。

O

用户使用产品的目标是什么？产品满足了用户的什么需求？主要从用户视角和业务视角确定目标，原则是切实可行、易理解、可干预、正向有益

S

为了达成上述目标我采取的策略是什么？

M

这些策略随之带来的数据指标变化有哪些？

以滴滴网约车为例，按照 OSM 模型，它的指标是什么样的？

O：用户来使用滴滴这个产品，需求和目标是什么？

用户需求及目标是便捷、快速打到车，安全到达目的地

那如何让用户感受到自己的需求被满足了呢？

S：滴滴做的策略是：

便捷方面，提供了独立 APP 版本、小程序版本，还可以多渠道打到车，例如在高德、微信、支付宝都有打车入口；起始、目的地地图智能精准定位；最优路线选择等

快速方面，针对不同人群不同诉求提供了多品类产品选择，例如快车、优享、拼车、出租车等业务，根据早晚高峰提高热点区域运力，减少用户排队时间

安全方面，司机准入机制，司机合规机制，司机画像

M：我们需要针对这些策略去做指标，在这里面我们的指标分别是结果指标和过程指标：

结果指标：渠道转化完成率、乘客取消率、供需比、司机服务分

过程指标：渠道发单数、渠道完单数、排队乘客数、乘客排队时长、司机好评率、司机接单量、司机取消数等

指标选取之后，下面就是最重要的分析维度选择了，前面指标体系定义里讲过维度是指标体系的核心，没有维度，单纯说指标是没有任何意义的。所以维度选择层面主要通过数据分析视角结合实际分析业务场景来确定。例如城市维度、商圈维度、渠道维度、时间维度、用户标签维度等。

2. 用分析模型搭建指标体系

在《精益数据分析》一书中给出了两套比较常用的指标体系建设方法论，其中一个就是比较有名的海盗指标法，也就是我们经常听到的 AARRR 海盗模型。海盗模型是用户分析的经典模型，它反映了增长是系统性地贯穿于用户生命周期各个阶段的：用户拉新(Acquisition)、用户激活(Activation)、用户留存(Retention)、商业变现(Revenue)、用户推荐(Referral)。

AARRR 模型

A 拉新

通过各种推广渠道，以各种方式获取目标用户，并对各种营销渠道的效果评估，不断优化投入策略，降低获客成本。涉及关键指标例如新增注册用户数、激活率、注册转化率、新客留存率、下载量、安装量等

A 活跃

活跃用户指真正开始使用了产品提供的价值，我们需要掌握用户的行为数据，监控产品健康程度。这个模块主要反映用户进入产品的行为表现，是产品体验的核心所在。涉及关键指标例如 DAU/MAU 、日均使用时长、启动 APP 时长、启动 APP 次数等

R 留存

衡量用户粘性和质量的指标。涉及关键指标例如留存率、流失率等

R 变现

主要用来衡量产品商业价值。涉及关键指标例如生命周期价值(LTV)、客单价、GMV 等

R 推荐

衡量用户自传播程度和口碑情况。涉及关键指标例如邀请率、裂变系数等

可以根据实际业务场景，结合使用 OSM 和 AARRR 模型，来系统性的选择不同阶段所需要的核心数据指标。

	目标	策略	指标
获取	拉新	拉新活动、渠道推广、媒体广告	新增注册用户数、下载量、安装量、注册转化率	
活跃	提高使用产品频次	活动奖励、增加产品品类、短信触达	DAU、MAU、功能点击率	
留存	提升留存率	优化产品功能、用户运营活动	留存率、流失率	
变现	完单收益	导流	客单价、活跃付费用户数	
推荐	拉新	分享	K因子	

3. 场景化搭建指标体系

目前阶段互联网业务比较流行的一种通用抽象场景“人、货、场”，实际就是我们日常所说的用户、产品、场景，在通俗点讲就是谁在什么场景下使用了什么产品，不同的商业模式会有不同的组合模式。以滴滴实际场景为例：哪些场景（此处场景定义为终端，如 Native，微信，支付宝）的什么人（乘客）在平台上使用了哪些货（平台业务线，如快车/专车等），进而为评估用户增长的价值和效果。

"人"的视角

从"人"的视角，我们比较关心的是什么乘客在什么时间打的车，排了多长时间，等了多长时间上车，周期内第几次打车，打车花了多少钱，是否有投诉和取消行为，具体到数据指标主要看发单用户数、完单用户数、客单价、周期内完单订单

数、取消订单数、评价订单数等。

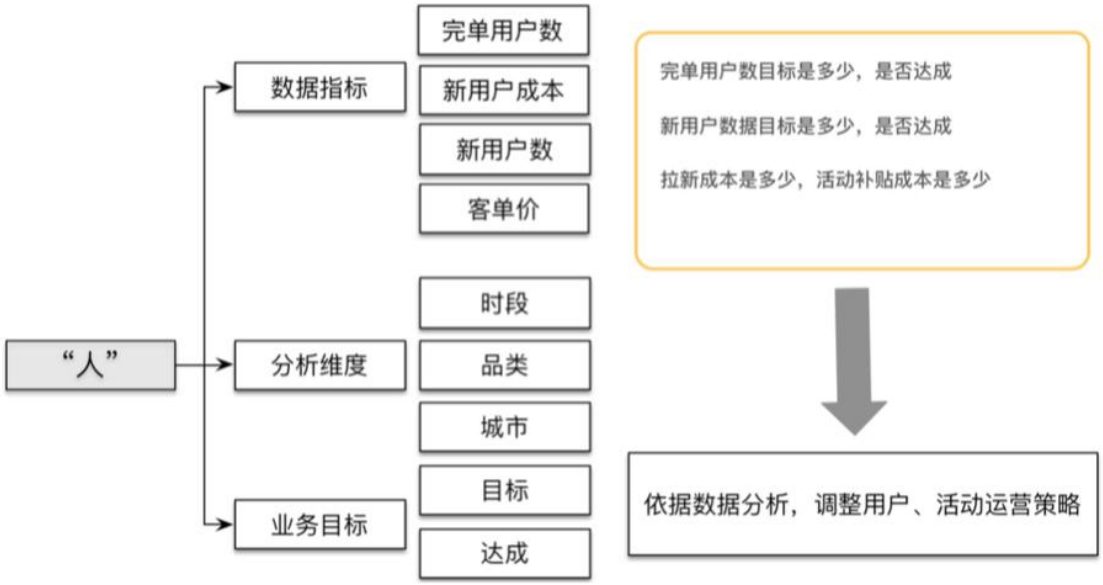

"货"的视角

从"货"的视角，我们比较关心的就是成交了多少，交易额多少，花了多少，到具体数据指标主要会看 GMV、成交率、取消率指标，在进一步会细分到城市、区域，一级品类、二级品类。数据的效果通过目标对比，横向对比、历史比较等方式进行分析确定。

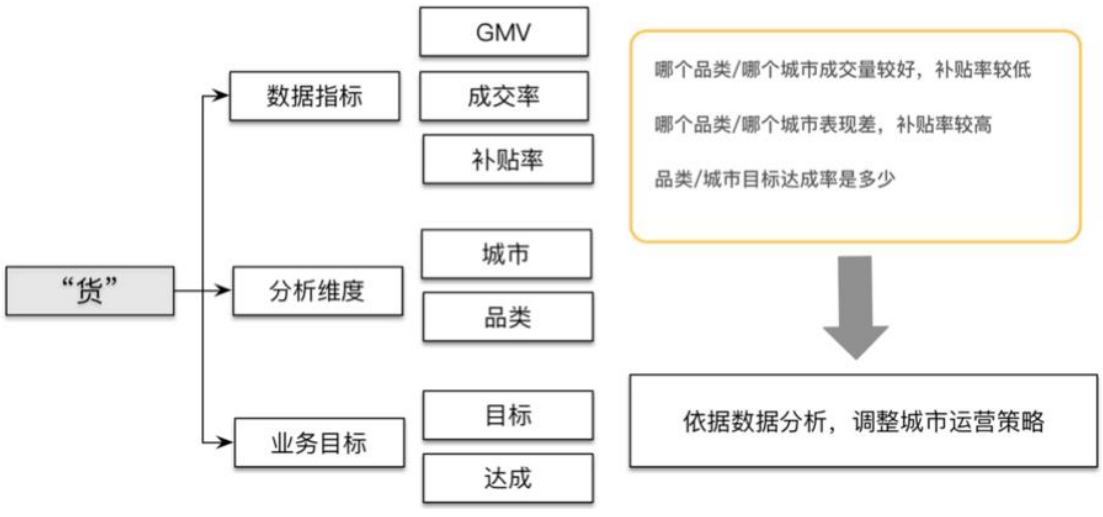

"场"的视角

从"场"的视角，我们比较关心的就是哪个渠道用户点击量大曝光率大，带来了多少新用户，完成多少交易订单，客单价是多少；或者是哪个活动拉新或促活效果怎么样转化率多少，结合场景数据实际情况制定对应策略。

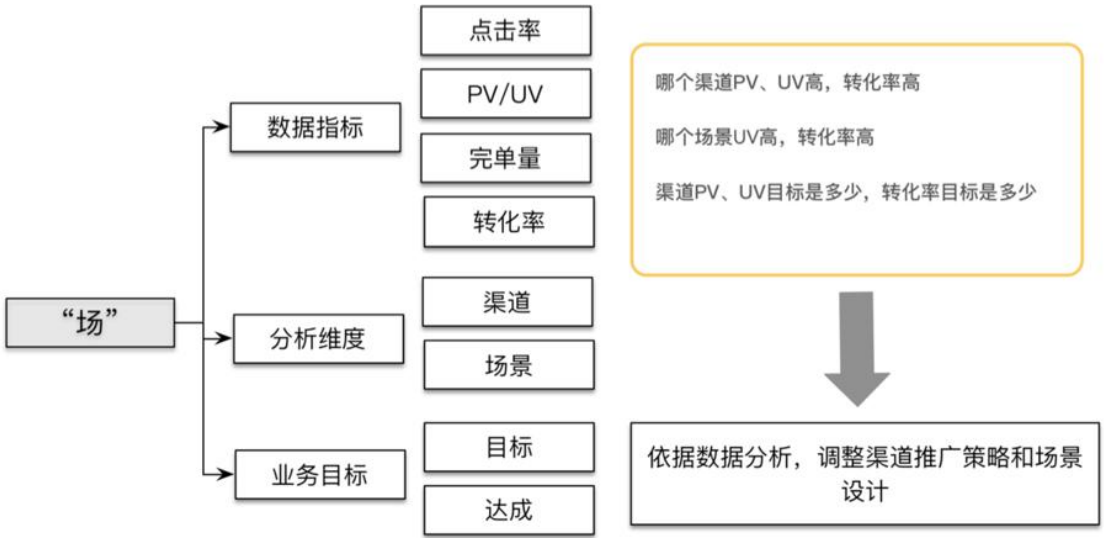

以上分别从"人"、"货"、"场"三个角度进行了数据指标和分析维度的提炼，下面我们把三类指标结合指标分级方法进行分解关联。

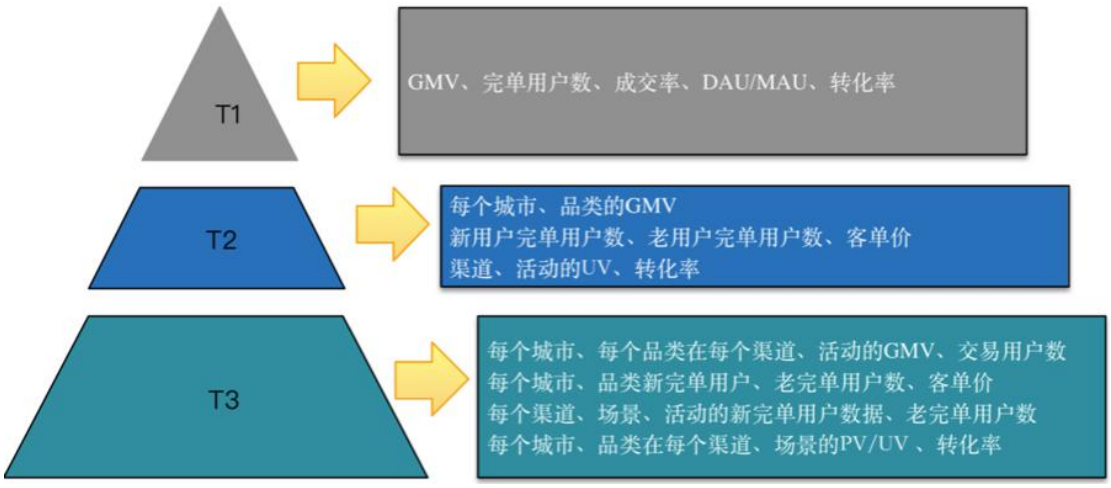

04

怎么管理指标体系

1．痛点分析

主要从业务、技术、产品三个视角来看：

业务视角

- 业务分析场景指标、维度不明确；
- 频繁的需求变更和反复迭代，数据报表臃肿，数据参差不齐；
- 用户分析具体业务问题找数据、核对确认数据成本较高。

技术视角

- 指标定义，指标命名混乱，指标不唯一，指标维护口径不一致；
- 指标生产，重复建设；数据汇算成本较高；
- 指标消费，数据出口不统一，重复输出，输出口径不一致；

产品视角

缺乏系统产品化支持从生产到消费数据流没有系统产品层面打通；

2. 管理目标

技术目标

统一指标和维度管理，指标命名、计算口径、统计来源唯一， 维度定义规范、维度值一致

业务目标

统一数据出口、场景化覆盖

产品目标

指标体系管理工具产品化落地；指标体系内容产品化落地支持决策、分析、运营

例如决策北极星、智能运营分析产品等

3. 模型架构

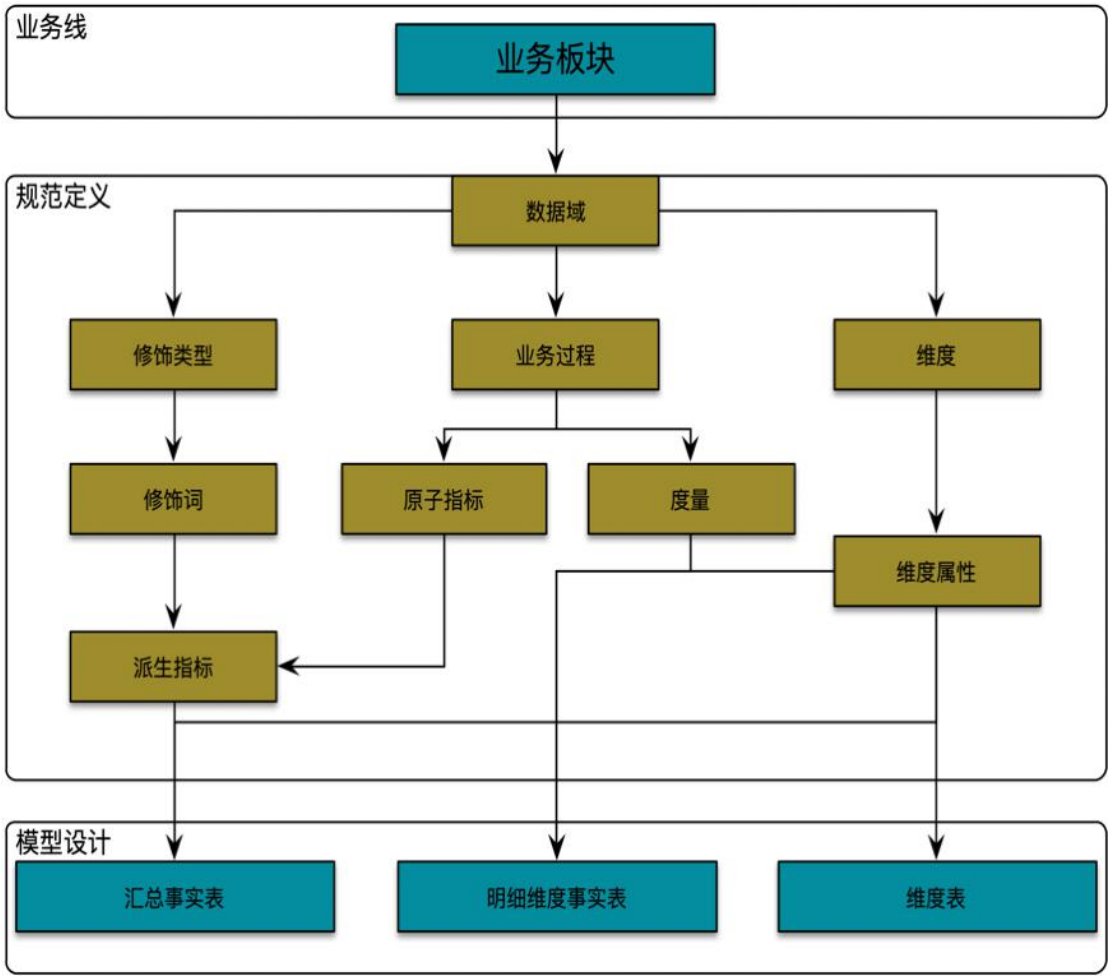

业务线：业务板块定义原则：业务逻辑层面进行抽象、物理组织架构层面进行细分，可根据实际业务情况进行层级分拆细化，层级分级建议进行最多进行三级分拆，一级细分可公司层面统一规范确定，二级及后续拆分可根据业务线实际业务进行拆分。例如滴滴出行领域业务逻辑层面两轮车和四轮车都属于出行领域可抽象出行业务板块(level 一级)，根据物理组织架构层面在进行细分普惠、网约车、出租车、顺风车（level 二级），后续根据实际业务需求可在细分,网约车可细分独乘、合乘，普惠可细分单车、企业级。

规范定义：

数据域

指面向业务分析，将业务过程或者维度进行抽象的集合。其中，业务过程可以概括为一个个不拆分的行为事件，在业务过程之下，可以定义指标；维度，是度量的环境，如乘客呼单事件，呼单类型是维度。为了保障整个体系的生命力，数据域是需要抽象提炼，并且长期维护更新的，变动需执行变更流程。

业务过程

指公司的业务活动事件，如，呼单、支付都是业务过程。其中，业务过程不可拆分。

时间周期

用来明确统计的时间范围或者时间点，如最近 30 天、自然周、截止当日等。

修饰类型

是对修饰词的一种抽象划分。修饰类型从属于某个业务域，如日志域的访问终端类型涵盖 APP 端、PC 端等修饰词。

修饰词指的是统计维度以外指标的业务场景限定抽象，修饰词属于一种修饰类型，如在日志域的访问终端类型下，有修饰词 APP、PC 端等。

度量/原子指标

原子指标和度量含义相同，基于某一业务事件行为下的度量，是业务定义中不可再拆分的指标，具有明确业务含义的名称，如支付金额。

维度

维度是度量的环境，用来反映业务的一类属性，这类属性的集合构成一个维度，也可以称为实体对象。维度属于一个数据域，如地理维度（其中包括国家、地区、省市等）、时间维度（其中包括年、季、月、周、日等级别内容）。

维度属性

维度属性隶属于一个维度，如地理维度里面的国家名称、国家 ID、省份名称等都属于维度属性。

指标分类主要分为原子指标、派生指标、衍生指标

原子指标

基于某一业务事件行为下的度量，是业务定义中不可再拆分的指标，具有明确业务含义的名称，如呼单量、交易金额

1.

派生指标

是 1 个原子指标+多个修饰词（可选）+时间周期，是原子指标业务统计范围的圈定。派生指标又分以下二种类型：

事务型指标：

是指对业务过程进行衡量的指标。例如，呼单量、订单支付金额，这类指标需要维护原子指标以及修饰词，在此基础上创建派生指标。

存量型指标：

是指对实体对象（如司机、乘客）某些状态的统计，例如注册司机总数、注册乘客总数，这类指标需要维护原子指标以及修饰词，在此基础上创建派生指标，对应的时间周期一般为“历史截止当前某个时间”。

衍生指标

是在事务性指标和存量型指标的基础上复合成的。主要有比率型、比例型、统计型均值

模型设计：

主要采用维度建模方法进行构建，基础业务明细事实表主要存储维度属性集合和度量/原子指标；分析业务汇总事实表按照指标类别(去重指标、非去重指标)分类存储，非去重指标汇总事实表存储统计维度集合、原子指标或派生指标，去重指标汇总事实表只存储分析实体统计标签集合。指标体系在数仓物理实现层面主要

是结合数仓模型分层架构进行指导建设，滴滴的指标数据主要存储在 DWM 层，作为指标的核心管理层。

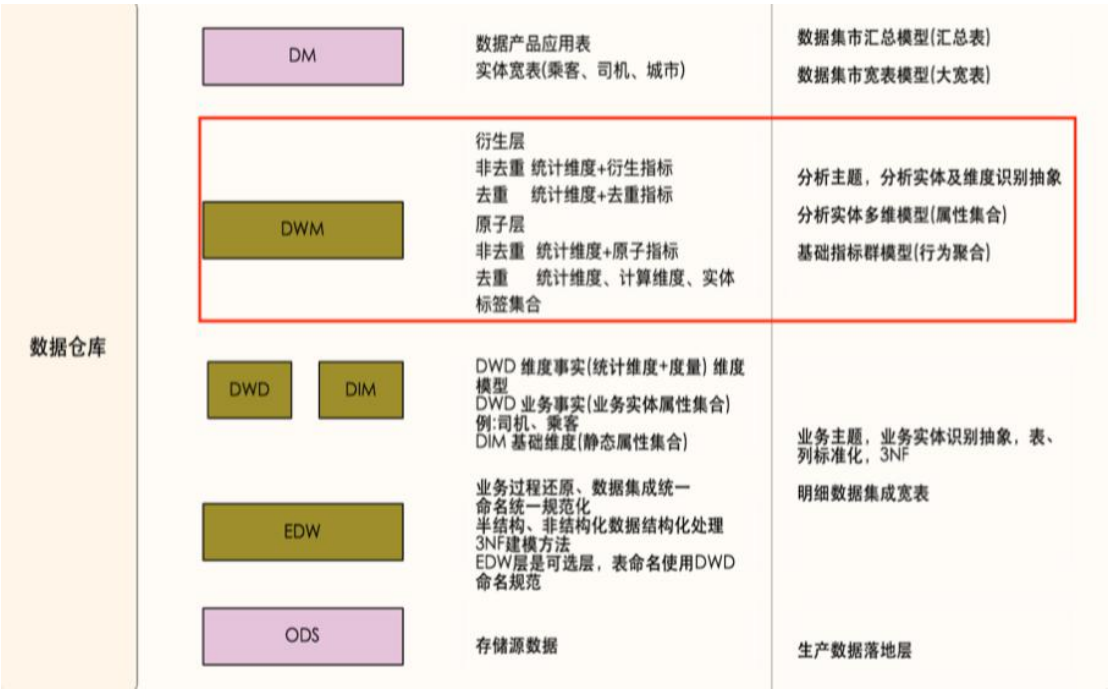

4. 指标体系元数据管理维度管理：包括基础信息和技术信息，由不同角色进行维护管理。

基础信息对应维度的业务信息，由业务管理人员、数据产品或 BI 分析师维护，主要包括维度名称、业务定义、业务分类。

技术信息对应维度的数据信息，由数据研发维护，主要包括是否有维表（是枚举维度还是有独立的物理维表）、是否是日期维、对应 code 英文名称和中文名称、对应 name 英文名称和中文名称。如果维度有维度物理表，则需要和对应的维度物理表绑定，设置 code 和 name 对应的字段。如果维度是枚举维，则需要填写

对应的 code 和 name。维度的统一管理，有利于以后数据表的标准化，也便于用户的查询使用。

指标管理：包括基础信息、技术信息和衍生信息，由不同角色进行维护管理。

基础信息对应指标的业务信息，由业务管理人员、数据产品或 BI 分析师维护，主要包括归属信息(业务板块、数据域、业务过程)，基本信息(指标名称、指标英文名称、指标定义、统计算法说明、指标类型(去重、非去重))，业务场景信息(分析维度，场景描述)；

技术信息对应指标的物理模型信息，由数据研发进行维护，主要包括对应物理表及字段信息；

衍生信息对应关联派生或衍生指标信息、关联数据应用和业务场景信息，便于用户查询指标被哪些其它指标和数据应用使用，提供指标血缘分析追查数据来源的能力。

原子指标定义归属信息 + 基本信息 + 业务场景信息派生指标定义时间周期 + 修饰词集合 + 原子指标修饰类型主要包含类型说明、统计算法说明、数据源(可选)**5. 指标体系建设流程建模流程：**建模流程主要是从业务视角指导工程师对需求场景涉及的指标进行主题抽象，归类，统一业务术语，减少沟通成本，同时避免后续的指标重复建设。

分析数据体系是模型架构中汇总事实表的物理集合，业务逻辑层面根据业务分析对象或场景进行指标体系抽象沉淀。滴滴出行主要是根据分析对象进行主题抽象的，例如司机主题、安全主题、体验主题、城市主题等。指标分类主要是根据实际业务过程进行抽象分类，例如司机交易类指标、司机注册类指标、司机增长类指标等。基础数据体系是模型架构中明细事实表和基础维度表的物理集合，业务逻辑层面根据实际业务场景进行抽象例如司机合规、乘客注册等，还原业务核心业务过程。

开发流程：

开发流程是从技术视角指导工程师进行指标体系生产、运维及质量管控，也是数据产品或数据分析师和数仓研发沟通协调的桥梁。

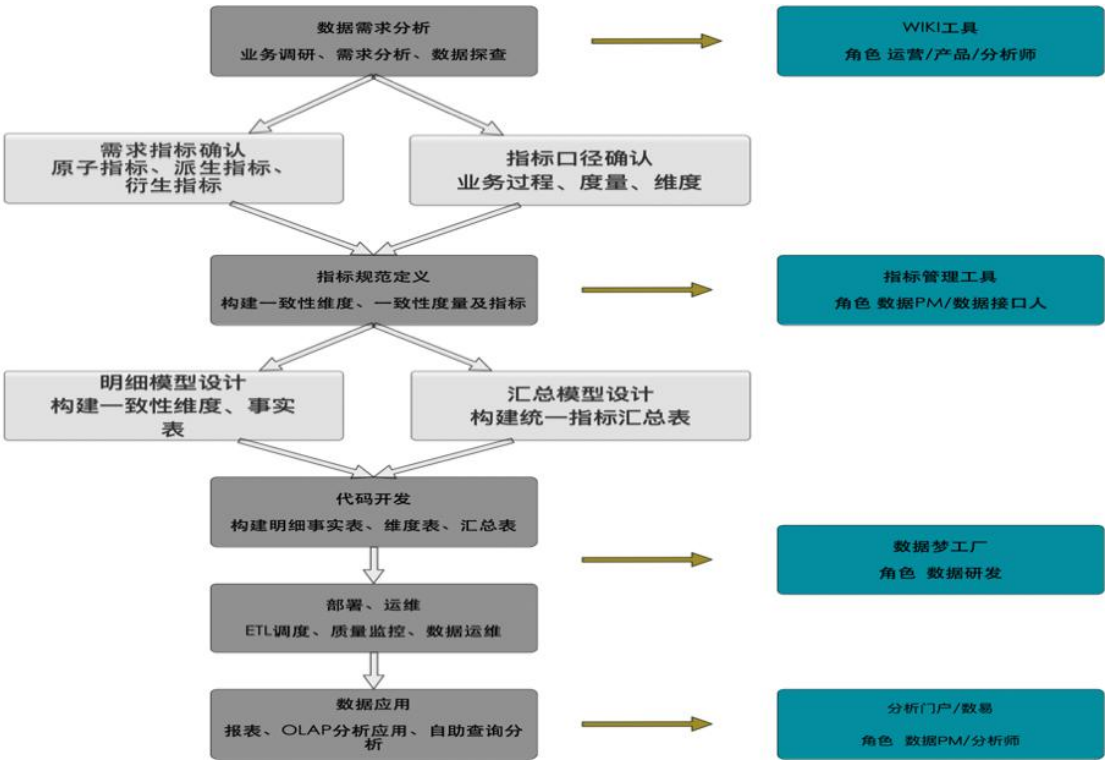

6. 指标体系图谱建设指标体系图谱概述：

指标体系图谱也可称为数据分析图谱主要是依据实际业务场景抽象业务分析实体，整合梳理实体涉及的业务分类、分析指标和维度的集合。建设方法：主要是通过业务思维、用户视角去构建，把业务和数据紧密关联起来，把指标结构化分类组织

建设目的：

对于用户：

便于用户能够快速定位所需指标和维度，同时通过业务场景化沉淀指标体系，能够快速触达用户数据诉求

对于研发：

利于后续指标生产模型设计、数据内容边界化、数据体系建设迭代量化和数据资产的落地

指标体系图谱模型：

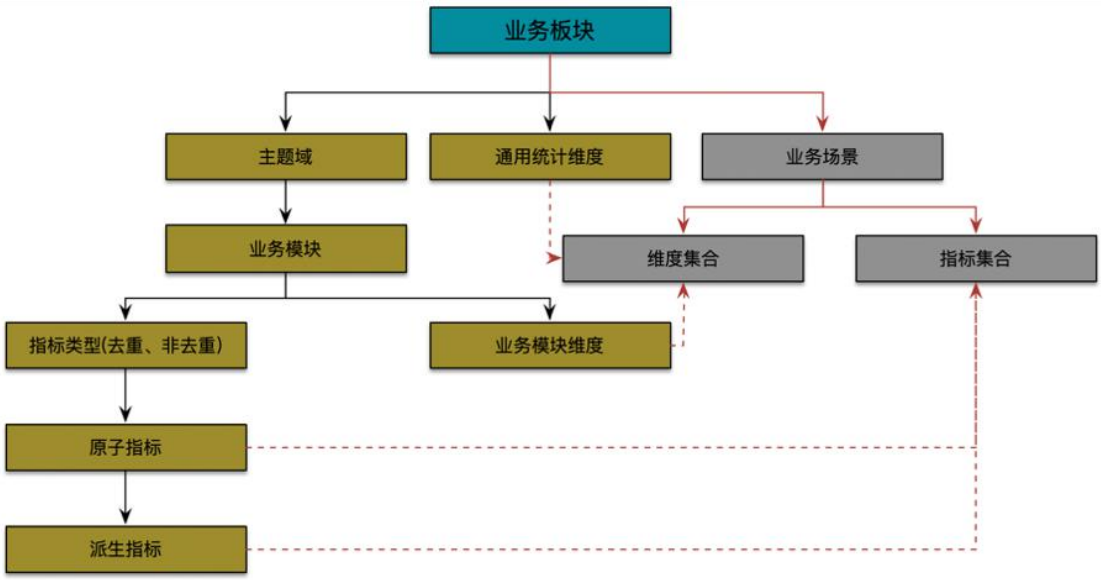

指标体系图谱实例：

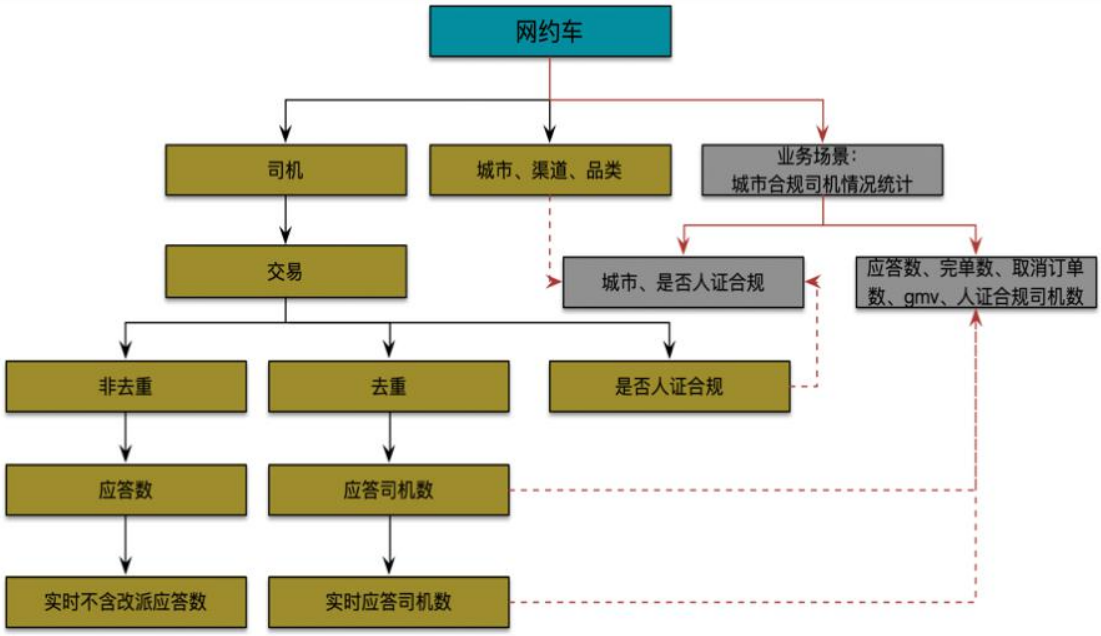

05

指标体系产品化

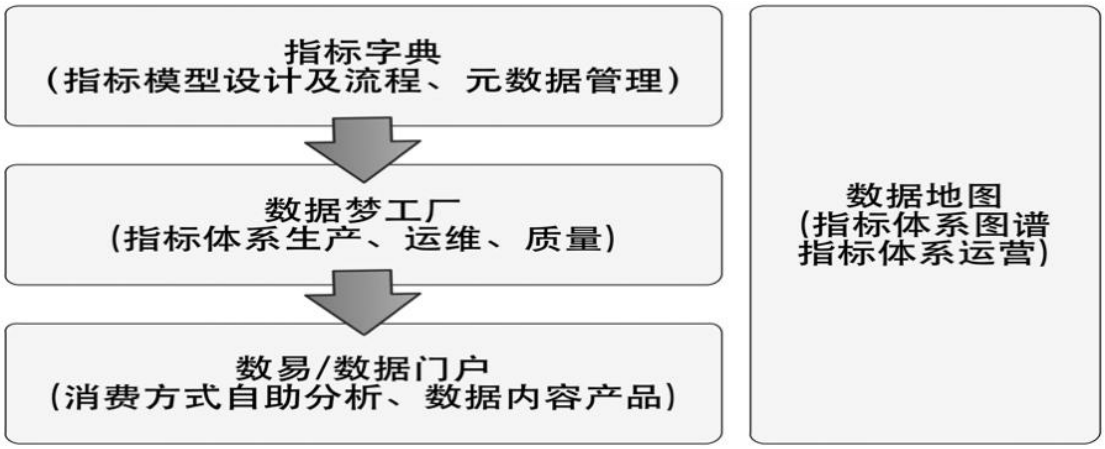

指标体系涉及的产品集主要是依据其生命周期进行相应建设，通过产品工具打通数据流，实现指标体系统一化、自动化、规范化、流程化管理。因为指标体系建设本质目标是服务业务，实现数据驱动业务价值，所以建设的核心原则是“轻标准、重场景，从管控式到服务式”。通过工具、产品、技术和组织的融合提高用

户使用数据效率，加速业务创新迭代。其中和指标体系方法论强相关产品就是指标字典工具的落地，其产品的定位及价值：

支撑指标管理规范从方法到落地的工具，自动生成规范指标，解决指标名称混乱、指标不唯一的问题，消除数据的二义性

统一对外提供标准的指标口径和元数据信息

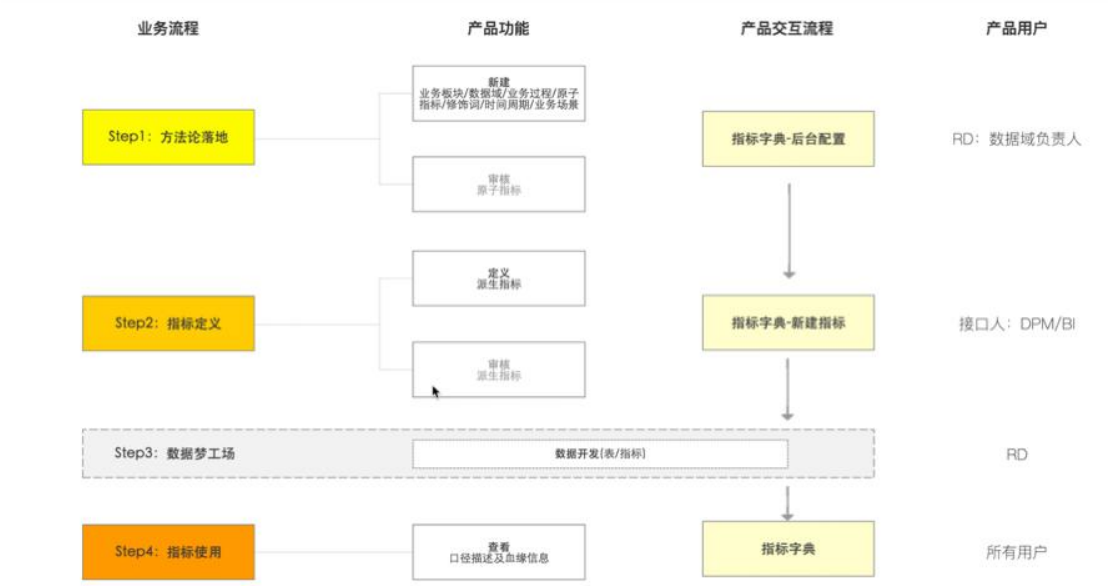

工具设计流程 (方法论->定义->生产->消费)

指标定义

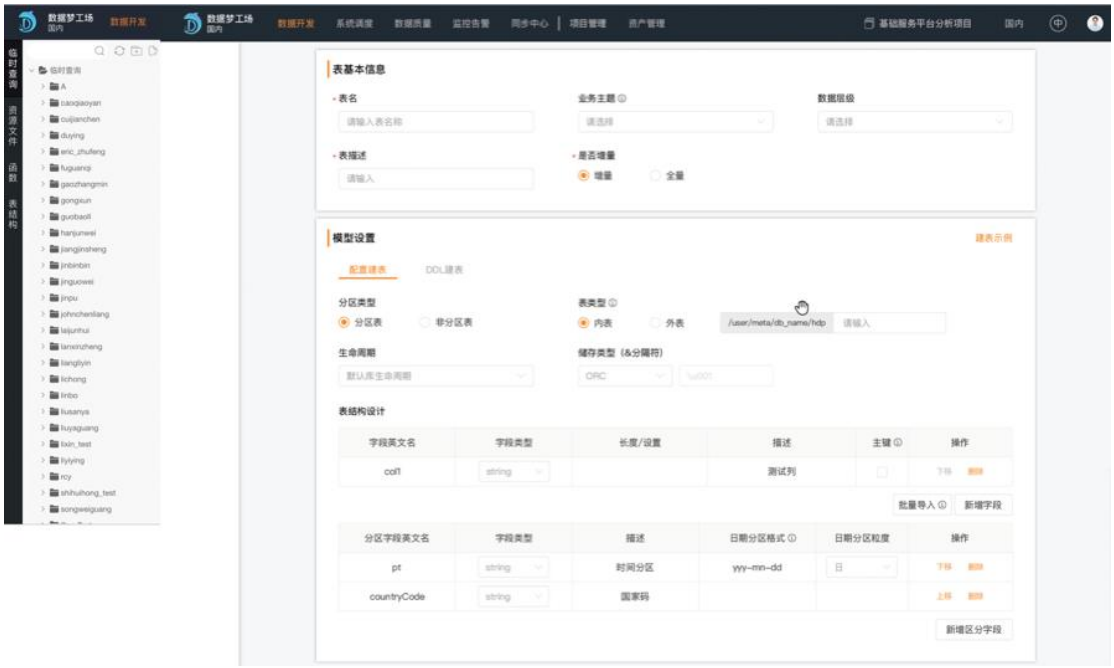

指标生产

06

结束语

文章整体介绍了滴滴指标体系建设方法论和工具产品的建设情况，目前指标字典和开发工具已实现流程打通，与数据消费产品的打通后续会通过 DataAPI 方式提供数据服务，规划建设中。指标体系建设方法论和工具已经在滴滴集团内进行推广使用，滴滴网约车、普惠、车服等部门已经开始接入使用，截止目前共有 5000+ 指标进入指标体系，覆盖公司核心业务板块、88 个数据域、385 个业务过程，52 个业务场景，方法论和工具也会持续迭代实践。

团队介绍：

滴滴云平台事业群滴滴基础平台部数据治理部-数仓团队负责公司网约车、出租车、顺风车、国际化出行业务的数据仓库的架构、规划、设计及数据内容产品的建设工作。支撑公司运营、产品、分析、战略、安全、体验等核心业务部门的数据决策分析，提供完整、可靠、高质量的数据服务。

因果推断在阿里文娱用户增长中的应用

分享嘉宾：天师 阿里文娱 高级算法专家
编辑整理：Hoh
内容来源：阿里文娱技术
出品平台：DataFunTalk

导读：如何实现产品的用户增长？显然，这是各家移动互联网应用的头等大事，也是悬在各家业务负责人头上的"天问"。在移动互联网进入下半场的大趋势下，过去粗放式的买量、厂商合作等模式越来越会受到掣肘，将更加依赖精细化的用户增长策略和产品用户体验的细致打磨；经典的 AARRR 模式会逐步转向 RARRA 模式，提升产品留存、拉活、分享传播等方式是构建增长的主要战场。而在此之中，对于一个内容型产品，个性化算法对于用户留存、拉活将起到决定性的作用。

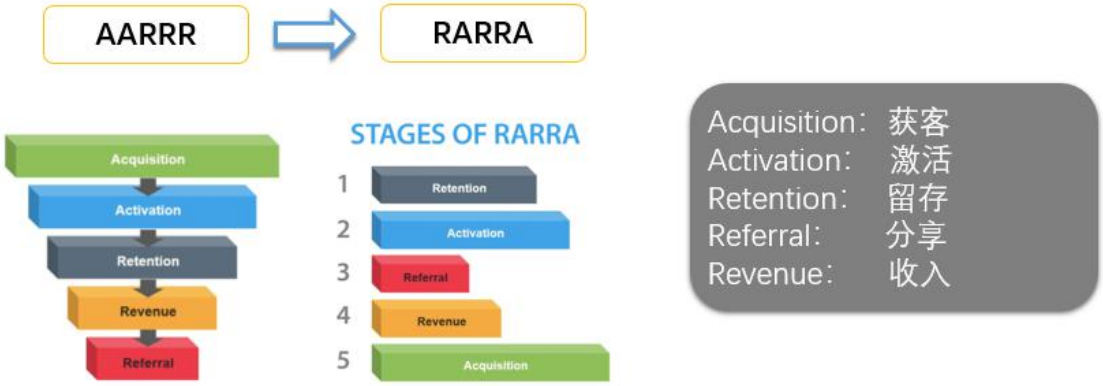

考察与优酷类似的应用，在内容领域，增长的成功案例有：

"头条快手"模式：内容分发类产品，代表是"今日头条"、"抖音"、"快手"等。这类产品构建了完善的内容生产和消费生态，旨在通过推荐系统同时刺激生产和消费，实现两端的同时增长。

"趣头条"模式：该产品同属内容分发类产品，但较早地参考了网络游戏模式，从各个环节设计用户里程碑和激励，不断引导新用户一步步完成点击、下刷、完整阅读、分享、关注等目标里程碑，并给予虚拟货币和真实货币的激励，在短时间内获取了大量下沉用户。

"爱奇艺"、"腾讯视频"模式：这类产品利用大量资金和精准的内容采买眼光，利用头部内容的流量聚集效应，在前几年迅速圈定大批用户，并形成长视频 app 特有用户心智。由于内容头部化，个性化算法在其中发挥的空间和作用较小，产品、模式趋于同质化，内容采买的巨大资金投入使得长视频网站的盈利遥遥无期。

会员增长是长视频产品体系下用户增长的特有子问题。优酷作为国内顶尖的视频内容提供商，上述三种增长模式都是需要进行借鉴的。用户增长问题需要从内容供给、内容分发、权益设计、产品设计等多环节进行联合优化，从算法的角度，其目标可以拆解为两大部分：

用户状态建模：深度建模用户状态和行为，从大数据集中找到使用户从低阶状态到高阶状态转化的干预因子。

个性化分发的升级：将用户行为建模后，在多个场景将这些干预动作落地为个性化推荐算法和营销算法，满足用户的视频内容消费需求。

阿里大文娱是阿里集团双 H 战略（Happiness & Health）中最为重要的践行者，在不断为广大网民提供优质内容与良好体验的同时，我们也面临着用户规模化增长以及营收有计划提升的压力。我们已经逐步形成以消息推送（push）、站外引导（dsp）以及新用户承接推荐等场景组成的用 户增长业务体系，也已经逐步形成了以权益发放（营销）以及商业化（广告）等抓手组成的收入增长业务体系。基于因果推断的推荐算法、基于双 pid 的动态报价算法以及基于 uplift model 的营销增益模型正是应用在这两大业务体系中的，我们已经在多个业务场景中取得了较为显著的效果提升，我们相信其中的一些技术必将对整个互联网业内在增长算法体系带来一些崭新的视角、思考和实践经验。本文将主要为大家介绍基于因果推断的推荐算法。

01

用户增长和智能营销算法的目标

刚刚已经介绍了优酷用户增长的业务打法和构思，其中已经提到，个性化的分发算法是实现用户增长的主战场。其中有两大目标：

目标 1：用户状态建模。深度建模用户状态和行为，从大数据集中找到使用户从低阶状态到高阶状态转化的干预因子。

目标 2：个性化算法的升级。将用户行为建模后，在多个场景将这些干预动作落地为个性化推荐算法和营销算法，满足和刺激用户的视频内容消费需求。

针对目标 1，传统数据分析主要是建模变量之间的相关性而非因果关系，不能从真正的因果关系来设计干预手段。

针对目标 2，传统的推荐算法主要进行短期的点击、时长等多目标预估，未能从用户状态的跃迁去设计个性化的目标机制；其次目前大量应用的深度学习类算法同样属于统计学习派别的延展，其模型可解释性差，不能从中推断用户兴趣与内容的因果关系，而该类技术方向的演化会导致用户画像的算法较为单薄，不能满足优酷会员营销核心业务的需求。

基于因果推断的推荐算法我们已经成功应用在消息推送（push）以及 dsp 外投买量算法等业务中，而在营销场景中应用的 uplift 模型本质上也是因果推断思想的一个典型应用。因此，我们在整个用户增长以及智能营销的业务场景中逐步推广地应用了因果推断的思想，在某些实验中取得了非常好的业务结果，比如我们在 push 和 dsp 业务中的沉默用户召回这个场景下就取得了点击量和点击率的显著提升。

02

用户状态表示

1. 用户画像与状态表示法

传统的用户画像表示技术要么服务于运营可解释性，要么服务于推荐或广告系统的模型预估，通常建模成向量（离散高维或低维稠密）。而我们在深入研究在线视频和付费会员业务后，发现状态转移图是更有力地建模该业务下用户画像的数据结构，原因如下：

用户从非会员到购买会员并逐步进入高阶会员的阶段，本质属于一种强规则定义的状态。

在线视频，尤其是长视频领域具备长时间、连续型消费（追剧、追网红）等特点，对比传统的图文推荐系统、电商推荐系统和广告系统，用户的消费行为可以在连续的时间上进行切分，状态表示法是对向量表示法的有力补充。

新用户的承接和推荐策略是用户增长中"促留存"，建立心智的重要阶段。借鉴网络游戏和趣头条的思路，将难度较大的"促留存"问题拆分为"目标达成"问题，产品通过策略不断使得用户完成高阶里程碑，是业内目前已证明成功的用户增长方法。

序中已经提到，会员模式是长视频业务的核心付费模式，在用户的整个生命周期内，其大体的会员状态转移图如下：

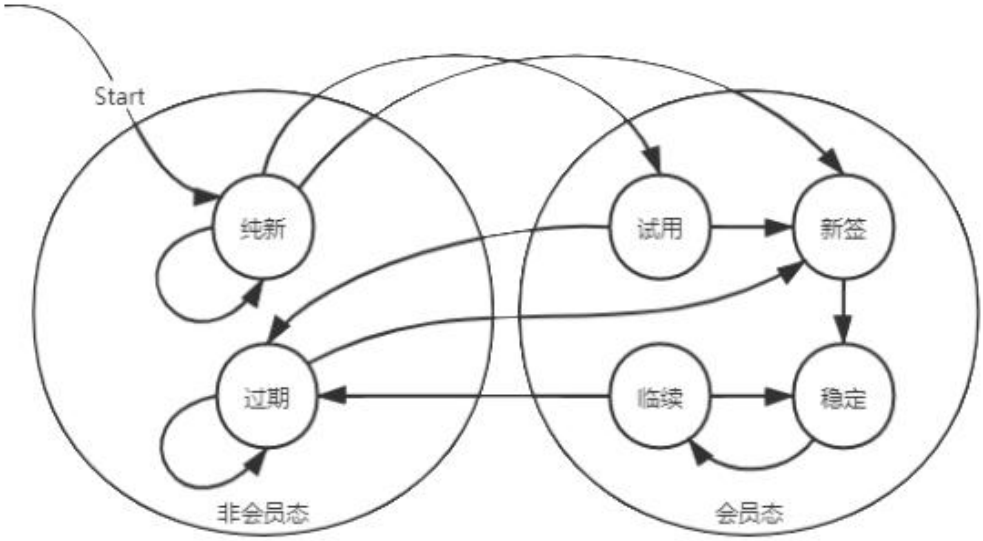

Figure 1：会员转化状态

新用户阶段是产品对用户建立信任感的最重要时期，新用户在优酷 app 中的里程碑可以大致描述如下：

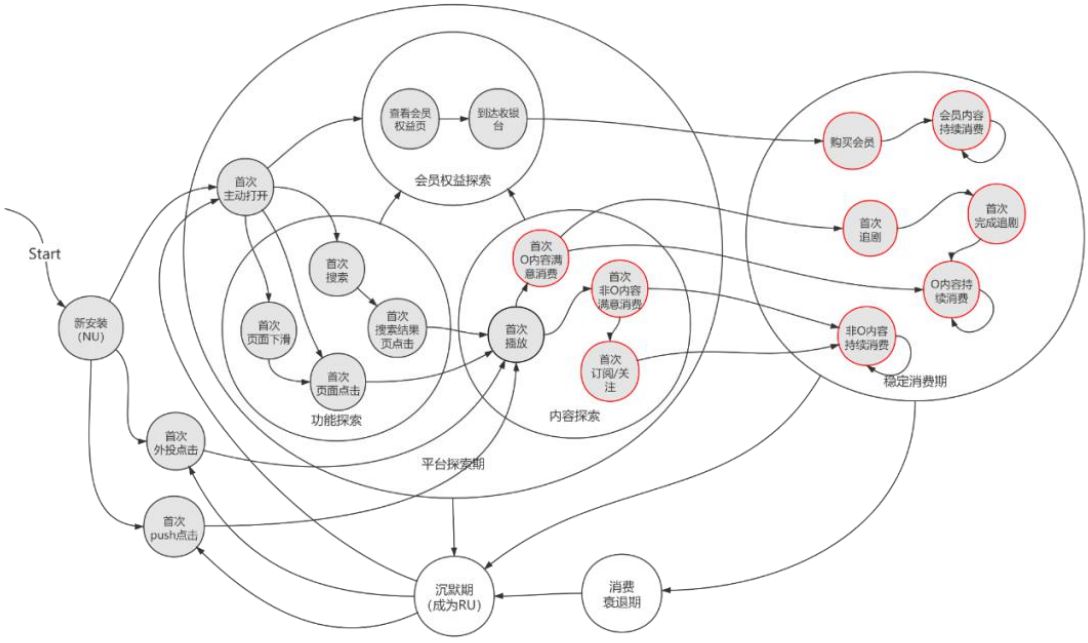

Figure 2：新用户状态里程碑

可以看到，用户在不同的状态下，我们期望他们能完成状态的"跃迁"，也就是从低阶状态不断往高阶状态："持续消费"，"订阅/关注"，"追剧"，"会员稳定期"等转化。

可以预见的是，这种用户画像的表示方法，将会对业内长久以来已经趋于成熟的个性化推荐算法步向新的发展阶段：即为用户增长这个核心业务问题更好的服务。首先是多目标的排序机制，对于在不同状态下的用户，个性化算法的机制目标会不同（跃迁至目标态）；其次启发我们从更前沿的算法高度来研究状态跃迁的干预手段问题，进而解决推荐系统中长期难解的"可解释性"、"幸存者偏差"、"兴趣探索"等问题。

针对干预手段的研究，在 2019 年用户增长 & 智能营销团队组建之后，对因果推断（Causal Inference）算法率先进行了研究和落地，目前在个性化推送、外投 DSP 应用了基于 matching 的无偏 user-cf 算法，智能红包发放场景应用了 uplift model，取得了显著的核心业务指标提升，并得到了业务方和兄弟团队的一致认可。现将无偏 user-cf 算法介绍如下，uplift model 可参考文末推荐文章。

03

基于因果推断的无偏 user-cf 设计

1. 因果推断（Causal Inference）简介

因果推断（Causal Inference）作为新兴的人工智能技术方向，旨在突破传统数据分析和机器学习方法的瓶颈，建模大规模数据集中的因果关系，为干预手段的设计提供指导，为构建下一代面向用户增长的全域分发系统提供理论基石。

因果推断的核心研究课题：

从众多观测到/未观测到的变量中找出致因（causes）

预估某个行为/因素的影响力/效益（causal effect）

对于个体，来说，核心是寻找反事实（counterfactual）镜像。在个性化推荐中，一个难题就是消除"幸存者"偏差，即如何将低活用户通过良好的路径推荐，逐步变成产品的高活用户。我们定义问题如下：

2. 目标

消去推荐系统的偏差。用户增长需要消去高活用户带来的行为偏置，提升低活用户推荐效果。

3. 假设

用户变成低活、沉默的原因主要是因为对之前推荐不满意（负例）。

4. 方法

① 构建 Counterfactual 镜像人：

利用无偏信息构造相似度量，构造低活 user 到高活 user 的 matching：

基础人口属性、安装的长尾 app 信息等

主动搜索行为（非被动推荐），尤其是长尾 query

② 去除低活用户的 leave causes，推荐相似高活用户的 stay causes。对于推荐系统来说，这些 causes 包括：

item 本身：但缺少泛化容易推出老内容

item 的泛化特征：标签、时效性、质量

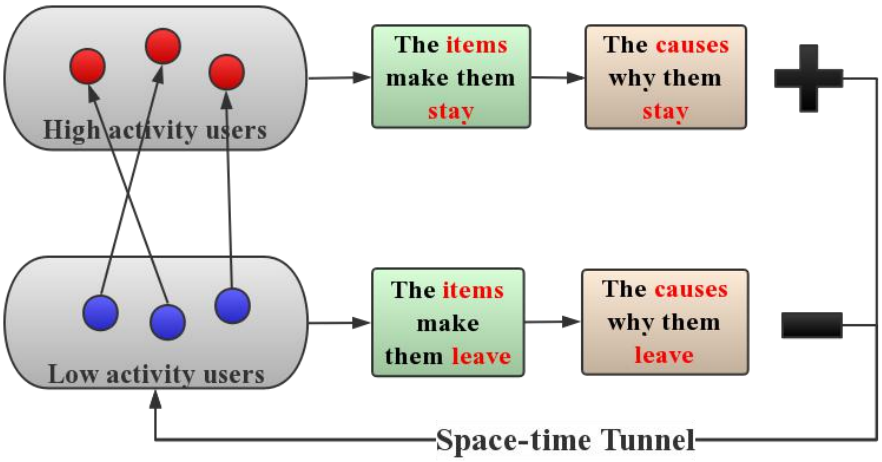

Figure 3：无偏 usercf 设计

注意，由于使用了 matching 方法，这里的算法非常类似传统的 user-cf 类算法，但是和传统 user-cf 核心的区别在于：

matching 不使被动推荐数据，个性化推送、站内推荐、运营推荐的内容都不使用。

只匹配低活到高活，活跃度相同的用户之间不进行匹配。

5. 业务收益

该算法落地后，在两个 baseline 相对较高的算法场景中取得了较大的收益：其中个性化推送（push），在沉默用户中获得了 50%+ ctr 和 50%+ click 的双增长，在外投 dsp 业务中，拉活量对比峰值接近翻倍。

04

总结与展望

目前算法的应用，只是对应了两个用户状态（低活->高活）之间的推断，如 Figure 1 和 Figure 2 所描述的，用户增长的目标是将细分的低阶状态往高阶目标态上进行跃迁，那么该类算法很显然将会在数据分析、产品设计、分发优化等各个环节发挥巨大作用。整个 2019 年团队的实践虽然取得了很大的业务效果，但只是对该算法方向相对较浅显的应用，且对于优酷整体的增长问题来说，应用的场景还不够多，未来期望在其基础理论和实践都投入更多的资源。

可以预见的是：对于整个业内用户增长的方法论，该方法在未来必将成为核心的理论基石。对于个性化推荐这一经典领域，该方法为解决经典难题"幸存者偏差"，"可解释性"，"用户表示"，"兴趣探索"等提供了漂亮的解法。

推荐系统衡量：ABtest 框架

文章作者：姚凯飞
编辑整理：Hoh Xil
内容来源：作者授权发布
出品社区：DataFun

无法衡量就无法优化，对于互联网产品而言，不仅是推荐系统，整个 app 系统的更新迭代必然需要建立一套度量衡，来把控整个流程优化的方向。而 abtest 系统就是一个很好的进行变量控制和优化方向选取的工具，循环：衡量-发现-迭代-验证。所谓精细化迭代是一种建立在数据基础上的思维方式——用较少的成本获得较好的效果。无数据，不优化， 线上分流实验是进行推荐算法优化的必由之路。并且 abtest 不仅是推荐迭代的利器，他还可服务于所有需要逐步完善的产品迭代。有人说为什么需要 abtest ，为什么不能够前后进行实验比较；因为同时期测试的 abtest 非常有必要的原因是不同时间的测试无法说明 b 比 a 好，通常时间也是一个变量，比如电商的双十一等。

在网络分析中，A / B 测试（桶测试或分流测试）是一个随机实验，通常有两个变体，A 和 B 。利用控制变量法保持有单一变量的前提下，将 A 、B 数据进行对比，得出实验结论。AB 是一种科学的利用数据证明方案可行性的手段，一般在网站中广泛使用。 通过 abtest 系统对迭代方案进行实验，并结合数据进行分析，反向再验证和驱动方案，是一个发现问题、提出假设、印证猜想、不断优化的过程。合适的推荐方法是要经过不断的实验去验证，验证的过程也是在校验数据，从而优化推荐系统策略，最终提升用户新增和留存。

1. 指标定义

在 abtest 前，我们需要梳理出我们关心的若干指标，并选择某个指标作为北极星指标，如点击率、转化率、浏览时长、gmv 、客单价等，未来讨论的推荐系统的相关优化也将围绕若干个目标进行。也有人将核心的指标成为北极星指标，北极星指标经常在增长黑客中被使用。来自微软 Bing 的例子：Bing 希望优化长期查询份额（ 市场中的查询百分比 ）和长期收入。短期内，通过展示更多广告很容易赚钱，但它可能会损害用户体验。所以其实短期和长期指标的定义也很重要，如何通过 abtest 平衡和评估长短期收益。

2. 了解几个事实

不是每个想法都是好的、大部分想法都是不好的；Many times, we have to tell people that their new beautiful baby is actually...ugly 。

根据微软官方发布的上万次 abtest 实验数据来看：

1) 1/3 of ideas were positive ideas and statistically significant

2) 1/3 of ideas were flat：no statistically significant difference

3) 1/3 of ideas were negative and statistically significant

3. 实验管理平台

3.1 实验报告

实验报告需要对脏数据进行过滤，并做一定的效果平滑，效果波动告警。异常值会产生明显的偏差：足以导致错误的统计结果。例：亚马逊上有围绕 100,000 名用户进行的 abtest 实验，其中 2% 的用户的客单价为 30 美元， 2% 的用户客单价是 1200 美元，有时（ 很少 ）“用户”购买足以显着扭曲结果。

3.2 分流 & 分层策略

如果流量不进行分层、分流可能会导致流量饥饿，即实验一在进行中占用了全站的 80% 的流量，实验二就只能使用 20% 的流量。因此良好的分层、分流规则可以充分使用网站的流量。常见的分流策略有：Random 一 随机分流，用于可变结果集，Partition By User 一 按用户切分 ，同一用户永远看到同样结果，Partition By Category 一 按分类切分，针对不同分类测试算法针对性。在分流的上层则会考虑分层，并且在互联网公司中应用广泛。

通常网站会利用分层和分流的机制保证本站的流量高可用，原因有以下几点：

1）网站的流量是有限的

2）实验的对象是多层的或同一层内互不干扰的。多层：例如网站不仅仅有 UI 层（ 界面 ），通常还有算法层等；同一层内互不干扰：例如网站的推荐位有多个（ 首页推荐位、商详页推荐位 ）。

3）AB tests 的需求是大量的

注意点：幂等-均匀化-并行-互斥；分层实验，促进流量的最大化利用。

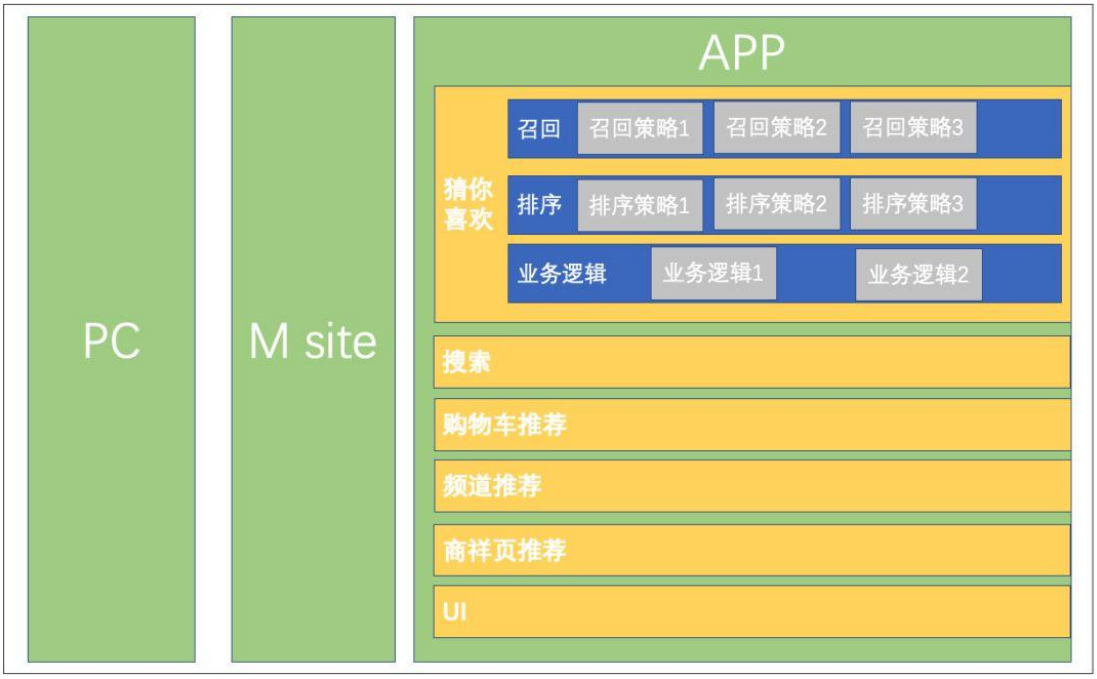

规则 1. 正交、互斥

在介绍分层规则之前，先介绍一下正交和互斥的概念。

1）正交，如何理解正交？

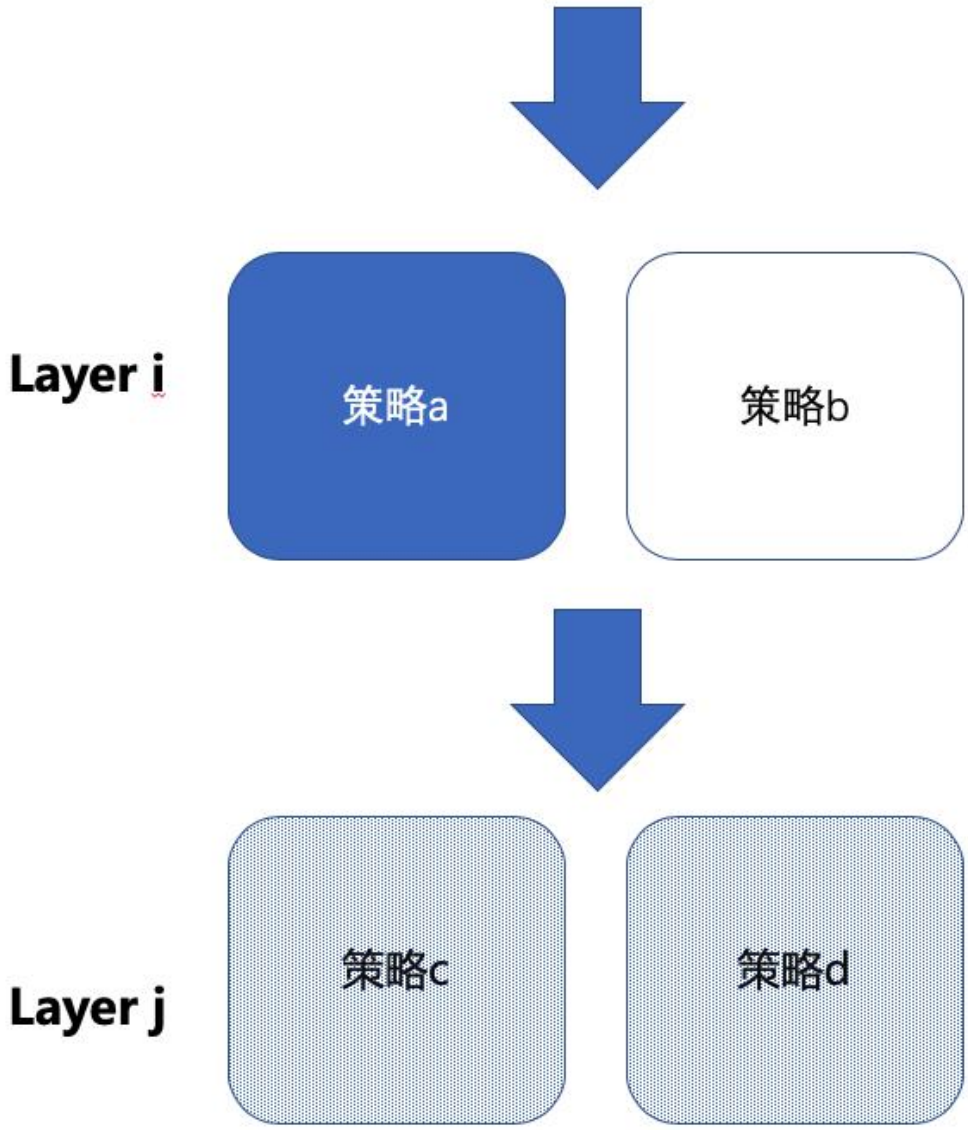

例如：我们有 100 个兵乓球，随机拿出来 50 个染成蓝色，50 个染成白色，则我们有蓝色、白色兵乓球各 50 个，现在我们把这 100 个兵乓球重新放在袋子中摇匀，随机拿出 50 个兵乓球，那么这 50 个兵乓球颜色蓝色和白色各 25 。当然举这个例子并不是非常的恰当，因为样本太少了，此处举例只为说明正交的意义。

正交实验：每个独立实验为一层，层与层之间流量是正交的，一份流量穿越每层实验时，都会再次随机打散，且随机效果离散。

2）互斥，如何理解互斥？

例如：我们有 100 个兵乓球，每 25 个为一组，分别染成蓝、白、橘、绿。若 X 实验拿的是蓝色、白色则 Y 实验只能拿橘色和绿色，我们说 X 实验的和 Y 实验是互斥的。

互斥实验：实验在同一层拆分流量，且不论如何拆分，不同组的流量是不重叠的。

其中，分流及分层实验设计基于 Goolge 论文：

Overlapping Experiment Infrastructure : More, Better, Faster Experimentation

https://dl.acm.org/citation.cfm?id=1835810

流量从上往下流过分流模型：

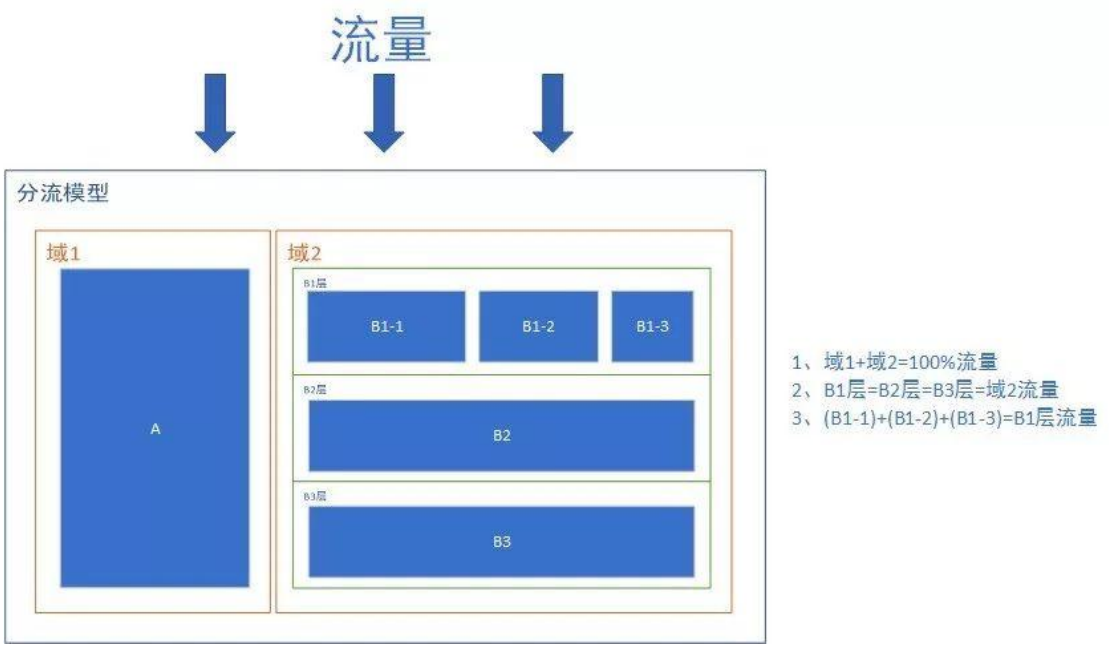

1）规则详述：

域 1 和域 2 拆分流量，此时域 1 和域 2 是互斥的。

流量流过域 2 中的 B1 层、B2 层、B3 层时，B1 层、B2 层、B3 层的流量都是与域 2 的流量相等。此时 B1 层、B2 层、B3 层的流量是正交的。

扩展：流量流过域 2 中的 B1 层时，又把 B1 层分为了 B1–1 ，B1–2 ，B1–3 ，此时 B1–1 ，B1–2 ，B1–3 之间又是互斥的。

根据以上规则我们可以不断的在此模型中增加域、层，并且可以互相嵌套。这要与实际的业务相匹配，拆分过多的结构可能会把简单的业务复杂化，拆分过少的结构又可能不满足实际业务。

2）使用场景

例 1：B1 层、B2 层、B3 层可能分别为：UI 层、搜索结果层、广告结果层，这几层基本上是没有任何的业务关联度的，即使共用相同的流量（ 流量正交 ）也不会对实际的业务造成结果。但是如果不同层之间所进行的试验互相关联，如 B1 层是修改的一个页面的按钮文字颜色，B2 层是修改的按钮的颜色，当按钮文字颜色和按钮颜色一样时，该按钮已经是不可用的了。因此建议同一类型的实验在同一层内进行，并且需要考虑到不同实验互相的依赖。

例 2：域 1 的此种分流的意义在于，当我们做一个实验，并且希望其他任何实验都不能对我实验进行干扰，保证最后实验的可信度。

3.3 AA/AB 测试要点

1）候选策略+预测模型作为最小的考察单元

2）通过规则配置 ABtest：配置流量切分，候选策略及预测模型

3）重视抽样误差

4）关注时间周期效应

3.4 流程

1）随机分组（ ABCDE... ）： A – 控制组，与线上一致;B – 测试组;C ...

2）收集相关数据（ 对决策有用的数据 ）

3）数据分析，必须通过假设检验来确定差异不是来自于偶然，通过因果关系证明变化由测试桶的变化带来。

4. abtest 的那些技术

4.1 为什么灵敏度（ p-value ）很重要

p-value 即概率，反映某一事件发生的可能性大小，主要在 abest 中说明实验的提升的显著性，并且往往与假设检验相挂钩。统计学根据显著性检验方法所得到的 P 值，一般以 P < 0.05 为有统计学差异， P<0.01 为有显著统计学差异，P<0.001 为有极其显著的统计学差异。其含义是样本间的差异由抽样误差所致的概率小于 0.05 、0.01 、0.001 。实际上，P 值不能赋予数据任何重要性，只能说明某事件发生的几率。在实践中建议，运行 A / A 测试，并同时也关注相关指标及 p-value 。 A / A 测试中度量的 P-value 分布应该是统一的，进行 1,000 次 A / A 测试，并检查分布是否均匀，当我们得到异常信息时，则需要纠正一些事情。

4.2 假设检验

假设检验是推论统计中用于检验统计假设的一种方法。而“统计假设”是可通过观察一组随机变量的模型进行检验的科学假说。一旦能估计未知参数，就会希望根据结果对未知的真正参数值做出适当的推论。 统计上对参数的假设，就是对一个或多个参数的论述。而其中欲检验其正确性的为零假设（null hypothesis），零假设通常由研究者决定，反映研究者对未知参数的看法。相对于零假设的其他有关参数之论述是备择假设（alternative hypothesis），它通常反映了执行检定的研究者对参数可能数值的另一种（对立的）看法（换句话说，备择假设通常才是研究者最想知道的）。

常见假设检验的种类包括：t 检验，Z 检验，卡方检验，F 检验等等。

4.3 t-test、z-test、p-value、ci（confidence interval）

1）T 检验，亦称 student t 检验（Student's t test），主要用于样本含量较小（例如 n<30），总体标准差 σ 未知的正态分布数据。T 检验是用 t 分布理论来推论差异发生的概率，从而比较两个平均数的差异是否显著。

适用条件： 已知一个总体均数；可得到一个样本均数及该样本标准误； 样本来自正态或近似正态总体。

T 的公式：

T=(T−μ)/S/n 的平方根

若 T 值大于临界值，则拒绝原假设，否则不拒绝。

2）Z 检验是一般用于大样本（ 即样本容量大于 30 ）平均值差异性检验的方法。它是用标准正态分布的理论来推断差异发生的概率，从而比较两个平均数平均数的差异是否显著。 当已知标准差时，验证一组数的均值是否与某一期望值相等时，用 Z 检验。

Z 检验的步骤 适用条件：已知一个总体均数；可得到一个样本均数及该样本标准误； 样本来自正态或近似正态总体。

第一步：建立虚无假设，即先假定两个平均数之间没有显著差异，

第二步：计算统计量 Z 值，对于不同类型的问题选用不同的统计量计算方法.

如果检验一个样本平均数（ x ）与一个已知的总体平均数（ μ0 ）的差异是否显著。其 Z 值计算公式为：

Z=（X−μ)/S/n 的平方根

若 Z 值大于临界值，则认为为二者有差异，否则认为没差异。

注：事实上由于总体参数标准差未知，因此一般使用 T 检验。

3）p-value ，就是当原假设为真时，所得到的样本观察结果或更极端结果出现的概率。如果 p-value 很小，说明原假设情况的发生的概率很小，而如果出现了，根据小概率原理，我们就有理由拒绝原假设，p-value 越小，我们拒绝原假设的理由越充分。p-value 代表的是不接受原假设的最小的显著性水平，可以与选定的显著性水平直接比较。例如取 5% 的显著性水平，如果 p-value 大于 5% ，就接受原假设，否则不接受原假设。这样不用计算 t 值，不用查表。p-value 能直接跟显著性水平比较；而 t 值想要跟显著性水平比较，就得换算成 p-value ，或者将显著性水平换算成 t 值。在相同自由度下，查 t 表所得 t 统计量值越大，其尾端概率 p 越小，两者是此消彼长的关系，但不是直线型负相关。

联邦学习与安全多方计算

分享嘉宾：洪澄博士 阿里巴巴 高级安全专家

编辑整理：徐华卿

出品平台：DataFunTalk、AI 启蒙者

导读：联邦学习和安全多方计算是当前跨机构数据协同的两类主流技术，本文将从基本思想、安全性、性能等多个方面介绍二者的区别，并介绍阿里在安全多方计算方面的最新成果。

01

联邦学习的发展历史

1. 联邦学习

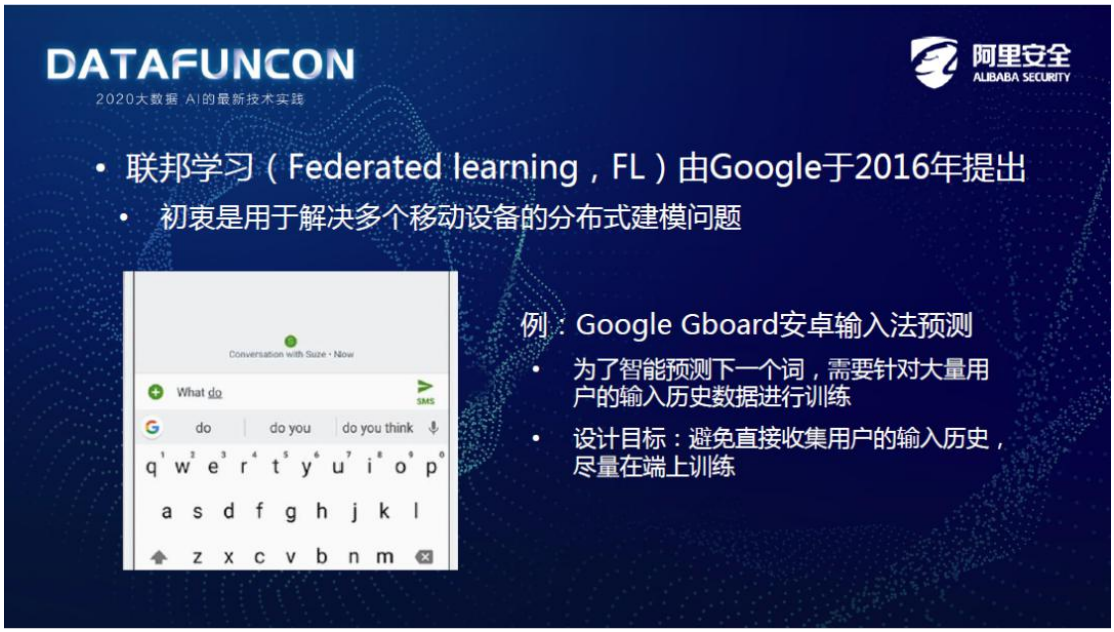

联邦学习在 2016 年由谷歌提出，因为 Google 有安卓系统，需要解决多个安卓设备的分布式建模问题。其中，主要是针对输入法的建模，比如客户在安卓输入法中输入单词“what”，或许他可能想继续输入“do you think”，Google 输入法如果能自动联想出来，用户体验就会变得比较好，但是自动联想功能需要大量的用户数据才能学习出来，怎么获得这些用户数据呢？

一个比较粗暴的做法是用户输入了什么字就把这个字全部收集到云端上，但这种做法无疑是对用户隐私的一种破坏。由于谷歌崇尚不作恶，怎样在不收集用户输入文字的前提下，从而预测出用户接下来需要输入的文字？因此，产生了联邦学习。

2. 联邦学习用于多移动端分布式建模

联邦学习的设计优点就是用户数据尽量不离开用户自己的安卓设备，用户尽量在本地完成一部分的训练，然后把训练的梯度传到谷歌的云端，这样谷歌只看见一个梯度，它并没有获得这个用户的设备以前的聊天内容，这样在设计上有一种privacy by design 的设计优点。有很多这样的安卓设备，比如：Parameter Server设备是谷歌的云端服务器，它开始会有一个全局的初始化模型，云端服务器会把模型推到各个设备上，然后各个设备基于本地的数据来优化模型，得到一个更新的梯度，把这个更新的梯度发给服务器，服务器收到这么多梯度之后，会更新全局模型，然后发到这些设备上，这些设备又迭代，直到这个模型在某种程度上收敛为止，这就是联邦学习最开始的一个雏形。

3. 国内联邦学习与谷歌联邦学习的区别

区别一：

大概在 2018 年左右，国内开始引入联邦学习概念，与谷歌的联邦学习相比有了一些发展和改变。两者主要的区别是谷歌的联邦学习主要是面向海量移动设备的数据之间的合作，但是国内主要是机构之间的合作，被称为 cross silo FL，一般都是两个或者三个机构之间的合作。但是，目前的应用主要以信贷或者广告为主，例如：两个或多个机构一起判断用户的信用，从而决定要不要借钱给他，或者要不要给他推一些广告。这种情况下参与方的数目实际上跟 Google 的联邦学习相比是有很大的降低的。

区别二：

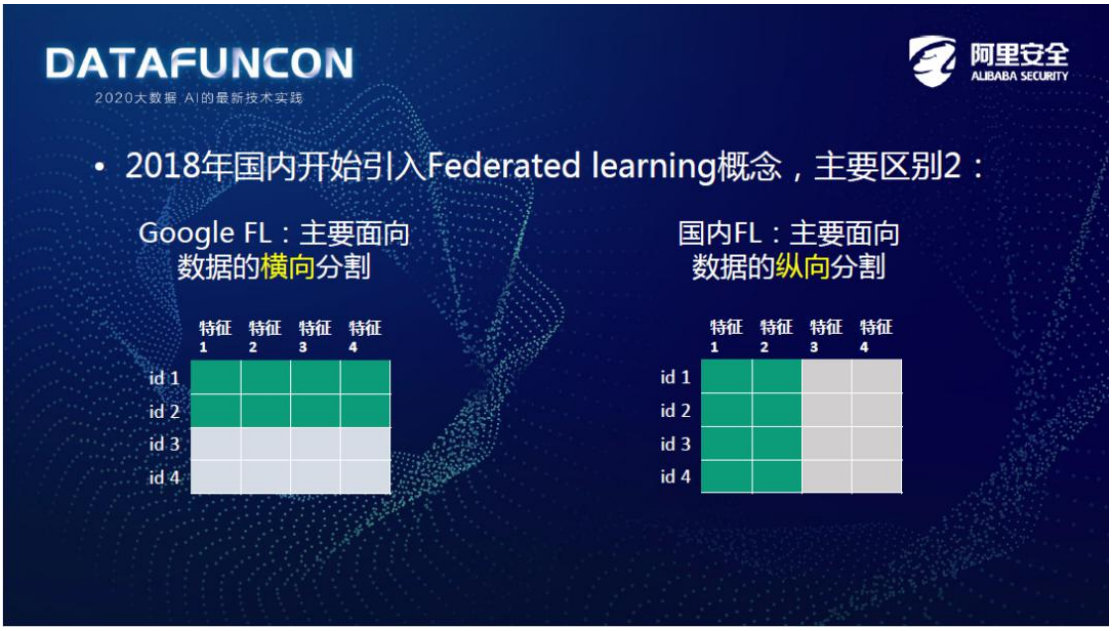

Google 有很多的设备，每个设备上都有自洽的一些样本，也就是说数据在多个参与方之间，它是横向分割的，比如说这个绿色的在一个设备上，这个白色的在另一个设备上就是横向的分割，每个都有一个完整的样本。

但是国内经常使用的联邦学习，主要是面向数据的纵向分割的。以信贷为例，其通常都是针对一个人的不同特征并把它们组合起来做联邦学习。比如说特征 1 与特征 2 在一个机构，特征 3 与特征 4 以及 label 是在另外一个机构，也就是说它主要是面向数据的纵向分割。当然横向分割这种应用国内同样存在，但是用的比较多的或者说比较赚钱的，还是在这种纵向的分割法上。

02

联邦学习面临的安全挑战

谷歌原版的联邦学习有什么样的安全挑战？而在国内，会面临什么样的新的安全挑战？

1．谷歌原版的联邦学习的安全挑战

首先是原版横向跨设备的联邦学习。因为它设计上只传梯度，梯度本质是一个函数，它是根据初始的模型以及本地的数据算出来的一个函数，那么这个函数可能是跟原数据是相关的，不能说有梯度就算不出原数据了，那多大程度上相关呢？其实算出来是有一定的难度，但是有一些学者也能算出来，比如说假设我们训练的模型是一个简单模型，比如逻辑回归，我们有了一堆梯度跟原始数据的这种关系，可以通过解方程组把这个未知数解出来的，这是我们在 NIPS 联邦学习 workshop 上的一个工作。如果这个模型比较复杂，解方程组算就变得不现实了。

这时有一些其他的方法，比如我们用 machine learning 的优化方法来反向的优化求得一个近似的解，可能求不到精确的结果，但可以取到一个大致差不多的结果，这里有一个去年的 NIPS 的文章，它可以反向的从梯度求出人脸，然后这个人脸

可能只有若干个像素的区别。所以我们看到如果不保护这个梯度的话，本质上还是能推出原始数据的。

谷歌的解决方法：

① 加差分隐私

Google 应对的方法，主要通过加差分隐私，也就是说 client 上传到云端的梯度，它不直接上传，而是加一个 noise，但是准确率会下降。准确率的下降，对于 Google 输入法 somehow 是可以接受的，因为输入法的 Top3 顺序换了一下，或者推荐的东西错了一点，对于用户体验可能差别不大，但是对于我们这种用在广告或者信贷场景下，准确率差 1%就可能差很多很多钱，所以对我们来说加差分隐私不是一种能够接受的方案。

② secure aggregation

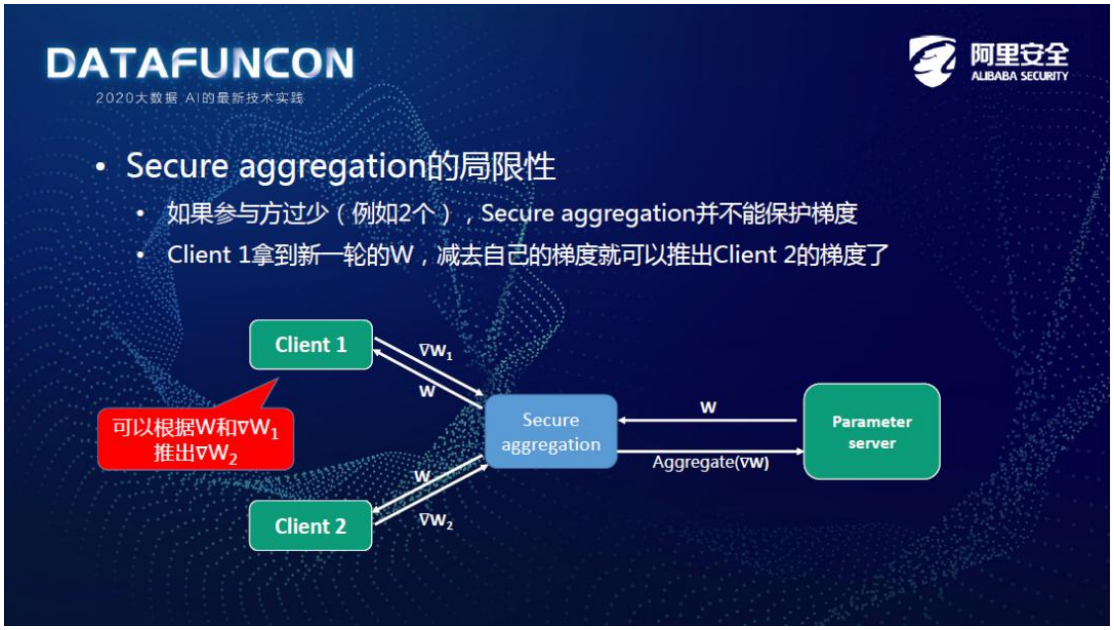

Google 还有一种方案叫做 secure aggregation，也就是说要通过 secure 的方法把这些多梯度聚合在一起，最后效果就是 Server 只看到了 n 个梯度聚合在一起的结果。但是，不知道某个具体的 client 梯度是多少的，从而导致了 Server 要攻击某个 client 的概率非常的低，但是我们观察到 secure aggregation 只适用于 client 数目比较多的情况。我们可以假设只有两个 client，那么这个 aggregate

的结果就是两个梯度的和，通过第一个 client 可以推出第二个人的梯度，所以参与方至少要三个人以上，而且这些参与方之间还不能够合谋，所以说这是 secure aggregation 的局限性。

2. 联邦学习应用面临的新安全挑战

讲解完横向联邦学习的问题之后，接下来了解下国内引入新的联邦学习应用后，会面临什么样的新的安全挑战。

① 参与方过少带来的问题

我们经常遇到 cross silo FL 参与方很多情况下都是两个，由于参与方过少会引来新的安全问题。

我们传的梯度是可以用半同态对它进行加密的，例如：Alice 把它的梯度用半同态加密，然后传给 Bob，这样是没问题的。Alice 的参数确实是对 Bob 保密的，但是 Bob 在这个加密的数据上运算完之后他是需要传回给 Alice，Alice 最终需要解密，或者说每一个 round 都需要解密，每一个 round 中 Bob 的参数实际上是被 Alice 知道的。因为参与方只有两个，Alice 得到两个人的计算结果，她肯定是可以从这中间推断出 Bob 的信息的。也就是说，在这种同态加密保护梯度中，只有一方是受益的，另一方他其实没有受益，跟普通的联邦学习是一样的。就是说半同态加密参数只能实现单向的防护。

② 纵向 FL 带来的问题

怎样对齐样本？

纵向的联邦学习又带来了一个新的问题——怎么对齐样本？例如：不安全的方法跟安全的方法，无论怎么对齐，其都是要按照主键对齐的。在对齐之后，不可避免的泄露了一个信息，对齐的用户都是谁？可能没对齐的用户呢？我们是可以用 PSI 这种方法来保护它的。一旦建模，就不可避免的要把这些数据提取出来，也就是说只要在交集里面的那些用户，就会不可避免的泄露了，我们可以再往里面加入假数据等等，但毕竟它在里面就是在里面了。比如说 A 公司跟 B 公司合作，他们之间想进行一个聚合，可能 A 公司的用户并不想把我是 A 的注册用户这个信息告诉 B，也就是说对齐这个东西它的 somehow 是在一个灰色地带，所以严格来说如果要对齐的话，应该用户显式的点击同意，我同意 A 把我的信息授权给 B，所以纵向的样本对齐问题是一个老大难的问题，虽然现在可能大家都在做，但如果监管严格了，这个问题，我们需要一起来想怎么处理。

无标签方

纵向的联邦学习肯定有一个人是无标签方，无标签方他可能需要做特征工程，他不能直接把这个特征直接传给别人或者直接进行联邦学习，那么有些特征工程是需要用到这个标签的，所以它怎么用呢？这也是一个难题。

实际上这个特征工程本身就是一个特定的算法，跟 Google 的横向联邦学习已经没有关系了，我们需要定制一种方案，比如说我们就是要算那个 WOE。那我们就要定制一个方案来安全地算这个 WOE，这也是第二个难题，也就是说纵向的联邦学习带来了很多新的我们以前传统的联邦学习没有遇到过的问题。

	正样本数	负样本数	反例总占比	正例总占比	WOE
0-18岁	100	50	10%	10%	0
18-40岁	500	100	50%	20%	0.92
40-60岁	300	150	30%	30%	0
>60岁	100	200	10%	40%	-1.39
总数	1000	500			

上图是 WOE 的例子，WOE 它是要计算这个特征的重要性，比如说我想把年龄分成不同段，比如 0~18 岁等这样几个段，那么每个段段内都存在正样本数与负样本数。那么，这个 WOE 就是把反例总占比比上正例总占比，然后求一个 log，这个数越大，说明这个特征这个分段对这个模型越重要，也就是它的判别度越高，我们最后就可以给它加一些分，这个分总可能比较好。但是，对绿色的参与方来

说，他是不知道那个标签的（假设标签是在另一方），那他怎么知道这正样本数跟负样本数呢，所以他是没办法知道的。

所以，怎么计算 WOE 也是一个难题，这也是纵向联盟带来的新的难题。

03

安全多方计算解决方案

1．安全多方计算

什么是安全多方计算？怎么用它来解决这些难题？

安全多方计算是一个密码学的定义，它叫 secure multi party computation MPC，它是可证明安全的，也就是说它有一个严格的安全定义，双方想计算什么东西，除了这个计算的结果之外，中间的任何步骤都是不泄露任何数据内容的。

比如说 a 和 b 想一起算个 f(a,b)，双方就真的就只知道 f(a,b)，其他任何东西，都是零泄露的。当然它里面有细分，比如说有 semi honest model 跟 malicious model，这个就是具体技术问题，就不细讲了。

2. 举例子说明安全多方计算到底怎么做？

比如说 Alice 跟 Bob，他们分别拥有数据 a 和 b，他们想进行一个联合的机器学习 f(a,b)。这里我们不管它是纵向横向总之它就有一堆数据 a，它有一堆数据 b 就对了。安全多方计算 MPC 有很多种，我们这里是用基于秘密共享的例子，就是说用秘密共享的 MPC 方法怎么做这个建模。

DATAFUNCON
2020大数据 AI的最新技术实践
阿里安全
ALIBABA SECURITY
• Step 1：随机拆分
Alice
a-r,r
r, r′ 是随机数
Bob
b-r',r'

DATAFUNCON
2020大数据 AI的最新技术实践
阿里安全
ALIBABA SECURITY
• Step 2：交换分量
• 得到秘密分享状态的a和b
• 单方视角下都是乱码，只有双方同意的情况下才能复原
Alice
a-r,b-r'
r, r′ 是随机数
Bob
r,r'

首先，a 跟 b 会把他自己的这个数据进行一个随机拆分，比如 a 有一堆数据，生成了一堆随机数，a 减去这个随机数，这个 r 是他本地生成的随机数，同理，Bob 他也会本地生成随机数 r'，那这个 r 跟 r'先不告诉对方，那我就把这个数据分成了两份，任意一份单拎出来看好像都是个 nonsense 的 garbage，因为它是随机的嘛，它减去随机的也是个随机的，然后，他们两个人可以交换一下这个分量，比如说 Bob 把这个 b-r'发给对方，Alice 把这个 r 发给 Bob。之后，我们称这个数据集现在处于一个秘密共享的状态，也就是说单方视角上他们看到的都是乱码，只有双方同意的情况下，把这两个数据拼到一起，他才能知道最终的数据是什么。那么这个秘密共享状态下的数据集，它的优点就是它还是能够计算的。

我们怎么算 a 加 b？其就是本地把这两个分量相加。比如 Alice 算出了 a 加 b 减去这两个东西，Bob 就把这两个东西加起来，可以看到这两个东西如果拼在一起的话，它是可以得到 a 加 b 的。同理，我们也可以在秘密共享的状态下做 a 乘 b、a 除 b，a greater than b 等等，协议会复杂一点，但是都是能做的。然后这些操

作它构成了整个机器学习的算法，比如说我可以在上面算一个 f(a,b)，然后得到 f(a,b)的秘密共享状态，我们两个人再商量一下，把这个拼起来，发现了 f(a,b)是多少，同时中间的任何中间结果都是秘密共享状态的，都是零泄漏的。

3. WOE 为例子，我们怎么来无泄漏的计算这个 WOE 呢？

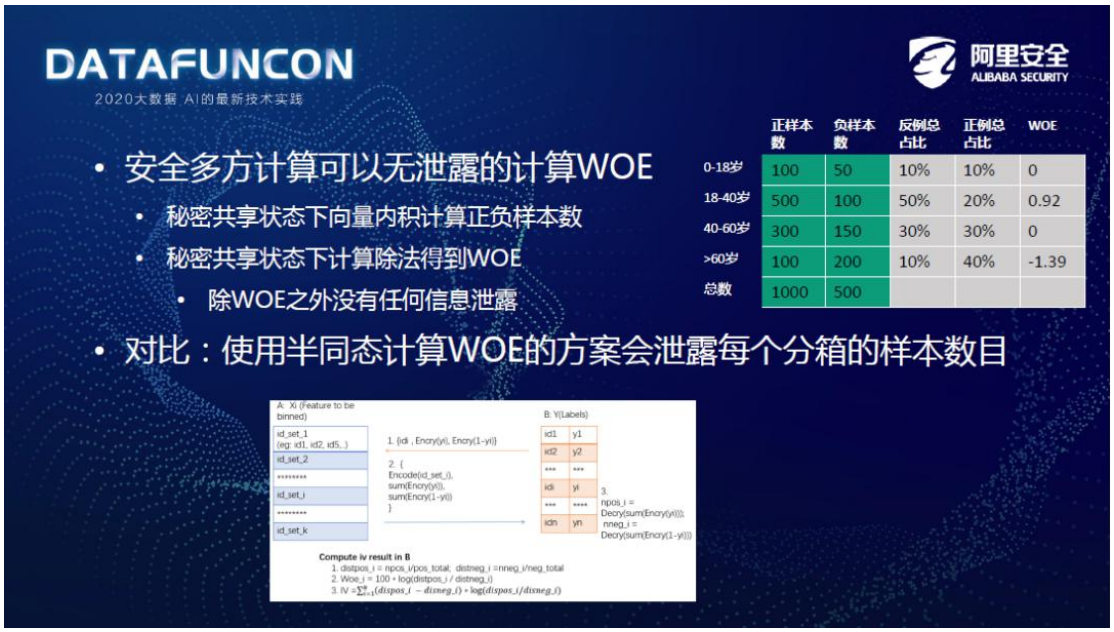

因为 WOE 就是一个正负样本的比值，正负样本我不知道，但是知道标签的那一方可以发一个秘密共享的向量过来。比如，正样本的就是 1，负样本的就是 0，他把这个向量以秘密共享的方式发过来，我自己的这个向量跟这个秘密共享的向量进行一个乘法，得到一个秘密共享的这个结果，这个秘密共享的结果就是这个正样本的数。但是，它是秘密共享状态的，所以我也不知道它是多少。之后，我可以进行一个秘密共享的除法，可以再次进行一个秘密共享的 log。最后，如果我要是必要的话，我就把这个数据复原出来，比如算出 WOE 是 0.9，然后这个过程中任何数据都是没有泄露的，除了你要计算的那个 WOE 最终的结果。如果我们

不用安全多方计算，用其他的自设方法来算 WOE 呢？比如说我们用半同态来算这个 WOE，那边把加密的 0 跟 1 发过来，这样会泄露我每个分箱的样本数目，比如我 0~18 岁有 150 个人，这个数据有样本有标签的一方，不可避免的被他知道了，这个泄漏虽然少，但是中间肯定是有泄漏的。

对于这两个方法，因为我们安全多方计算的除法跟向量内积还是比较高效的，所以这个方法还是比较好的。

4. 安全多方计算不需要“数据对齐”就可以建模

然后来到比较关键的数据对齐方面，虽然有 PSI 的数据对齐，但交集里面的用户身份是不可避免的泄露，不过我们有方法可以在秘密共享的状态下进行匹配。

比如说商家 A 持有用户 1 与用户 2，商家 B 它持有用户 2 与用户 3，然后他们可以把他们所有的数据都以秘密共享的形式分成两份。大家有 4 个秘密共享的数据，

谁也不知道哪个是谁，然后在这个秘密共享状态下可以进行匹配，得到一个秘密共享的结果。从 4 行得到了 1 行，但是大家只看见了 4 行变成 1 行，谁也不知道这一行是 user2，最后得到了秘密共享状态下的 user2，然后秘密共享状态的数据是可以进行 MPC 建模的。这样完美的保护了用户的隐私，谁也不知道这是 user2，user2 呢也没有让任何人知道她是 A 的客户还是 B 的客户，那么这样做有什么好处呢？

我们可以下结论说我们这样做是合规的。例如：我们以 GDPR 为例子，其第 5 条规定：对个人数据的处理不应当违反最初收集该数据时的初始目的，意思就是：用户让你干什么你就可以干什么，用户没答应干什么你就不能干什么。严格来说对齐数据的处理这个过程，用户是没有同意商家 A 把我是你的注册用户这个信息告诉商家 B 的，所以，这个过程 somehow 是存在风险的。但是 GDPR 也规定，统计用途是可以超出这个初始目的，很明显建模是一个统计性的。比如，他在这个交集上建出一个模型，这个肯定是一个统计性的模型，也就是我们可以说秘密共享状态下的数据对齐是合规的，这是安全多方计算的一个优势。

具体的算法比较密码学，大家可以参考一下 Facebook 最近发的一个 blog，上面的方法就是在秘密共享状态下进行数据对齐，这是安全多方计算解决的第二个数据挑战——怎么对齐数据。

5. 安全多方学习缺点

安全多方计算有什么缺点呢？它的缺点就是它性能肯定是低于联邦学习的，为什么这么说？

因为联邦学习中每个 round 总有一部分是可以本地算的，不需要网络，然后算完之后再交互一次。但是安全多方计算，他每一个操作都需要交互，例如：每一个乘法，每一个比较都需要双方的交互，也就是说它的性能可能是比较弱的。但是，目前在 logistic regression 这种简单模型下，它的性能经过我们的优化已经是完全可接受了。比如说万级样本百级特征可以 10 秒钟跑完，我们去年参加了一个 iDASH 的安全多方计算比赛，他的题目是：有三个医院，每个医院是有一些病人的数据，他们规定这个病人的数据是严格不能够传给别的医院的，他们三个医院想合作在这个数据上进行一个建模，也就是说判断某些基因的人可能/不可能得某些病，这样数据越多建模是越准确的。但是，由于合规问题，医院之间不能互传数据，所以比赛要求要使用安全多方计算来实现医院之间的联合建模。

我们是取得了这个比赛的冠军，我们是唯一一个准确率超过 70%的队伍，我们的性能也非常好，是 20 秒，这也是这个比赛 6 年以来第一次有中国队获得冠军。

总的来说，安全多方计算在某些场景是完全可用的，但是我们不能否认它对复杂模型，比如说 XGBoost 等等，多方安全计算的性能还是存在明显的瓶颈，这方面 Secure Boost 的性能就会比它强很多。

04

总结

我们国内在流行的联邦学习方案与 Google 最初发明的联邦学习方案之间存在很大的不同：

技术角度来讲，国内的联邦学习主要类似于 cross silo 的这种联邦学习，它是纵向的，Google 的联邦学习主要是横向的，国内联邦学习主要是面向少量的两个或三个机构的合作，Google 联邦学习面向海量的安卓终端之间的合作。

这个变化肯定带来了新的安全挑战，当我们要面对这些安全挑战时，我们设计上必须慎之又慎，我们要设计完善的解决方案。如果我们为了性能进行了妥协，这是无可厚非的，但是我们一定要详细的对参与方说明，我们这个算法解决方案是解决了什么样的安全问题？提供了何种安全保障？比如说对谁可能会产生何种信息泄露，能抵抗何种攻击，让用户有这样一种知情权。

安全多方计算解决方案，它是有其独到的安全优势，因为其中间没有结果泄露，那么它是有更广阔的应用前景。我们也很高兴看到 FATE 他也现在已经提出了 SPDZ 的安全多方计算 protocol，我们相信它可以进行更好的后面的迭代开发。

这是我们阿里安全双子座实验室，这个平台的 logo 叫可用不可见，就是 BLINDFOLDED COMPUTING，闭着眼睛计算，并看不到数据的内容。

今天的分享就到这里，谢谢大家。

京东超大规模联邦学习探索实践

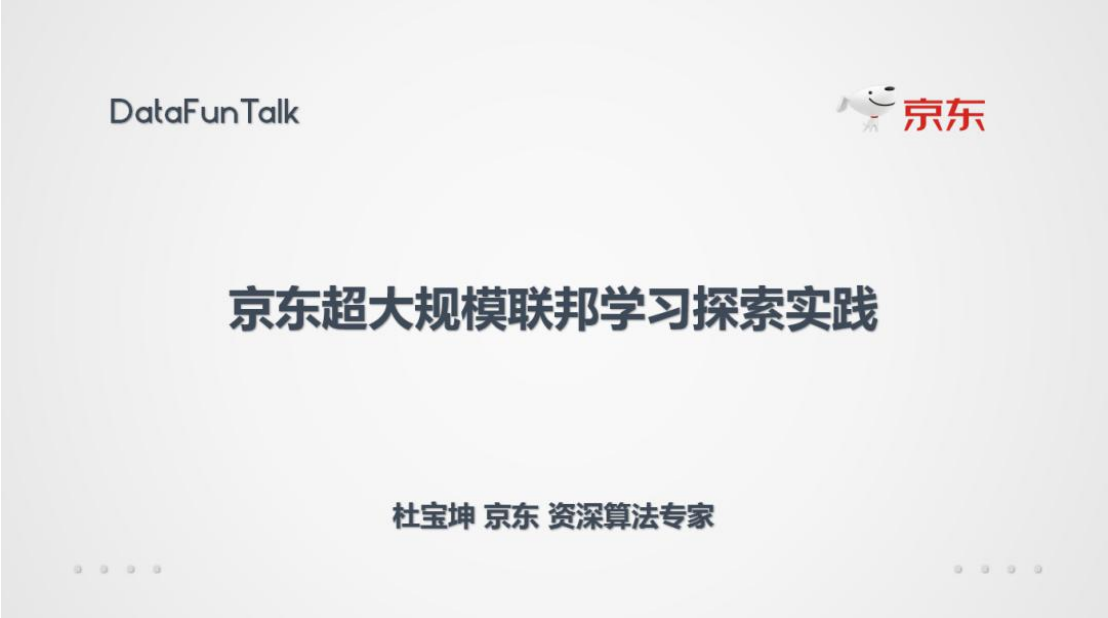

分享嘉宾：杜宝坤 京东 资深算法专家
编辑整理：侯雅新
出品平台：DataFunTalk

导读：对于 AI 飞速发展的今天来说，大规模的多维度、高质量的数据是其成功的关键要素，也是制约其进一步发展的重要瓶颈。随着大家对数据的重要性与隐私性的认知程度的不断提升，跨组织的数据的合作越来越谨慎，相关隐私法律法规也陆续出台（GDPR），这样就造成了大量了的数据孤岛，无法充分的利用数据进行分析、决策，严重制约了 AI 的发展。联邦学习在保证数据隐私安全及合法合规的基础上，打破数据孤岛，实现共同建模，共创共赢，将成为未来 AI 发展的一个重要方向，9N-FL 作为联邦学习的整体开源解决方案，也会在未来发挥越来越大的作用。

本文将通过了解联邦学习的原理以及解决方案 9N-FL，并且结合本公司的业务，进行应用，为大分享如何开辟新的业务模式与增长点。

01

背景

基于数据孤岛的考量而提出联邦学习，数据孤岛的产生有以下两方面的原因：

数据重要性：数据是 AI 的石油，加速了 AI 的高速发展，同时多维度高质量的数据是制约其进一步发展的瓶颈。随着各个组织对于数据重视程度的不断提升，跨组织以及组织内部不同部门之间的数据合作将变得越来越谨慎，大量数据以孤岛的形式存在。

数据隐私法：鉴于数据隐私的重要性，国内外对于数据的保护意识逐步加强。2018 年欧盟发布了《通用数据保护条例》（GDPR），我国国家互联网信息办公室起草了《数据安全管理办法（征求意见稿）》，因此数据在安全合规的前提下自由流动成了大势所趋。这些法律法规的出台，不同程度的对人工智能传统处理数据的方式提出了更多的挑战。

上述都限制了数据的流动，造成了大量信息孤岛。如右图所示，主要有两种方式造成信息孤岛：第一是企业获得用户信息越来越难；第二是企业之间数据不共享。

02

联邦学习概述

1. 联邦学习概述

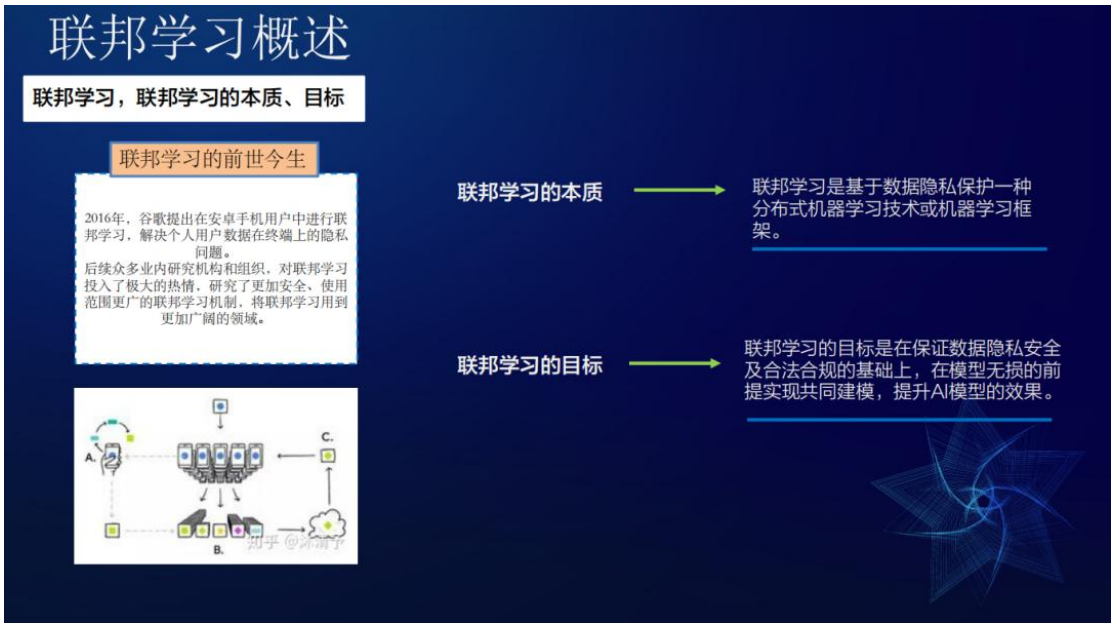

信息孤岛的解决方案是联邦学习。2016 年，谷歌提出在安卓手机用户中进行联邦学习，解决个人用户数据在终端上的隐私问题，它可以不上传用户隐私数据，在终端上进行模型训练。后续众多业内研究机构和组织对联邦学习投入了极大的热情，研究了更加安全、使用范围更广的联邦学习机制，将联邦学习应用到更加广阔的领域。

联邦学习的本质是基于数据隐私保护的一种分布式机器学习技术或机器学习框架。联邦学习的目标是在保证数据隐私安全及合法合规的基础上，在模型无损的前提实现共同建模，提升 AI 模型的效果。

2. 联邦学习的特征

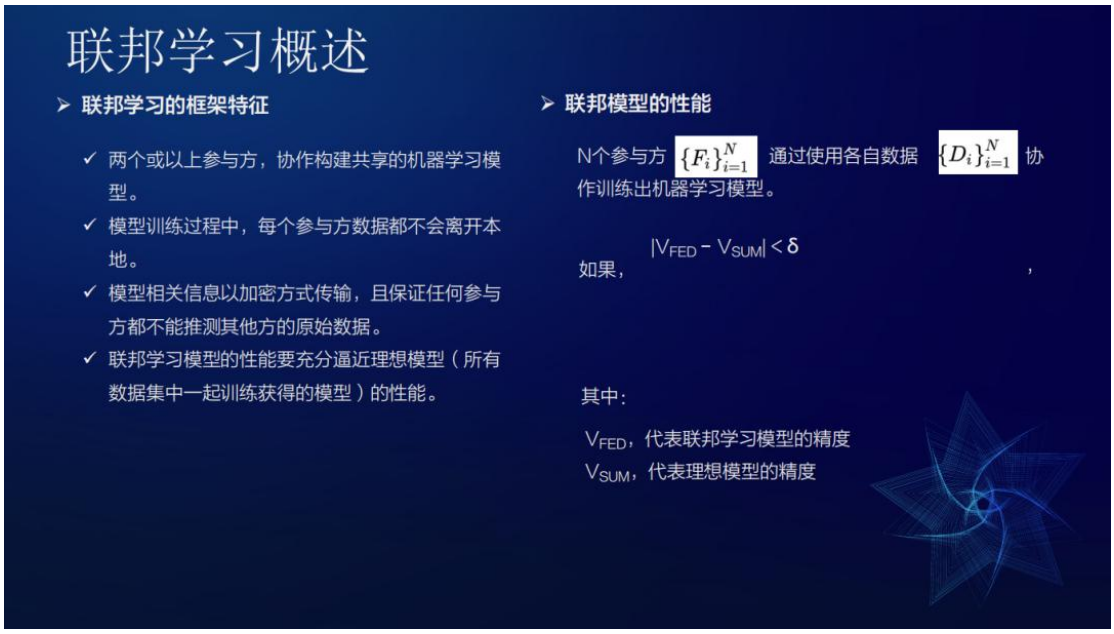

联邦学习框架有以下四个特征：

两个或以上两个以上参与方，共同构建机器学习模型。

在模型训练过程中，每个参与方数据都不会离开本地，也就是它的原始特征不会离开本地。在进行联合训练的时候，其实是把分布式平台的计算资源放到多家公司的机房里分开部署，而不是把数据集中起来放到一个地方进行训练。

模型的相关信息以加密方式传输。因为在模型训练的时候，需要传递梯度这些中间结果，所有的中间结果是通过加密的方式进行传输，并且保证任何参与方都不能推断出其他方的原始数据。

联邦学习模型的性能要充分逼近理想模型的性能。所有数据集中在一起搭建的模型和联邦学习这种跨域进行训练的模型的性能是比较接近的，右侧是性能逼近的公式。

3. 联邦学习的分类

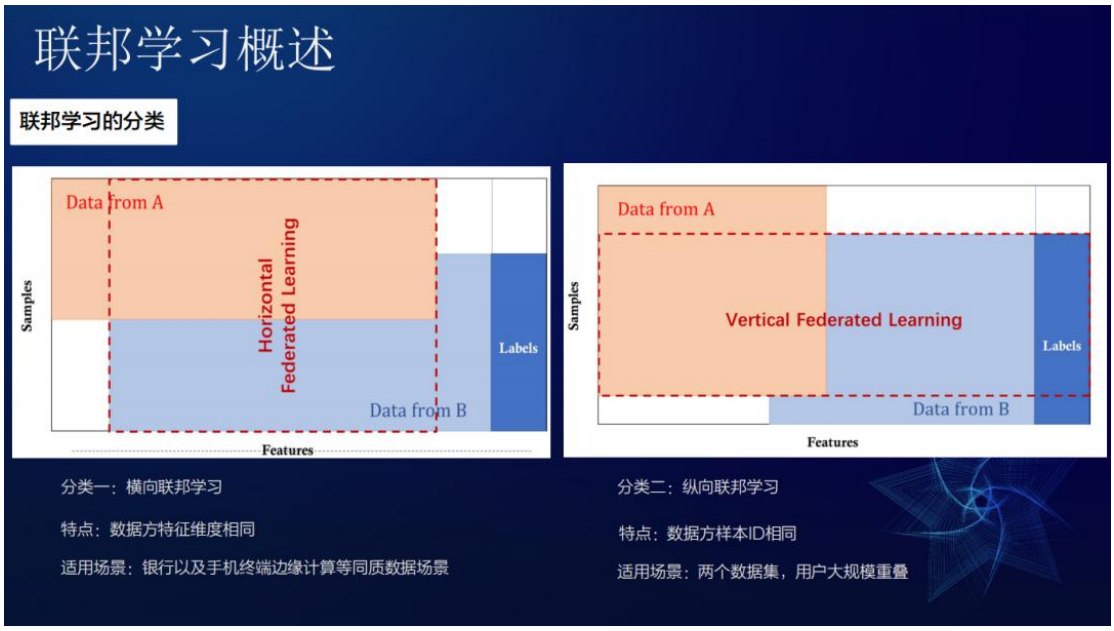

联邦学习主要分为三大类：横向联邦学习、纵向联邦学习、联邦迁移学习，联邦迁移学习用的稍微少一些。

横向联邦学习：比如刚才介绍的谷歌输入法案例，就是一个比较典型的横向联邦学习的案例。它的特点是各个参与方数据的特征维度是相同的，但是样本 ID 不同。适用于银行以及手机终端边缘计算等同质数据场景。

纵向联邦学习：它的特点是数据样本 ID 基本相同，特征不同。比如两个数据集的用户大规模重叠，但它们的特征不一样。

9N-FL 主要解决的是纵向联邦学习的问题。

4. 联邦学习的架构

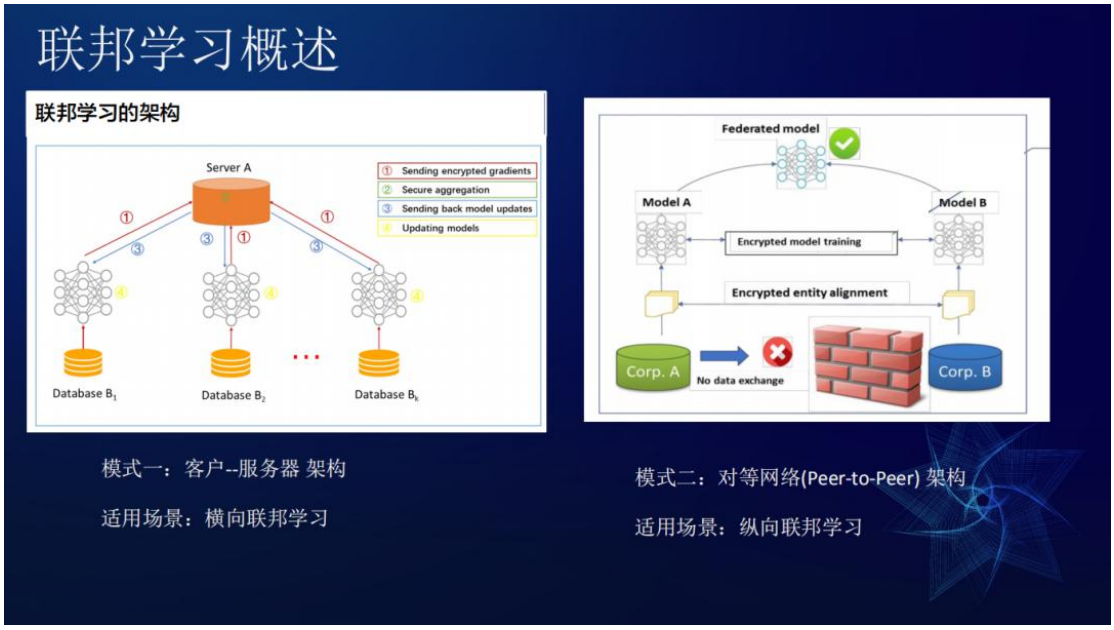

如图是联邦学习的架构，主要简单介绍了横向联邦学习架构和纵向联邦学习架构。

03

京东开源联邦学习解决方案-9NFL

1. 9N-FL 总体架构

项目背景：我们部门主要是做广告营销，在京东站外的一些营销场景中有很多用户，对于我们来说我们并不认识，比如在抖音、快手这些渠道投放广告的时候，这个用户我们不认识，但我们又想给他都放广告，对于头条和快手来说，他们不可能把用户的原始数据给我们。我们就想了一个办法，可以做一下联邦学习，这样对于我们不认识的用户，也可以去进行广告竞拍。

项目大概是在 2019 年 11 月份进行的开发，2020 上半年进行了正式的上线，并且在 2020 年 9 月份完成了正式的对外开源。9N-FL 平台主要包含以下几个重要的部分：

- 多任务跨域调度
- 跨域高性能网络代理

- 大规模样本匹配

- 大规模跨域联合训练

- 模型分层级加密

主要创新点：

- 业界前沿技术自主研发：从 0 到 1 开发设计的，实现了从大规模样本匹配到模型训练/预测的完整解决方案。

- 营销推荐领域技术落地：支持百亿规模的样本和百 T 容量的数据，并且在电商领域进行了业务落地，取得了不错的落地效果。

- 复杂场景下平台演进：整个场景比较复杂，涉及到跨域跨网，在这种复杂多变的环境下，要进行联合训练，难度还是比较大的。

取得的成绩：自上线以来，九数联邦学习平台（9N-FL）在取得了较好业务成绩的同时，也经受住了业务大数据、大算力的考验。在与媒体进行京东广告投放业务场景中，基于媒体侧大量的数据（例如，媒体兴趣标签）、京东侧大量的用户商业兴趣及商品标签数据，双方使用联邦学习平台联合建模，来优化广告的触发召回、CTR/CVR 模型等多个模块，最终成功上线，取得了大概 15%的收入提升。

2. 9N-FL 项目时间轴

这个是 9N-FL 的一个时间轴，2017 和 2018 年做联邦学习的比较多，像微众银行、腾讯、百度、阿里，它们相对来说比较早。京东是在 2019 年 11 月正式开始进行联邦学习平台的开发，当时是基于业务为出发点进行开发；在 2020 年 4 月份，完成了平台的开发落地，双方开始联合建模；在 2020 年中做出了业务效果，并且进行了上线。在 2020 年 9 月，进行了平台的开源，在 github 上搜 9N-FL 就可以搜到。

3. 京东开源联邦学习解决方案 9N-FL

对于联邦学习来说，它是一个全新的多交叉的领域知识，主要需要以下几个方面的能力：

数据隐私：同态加密、可信计算、秘密分享、混淆电路为联邦学习奠定了一个坚实的基础。

抽象异构资源限制：联邦学习不光要构建在不同公司，两个公司的技术栈、技术能力、基础设施都不一样，可以用云平台 K8S 进行一些抽象，另外还需要跨网，比如在联合训练的过程中、在大规模样本匹配中，需要大量跨网的交互，而且整个交互过程非常复杂、异常情况比较多。我们抽象了一些网络代理，自研了基于应用层的一些高效的网络协议。

高性能、高可靠：高效的网络协议、可靠的容错机制 failover。比如在联合训练过程中，两边集群可能是若干台机器，但如果有一台机器宕机，整个模型训练就

停止了，需要重新进行训练。最开始我们有些优化没有做的很完整，模型训练时间较长，大概是七八天，在 fail 的情况下重新训练就有很大的问题，整个研发进度无法保障。

联合建模：联邦学习平台对模型结构不做限制。在联邦学习过程中，大家都是独立建模，也就是我和另一家公司在建模的过程中，我们可以互不感知对方的模型结构，只关注上层连接之后的反向梯度的传输。

联邦学习是一个跨多个领域的技术，它包含了大数据、实时计算、云平台、机器学习、深度学习、高并发架构、密码学等方面的一些知识，整体要求比较高。

4. 9N-FL 具体工作

具体工作分为以下几个方面：

组件化：平台的一些策略、一些组件都是可以任意组合。比如有的公司数据体量比较大，可以用 hadoop 做数据存储；有的公司数据体量比较小，可能是一个本地文件，也可能是数据库这种方式，都可以支持。9N-FL 平台可以从大、中、小方面进行一个全方位的覆盖，另外可支持策略的热插拔。

高可靠：第一是虚拟化技术，这种虚拟化技术有底层团队在维护。第二是 failover 机制，比如节点故障的恢复。第三是高效、高容错的网络协议。

大数据、大算力：拥有横向水平扩展能力，整个系统支持分布式以及大数据的一些外围工具：HDFS、分布式文件系统、实时数据 kafka 等。

高性能：自研的分布式异步框架、高效自研网络传输应用协议,实现尽可能的并发。大部分模块采用 C++来编写，包括训练器，训练器基于 tensorflow，并没有重复造轮子。

5. 9N-FL 联邦学习模型

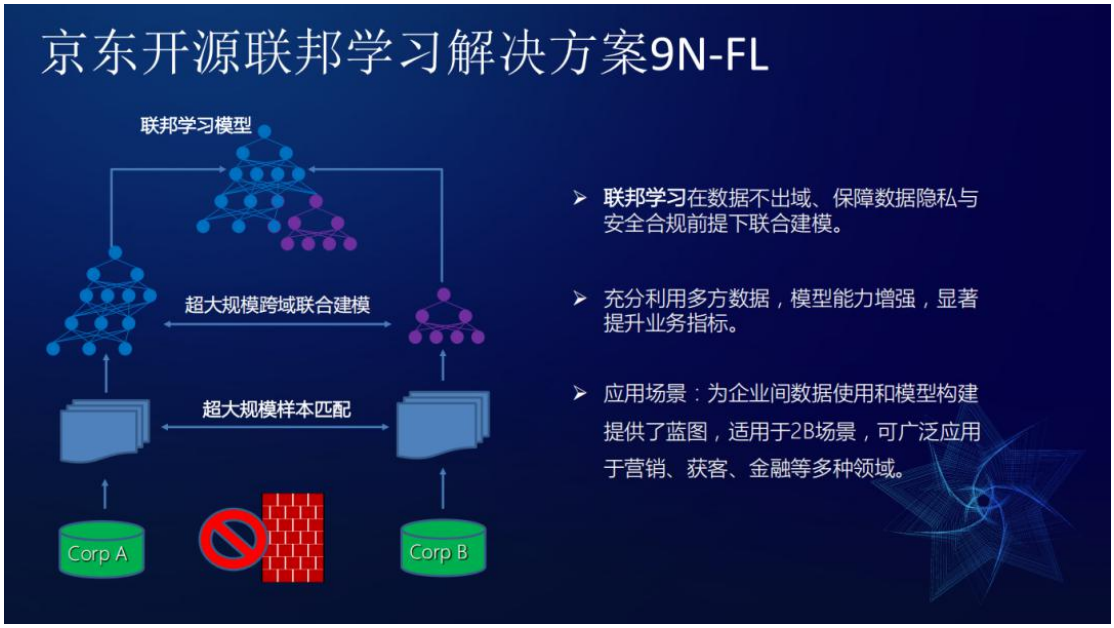

整体架构图中公司 A 和公司 B 的数据是无法打通的，其实这就是一个超大规模的样本匹配工作，为下一步建模做准备。在传统的联邦学习过程中，一条样本就是一个完整的输入，中间可能会进行拆图，没有在最开始的输入过程中拆，只是在中间的某一步进行了拆图。但是联邦学习从纵向上来看，把一个用户的样本数据一下子拆成了两部分，联邦学习的基础就是一个超大规模样本匹配的过程。接着往上就是大规模跨域联合建模，蓝色和紫色模型互不感知，只是在上层进行了数据连接，算一下 loss 作为反向梯度传输。

联邦学习主要解决数据跨域问题，保证数据不出域，也就是计算资源向数据资源靠拢，保证数据安全隐私、安全合规。联邦学习之前，只能用左边的一路或者右边的一路数据进行建模，其实模型能力也是可以的，但两个数据如果结合在一起，从直观或者理论上来说，这个模型能力肯定是有一些显著的增强，我们通过实践证明了这一点。

我们将 9N-FL 的应用场景瞄准了大数据营销这块，当然金融领域也在考虑范畴之内。金融对数据隐私性要求比较高，但对实时性要求不高，所以一般采用加密或比较简单的模型，比如 LR 模型或者树模型，它的数据量也比较小，大概几十万，离线可能跑几个小时。大数据营销这块的场景就比较多。

6. 9N-FL 分层架构

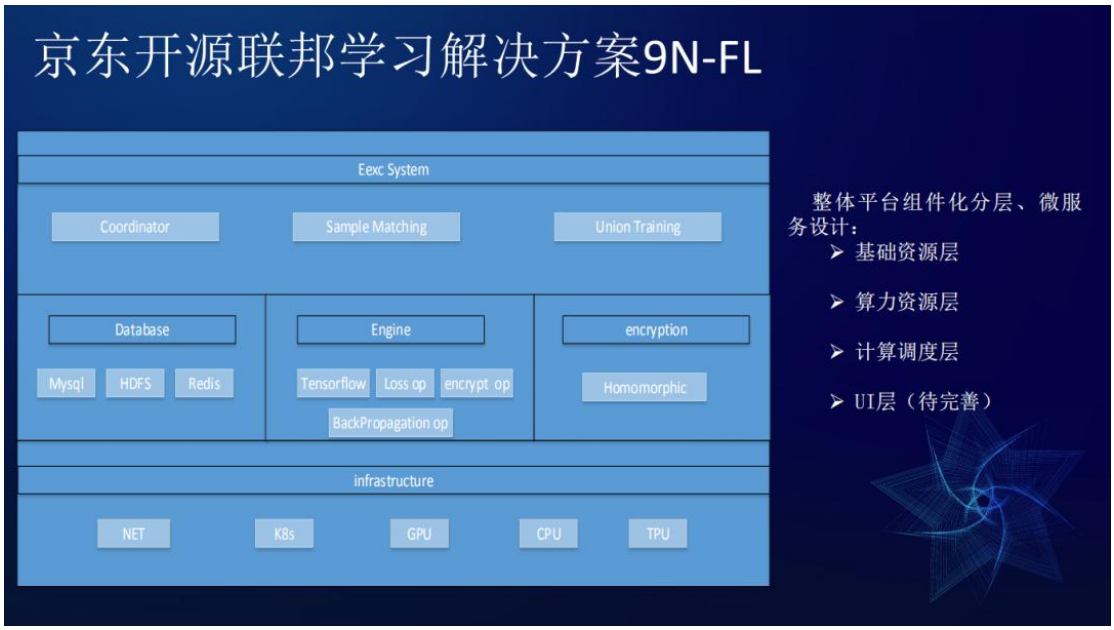

基础资源层：包括基础硬件资源、网络

算计资源层：改造 TensorFlow、op、加密模块

计算调度层：Coordinator、Sample Matching、Union Training

UI 层：待完善

7. 9N-FL 总体架构

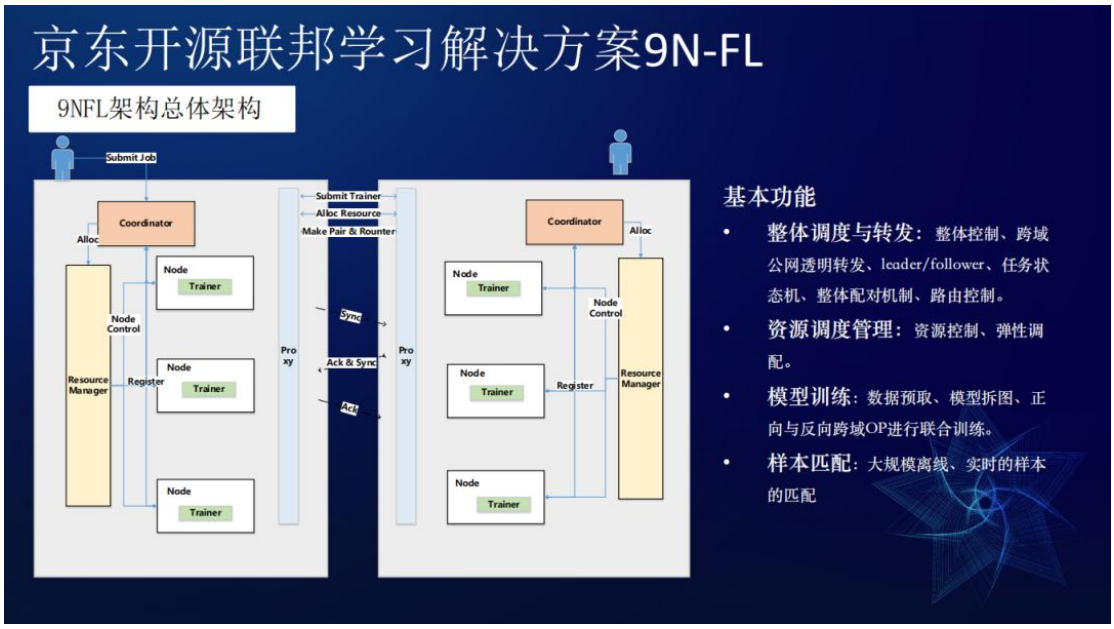

9N-FL 的整体架构图是一个对称的结构，服务部署在两家公司，每家公司都有一套完整的服务。比如 Coordinator：它是整个系统的总控；Proxy：涉及到跨网，可以理解成 gateway；Resource Manager：资源控制；Trainer：训练器。

详细过程：Coordinator 分为 leader、follower 两个角色。我们平时在机器学习平台训练的时候，只要开启训练就好，因为不涉及跟别人的协调，但是对于联邦学习来说，开启训练的时候涉及一个协调的问题，谁是主导者谁是跟随者？主导发起训练的就是主导者，比如图的左侧是主导者，它就是一个 leader，右侧就是跟随者 follower。所有的调度单元都是基于一个任务来调度，整个系统支持多任务的调度。首先左侧的 Coordinator 通知对端，我要进行训练，并且告诉对端我的样本 meta 信息，包含样本（比如 ctr、cvr 样本）信息、时间信息，两边还有一些协商，就是针对这次任务，我要开启多少个 trainer，比如要开启 20 个，那么两边都开启了 20 个 trainer，但是怎么调度起来呢？联邦学习可以仿照传统

的机器学习，也就是现在的样本分了两个训练器，一边消费一半，这种情况下，我把样本拼起来，把训练器拼起来，我们就做了这么一件事儿，把不同的训练器做了个配对。配对完之后就涉及到训练器的协商，左边的训练器会通知右侧训练器，告诉它我在我们这边拿到了一条数据，这个数据的 meta 信息是什么，同时会告诉对端也去拿相应的文件，两边都把相应文件拉下来之后，相当于做了消费同样文件的动作。这样两边就可以同时进行训练，在训练的过程中，不断的交换这些梯度，把整个模型构建起来。Proxy 的作用是路由控制，比如第一个 trainer 把梯度分发给对端 proxy 之后，对端 proxy 知道它是要发给第一个 trainer 而不是发给第二个 trainer。整个 proxy 是一个无状态的服务，它起到一个 gateway 的作用，是整个系统对外的暴露。我可能只监听对外的一些端口，会有一些安全措施在里面，里面的服务包括 Coordinator、Resource manager、Trainer，它们都是不对外的，保证了数据安全。Trainer 主要包含两个动作，一个就是两边取完数据后的协商，另一个就是在训练过程中正向结果的传输和反向梯度的传递。

整体调度：

整体调度这块是整个系统的总控，它控制整个系统的生命周期，比如任务的启动、停止、监控；资源的申请，比如会给 trainer 申请资源；多任务的并发调度，比如我们进行联邦学习的时候，是和多家公司进行合作，每家公司有不同的训练目标，有的是训练转化的、有的是训练召回的，建模方式可能不太一样，所以说是多任务的并行并发调度。

资源管理：

资源管理用的是 K8S。

加密训练：

同态加密：满足密文同态运算性质的加密算法，即数据经过同态加密之后，对密文进行特定的计算，得到的密文计算结果在进行对应的同态解密后的明文等同于对明文数据直接进行相同的计算，实现数据的“可算不可见”。

假如有两个整数 A 和 B，要计算 A+B 的和 C 是多少。两个数据对别人是不可见的，将这两个数据拿给第三方计算，算之前同时先对 A 和 B 进行加密，再对密文计算结果，在整个计算过程中，原始数据 A 和 B 没有暴露，得到密文结果后，再用同态解密的方式将密文解掉。

线性回归模型的训练步骤：例子是基于第三方的方式，第三方持有私钥，他会把公钥发给 A 和 B，公钥进行加密，私钥进行解密。算 loss 和算梯度的整个过程是加密的，之前未加密的计算都对应着一个加密的计算。对于 LR 模型和树模型都有公开的加密解决方案，计算速度偏慢，无法用在在线。京东在做对神经网络加密方案的研究，目前已经在实验阶段，后续会有可用于实时的方案。

8. 9N-FL 开源解决方案

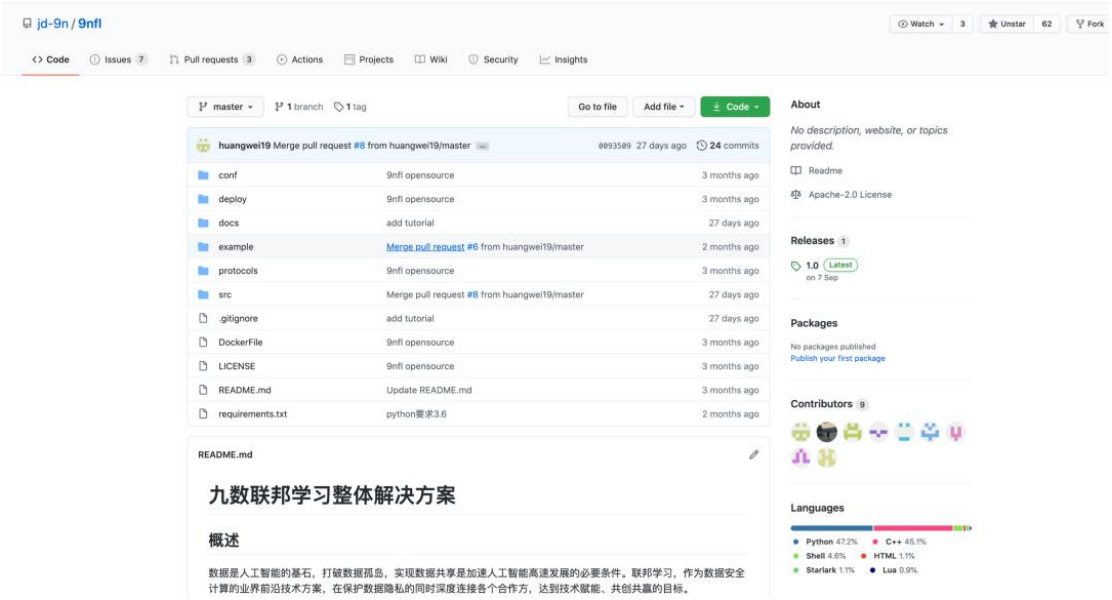

这块是京东 9N-FL 开源的情况，大家有问题可以提 issue。

04

业务效果

如图是基于媒体侧广告的投放的基本流程，双方收入累计提升 20%+。

05

未来思考

京东 9N-FL 起步于 2019 年 11 月，团队比较精简，以下几个方面待完善：

- 平台功能：UI 界面化，减少使用成本
- 部署便捷性：实现一键部署，简单快捷、方便
- 监控报警完善化：完善报警机制、完成监控机制

今天的分享就到这里，谢谢大家。

微众银行在联邦推荐算法上的探索及应用

分享嘉宾：谭奔 微众银行 高级研究员
编辑整理：王少华
内容来源：微众·AI
出品平台：DataFunTalk

导读：现如今推荐系统已经得到了广泛的应用，其性能通常是随着数据量的增加而提高。但现实中，数据往往分散在各个提供方手上，且随着数据监管政策趋严，以及数据隐私保护问题越来越受到重视，导致目前集中式的推荐系统难以进一步提高。因此，联邦推荐算法得以兴起。联邦推荐可以在数据不出本地的情况下，在加密的环境中实现和传统推荐算法一致的性能。其中，微众银行的开源平台 FATE 在这方面落地了多种算法，得到了越来越多的应用。今天将为大家带来微众银行在联邦推荐算法上的探索及应用。

主要内容包括：

- 推荐系统简介

- 联邦推荐系统
- 联邦推荐算法原理及实现
- 联邦推荐云服务和应用

01

推荐系统简介

1. 推荐系统应用广泛

推荐系统在互联网中的应用非常广泛，包括：电商、社交、信息流、在线视频、在线广告等场景。

2. 推荐系统极大提高效率

个性化推荐服务

精准营销

YouTube: 60%+ more clicks [Davidson et al. 2010]

Netflix: 80%+ more movie watches [Gomze-Uribe et al 2016]

Amazon: 30%+ more page views [Smith and Linden, 2017]

同时，推荐系统也是 AI 在商业领域成功应用的典型代表。推荐系统大大提高了用户获取信息的效率，帮助用户在海量信息中快速找到匹配的信息；另外，推荐系统还可以帮助企业找到合适的用户群，从而降低获客成本，提高投资回报率。比如，在应用推荐系统后，Youtube 视频点播率提高了 60%；Netflix 电影的播放量提高了 80%，亚马逊的用户浏览量提高了 30%，这都是很大，很可观的提升。

3. 推荐系统的原理

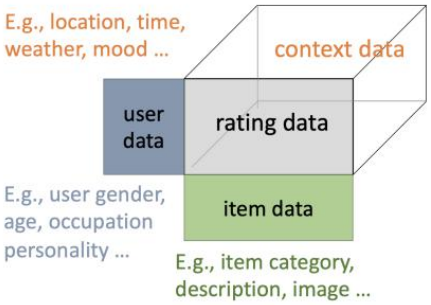

输入: 用户在内容/商品上的历史行为，用户、内容/商品的信息，例如用户基础信息、兴趣、内容/商品属性等

输出: 用户与内容/商品发生交互的概率，交互行为根据场景有点击、购买、评分等

在数学上，推荐系统是一个矩阵填充的问题。其中，矩阵的行表示用户，列表示内容/商品，矩阵中的值表示用户的行为。根据场景的不同，值可以是点击，购买，评分。以评分为例，1-5 表示对应的评分，空白表示用户在这个商品上还没有评分。我们的目的是根据已有的行为记录来预测空白的值，然后根据预测的值进行推荐。为了更精准的进行推荐，还会用到很多其它的信息：包括用户信息（如用户的性别、年龄、职业等维度）和商品信息（如商品的类别、描述文字以及推荐的环境数据（如推荐发生的时间点））。

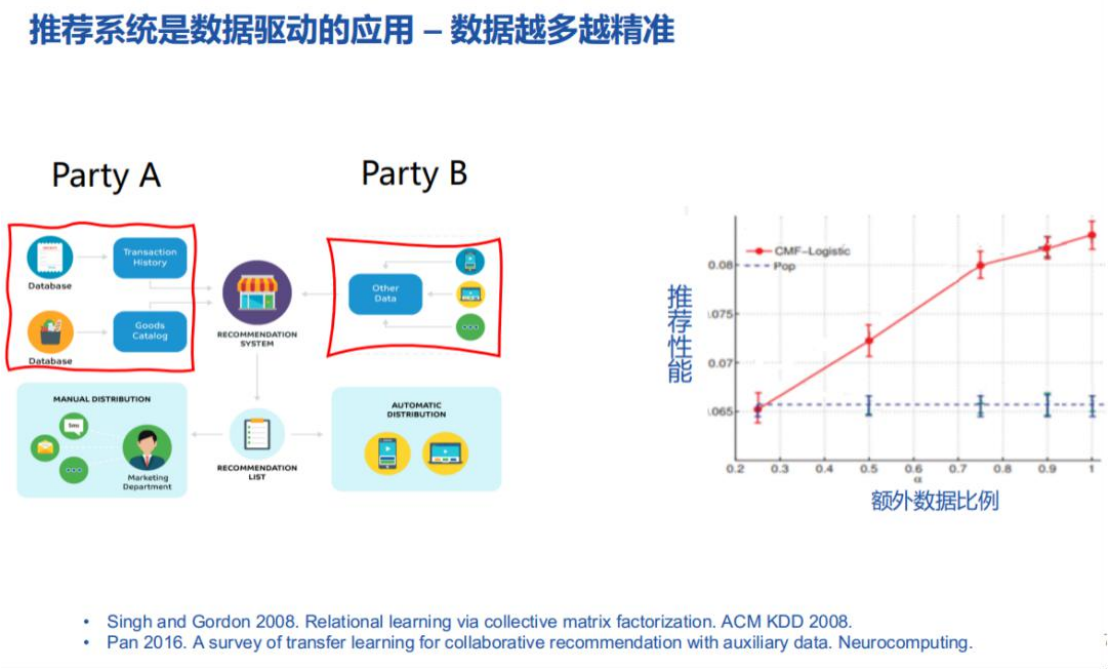

推荐系统通常会与多个数据方进行合作，从而收集更多的信息，以此提升推荐的效果。因为数据越多，对用户了解越深入，覆盖面越广，效果的提升就越大。图中相关研究也表明：随着额外数据的增加，性能随之提高。

4. 推荐系统面临的问题

① 数据孤岛问题

推荐系统是大数据驱动的应用。在理想情况下，大家可能认为数据质量很好，标签数据很充足，数据也是可以集中收集，并且触手可得的。但现实是，数据通常是分散隔离的，存储在不同的企业，即所谓的数据孤岛问题。

② 数据监管问题

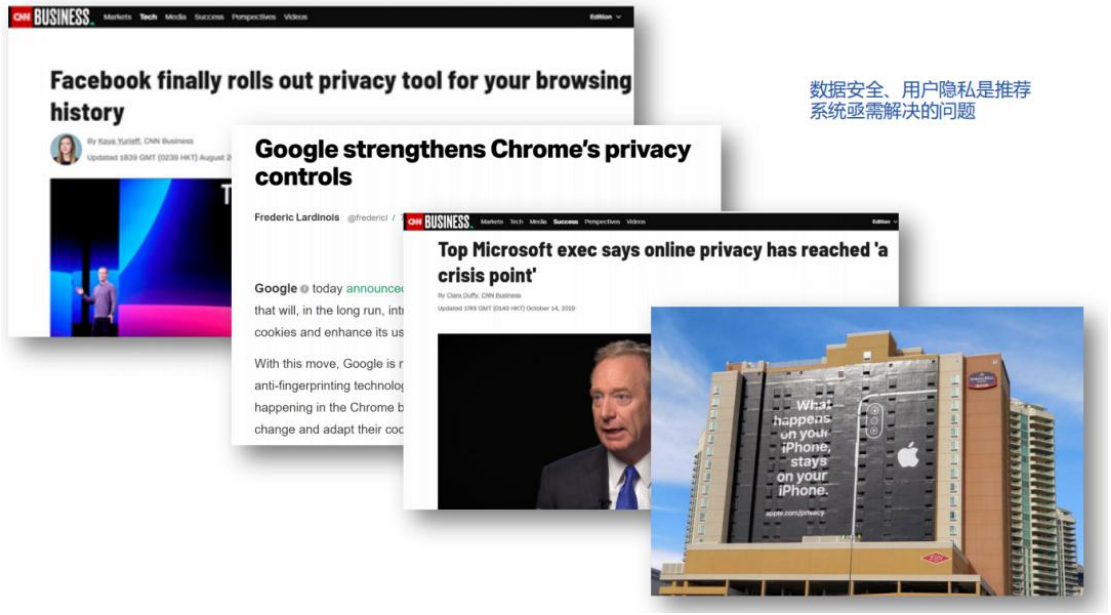

例如欧盟的 GDPR 和国内监管政策的严格，隐私保护是推荐系统必不可少的一个环节。随着数据监管体系不断完善，各个企业都在不断的加强对用户隐私的保护。

5. 差分隐私解决方法

差分隐私可用于建模的各个环节 [Knijnenburg and Berkovsky, 2017]

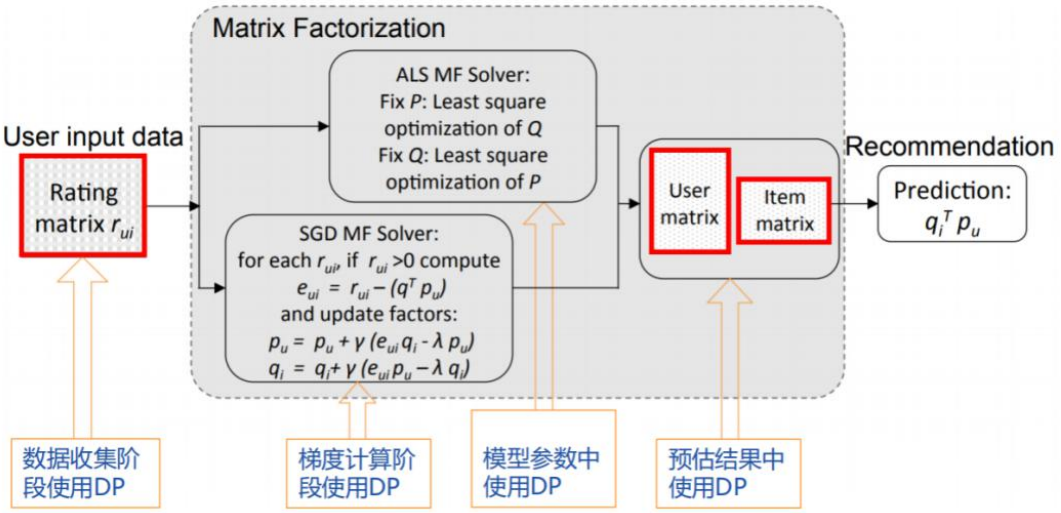

Bart P. Knijnenburg and Shlomo Berkovsky, 2017. Privacy for Recommender Systems. RecSys 2017 Tutorial.

10

在这种情况下，比如差分隐私是一种比较常用的隐私保护方法。它是在数据中加入一些差分隐私来保护用户的隐私。它可以用于建模的各个环节，比如在用户数据收集的过程中加入，也可以在建模的过程中，比如梯度计算，模型参数中加入差分隐私噪声，还可以在预估结果中加入噪声。

差分隐私噪声带来性能下降

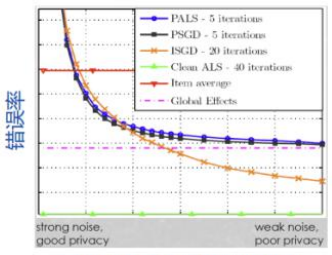

逐步减少差分隐私隐私噪声

增加DP噪声保护更多隐私带来性能下降

我们需要新的技术:

与集中收集数据相比，性能无损

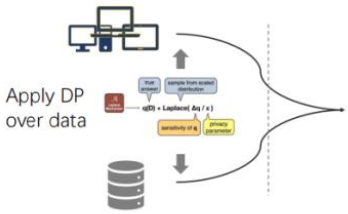

加入DP噪声后的数据，仍有可能被集中管理.

数据不出本地，保障数据安全和用户隐私

11

但是，现在的方法，包括差分隐私并不能完全满足我们的需求。随着差分隐私噪声的增加，确实可以保护隐私，但性能是下降的。如上图，在增加差分隐私噪声的情况下，性能下降非常快。我们希望，有一种新的技术可以在保护隐私的情况下做到性能无损。另外一个问题是，加入噪声的数据还是有可能被集中收集，所以其并没有从根本上解决数据安全的问题。我们希望新的技术可以做到数据不出本地，从而保障数据安全和用户隐私。

02

联邦推荐系统

1. 联邦学习的优点

Yang et al. 2018, Federated machine learning: concepts and applications. ACM TIST.

性能无损，A fed B 在保护隐私的前提下，性能和直接收集 A 和 B 数据的效果是一样的

原始数据不出本地

在加密条件下交换模型的参数来构建模型

2. 联邦推荐系统的分类

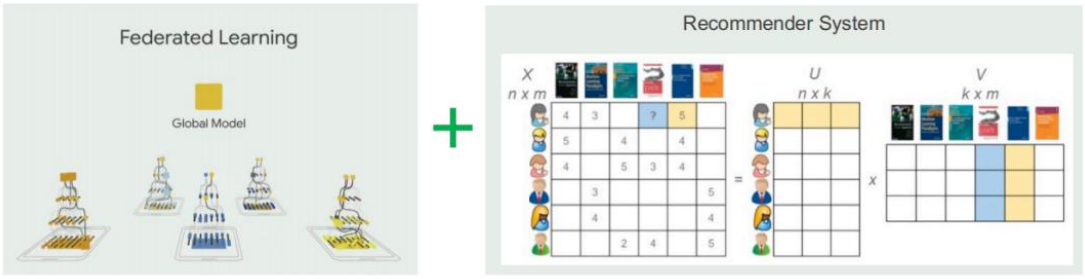

推荐系统中的核心数据为用户和物品的交互行为数据。根据物品和用户的共享情况，可以将推荐系统分为：

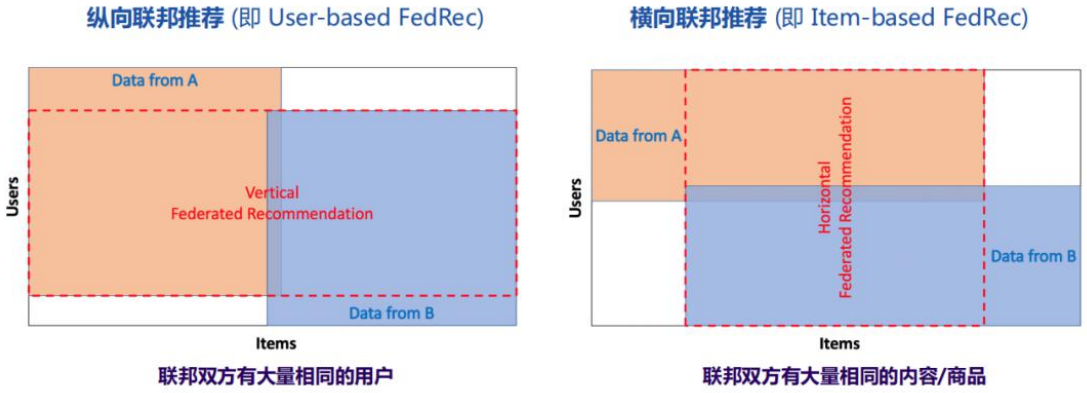

纵向联邦推荐：有大量相同的用户，但是 item 不同，因此也叫 user-based 联邦推荐系统。

横向联邦推荐：有大量相同的物品，但是用户不同，也叫 item-based 联邦推荐系统。

03

联邦推荐算法原理及实现

1. 纵向联邦推荐

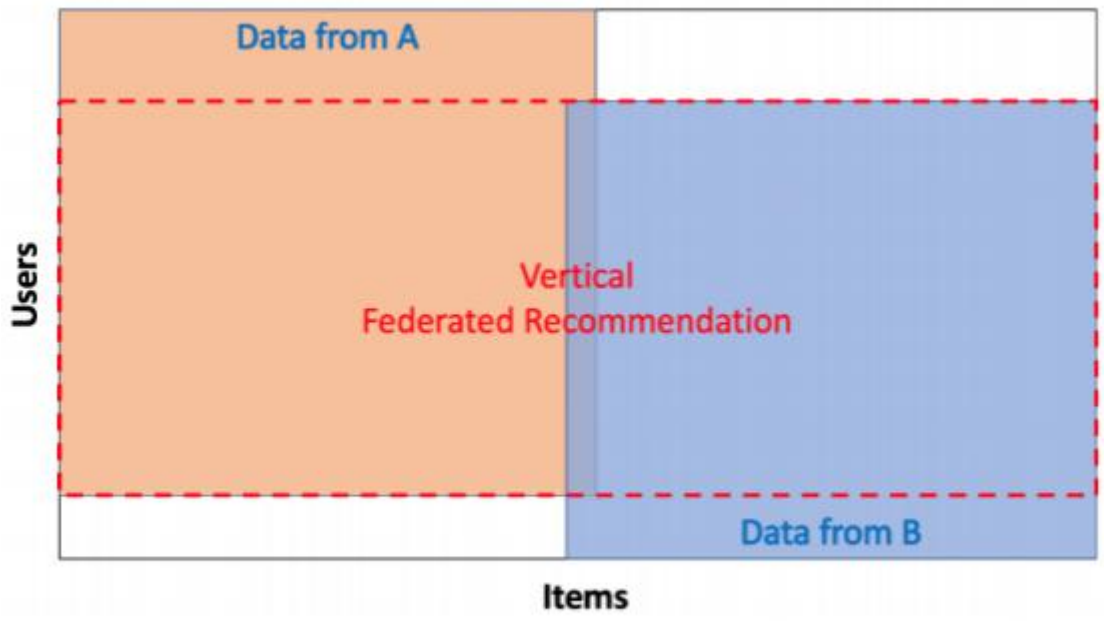

联邦双方有大量相同的用户

纵向联邦推荐介绍：

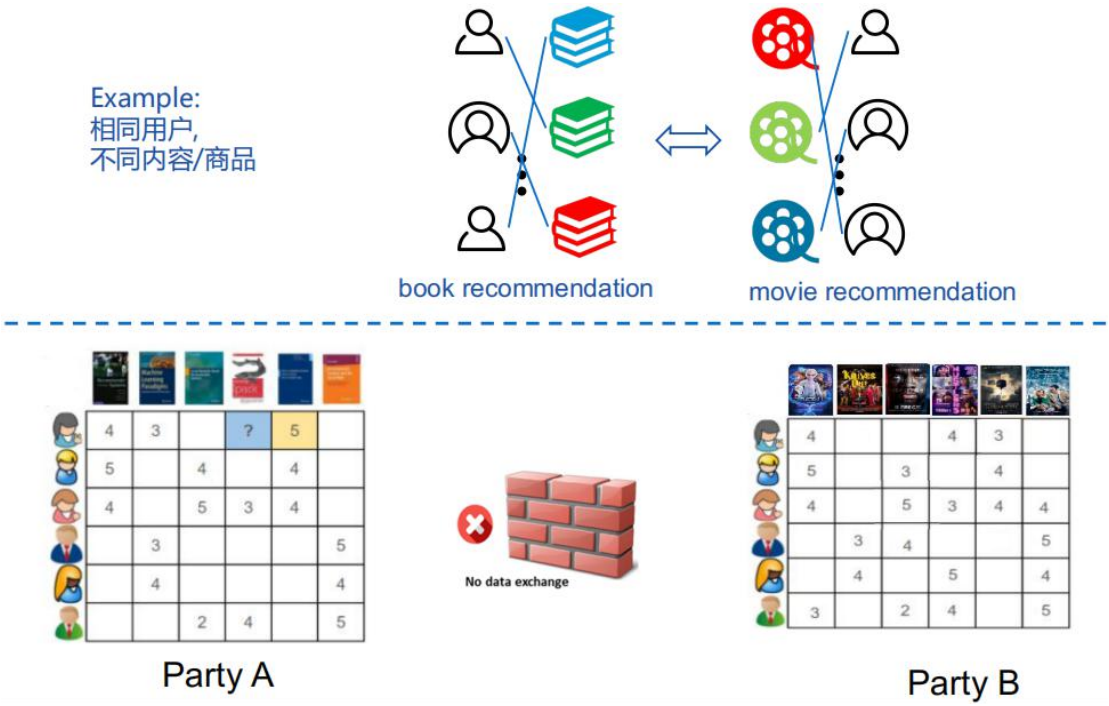

在这个场景中，书籍和电影这两个推荐系统有共同的 user，但是 item 不同。根据一些研究指出：将这两个推荐系统进行联合，可以提高推荐效果，因为这两个推荐系统的用户偏好是一样的。

纵向联邦矩阵分解：

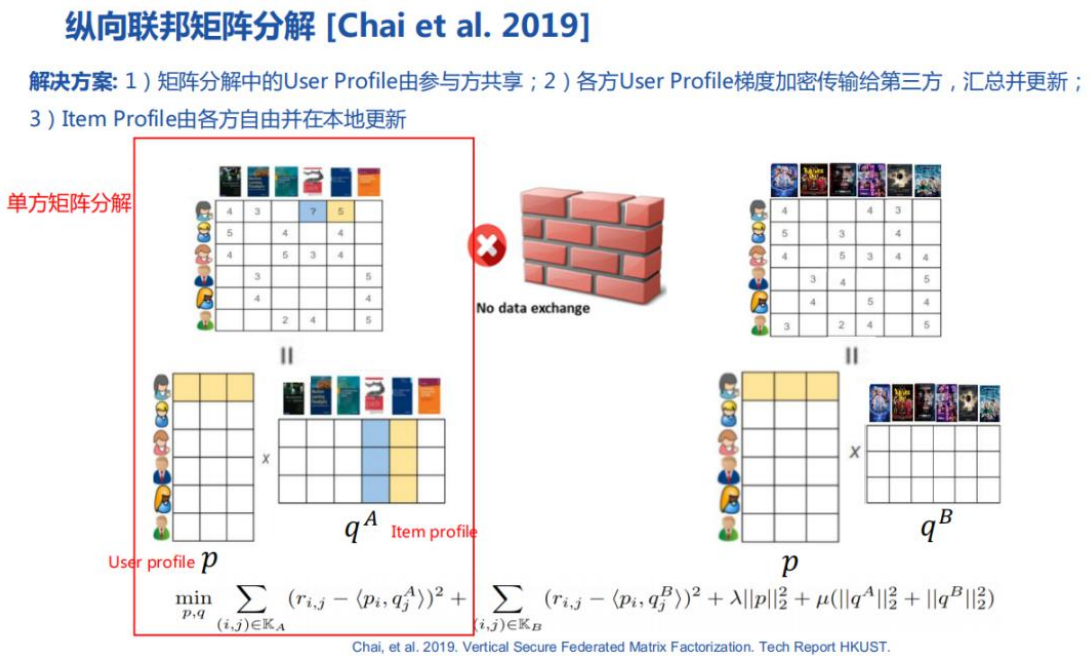

以矩阵分解为例，在数据不出本地的情况下，如何构建推荐系统？

在单方的情况下，用户的评分矩阵可以分解为两个低维矩阵的乘积，即 user profile p 和 item profile q。这两个矩阵乘积可以很好的拟合历史数据，同时可以填充矩阵中的空白值，并利用这些值进行推荐。

在多方的情况下，可以把两者的矩阵分解合并在一起，即图中的公式：第一项为 A 方的矩阵分解，第二项为 B 方的矩阵分解，第三项是正则项。其中，两方的 user profile 是共享的，item profile 是各自独有的。为了让两方可以及时的获得最新的 user profile，通过引入第三方服务器，由它来维护 p，并实时分发给 A 方和 B 方。

纵向联邦矩阵分解的训练过程：

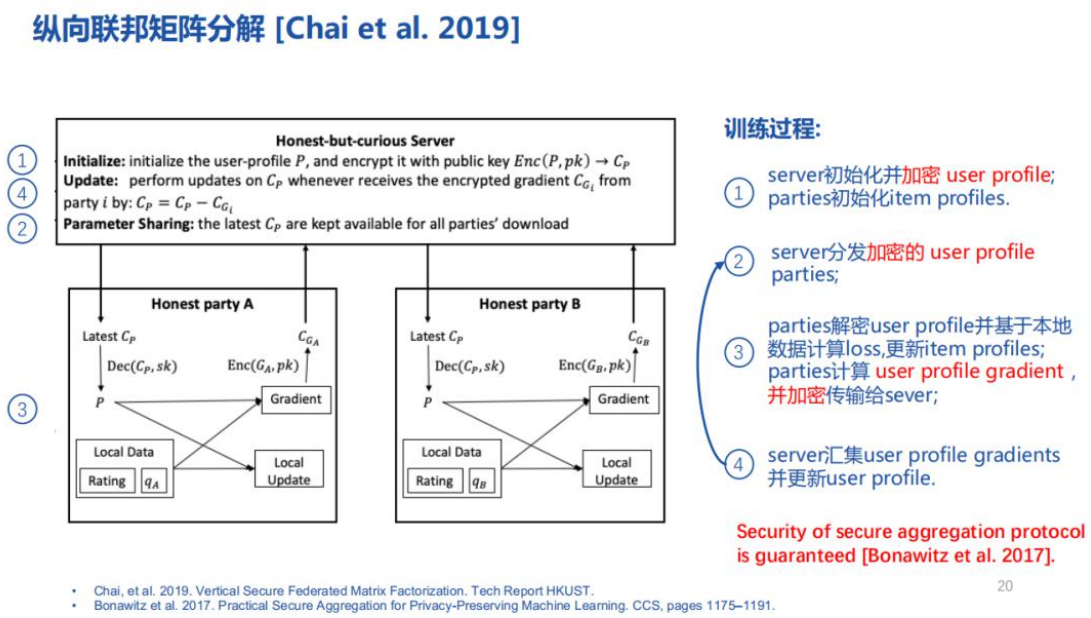

① 服务器初始化并加密 user profile，参与两方各自初始化 item profile

② 服务器分发加密的 user profile 给 A 和 B 方

③ AB 两方解密 user profile 并基于本地数据计算 loss，更新各自的 item profile，然后两方分别计算 user profile 的梯度，并加密传输给服务器

④ 服务器汇集 user profile 梯度并更新 user profile 矩阵

⑤ 如此迭代，直到模型收敛

纵向联邦矩阵分解在 FATE 中的实现：

计算更新的公式如下：

矩阵分解目标函数：

$$\min_{p,q} \sum_{(i,j)\in\mathbb{K}_A} (r_{i,j} - \langle p_i, q_j^A \rangle)^2 + \sum_{(i,j)\in\mathbb{K}_B} (r_{i,j} - \langle p_i, q_j^B \rangle)^2 + \lambda ||p||_2^2 + \mu(||q^A||_2^2 + ||q^B||_2^2)$$

各参与方计算use profile梯度、更新item profile公式：

$$p_i^t = (1 - 2\gamma\lambda)p_i^{t-1} + G_{A,i}^{t-1} + G_{B,i}^{t-1}$$

$$q_j^{A,t} = q_j^{A,t-1} - \gamma \nabla_{q_j} F(p^{t-1}, q^{A,t-1}),\ where\ j : (i,j,r) \in \mathbb{D}_{n_b}^A$$

$$q_j^{B,t} = q_j^{B,t-1} - \gamma \nabla_{q_j} F(p^{t-1}, q^{B,t-1}),\ where\ j : (i,j,r) \in \mathbb{D}_{n_b}^B$$

核心逻辑

Clients send shared profile to 3rd party coordinator

3rd party coordinator aggregate and broadcast back to Clients

```
while self.aggregator_iter < self.max_iter:
    LOGGER.info(f"start {self.aggregator_iter}_th aggregation")

    # train
    self._model.train(
        data, aggregate_every_n_epoch=self.aggregate_every_n_epoch)

    # send model for aggregate, then set aggregated model to local
    modify_func: typing.Callable = functools.partial(
        self.aggregator.aggregate_then_get,
        degree=epoch_degree * self.aggregate_every_n_epoch,
        suffix=self._iter_suffix())
    self._model.modify(modify_func)
```

```
def aggregate_model(self, ciphers_dict=None, suffix=tuple()) -> Weights:
    models = self.get_models_for_aggregate(ciphers_dict, suffix=suffix)
    total_model, total_degree = reduce(lambda x, y: (x[0] + y[0], x[1] + y[1]), models)
    total_model /= total_degree
    LOGGER.debug("In aggregate model, total_model: {}, total_degree: {}".format(total_m
    return total_model

def aggregate_and_broadcast(self, ciphers_dict=None, suffix=tuple()):
    """
    aggregate models from guest and hosts, then broadcast the aggregated model.

    Args:
        ciphers_dict: a dict of host id to host cipher
        suffix: tag suffix
    """
    self.model = self.aggregate_model(ciphers_dict=ciphers_dict, suffix=suffix)
    self.send_aggregated_model(self.model, ciphers_dict=ciphers_dict, suffix=suffix)
    return self.model
```

纵向联邦矩阵分解在 FATE 中的使用：

首先是准备好数据，数据是以三元组形式保存的，包括有 user ID，item ID 和用户的评分。再配置好 FATE job 的文件，最后 submit job，就可以看到模型训练的结果。

训练时的模块流程： Data IO – Intersection – Hetero MF - Evaluation

Hetero MF job DSL:

```
{
    "components" : {
        "dataio_0": {
            "module": "DataIO",
            "input": { ··· },
            "output": { ··· },
            },
        "hetero_mf_0": {
            "module": "HeteroMF",
            "input": { ··· },
            "output": { ··· },
            },
        "evaluation_0": {
            "module": "Evaluation",
            "input": { ··· },
            "output": { ··· },
            },
        }
}
```

Sample Data:

```
# id,userId,itemId,rating
0,2031,5286,0
1,4368,5958,0
2,2174,4059,0
3,3815,5824,0
4,3831,3182,0
5,3359,3612,1
6,1094,3288,0
7,3573,3229,0
8,5391,4596,0
```

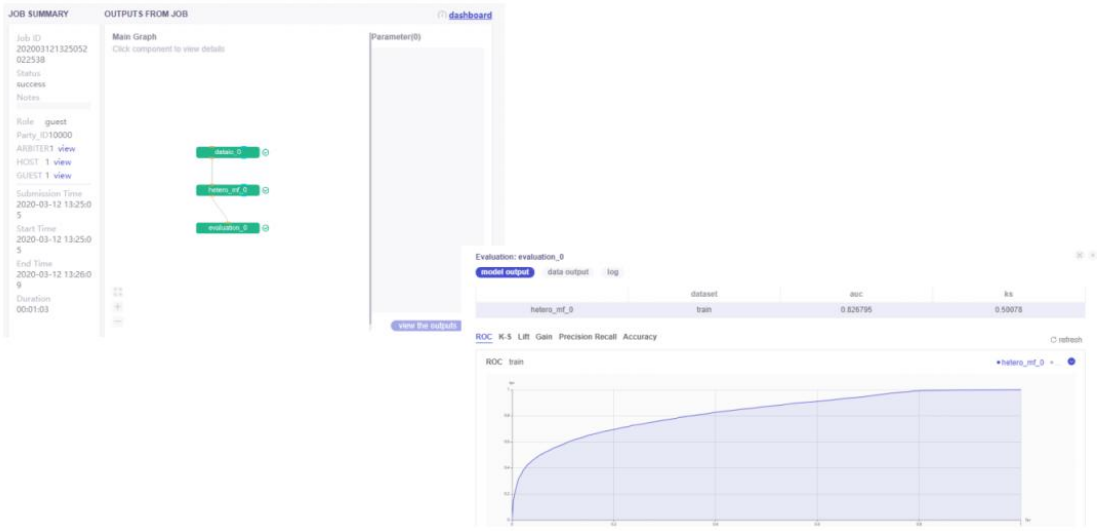

2. 纵向联邦推荐案例

在这个案例中，参与各方是有相同用户，但用户特征不一样。这个场景也是很常见的，一个推荐系统和另外一个数据提供方进行合作来提高推荐效果。

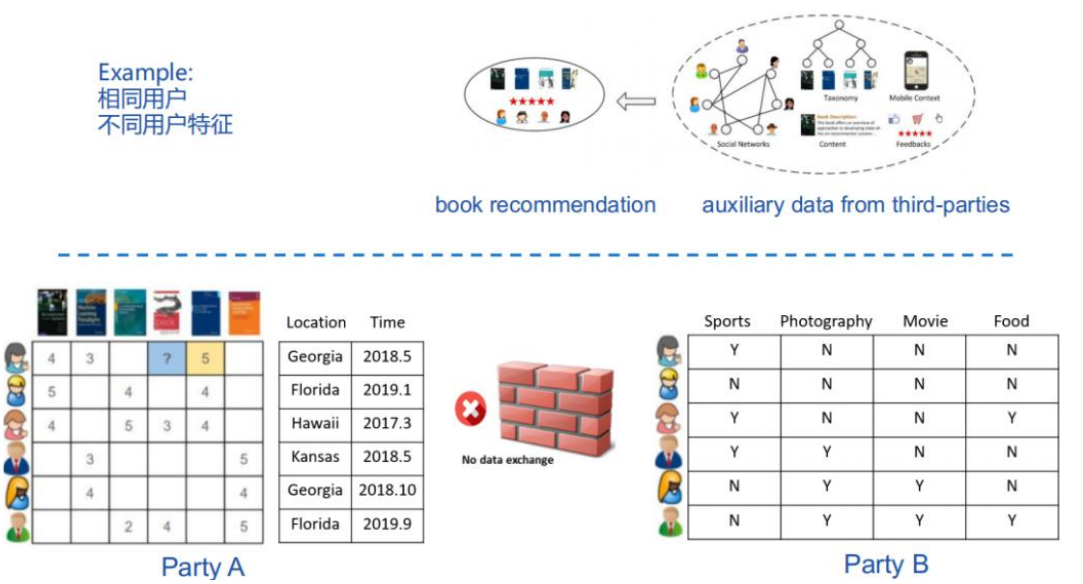

在这个场景中，需要做特征交叉。其中因子分解机是处理交叉特征的常用算法。比如将性别和电影类型进行交叉，可以挖掘出男性在战争电影、男性在爱情电影、女性在战争电影和爱情电影的不同偏好程度。对于图中例子的特征交叉，可以知道不同地区的人对不同体育项目的偏好。

联邦因子分解机：

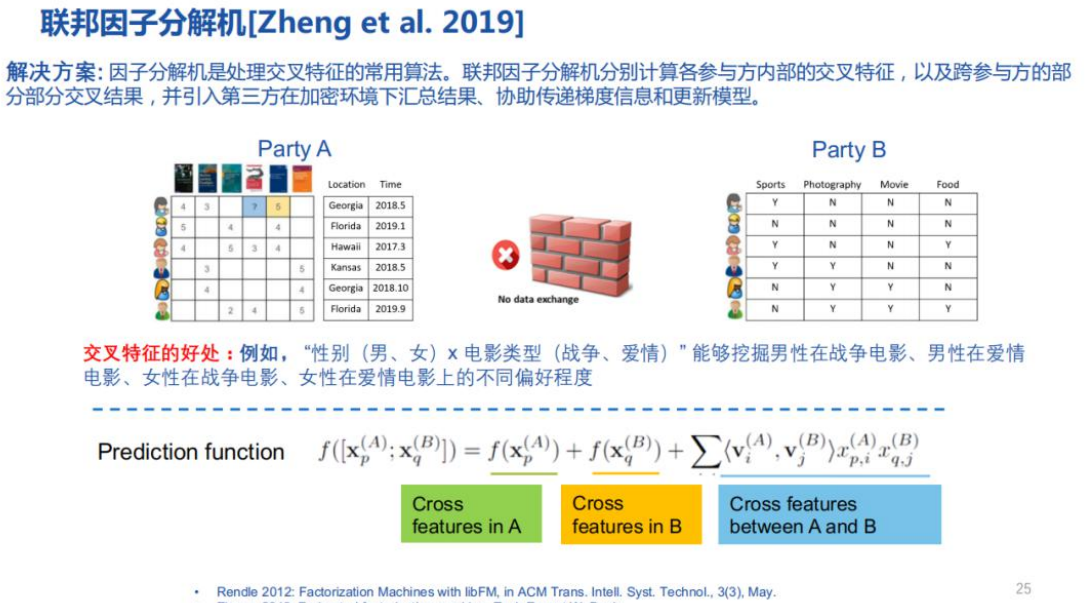

在数据可以自由传输的情况下，是很容易处理的。但是联邦场景下，如何进行交叉呢。联邦因子分解机的目标函数经优化后，由三部分组成：在 party A 和 party B 各自内部进行特征交叉，以及在 A 和 B 之间的特征交叉。我们分别在 A 方和 B 方做一部分计算，然后在合并起来，数据不出本地。同样的，通过引入第三方服务器，在加密的状态下在 A 方和 B 方之间传递模型参数和特征交叉求和的中间结果。

联邦因子分解机训练过程：

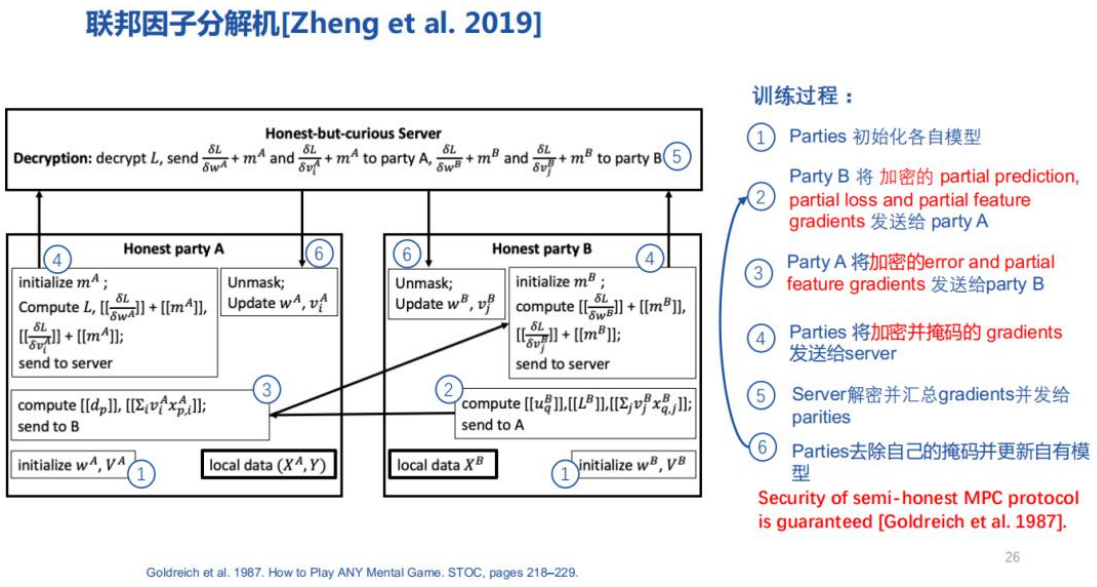

① Party A 和 Party B 分别初始化各自的模型

② Party B 基于自己的特征计算部分预估值和部分 loss，并加密发送给 A

③ A 方接收到以后，基于自己的特征计算部分预估值，并结合 B 方的预估值，计算最终的损失函数和梯度，然后将 B 需要的梯度和损失函数发送回 B

④ A 和 B 在完成梯度计算以后，分别将梯度进行加密并掩码，发送给第三方服务器

⑤ 第三方服务器解密并汇总梯度并发给 A 和 B

⑥ A 和 B 去除自己的掩码并更新自有模型

不断循环，直至收敛，最终得到自己那部分的模型。

联邦因子分解机推理过程：

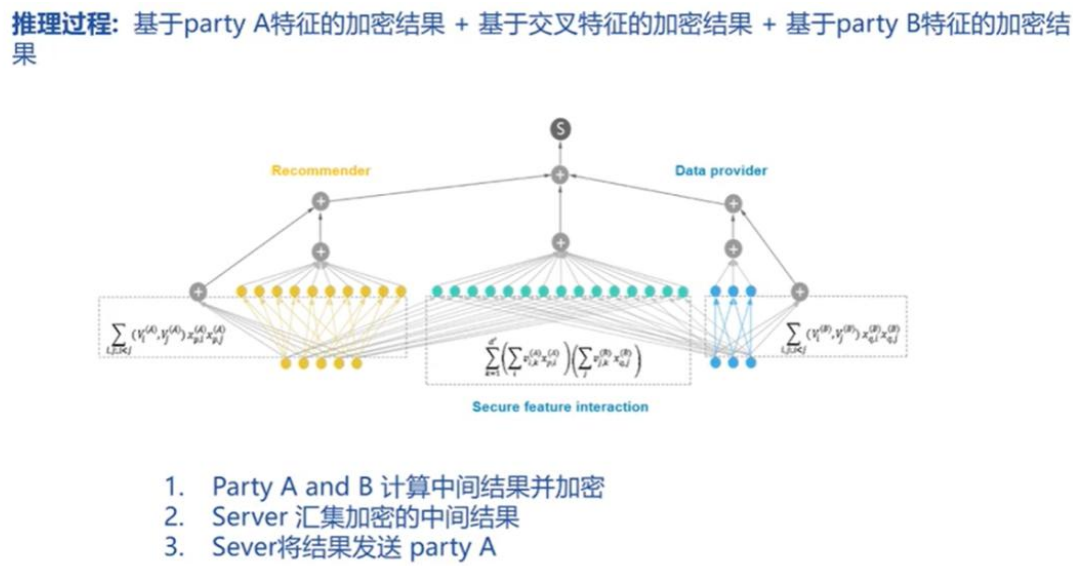

在推理过程中，对于新样本，需要 A 方和 B 方共同参与，才能完成模型的预估。

① A 和 B 首先基于自己的模型和自己的特征计算自己的特征交叉结果以及跨合作方的特征交叉结果，并加密发送给第三方服务器

② 第三方服务器汇集的中间结果

③ 第三方服务器将汇总结果发送给 A 方，解密后即可使用

联邦因子分解机在 FATE 中的实现：

联邦因子分解机的预测函数和损失函数如下图所示。特别的，将 AB 两方共同完成的交叉项分解为各自需要完成的计算过程。

联邦因子分解机的预测函数：

$$
\begin{aligned}
f([X_p^{(A)}; X_q^{(B)}]) &= f(X_p^{(A)}) + f(X_q^{(B)}) + \sum_{i,j} x_p, i^{(A)} x_q, j^{(B)} \\
&= f(X_p^{(A)}) + f(X_q^{(B)}) + \sum_{i} \sum_{j} \sum_{k=1}^{d'} v_{i,k}^{(A)} v_{j,k}^{(B)} x_{p,i}^{(A)} x_{q,j}^{(B)} \\
&= f(X_p^{(A)}) + f(X_q^{(B)}) + \sum_{k=1}^{d'} (\sum_{i} v_{i,k}^{(A)} x_{p,i}^{(A)}) (\sum_{j} v_{j,k}^{(B)} x_{q,j}^{(B)})
\end{aligned}
$$

联邦因子分解机的损失函数:

$$
\begin{aligned}
&\ell([W^{(A)}; W^{(B)}], [V^{(A)}; V^{(B)}]) \\
&= \frac{1}{2nA} \sum_{p=1}^{nA} (y_p - f([X_p^{(A)}; X_q^{(B)}]))^2 + \frac{\alpha}{2} \Omega([W^{(A)}; W^{(B)}], [V^{(A)}; V^{(B)}])
\end{aligned}
$$

其中 $\alpha > 0$ 是超参数.

其核心逻辑有四个：

- 首先是实现预测函数；
- 然后计算 loss 和梯度；
- 发送给第三方服务器以及汇总，并更新；
- 分别发送给 ab 方，不断进行迭代。

联邦因子分解机在FATE中的实现

核心逻辑

FM prediction

```
def compute_fm(self, data_instances, model_weights, fit_intercept=True):
    """ calculate wx + (v*x)^2 - (v^2)*(x^2)
        data_instances: batch_size * feature_size
        model_weights: FM Model weights

        model_weights.w_'s shape is feature_size
        model_weights.embed_'s shape is feature_size * embed_size
    """

    def fm_func(features, embed):
        re = np.multiply(np.expand_dims(features, 1), embed)
        re = np.sum(re, 0)
        part1 = np.sum(np.power(re, 2))
        features_square = np.power(features, 2)
        embed_square = np.power(embed, 2)
        part2 = np.sum(np.dot(features_square, embed_square))
        return 0.5*(part1 - part2)

    wx = data_instances.mapValues(lambda v: np.dot(v.features, model_weights.w_))
    fm = data_instances.mapValues(lambda v: fm_func(v.features, model_weights.embed_))
    pred = wx.join(fm, lambda wx_, fm_: wx_ + fm_)

    if fit_intercept:
        pred = pred.mapValues(lambda v: v + model_weights.intercept_)

    return pred
```

Host send out encrypted forwards.

```
def compute_gradient_procedure(self, data_instances, model_weights,
                               encrypted_calculator, optimizer,
                               n_iter_, batch_index):
    """
    FM model gradient procedure
    Step 1: get host forwards which differ from different algorithm
            For Factorization Machine: forwards = wx + <v,v>x,x + b
    """
    current_suffix = (n_iter_, batch_index)

    # encrypted host forwards (en_wx_plus_fm, en_vx)
    self.forwards, host_vx = self.compute_forwards(data_instances,
                                                   model_weights,
                                                   encrypted_calculator[batch_index])

    self.remote_host_forward(self.forwards, suffix=current_suffix)
```

Aggregate Host and Guest forwards

```
def compute_and_aggregate_forwards(self):
    """
    Here we compute guest forward and aggregated with host forward.
    Cross feature between host and guest is implemented.
    """
    assert(len(self.host_forwards) == 1, "Current FM only support single host party")
    # encrypted host forwards (en_wx_plus_fm, en_vx)
    host_forward = self.host_forwards[0]

    # Here we compute cross feature between host and guest
    # Guest forward includes: 1. en_wx_plus_fm 2. vx 3. en_vx
    # Aggregate_forward = en_wx_plus_fm(host) + en_wx_plus_fm(guest) + en_vx(host) * vx(guest)
    en_aggregate_forward = self.guest_forward.join(host_forward,
                                                   lambda g, h: g[0] + h[0] + np.dot(h[1], g[1]))
    self.aggregated_forwards = en_aggregate_forward

    return en_aggregate_forward
```

Compute FM gradient

```
def compute_gradient(data_instances, fore_gradient, vx_mul_fg, x_square_mul_fg, model_weights):
    """
    Compute hetero-factorization machine gradient
    Parameters
    ----------
    data_instances: DTable, input data
    fore_gradient: DTable, fore_gradient
    vx_mul_fg: DTable
    x_square_mul_fg: DTable
    model_weights: FM Model Weight

    Returns
    ----------
    DTable
        the hetero FM model's gradient
    """
    feat_join_grad = data_instances.join(fore_gradient, lambda d, g: (d.features, g))
    feat_join_grad = feat_join_grad.join(vx_mul_fg, lambda a, b: (a[0], a[1], b))

    # Now we have (x, fore_gradient, vx_mul_fg, x_square_mul_fg)
    feat_join_grad = feat_join_grad.join(x_square_mul_fg, lambda a, b: (a[0], a[1], a[2], b))

    f = functools.partial(__compute_partition_gradient,
                          embed=model_weights.embed_,
                          fit_intercept=model_weights.fit_intercept)

    gradient_partition = feat_join_grad.mapPartitions(f).reduce(lambda x, y: x + y)
    gradient = gradient_partition / data_instances.count()

    return gradient
```

联邦因子分解机在 FATE 中的使用：

训练时的模块流程： Data IO – Intersection – Hetero FM - Evaluation

Hetero FM job DSL:

```
{
    "components" : {
        "dataio_0": {
            "module": "DataIO",
            "input": { … },
            "output": { … },
            },
        "intersection_0": {
            "module": "Intersection",
            "input": { … },
            "output": { … },
            },
        "hetero_fm_0": {
            "module": "HeteroFM",
            "input": { … },
            "output": { … },
            },
        "evaluation_0": {
            "module": "Evaluation",
            "input": { … },
            "output": { … },
            },
        }
}
```

Sample data:

```
id,x0,x1,x2,x3,x4,x5,x6,x7,x8,x9,x10,x
133,0.449512,-1.247226,0.413178,0.3037
0,-0.728193,-0.442587,-0.272757,-0.608
273,-1.245485,-0.842317,-1.255026,-1.0
3639,0.348620,-0.552483,-0.526877,2.25
175,-1.549664,-1.126219,-1.546652,-1.2
66881,-0.779358,-0.708418,-0.637545,0.
551,-0.851273,0.733108,-0.843535,-0.78
772,0.453852,-0.431696,-0.494754,-1.18
199,0.091654,0.216499,0.103839,-0.0346
```

① 参与方准备数据，数据是以矩阵的形式进行存储的，包括用户 ID，样本 ID，样本标签，每个特征的特征值。

② 定义好配置文件

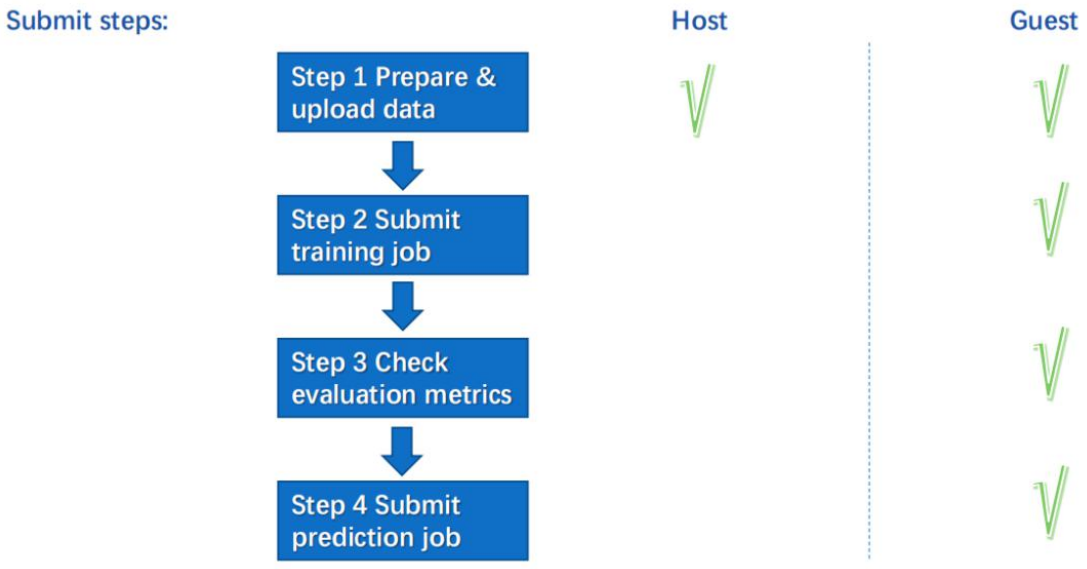

③ Guest 提交训练任务，获得 jobid

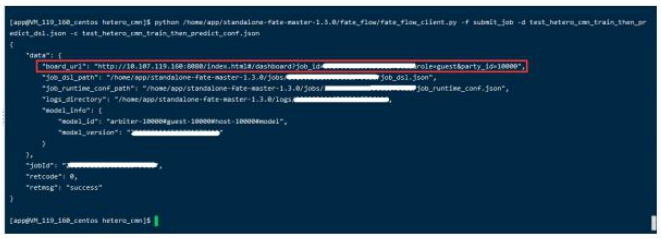

提交任务获取jobid

FATEBOARD中不同模块中的结果

④ 在 fate board 中查看中间结果，收敛情况，预估结果，预估准确率，并根据结果调整参数

3. 横向联邦推荐

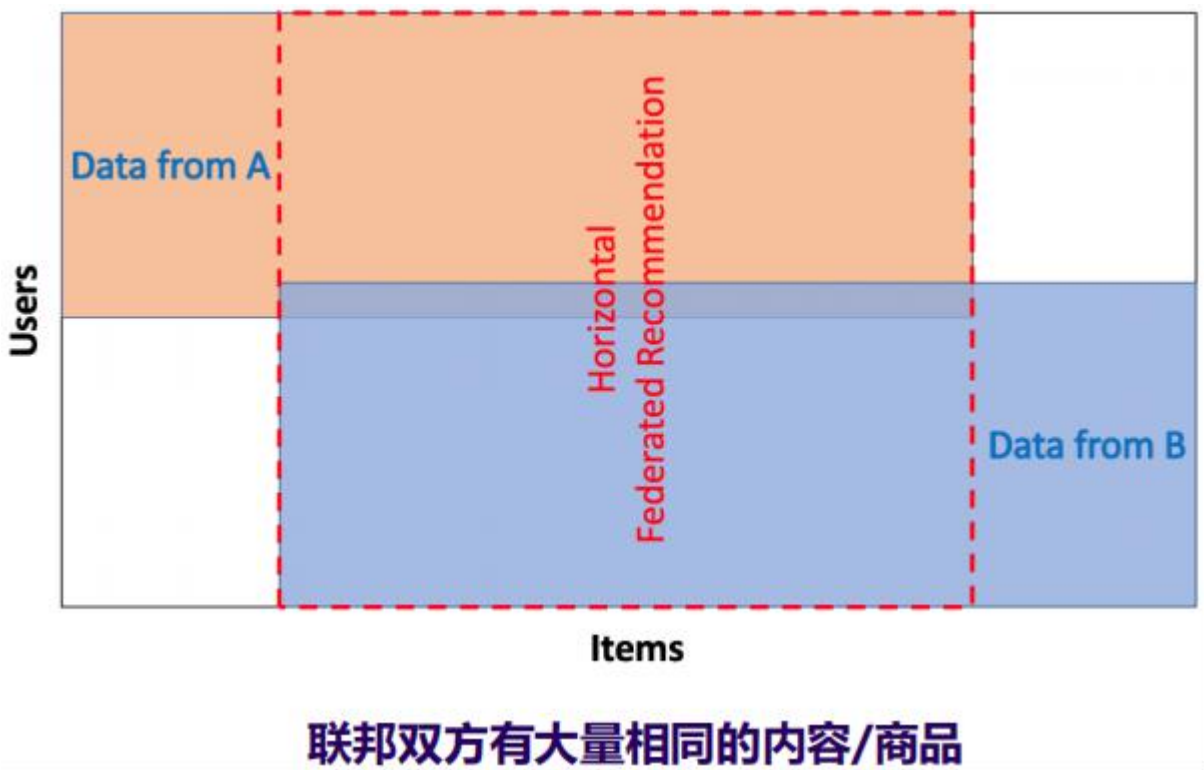

横向联邦推荐是有大量相同的物品，但各方有不同的用户。比如不同地区的电影推荐系统中，内容是一样的，但用户群体不一样。每个参与方都是一个单独的用户，但推荐的电影是一样的。

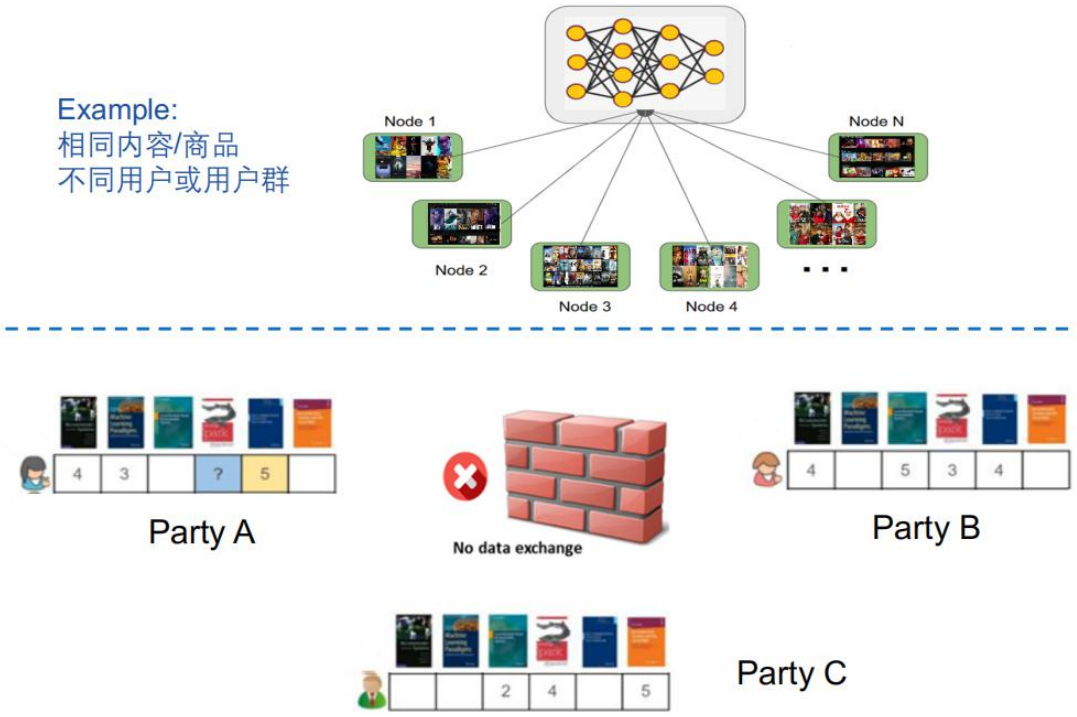

那么用户数据不出本地，如何构建推荐系统呢。

横向联邦矩阵分解：

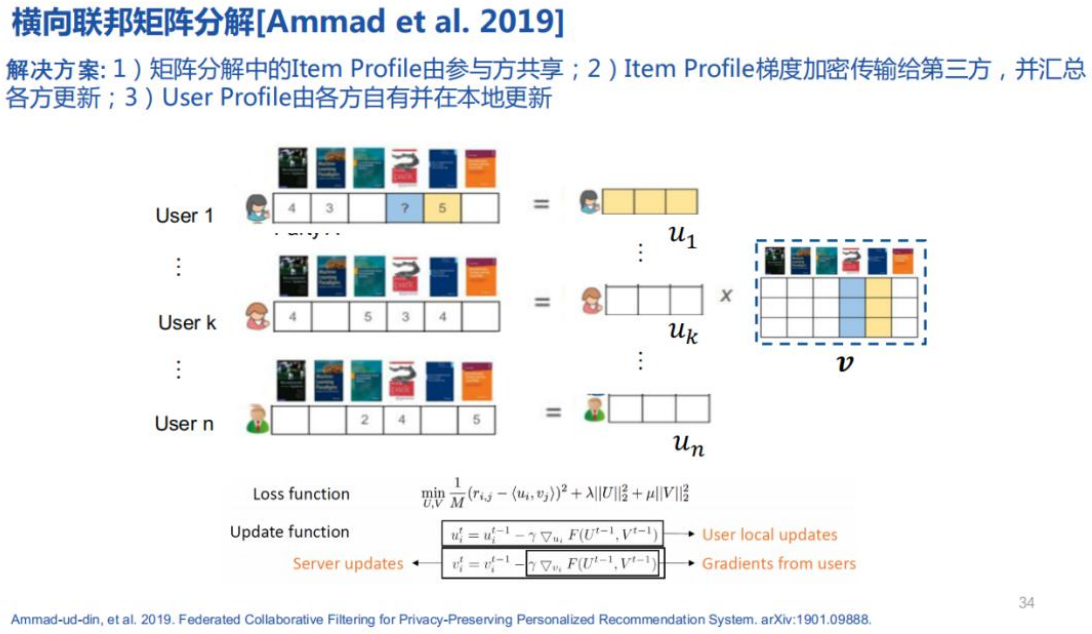

类似于纵向联邦矩阵分解，横向联邦矩阵分解是 item profile 共享。

横向联邦矩阵分解的训练过程：

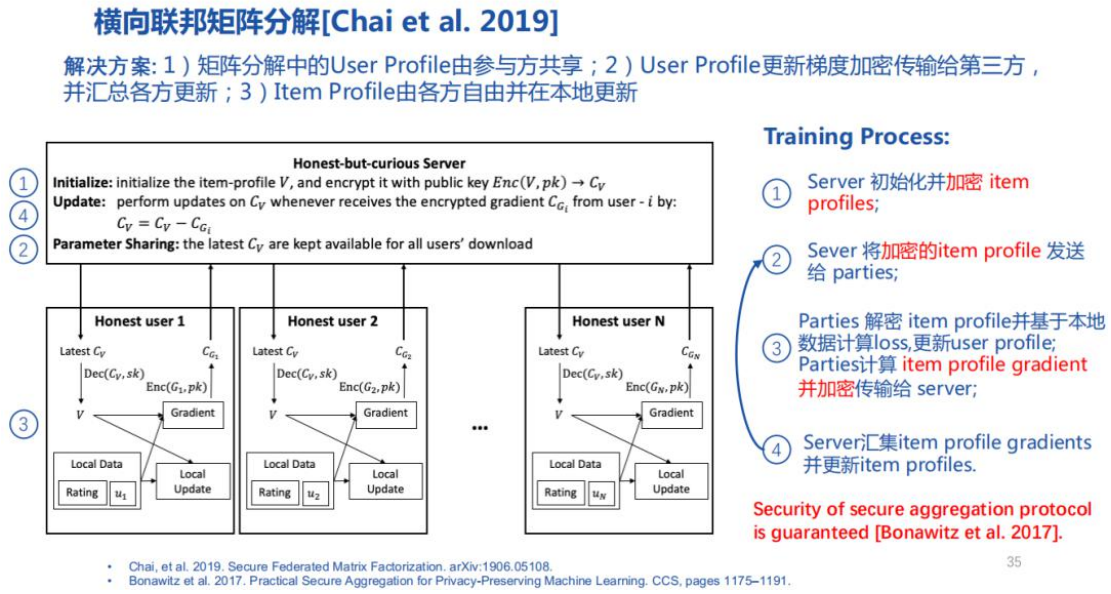

① 服务器初始化并加密 item profile

② 服务器将加密的 item profile 发送给各参与方

③ 参与方解密 item profile 并基于本地数据计算 loss，更新各自的 user profile，并将 item profile 的梯度加密传输给服务器

④ 服务器汇总 item profile 的梯度并更新 item profiles

⑤ 完成以后，每个参与方都会有各自的 user profile 和 item profile，然后利用矩阵分解进行推荐

4. 联邦矩阵分解与传统矩阵分解的效果对比

测试中，我们将联邦矩阵分解和明文中心化的传统矩阵分解算法进行比较，两者的收敛曲线一致

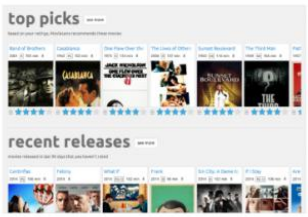

MovieLens

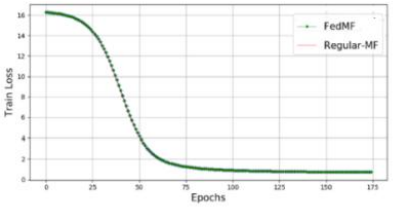

	RegularMF	FedMF
RMSE	1.3969165	1.3965372

Chai, et al. 2019. Secure federated matrix factorization. arXiv:1906.05108.

以 movielens 数据集为例，将联邦矩阵分解和明文中心化的传统矩阵分解算法进行比较。从下图中可以看出 training loss 的变化趋势基本是一致的，因此可以说联邦矩阵分解是无损的，是可以保护用户隐私的。

04

联邦推荐云服务和应用

1. 目前腾讯云上提供两种接入方式

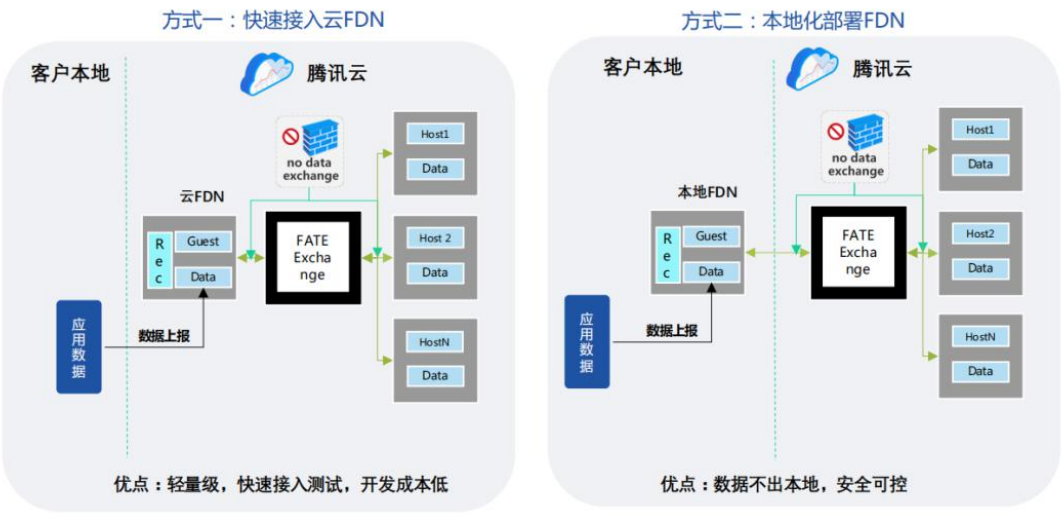

https://market.cloud.tencent.com/products/19083

客户可以将自己的数据上传到腾讯云 FDN，在加密的环境下，和数据提供方进行联邦推荐模型训练，并最终保存到云服务上。然后就可以调用训练好的模型。优点是轻量级，快速接入测试，

另外一种是本地部署 FDN，优点是数据不出本地，安全可控。将应用数据上传到本地 FDN 中，FDN 以加密的形式，与云服务和数据提供方进行联邦建模，最后将训练好的模型发送回本地 FDN 上，进行调用。

2. 联合建模预测示意图

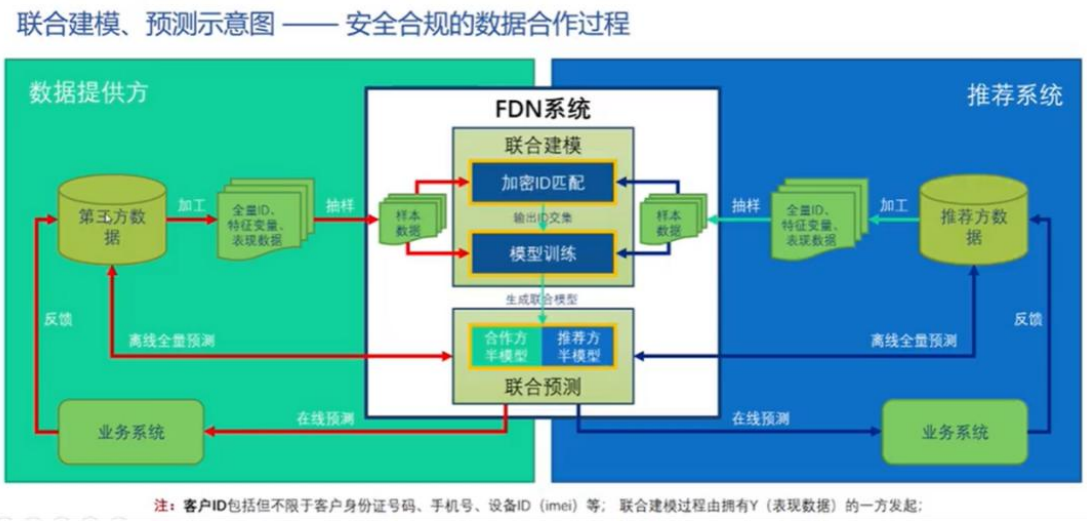

数据提供方和推荐系统分别处理自己的数据，然后进行特征加工，抽样到 FDN 系统中，FDN 会加密 id 匹配，并输出 id 交集或并集，进行模型训练。参与方和数据提供方会得到自己部分的模型，然后进行离线预测，评估效果或在线预测，不断的收集数据，不断的迭代和重复这个过程，优化模型。

3. 联邦推荐的应用

通过新闻推荐引擎和第三方数据提供方进行联邦学习，可以看到各种推荐指标都大幅提升。

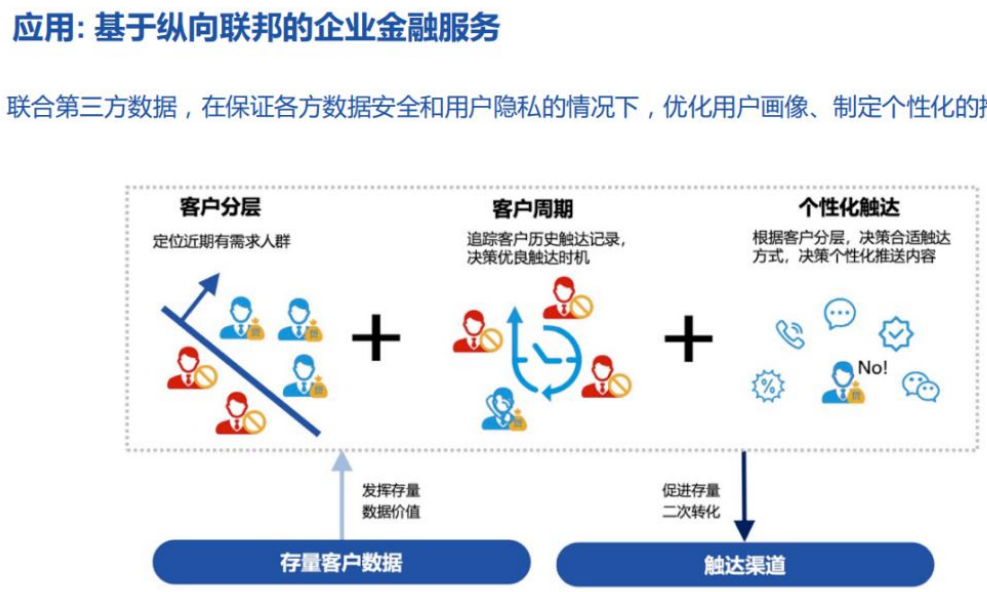

联合第三方数据，在保证各方数据安全和用户隐私的情况下，可以做到更精确的用户分层。根据用户的数据，优化用户画像，判断是否对利润有不同的偏好，从而制定个性化的推送策略。最终提高了 30%的性能。

05

总结

推荐系统是数据驱动的应用，数据对效果的提升显著。在现实中，数据孤岛、隐私保护和数据安全是亟需解决的问题。微众银行首创联邦推荐，并将其应用于多个实际场景中取得了良好的效果。

分享嘉宾：

谭奔，微众银行人工智能部高级研究员。博士毕业于香港科技大学，主要研究方向为迁移学习、推荐系统、机器学习等，目前在微众银行人工智能部门负责推荐算法研发工作，曾就职于腾讯，负责广告转化率预估、商品推荐等工作。在 KDD、AAAI、SDM、TIST 等国际学术期刊会议上发表论文 10 余篇，多次在国际数据挖掘大赛中名列前茅。

联邦推荐算法 Github 地址：

https://github.com/FederatedAI/FATE/tree/master/federatedrec

今天的分享就到这里，谢谢大家。

新一代联邦学习技术及应用实战

分享嘉宾：范涛 微众银行 高级研究员
编辑整理：Hoh Xil
内容来源：微众银行 & DataFun AI Talk
出品社区：DataFun

导读： 随着大数据的进一步发展，重视数据隐私和安全已经成为了世界性的趋势， 同时，大多数行业数据呈现数据孤岛现象，如何在满足用户隐私保护、数据安全和政府法规的前提下，进行跨组织的数据合作是困扰人工智能从业者的一大难题。而“联邦学习”将成为解决这一行业性难题的关键技术。今天会和大家分享下微众银行主导的新一代联邦学习技术及应用，而 FATE 则是联邦学习落地的一个工业级开源平台。

今天的介绍会围绕下面五点展开：

- 联邦学习背景介绍
- 纵向联邦学习
- 横向联邦学习
- 应用案例
- FATE：联邦学习开源平台

联邦学习背景介绍

首先和大家分享下联邦学习的背景。

1. AI 落地的理想与现实

我们知道 AI 落地的时候，会遇到很多现实的问题：

- 现实中，我们的数据质量是非常差的，比如聊天数据中有很多噪音；数据标签，收集是比较困难的，很多场景中的数据是没有标签的；

- 数据是分散的，（这也是最重要的一点）每家应用的数据不一样，比如腾讯用的是社交属性数据，阿里用的是电商交易数据，微众用的是信用数据，都是分散来应用的。现实中，如何进行跨组织间的数据合作，会有很大的挑战。

2. 国内数据监管法律体系研究

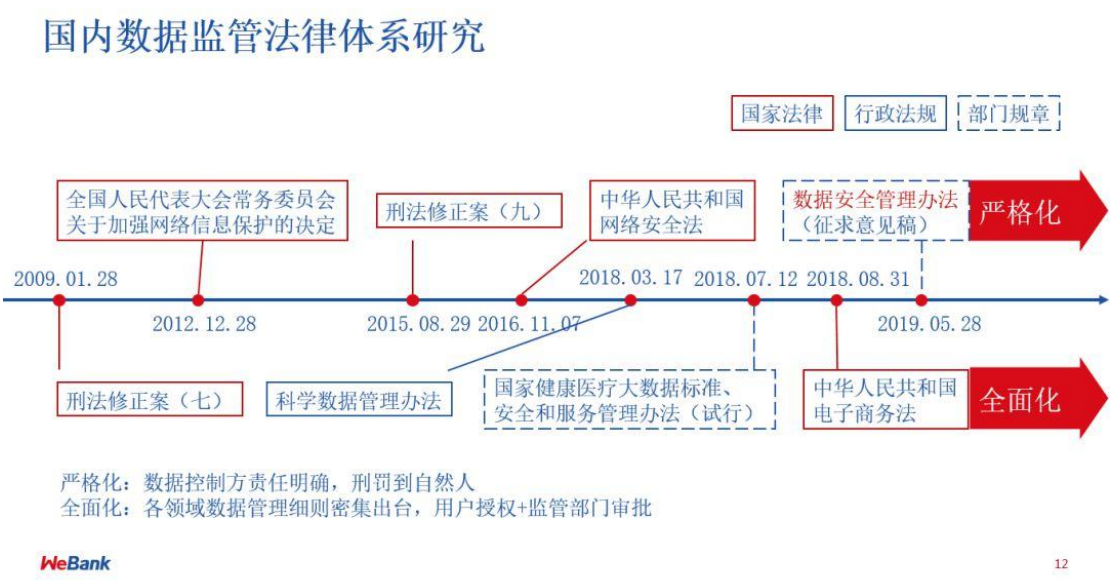

从 09 年到现在的 10 年时间内,国家关于数据的法律条例是趋向于严格化的，同时趋向于全面化，每个细分领域都纷纷出台了相应的条例和条款。相对来讲，让之前可行的一些数据合作方案变得不太可行。

3. 基于联邦学习的技术生态

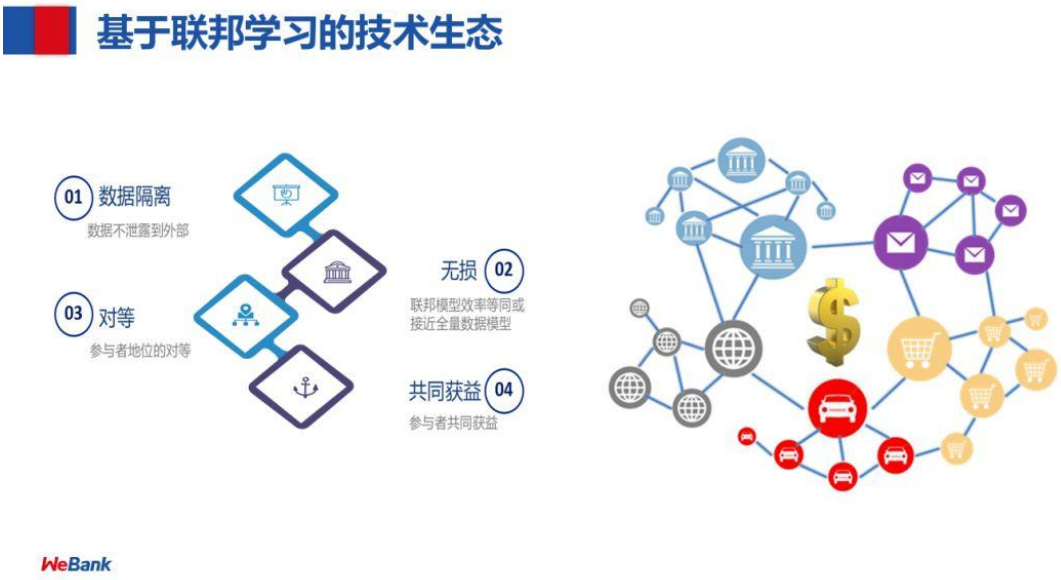

针对上述问题，微众银行提出了基于联邦学习的技术生态，特点如下：

- 数据隔离：联邦学习的整套机制在合作过程中，数据不会传递到外部。
- 无损：通过联邦学习分散建模的效果和把数据合在一起建模的效果对比，几乎是无损的。
- 对等：合作过程中，合作双方是对等的，不存在一方主导另外一方。
- 共同获益：无论数据源方，还是数据应用方，都能获取相应的价值。

4. 联邦学习的分类体系

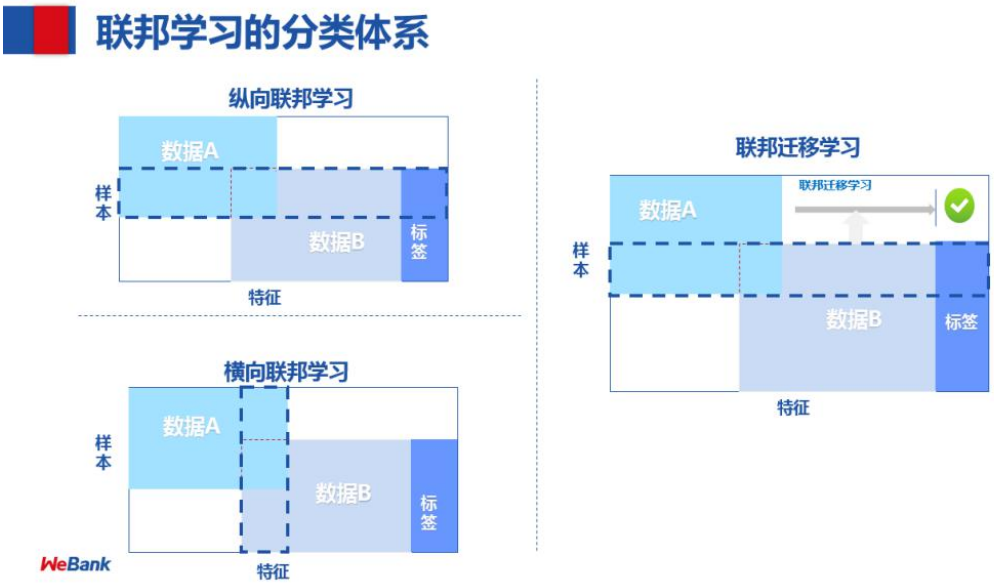

联邦学习的分类体系，包括：

纵向联邦学习，两个数据集的用户（U1, U2, …）重叠部分较大，而用户特征（X1, X2, …）重叠部分较小；

横向联邦学习，两个数据集的用户特征（X1, X2, …）重叠部分较大，而用户（U1, U2, …）重叠部分较小；

联邦迁移学习，通过联邦学习和迁移学习，解决两个数据集的用户（U1, U2, …）与用户特征重叠（X1, X2, …）部分都比较小的问题。

下面，重点分享下纵向联邦学习和横向联邦学习。

纵向联邦学习

1. 联合建模需求场景

举个例子：微众与合作企业进行联合建模，比如做信贷逾期模型，微众有 Y 数据，包括标签数据，逾期记录，用这样的数据可能会建一个很好的模型，但我们希望用更多的数据，比如合作方的标签数据和画像数据来更大的提升风控模型的效果和稳定性。

传统模式的问题是：

合作企业缺乏 Y 无法独立建立模型，需要微众把 Y 数据，带入到合作方的生产环境建模，但是由于国家的数据保护条款和各企业自身对数据的严格规定，得到的 X 数据不能全量的传输到微众。

针对这个问题，通过纵向联邦学习来解决。如右图，两边的数据都有共同的 ID，特征是完全不一样的，可以通过一方特征来弥补另一方特征的不足。

2. 同态加密技术保护隐私

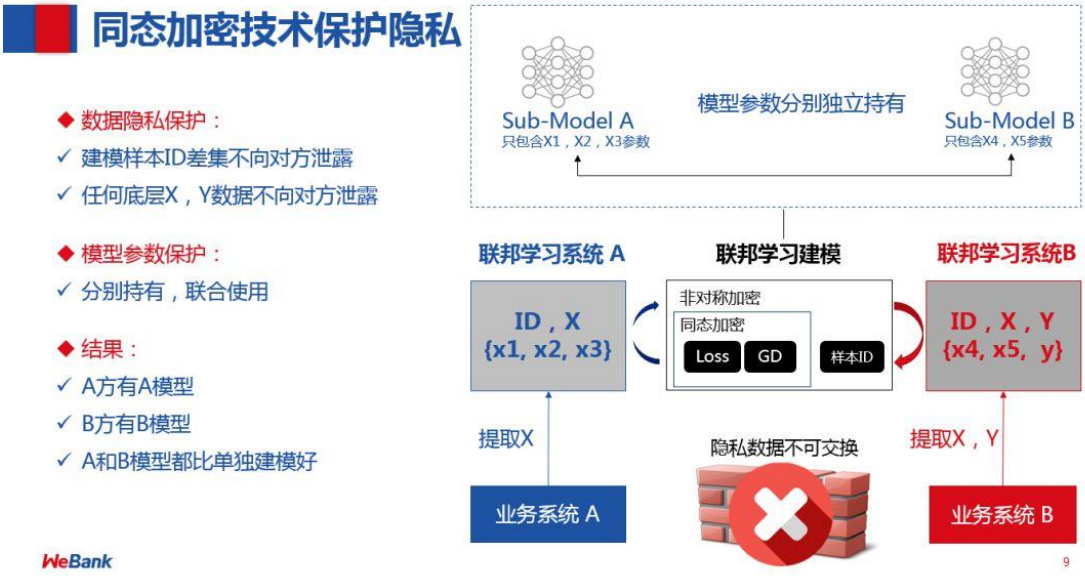

纵向联邦学习的技术实现，首先应做好两点，来保护数据隐私：

- 建模样本 ID 差集不向对方泄露，在合作之初需要进行用户匹配，需要找出用户的交集，但是不能泄露差集，因为这是企业最核心的资产。

- 任何底层（X，Y）数据不向对方泄露，建模过程中如何保证数据不被泄露。

解决方案：

通过 RSA 和 Hash 的机制，保证双方最终只用到交集部分，且差集部分不向对方泄露。

采用同态加密技术，这个过程中，各方的原始数据，以及数据加密态都没有被传输。交互部分，双方通过损失中间结果，用同态加密的机

制进行交互，模型训练完之后，会各自得到一个模型，各自的模型会部署在各自的一方，就是如果我只提供了 3 个特征，那么我只有 3 个特征的模型，只提供 2 个特征，就只有 2 个特征的模型，任何一方的模型都没法单独去应用，只有共同应用的时候，才能进行决策。

3. 基于隐私保护的样本 id 匹配

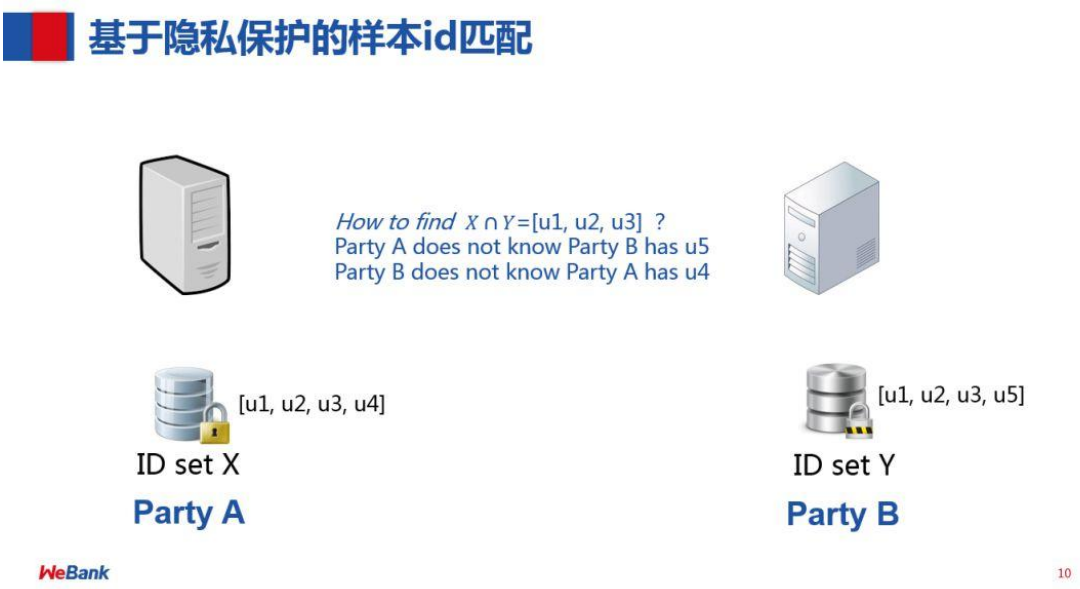

刚才提到基于隐私保护的样本 id 匹配，和大家分享下具体的技术方案。比如，A 方有 [u1，u2，u3，u4] 四个用户，B 方有 [u1，u2，u3，u5]，那么整个过程中，如何保证双方知道 [u1，u2，u3]，而 A 方不知道 B 方有 [u5]，B 方不知道 A 有 [u4]？

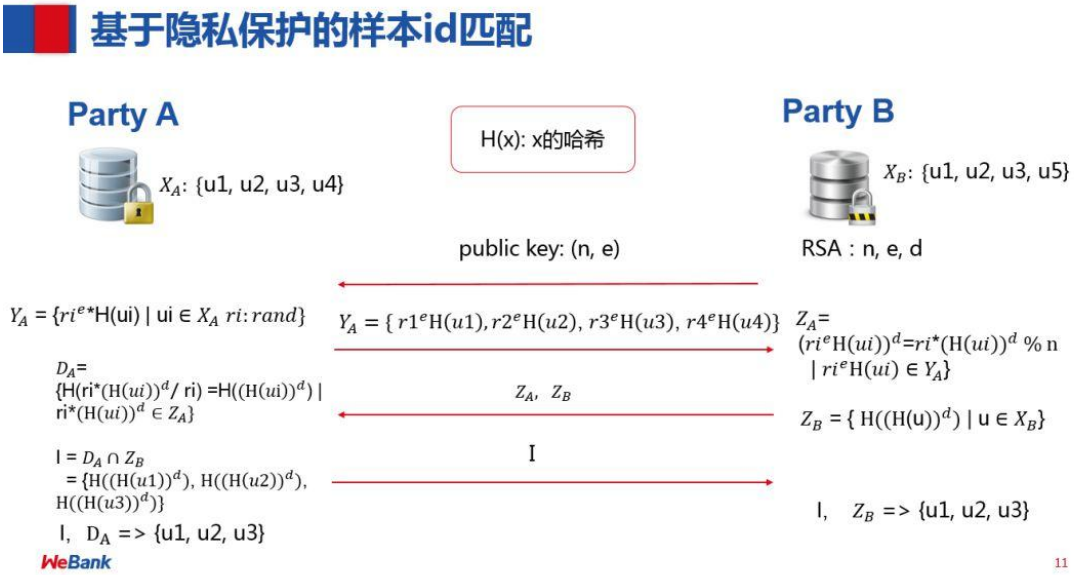

这里是通过 RSA 和 Hash 的机制做到的，B 方会作为公钥的生成方，会把公钥给到 A 方，A 方基于 Hash 引用一个随机数，再交互传给 B 方，B 方同时做 Hash 然后传给 A 方，A 方会最后做一个结果的交集。整个过程中，你可以看到没有任何一个明文数据传递过来，即使采用暴力或者碰撞的方式，依然解析不出原始的 id。通过这套机制，我们很好的保护了双方的差集部分。

4. 同态加密

同态加密

- 全同态或者半同态 Full Homomorphic Encryption and Partial Homomorphic Encryption
- 数据层面的信息保护 Data-level information protection

Paillier **半同态加密** Partially homomorphic encryption

Addition :	[[u]] + [[v]] = [[u+v]]
Scalar multiplication:	n[[u]] = [[nu]]

Rivest, R. L.; Adleman, L.; and Dertouzos, M. L. 1978. On data banks and privacy homomorphisms. Foundations of Secure Computation, Academia Press, 169 - 179.

分享了匹配过程中隐私保护的问题，接下来分享一个通用的技术，同态加密。

刚才提到建模过程中，引用了同态加密技术，比如对两个数字进行加密，加密后两个数字的密文可以进行数学运算，比如加法，其结果依然是密文，对密文解密后得到的结果和它们明文的加法结果是一样的。

联邦特征工程

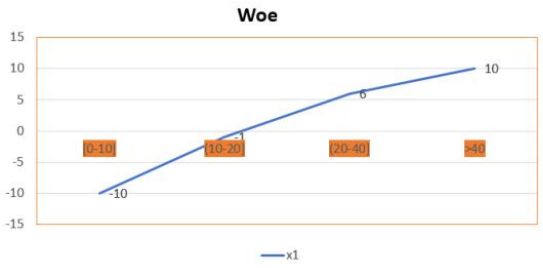

特征IV值

特征	IV
x1	0.3
x2	0.2
x3	0.4
x4	0.01
x5	0.05

问题：在保护双方隐私下，A侧(含X)和B侧(含X, Y)特征如何计算WOE和IV？
难点：

- A 侧只有特征x，没有y; 计算Woe和IV得同时依赖x,y (B侧特征Woe &IV 可以本地计算)
- A侧不能对B侧暴露x，B侧不能对A侧暴露y
- 最终只能让B侧获得所有特征Woe & IV

通过这样的同态加密技术，我们把它应用到机器学习，包括特征工程中。接下来会重点介绍，联邦机制下特征工程和机器学习建模的一些细节。

我们知道特征工程是机器学习建模中非常重要的一环，在联邦机制下，如何完成联邦特征工程？尤其 A 方只有 X 没有 Y，如果想做一个 WOE 或者 IV 值的计算是非常困难的。那么如何在联邦学习的机制下，A 方利用 B 方有 Y 的数据计算 WOE 和 IV 值，且在这个过程中 B 方没有泄漏任何数据？

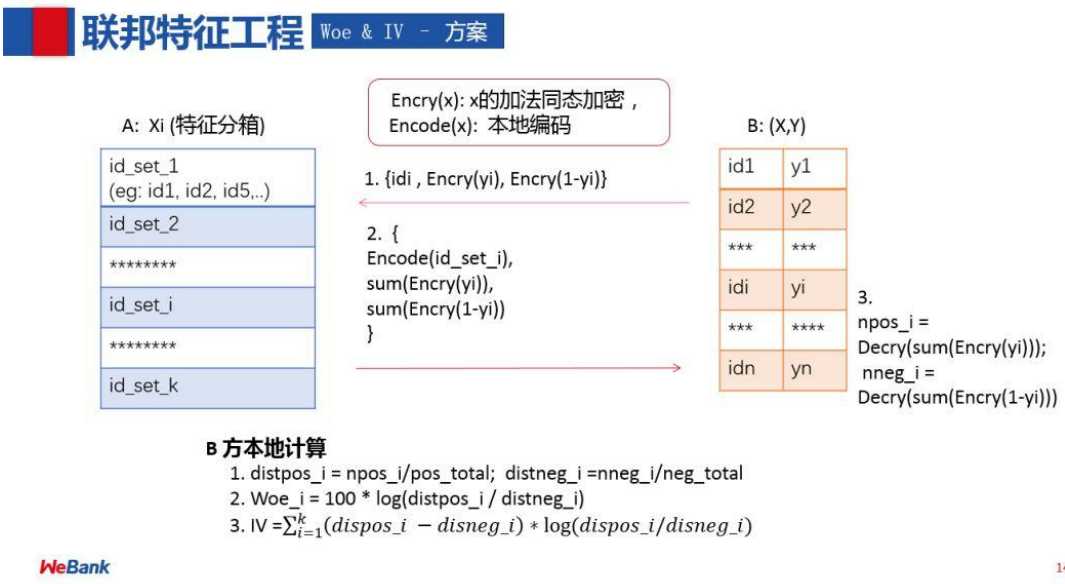

首先，B 方对 y 以及 1-y 进行同态加密，然后给到 A 方，A 方会对自己的特征进行分箱处理，进而 A 方在分箱中进行密文求和的操作，再把结果给到 B 方进行解密，然后算出 A 方每个特征分箱的 WOE 值和 IV 值。在这个过程中，没有明文数据传输，A 方不知道 B 方的 y 值，同时 B 方也不知道 A 方每个特征的值是什么，从而在安全隐私保护的情况下，完成了特征工程的计算。

同态加密在机器学习上应用

多项式近似 Polynomial approximation for logarithm function

$$l(w) = \log(1+\exp(-yw^T x)) \approx \log 2 - \frac{1}{2}yw^T x + \frac{1}{8}(w^T x)^2$$

$$\nabla l(w) = \left(\frac{1}{1+\exp(-yw^T x)} - 1\right)yx \approx \left(\frac{1}{2}yw^T x - 1\right)\frac{1}{2}yx$$

加密计算 Encrypted computation for each term in the polynomial function

$$loss = \log 2 - \frac{1}{2}yw^T x + \frac{1}{8}(w^T x)^2$$

$$[[loss]] = [[\log 2]] + (-\frac{1}{2}) * [[yw^T x]] + \frac{1}{8}[[(w^T x)^2]]$$

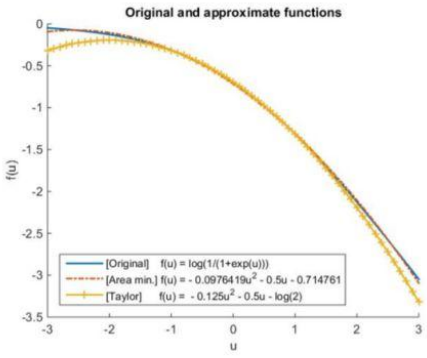

- Kim, M.; Song, Y.; Wang, S.; Xia, Y.; and Jiang, X. 2018. Secure logistic regression based on homomorphic encryption: Design and evaluation. JMIR Med Inform 6(2)
- Y. Aono, T. Hayashi, T. P. Le, L. Wang, Scalable and secure logistic regression via homomorphic encryption, CODASPY16

WeBank 15

说完特征工程，再讲下最核心的机器学习，比如常见的逻辑回归，这是经典的 loss function 和梯度，刚才说的同态加密的特性，目前用到的是半同态的技术。所以，需要对 loss function 和梯度进行多项式展开，来满足加法操作。这样就可以把同态加密的技术应用在 loss function 和梯度中。

5. SecureBoost

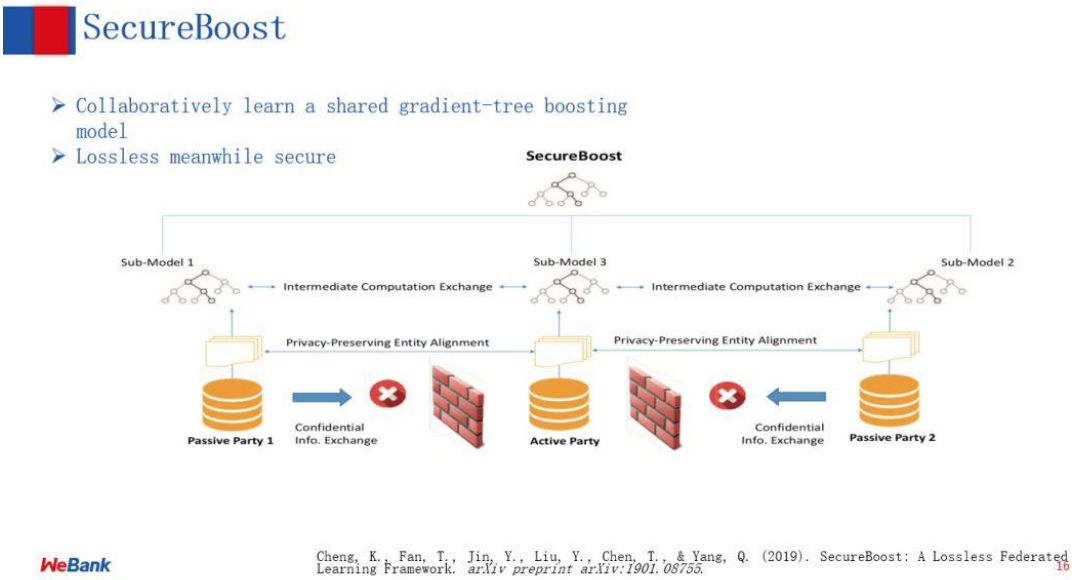

在很多现实的业务应用中，树模型是非常重要的，尤其是 XGBoost，对很多应用来说，提升非常明显，因而被业界广泛使用。在联邦机制下，如何构建这样的树？这里我们提出了 SecureBoost 技术方案，双方协同共建一个 boosting 树，我们证明了整个过程中是无损的。图中为一些 paper 和链接，感兴趣的小伙伴可以查找下。

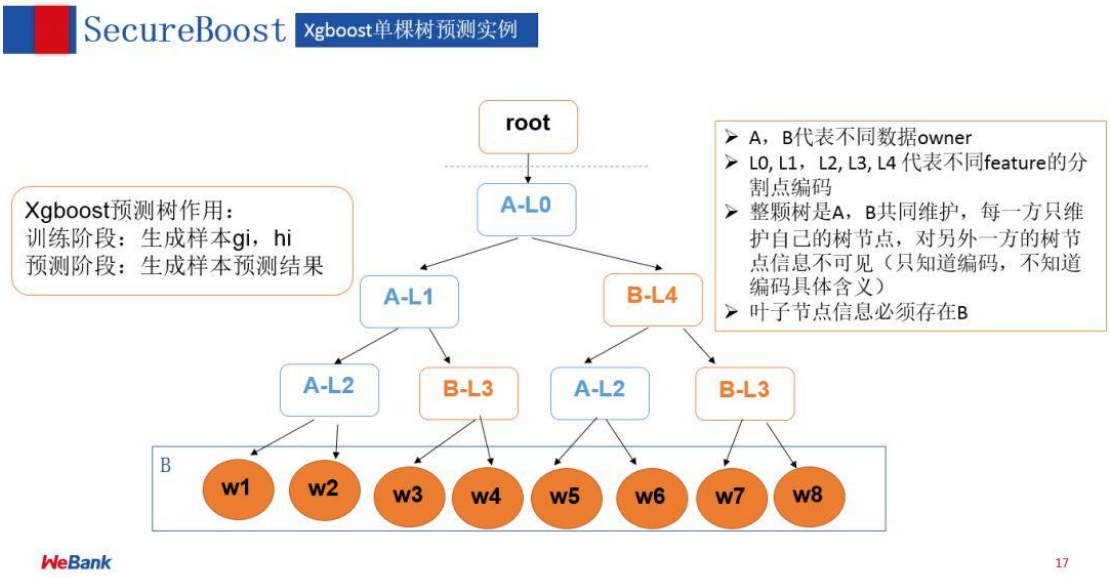

SecureBoost 的核心技术点。上图为基于 SecureBoost 构建的树，A 和 B 代表不同数据的 owner，L0，L1，L2，L3，L4 代表不同 feature 的分割点编码，整颗树由 A 和 B 共同维护，每一方只维护自己的树节点，对另外一方的树节点信息不可见（只知道编码，不知道编码具体含义），保证整个训练和预测过程都是安全的。

构建 SecureBoost 核心的关注点是如何构建分裂节点，尤其一方只有 X，另一方有（X，Y）的情况。

基于同态加密的机制，B 方会把 1 阶梯度和 2 阶梯度传递给 A 方，A 方基于分箱之后的结果算出每个分箱中的 1 阶梯度和 2 阶梯度的求和值，然后传递给 B 方，B 方会解密这个求和值，算出信息增益，然后给到 A 方。求分裂节点的核心就是如何算信息增益，通过这样的机制，就可以算出每个分裂节点，同时没有泄露任何隐私信息。

横向联邦学习

举个例子：微众和合作行共建反洗钱模型，期望优化反洗钱模型。因为，各自利用自家样本建立的反洗钱模型的效果和稳定性都不能满足现实需求。我们可以利用联邦学习的机制，充分利用多家的反洗钱样本，同时在不泄露样本的条件下，构建一个非常大的模型，可以看到横向联邦学习中，微众银行和合作行，都是有（X，Y）的。

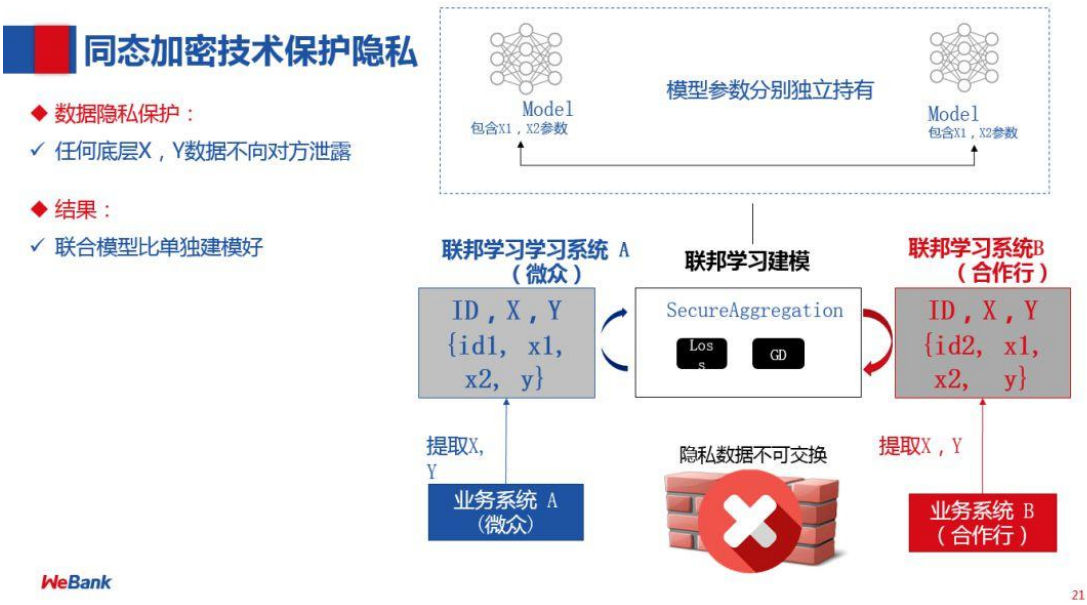

技术层面上，采用了同态加密、Secret-Sharing 技术，整个过程中，双方交互的是模型和梯度，同时引入了 SecureAggregation 机制，让交互过程中的梯度也是很难被反解的。最终，大家都会得到一个相同的模型。横向联邦学习，综合多家样本，可以让模型更加稳健，效果更好。

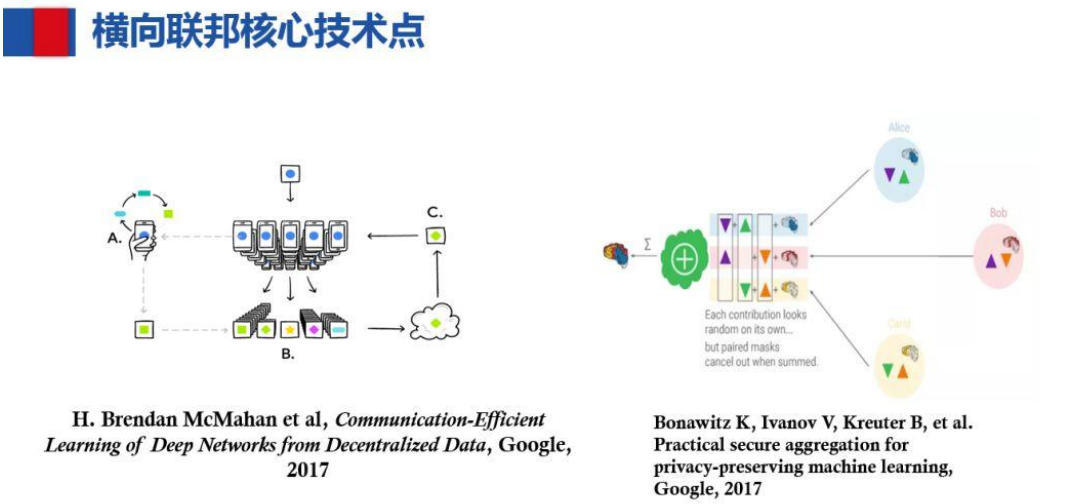

下面分享下横向联邦学习的核心技术点，这是 Google 的两篇 paper ，第一个是每个端自己训练模型，然后发给云端进行综合各个模型的效果，但是这里面会有个问题，就是模型本身也可能会泄露隐私信息，所以引入了 SecureAggregation，各方在传输模型的时候会加一些噪音，通过云端来消除这些噪音，使数据和模型得到保护。

应用案例

联邦学习目前已经赋能众多关键领域，取得了不错的效果：

- 银行+监管，联合反洗钱建模
- 互联网+银行，联合信贷风控建模
- 互联网+保险，联合权益定价建模

- 互联网+零售，联合客户价值建模

以其中的两个场景以及在视觉领域的应用来说明：

1. 保险业个性化定价

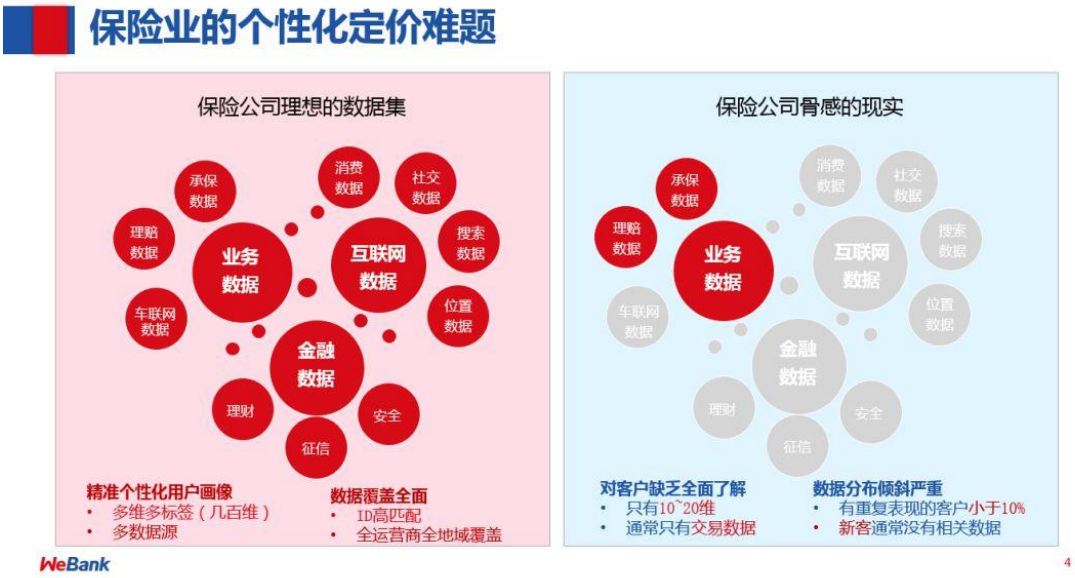

对于保险公司如果想做个性化的定价，是一件非常困难的事情，保险公司只有一些业务数据、承保数据和理赔数据，通过这样的数据，对用户做千人千面的定价是非常难的。通过联邦学习机制，可以融合多个数据源，来构建这样一个千人千面的定价。

这是我们目前在做的案例，当你购买权益产品之后，如果违章了，可以帮你免赔，在这里每个人看到的价格是不一样的，这就是我们通过联邦学习帮它们做的。我们综合了出险数据和互联网数据，如标签、用户画像，构建了一个基于保险定价的联邦学习产品。

2. 小微企业信贷风险管理

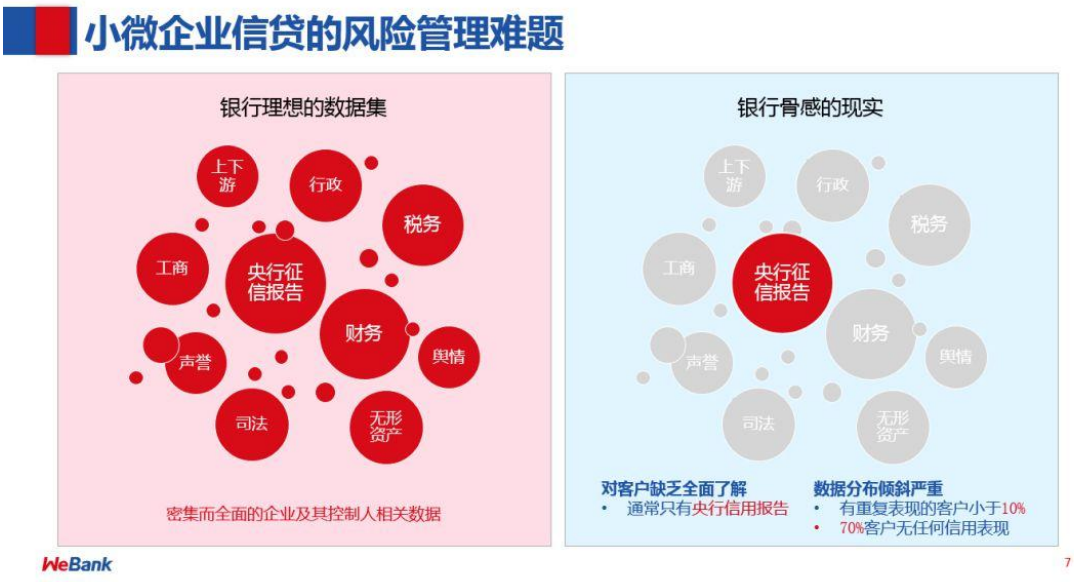

很多时候对小微企业我们只有央行的征信报告，想要更精准的刻画企业的信用状况，需要更多的数据，比如发票、工商、税务的数据。

这是我们的一个案例，我们利用了开票金额和央行的征信数据共建了一个联邦学习模型，来预估每个企业的风险。

3. 联邦学习在视觉领域的应用

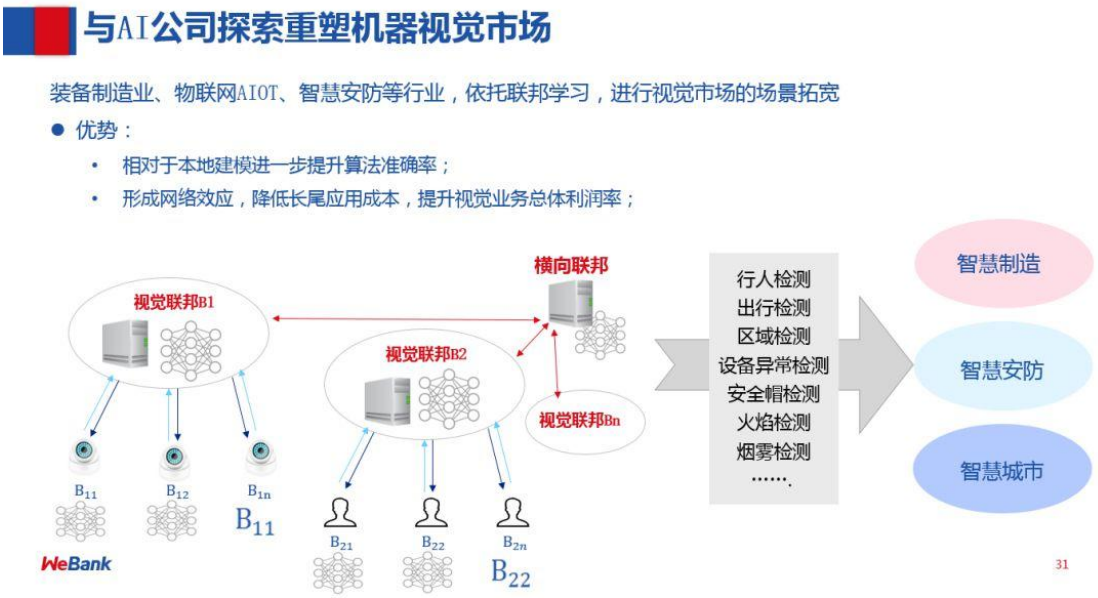

与 AI 公司探索重塑机器视觉市场，利用联邦学习的机制，相对于本地建模，进一步提升算法准确率，并且形成网络效应，降低长尾应用成本，提升视觉业务总体利润率。

这是联邦视觉在城市管理上的应用。

联邦学习开源平台：FATE

通过刚刚的介绍，相信大家对联邦学习能够做什么，有了大体的认识。而联邦学习想要落地，不可避免的就是开源，接下来为大家介绍下微众银行开源的联邦学习平台——FATE：

FATE 定位于工业级联邦学习系统，能够有效帮助多个机构在符合数据安全和政府法规前提下，进行数据使用和联合建模。

设计原则：

支持多种主流算法：为机器学习、深度学习、迁移学习提供高性能联邦学习机制。

- 支持多种多方安全计算协议：同态加密、秘密共享、哈希散列等。
- 友好的跨域交互信息管理方案，解决了联邦学习信息安全审计难的问题。

FATE 的 Github 地址：

https://github.com/FederatedAI/FATE

1. 里程碑

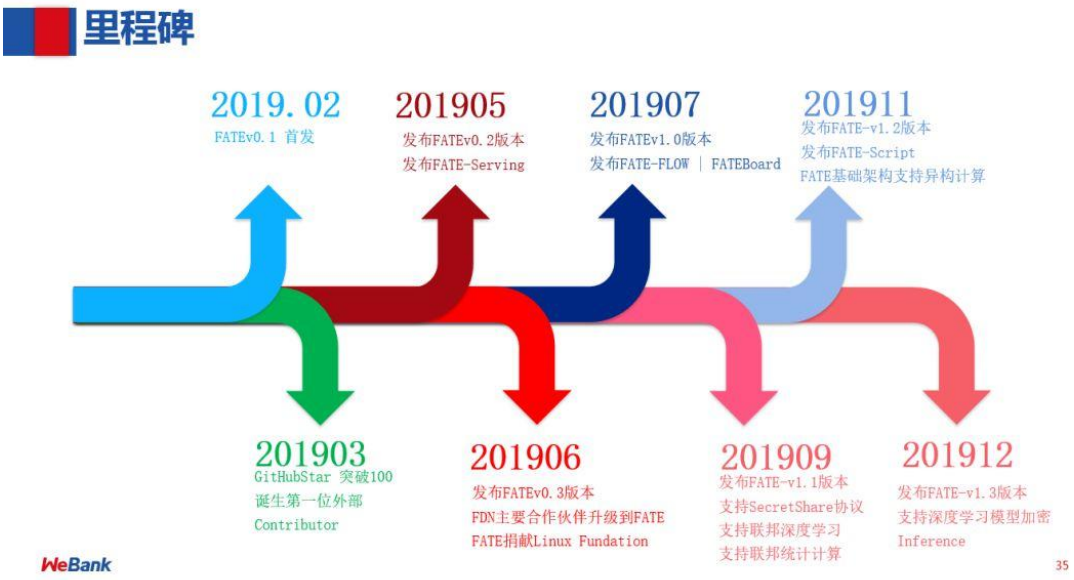

介绍下 FATE 的里程碑，FATE 在今年 2 月份首发了 0.1 版本，3 月份的时候有了第一位外部 Contributor,同时 GitHubStar 突破 100，5 月份发布了 0.2 版本，支持了联邦特征工程和在线推理，6 月份发布了 0.3 版本，把主要的合作伙伴迁移到了 FATE，并把 FATE 捐献给了 Linux Fundation，8 月份发布了 1.0 版本，支持 FATE-Flow 和 FATE-Board，还有些后续的计划，大家可以了解下。

2. 挑战

联邦学习从一项技术真正成为一个关键系统和产品方案时，我们遇到了下述挑战：

- 一站式建模过程的联邦化
- MPC 协议下分布式算法（on WAN）易理解和易维护
- 跨站点数据传输安全性和可管理性，如何让交互部分是可以被管理和被审计的。
- 异构基础架构自适应，联邦学习可能会运行在 CPU、GPU 和端上，如何让上层不受底层的变化而变化。

3. 技术架构

技术架构总览

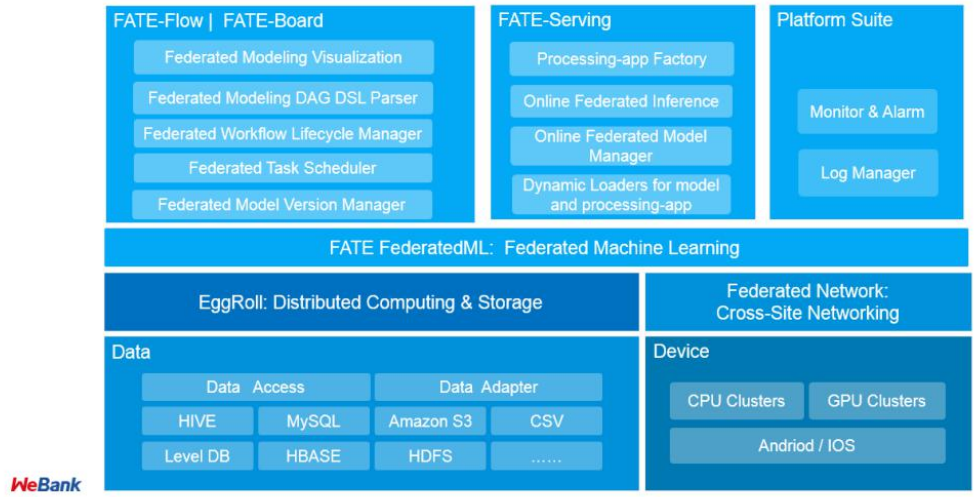

接下讲下 FATE 的整体架构：

- EggRoll：分布式计算和存储的抽象；
- Federated Network：跨域跨站点通信的抽象；
- FATE FederatedML：联邦学习算法模块，包含了目前联邦学习所有的算法功能；
- FATE-Flow | FATE-Board：完成一站式联邦建模的管理和调度以及整个过程的可视化；
- FATE-Serving：联邦学习在线推理模块。

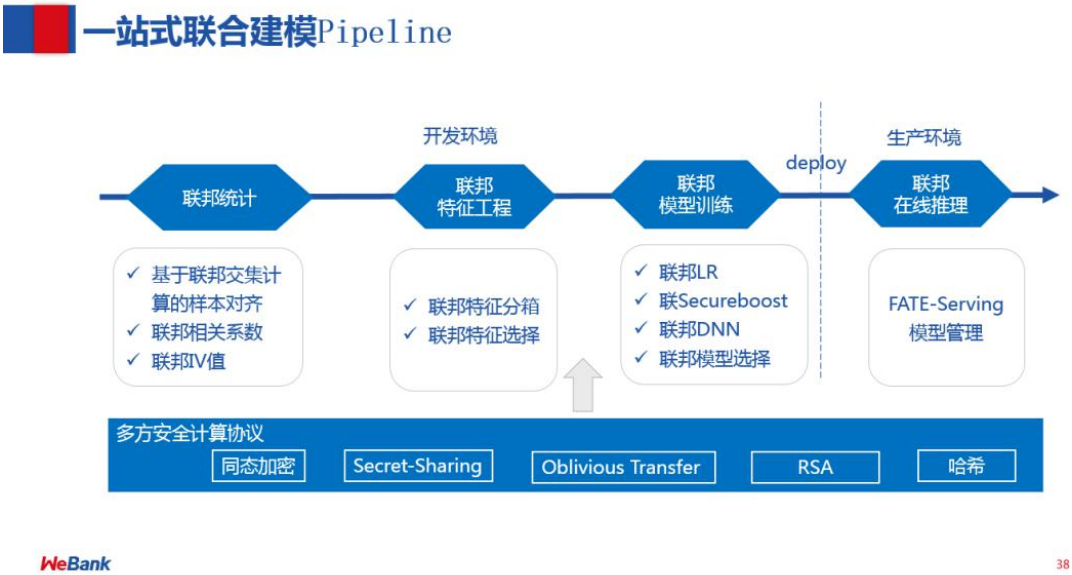

一站式联合建模 Pipeline，其流程：在开发环境下，其流程是从联邦统计->联邦特征工程->联邦模型训练，当上线部署的时候会有联邦在线推理模块，底层则会采用多方安全计算协议去支持上层各种联邦算法。

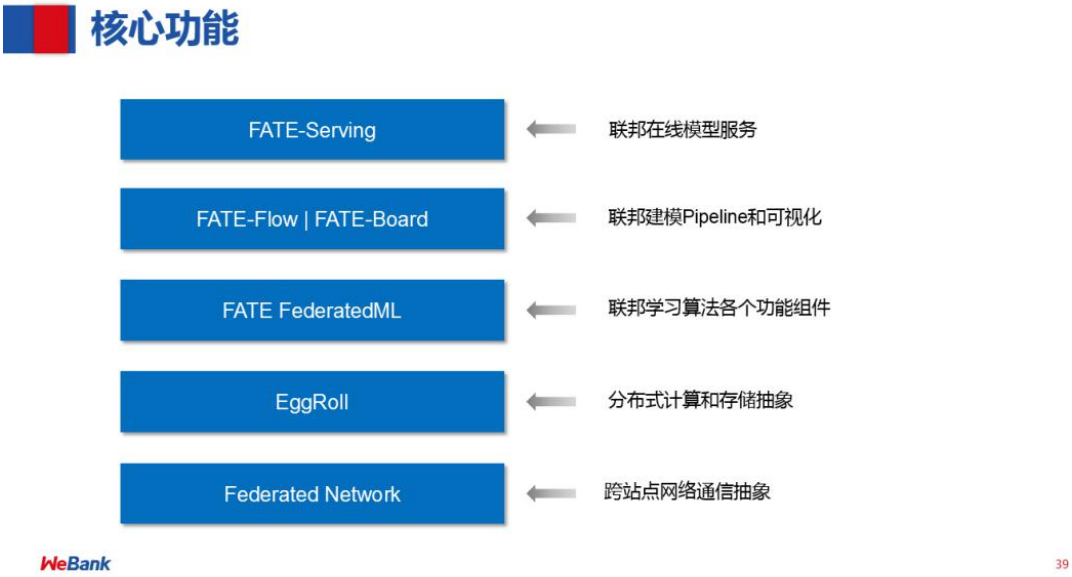

这是 FATE 的五大核心功能，这里不再复述。

① FATE FederatedML

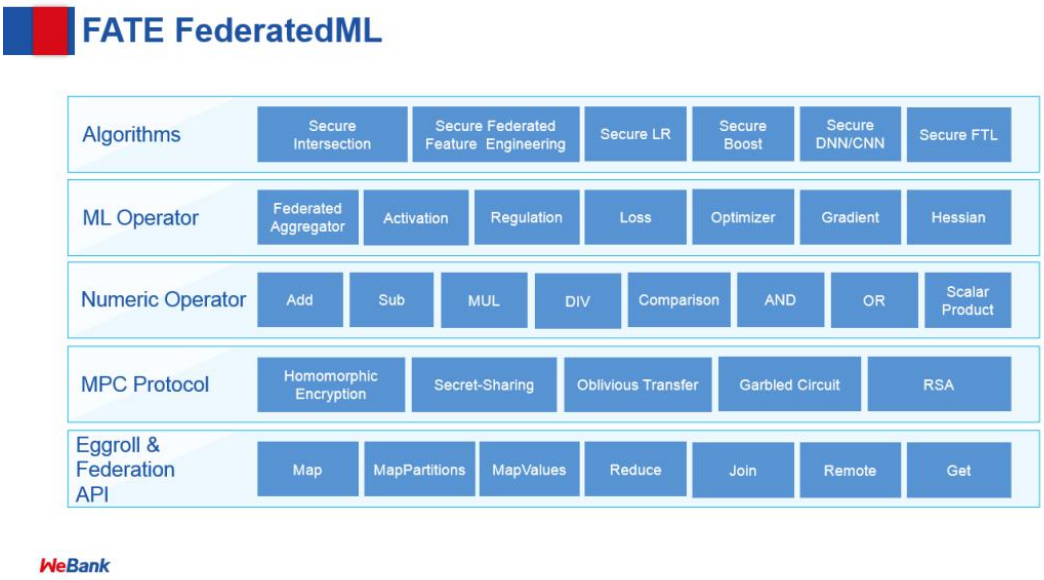

FATE FederatedML：

- EggRoll & Federation API：底层是 EggRoll 的算子，比如 Map 和 MapValues，Remote 和 Get 可以完成整个分布式计算的抽象；
- MPC Protocol：包括同态加密、秘密共享等多种多方安全协议，
- Numeric Operator：会抽象出数学算子，比如加法或者乘法；
- ML Operator：用建好的数学算子构建机器学习算子，而不用管底层的安全协议是什么；
- Algorithms：有了 ML 算子之后就构建各种算法模型。

② EggRoll

EggRoll,是整个分布式计算和存储的抽象。面向算法开发者,通过 API 实现分布式计算和存储。上面为 EggRoll 的整体架构图。

③ Federated Network

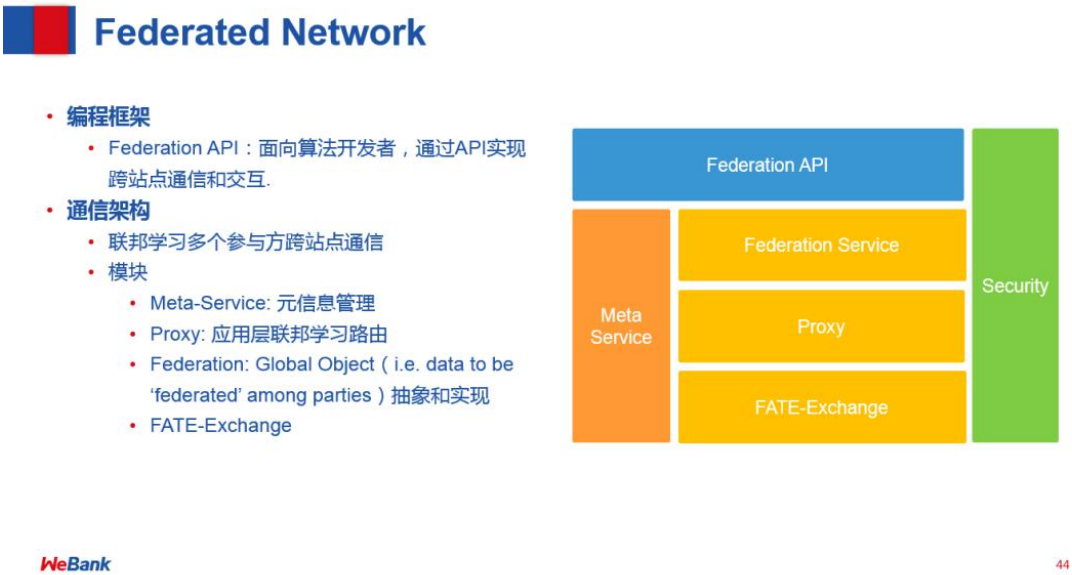

Federated Network：联邦学习不仅需要分布式计算，还需要跨站点通信和交互，上层会提供一个 API 给到开发者，通过 Remote 和 Get 就可以完成数据点的收发。具体模块，如上图。

④ FATE-Flow

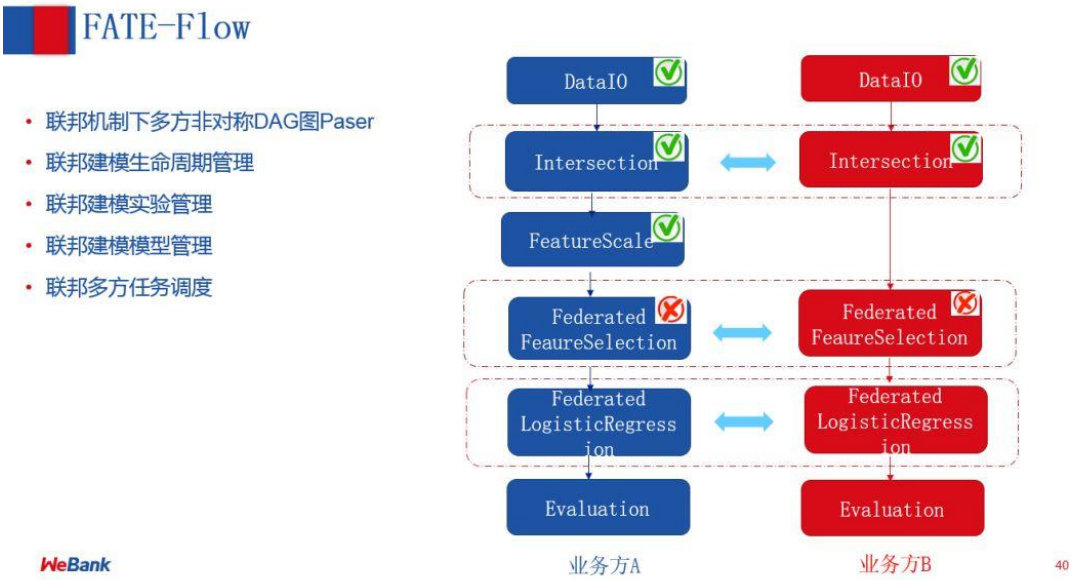

FATE-Flow：整个一站式联合建模 Pipeline 需要统一的调度管理。右边为 A、B 双方的建模流程，某些步骤是 A、B 双方共有的，某些步骤可能只有一方有，所以 FATE-Flow 完成了下述管理：

- 联邦机制下多方非对称 DAG 图 Paser
- 联邦建模生命周期管理
- 联邦建模实验管理

- 联邦建模模型管理

- 联邦多方任务调度

⑤ FATE-Board

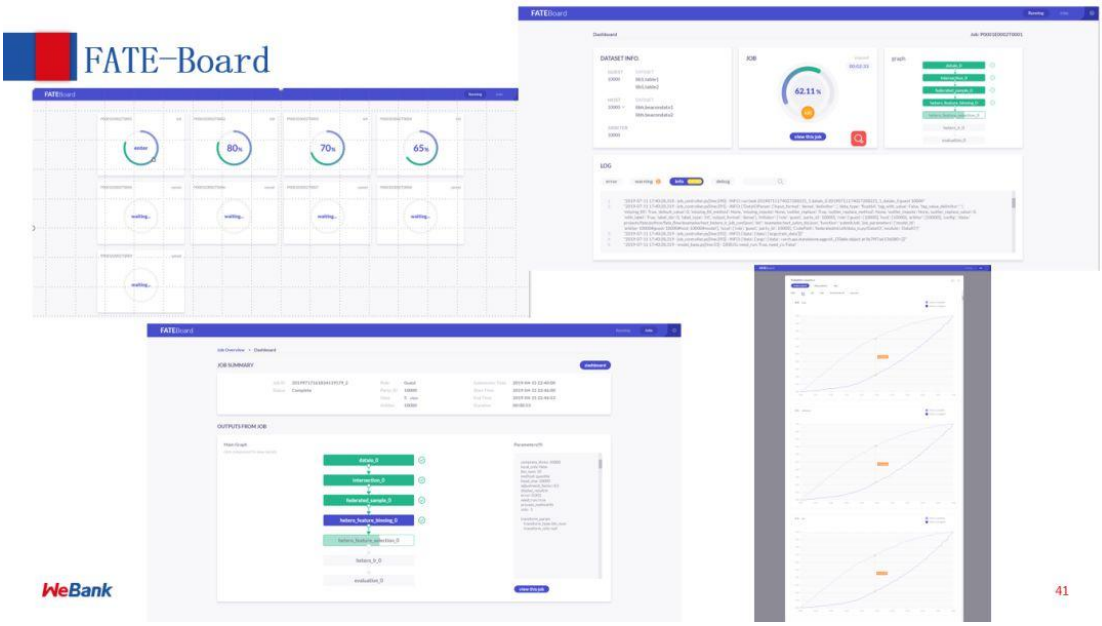

FATE-Board 的目的是实现整个联合建模 Pipeline 可视化追踪，记录联邦学习的全过程，可以监控建模进行到哪个步骤，以及模型效果如何。

4. FATE 部署架构

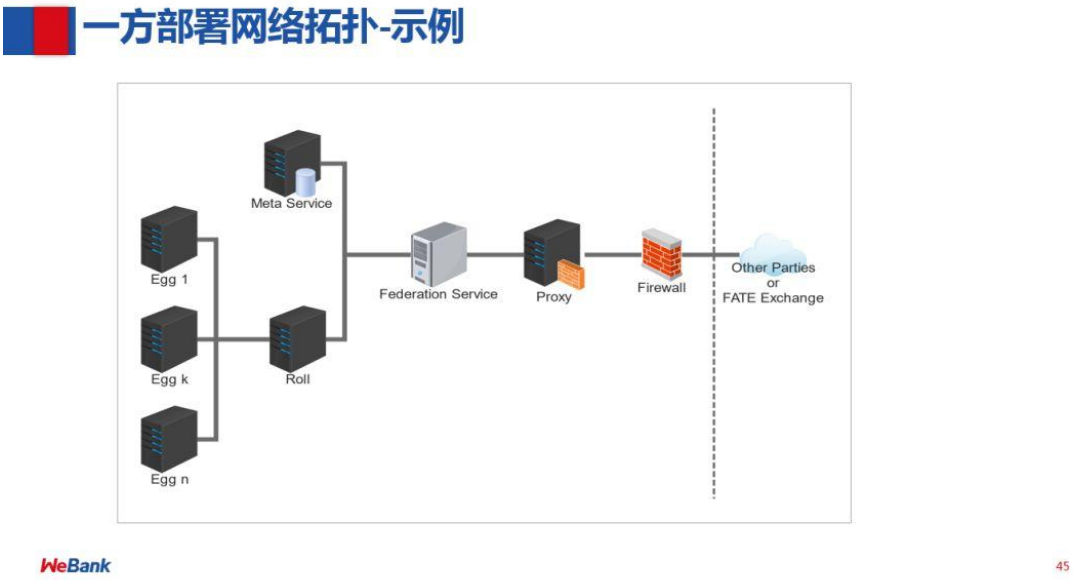

这是 FATE 的部署架构，每一方都是差不多的，是一个对称的结构，通过 EggRoll 实现分布式计算和存储，通过 Federation Service 和外部交互。

5. FATE 应用

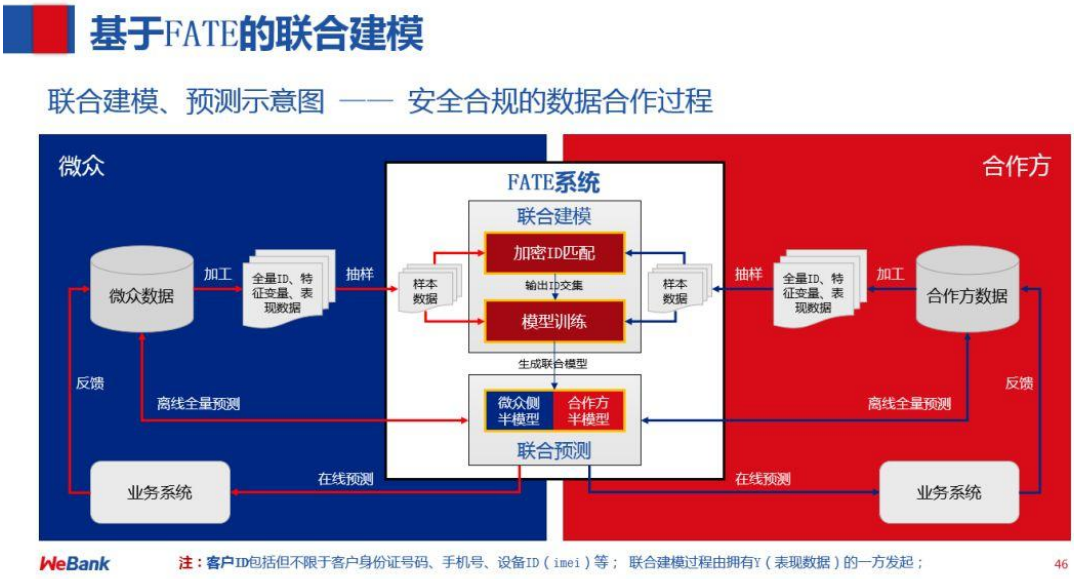

现实中，FATE 是如何应用的呢？这里和大家分享一个示意图，会在每一方部署一套 FATE 系统，双方都是在各自部署的 FATE 系统中进行交互。

6. 开发流程

如果大家对 FATE 感兴趣，作为开发者利用联邦学习框架实现算法，只需要四步：

① 选择一个机器学习算法，设计多方安全计算协议

② 定义多方交互的数据变量

③ 构建算法执行工作流

④ 基于 EggRoll & Federation Api 实现算法工作流中各个功能组件

7. 目前 FATE 项目中的算法和案例

这是目前 FATE 项目中的算法和案例，会根据需求，不断增加各种各样的算法。

最后分享下我们联邦学习的官网：

https://www.fedai.org.cn/cn/

今天的分享就到这里，谢谢大家。

阿里文娱智能营销增益模型（Uplift Model）技术实践

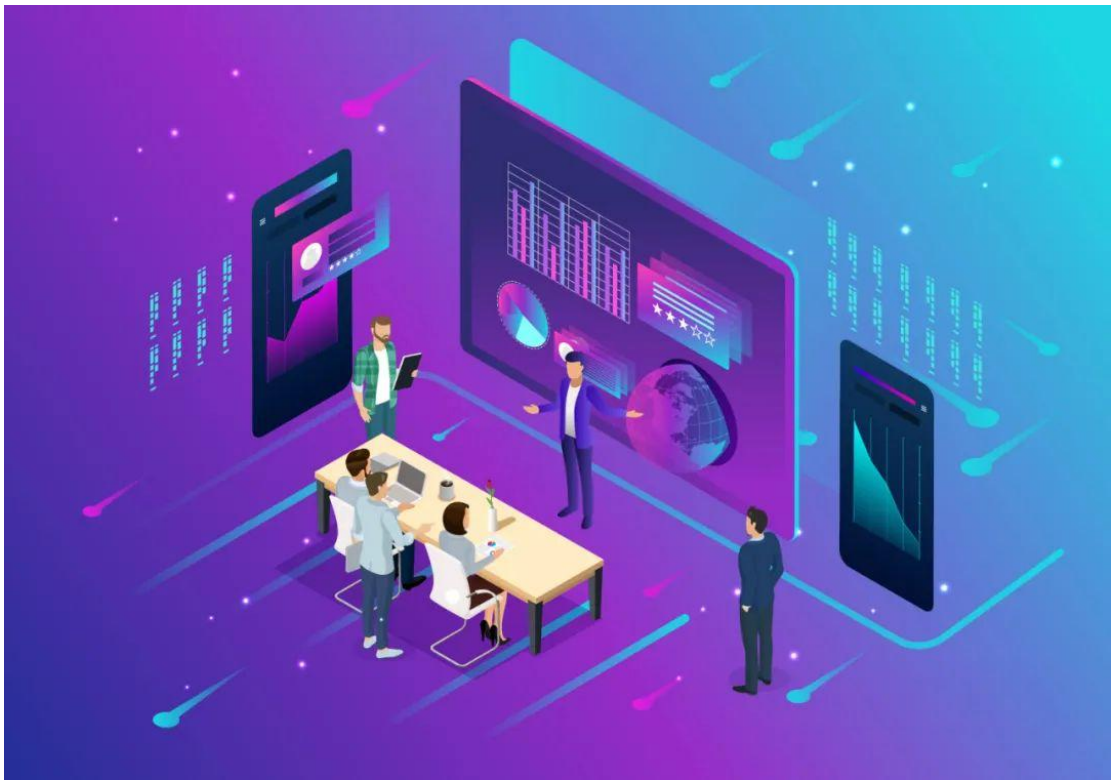

分享嘉宾：奕晴 阿里文娱 算法专家
编辑整理：有感情的打字机
内容来源：阿里文娱技术
出品平台：DataFun

导读：随着移动互联网和人工智能技术的发展，智能化营销正渗透到各行各业。如何衡量和预测营销干预带来的"增量提升"，而不把营销预算浪费在"本来就会转化"的那部分人身上，成为智能营销算法最重要的挑战。**我们以 Uplift Model 为基础，构建营销增益预测模型，帮助商家锁定营销敏感人群，驱动收益模拟测算和投放策略制定，促成营销推广效率的最大化。**本文将分享营销增益模型的原理和常见的建模及评估方法，并以淘票票智能票补为例介绍 Uplift Model 技术的实践经验。

本次分享主要包括：

❶ 智能营销面临的挑战及 Uplift Model 的价值

❷ Uplift Model 建模与评估方法

❸ Uplift Model 在淘票票智能票补中的应用

❹ 技术思考与后续规划

智能营销面临的挑战及 Uplift Model 的价值

1. 智能营销面临的挑战

目前，智能化的营销手段越来越普及，商家可以通过多种渠道触达消费者，比如，在手淘上商家可以圈定他想要的目标人群，进行广告推送，为店铺拉新，也可以通过短信或旺旺这些渠道定向发放优惠券。无论是红包还是广告，我们都称为营销的干预手段，其背后都是有成本的。营销的目标就是在成本有限的情况下最大化营销的总产出，这里面最关键的一点是我们能否准确找到真正能被营销打动的用户，我们称他们为营销敏感人群，可以通过下面的图进行简单的解释：

比如，我们对人群做四象限的划分，横纵坐标分别是用户在有干预和无干预情况下的购买状况。如上图，左上角人群的购买状况在干预后发生了正向变化，如果我们不对这类人群进行干预，那他有可能是不购买的，但是干预之后的购买概率有极大提升，所以这类人群是我们真正想要触达的用户，即营销敏感人群。而其他人群比如第 2 类和第 3 类，在干预前后的购买状况没有变化，所以预算花费可能是浪费。右下角是一类比较特殊的人群，虽然其在干预前后的状态有跳变，但这种跳变不是我们希望看到的，因为确实有一些人群对营销是反感的，所以对这类人群我们应该极力避免触达。Uplift Model 正是为了识别我们想要的营销敏感人群。

2. Uplift Model 的价值

接下来介绍什么是 Uplift Model，以及 Uplift Model 和传统的 Response Model 有什么样的差异。以广告投放为例，对于两个用户群，我们知道他

们对广告投放的转化率分别是 0.8%和 2%，假如只有一次广告曝光的机会，应该向哪类用户投放广告？

按照以往的经验和直觉，可能会向第二类用户群投放广告，因为其转换率是最高的，但这个结论是对的吗？经过进一步分析，除了广告曝光转化率之外，我们还能知道这两类用户群体在没有广告触达情况下的自然转化率，从而推算出广告所带来的增量。比如第一类用户的广告转化率虽然低，但在没有广告触达情况下的转化率更低，即广告所带来的增量反而是比第二个用户更高的，而我们要最大化总体的转化率其实等价于最大化广告的增量，按照这个逻辑，我们应该向第一个用户投放广告。也就是说 Response Model 很有可能会误导我们做出错误的决策，Uplift Model 和 Response Model 之所以有差异，主要在于两个模型的预测目标不一样。

❶ Response Model 的目标是估计用户看过广告之后转化的概率，这本身是一个相关性，但这个相关性会导致我们没有办法区分出自然转化人群；

❷ Uplift Model 是估计用户因为广告而购买的概率，这是一个因果推断的问题，帮助我们锁定对营销敏感的人群。所以 Uplift Model 是整个智能营销中非常关键的技术，预知每个用户的营销敏感程度，从而帮助我们制定营销策略，促成整个营销的效用最大化。

Uplift Model 建模与评估方法

1. 什么是 Uplift Model

Uplift Model 是一个增量模型，目的是预测某种干预对于个体状态或行为的因果效应。在数学上可以表达为两个条件概率的差值形式，如下图所示：

Y 代表的结果（比如用户的点击，转化等），X 是用户维度的特征，T 代表的是营销的变量（1 代表有干预，0 代表无干预），因此这个概率差值表示的是用户在有干预和没有干预情况下的变化，这个模型建模的难点在于我们获取到的训练数据是不完整的，对于个体来说，我们不可能同时观测到在有干预和没有干预两种情况下的表现，也就是因果推断中经常提到的反事实的问题。我们应当如何去建模呢？可以换一种思路，从人群的角度来对平均因果效应做统计，假设我们有两群同质用户，均来自一线城市/年龄段为 25-35/女性，我们可以对其中一组用户进行广告投放，另外一组不进行任何干预，之后统计这两群人在转化率上的差值，这个差值可以被近似认为是具备同样特征的人可能的平均因果效应。所以 Uplift Model 本质是从训练样本中学习条件的平均因果效应，同时因为模型是具有一定的泛化能力，可以对没有见过的样本也进行预测。

但这里需要强调的是，Uplift 建模对样本的要求是比较高的，需要服从 CIA（Conditional Independence Assumption）条件独立假设，要求 X 与 T 是相互独立的。什么样的样本有这样的特征，又如何获取呢？最简单的方式就是随机化实验 A/B Test，因为通过 A/B Test 拆分流量得到的这两组样本在特征的分布上面是一致的，也就是 X 和 T 是相互独立的。因此随机化实验是 Uplift Model 建模过程中非常重要的基础设施，可以为 Uplift Model 提供无偏的样本。

2. Uplift Model 建模算法

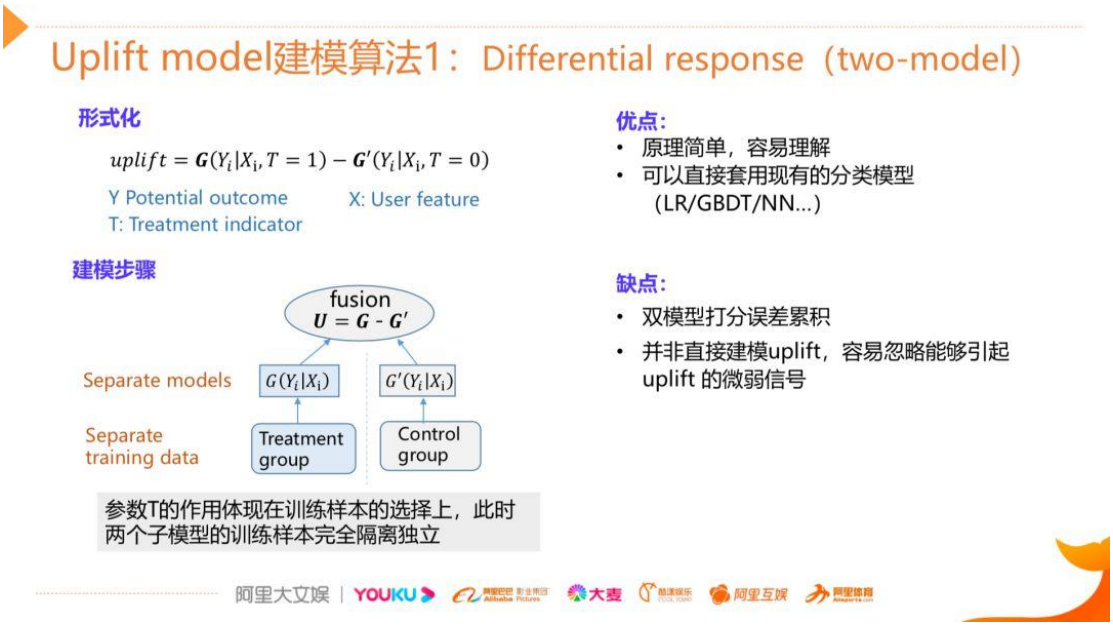

最简单的 Uplift 建模方法是基于 Two Model 的差分响应模型，它的形式和前面介绍的 Uplift Model 的定义非常相似，包含了两个响应模型，其中一个模型 G 用来估计用户在有干预情况下的响应，另外一个模型 G'是用来学习用户在没有干预情况下的响应，之后将两个模型的输出做差，就得到我们想要的 uplift。这种建模方法的优点是比较简单容易理解，同时它可以套用我们常见的机器学习模型，如 LR，GBDT，NN 等，所以该模型的落地成本是比较低的，但是该模型最大的缺点是精度有限，这一方面是因为我们独立的构建了两个模型，这两个模型在打分上面的误差容易产生累积效应，第二是我们建模的目标其实是 response 而不是 uplift，因此对 uplift 的识别能力比较有限。

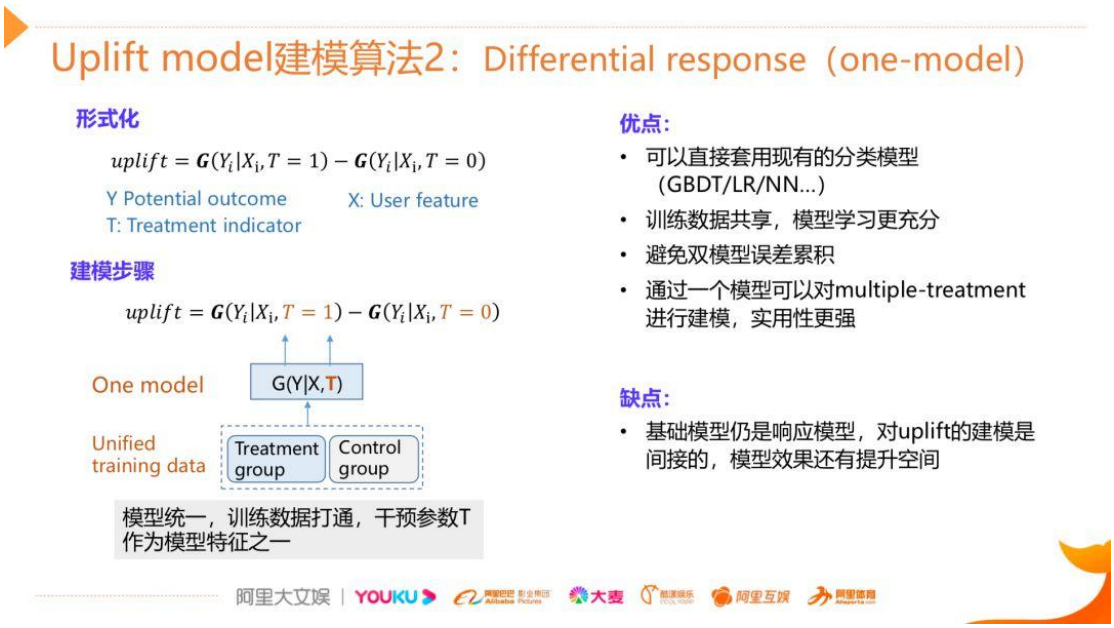

进一步地，还有一个基于 One Model 的差分响应模型，它和上一个模型最大差别点在于，它在模型层面做了打通，同时底层的样本也是共享的，之所以能实现这种模型层面的打通，是因为我们在样本的维度上做了一个扩展，除了 user feature 之外，还引入了与 treatment 相关的变量 T（T 如果是 0，1 的取值可以建模 single treatment，T 也可以扩展为 0 到 N，建模 multiple treatment，比如不同红包的面额，或者不同广告的素材 ），One Model 版本和 Two Model 版本相比最大的优点是训练样本的共享可以使模型学习的更加充分，同时通过模型的学习也可以有效的避免双模型打分误差累积的问题，另外一个优点是从模型的层面可以支持 multiple treatment 的建模，具有比较强的实用性。同时和 Two Model 版本类似，它的缺点依然是其在本质上还是在对 response 建模，因此对 uplift 的建模还是比较间接，有一定提升的空间。

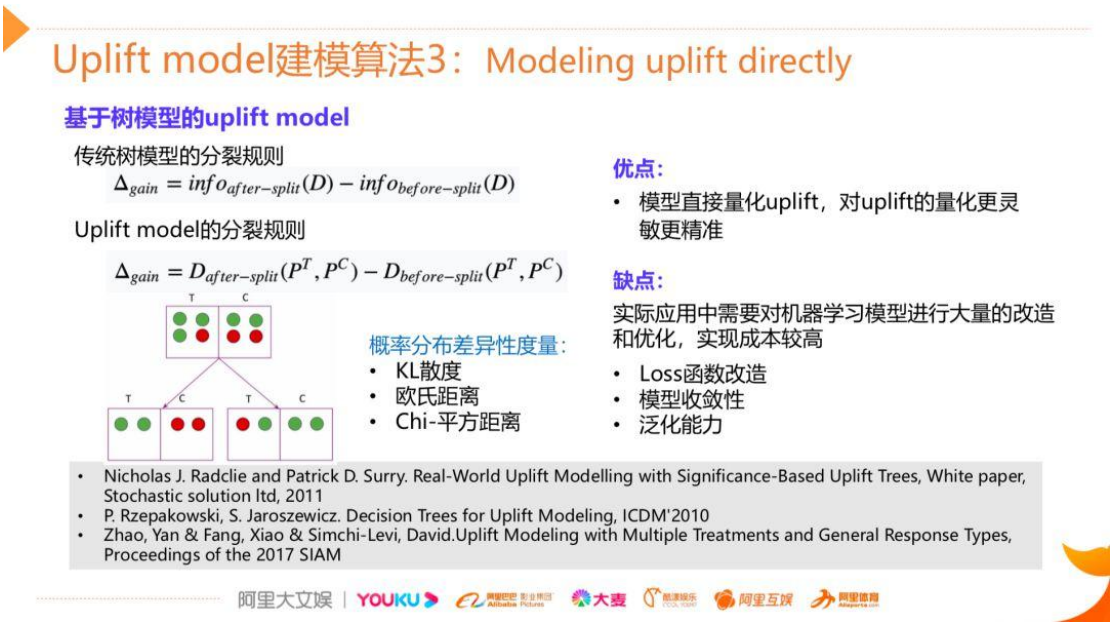

所以后续也有相关研究提出了第三种建模方法，通过对现有的模型内部进行深层次的改造来直接刻画 uplift，其中研究较多的是基于树模型的 uplift 建模，下面主要介绍它的思想，在传统的决策树构建中，最重要的环节是分裂特征的选择，我们常用的指标是信息增益或者信息增益比，其背后的含义还是希望通过特征分裂之后下游节点的正负样本的分布能够更加的悬殊，也就代表类的纯度变得更高。类似的，这种思想也可以引入到 Uplift Model 的建模过程中，虽然我们并没有用户个体的 uplift 直接的 label，但是我们可以通过 treatment 组和 control 组转化率的差异来刻画这个 uplift，以图中左下角的图为例，我们有 T 和 C 两组样本，绿色的样本代表正样本，红色的代表负样本，可以看到在分裂之前 T 和 C 两组正负样本的比例比较接近，但是经过一轮特征分裂之后，T 和 C 组内正负样本的比例发生了较大的变化，左子树中 T 组全是正样本，C 组全是负样本，右子树正好相反，C 组的正样本居多，意味着左子树的 uplift 比右子树的 uplift 更高，即该特征能够很好的把 uplift 更高和更低的两群人做一个区分。如

何从数学上度量这种概率分布的差异的方式呢？一些文章提出了可行的方法，比如基于 KL 散度，欧式距离，卡方距离的等等。这种模型的优点是可以直接对 uplift 进行建模，因此它的精度理论上是更高的，但是在应用层面我们需要做大量的改造和优化，除了前面介绍的分裂规则之外，我们还需要改造它的 loss 函数，后续的剪枝等一系列的过程，所以它的实现成本是比较高的。

3. Uplift Model 建模评估

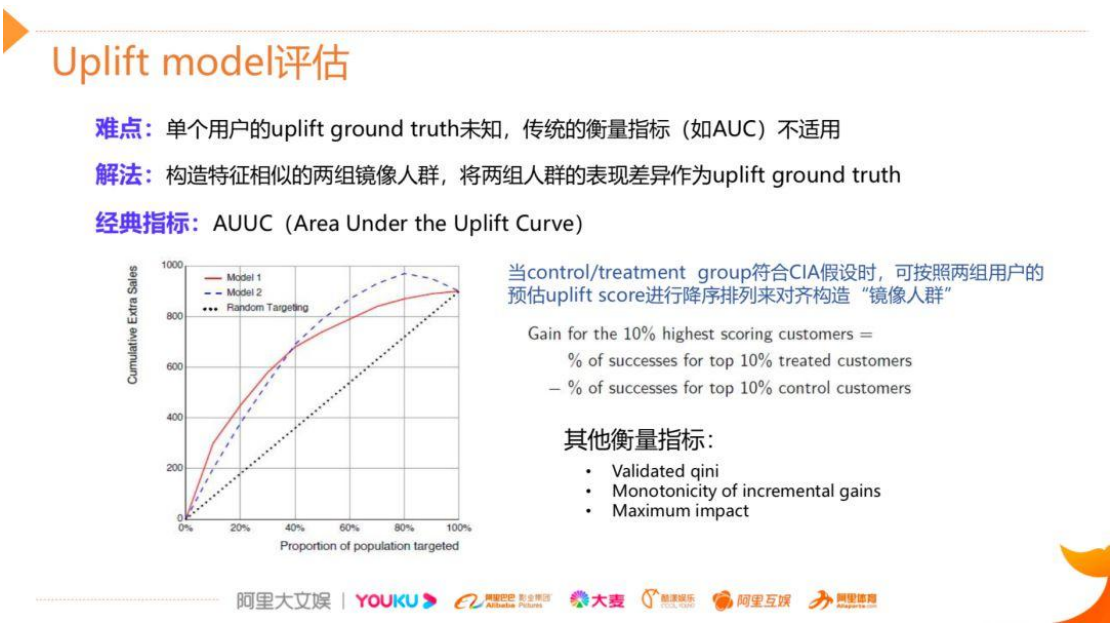

有了以上三种常见 uplift 的建模方法，我们需要对 uplift 模型进行评估，因为 uplift 评估最大的难点在于我们并没有单个用户 uplift 的 ground truth，因此传统的评估指标像 AUC 是无法直接使用的，解决的一个思路是通过构造镜像人群的方式来间接拿到 uplift 的 ground truth，比如说经典的 AUUC 的指标就是这样去计算的，假设现在有两个满足 CIA 条件假设的样本组，我们

可以对两群人分别预估他们的 uplift score，之后将人群按照 uplift score 进行降序排列，通过 score 分数这一桥梁，可以把两组人群进行镜像人群的对齐，之后分别截取分数最高的比如 10%的用户出来，计算这一部分人转化率的差异，这个差异就可以近似地认为是分数最高的这群人真实的 uplift，类似地，我们可以计算前 20%，40%一直到 100%的点上面的值，连线就能得到 uplift curve。理论上如果模型对 uplift 的识别比较准确，我们预测 uplift 比较高的区间段，真实的 uplift 也较高，uplift curve 就会呈现上凸的形式，我们也可以计算曲线下的面积度量不同模型的表现差异。当然除了这种方法之外，还有一些其他的指标如 Validated qini 等，在此不展开介绍。

Uplift Model 在淘票票智能票补中的应用

下面以淘票票实际场景为例，来说明 uplift model 如何在实际场景中进行应用。该项目的目标是希望对进入到首页的用户个性化地发送红包，实现

在预算和 ROI 的双重约束下提升平台总体购票转化率。我们的权益就是首页的红包，红包的使用规则、红包类型、预算和交互样式由产品运营设计，算法的作用是实现人和权益的精准匹配，我们需要确定应该给哪些用户发放以及发放哪种类型的权益。

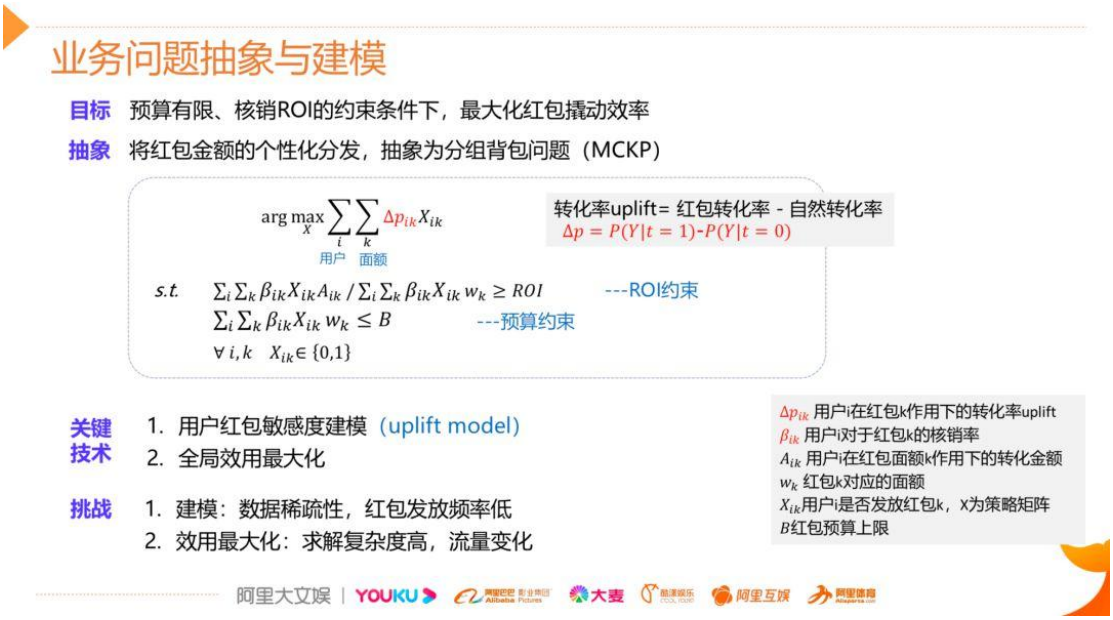

我们以平台通用券为例来说明问题是如何抽象和形式化的。在该场景下，每个用户最多只能发放一个红包，同时面额有固定几个分档，因此问题就精细化到如何对用户进行个性化的面额发放上，这可以通过经典的背包问题来抽象，如图所示，第一个公式是我们的目标，最大化的是红包撬动效率，下面的约束条件一个是 ROI 约束，一个是预算约束。目标函数公式中标红的部分是第 i 个用户在第 k 个红包下转化的 uplift，X_{ik} 是是否对用户 i 发放第 k 个红包，因此我们最终要决策的变量就是 X 矩阵。

该问题的求解中有两个关键点，一个是用户红包敏感度的建模，第二是在敏感度已知的情况下怎么进行全局效用最大化的求解。下面重点介绍uplift model模块。Uplift model的目标是预测每个用户在不同的红包金额下的转化率，从而构建出千人千面的敏感度曲线。

我们将建模的任务拆分成三个步骤：

❶ 收集训练样本

训练样本的收集和我们的实验是强相关的，我们采用的是随机化的分桶实验，它有两个好处，一是可以严谨公平地进行效果的评估，二是可以为uplift model的建模提供无偏的样本。建模中control组我们取的是随机化实验中的基准组，这部分用户是不进行红包发放的，而treatment组选用的是随机化实验中专为uplift model建模预留的一小部分随机探测的流

量，之所以没有用有算法干预下的样本是因为用户的发放的面额与用户的特征是强相关的，并不满足 CIA 条件，因此这一部分样本虽然量较大，但是不能用于训练。

❷ 模型的构建和训练

收集到样本之后可以进行建模，考虑到业务迭代的周期，我们使用的是前面介绍的 One Model 的差分响应模型，特征层面，除了 user 维度的基础属性，还有历史的观影行为，以及历史红包的反馈，同时也会引入线上实时的环境特征，最重要的是跟营销相关的特征 T，目前 T 代表的是红包的金额。

❸ 面向业务层的模型校准和优化

理论上到模型训练完成，就可以直接把模型放到线上去应用了，但是在离线调研时，我们发现一个问题，我们绘制的用户敏感度曲线和我们的预期不太一样，并不是严格的平滑递增的走势。我们分析有两个可能的原因：

一是与我们整体的样本规模比较有限有关，因为这种无偏样本目前大概只有几百万的量级；

二是由于用户行为的稀疏性，在这种场景下我们比较难收集到用户在不同面额下的历史数据，因此也会加剧这种不平滑性。

针对该问题，我们做了校准处理，把原始曲线做了一个函数的拟合，一方面可以让结果更加符合我们先验的假设，一方面经过这种函数化之后可以在后续支持更多面额的预测，但这种做法是否是最优的还值得进一步探讨。

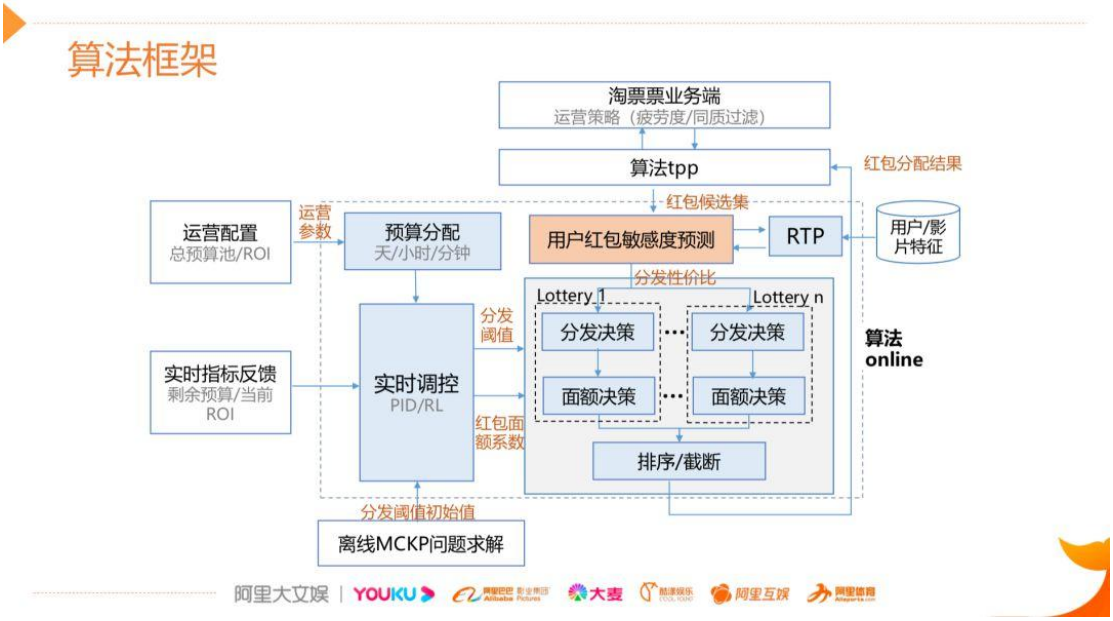

模型在线上应用的框架图，如上图所示，黄色区域是基于 uplift model 的实时预测的模块，当一条用户的请求过来的时候，我们会实时去数据库中取用户的特征以及影片的特征，同时结合当前的环境特征预测用户在当前状态下真实的敏感度，基于这个敏感度可以进行后续分发的面额决策等。

技术思考与后续规划

之后智能营销的发展态势是营销手段会越来越复杂，玩法也会越来越多，比如之前我们发放的更多是平台的通用券，后面也会发一些和影片相关的影片券或者影院券，这意味 treatment 的维度是在不断增长的，除了红包的金额之外还需要考虑不同的红包类型，这会给算法带来两个方面的挑战，一是我们需要对问题的建模形式做一个升级，除了之前单一维度的建模之外，我们可能还要考虑多维度的建模，同时维度的剧增会对样本的量级要求越来越高，样本的稀疏性问题会更加严重，针对这个问题我们有两个可能的解法：

❶ 可以采用多任务学习的方式，联合其他场景一起建模缓解单场景样本的压力，同时也可以通过人为构造无偏样本的方式增加整体的样本量。当然除了技术侧，整个营销上面还有非常多很有意思的研究方向，比如之前更多考虑的是单个营销场景，但其实多个场景下怎么去建模和刻画他们之间的相互影响也是非常有意思的课题；

❷ 我们之前 uplift model 建模更多考虑的是单次或者短期用户行为的增益，但实际上的营销往往是常态化或持续化的，用户的心智可能会不断发生变化，如何去建模长期的 uplift 也值得进一步去探讨。

今天的分享就到这里，谢谢大家。

爱奇艺数据中台的建设实践

分享嘉宾：马金韬 爱奇艺 数据中台负责人
编辑整理：陈国梅
出品平台：DataFunTalk

导读：随着市场对数据价值的认可，促进了数据在各行各业的爆发式增长，以及大数据设施的快速演化，同时也带来了不少新的数据问题；解决这些问题，发挥更大的数据价值，成为了各大公司的重点工作。爱奇艺通过数据中台的建设和实施，发挥通用化、中心化、服务化和标准化等能力和特点，将数据能力覆盖到公司任何角落，赋能业务发展，并通过加深数据 AI 化等新的技术方式，对数据价值进行深度探索；本文将从数据中台的概念、架构、建设理念等角度切入，对关键组成部分进行深入介绍，让大家能够在理解中台的同时，了解到如何通过中台解决问题，帮助业务挖掘数据价值。主要内容包括：

- 定位和价值
- 爱奇艺数据中台介绍
- 数据中台统一服务层

- 应用场景

01

定价和价值

首先和大家分享下数据中台的定位和价值,数据中台的定位主要是为了解决大数据快速发展过程中所遇到的各种棘手问题。

1. 现状和问题

大数据发展的现状特点主要归纳为以下几点：

- 基础设施发展的速度过快，导致在使用的层面需要快速响应，快速的迭代，从而给业务使用和数据挖掘带来很高的成本；

- 数据量级爆发式增长，对于存储、计算以及一些特殊场景的优化带来很大的挑战；

- 应用场景的融合叠加，以往数据产品主要用于报表分析，再进行应用分析，现在数据和 AI 技术深度融合，对大数据应用以及管理有更高的要求；

- 随着业务发展节奏越来越快，对数据时效性的要求也越来越高，已经不能止步于 T+1 的离线数据，或是 H+1 的数据，可能现在需要的是分钟级，甚至是秒级的延迟速度。

针对大数据发展特点遇到的各种问题,包括一些特殊业务场景中遇到的特例问题，在此仅罗列一些比较通用的问题：

- 数据口径的不一致；

- 数据质量的可靠性；

- 数据使用门槛高；

- 资源消耗浪费严重；

- 数据资产管理混乱；

- 数据接入成本高；

- 数据流通性差；
- 数据生产链路长；
- 数据业务打通难；

2. 数据中台的定义

中台是一个企业架构，是把一些通用的能力进行抽象。数据中台,就是对数据能力进行抽象，并且把数据的治理以及资产的管理统一抽象出一种通用的能力，把这种数据使用的门槛降到一定程度，让更多的业务，更多的用户可以通过数据去挖掘一些业务价值。

数据中台如何解决问题可从以下八个点展开:

① 打造一站式数据开发平台,这个方式是为了解决因大数据基础设施快速发展，面对不同的场景下需要大家用不同的技术手段去处理数据，然而设置零散性的数据组织形式会导致数据使用效率以及维护效率特别低。

② 建立统一的元数据中心,以往企业更关注数据生产，在管理上相对来说比较薄弱,因此需要建立统一的数据中心对数据的元数据元信息进行统一的管理，后续会为更多使用场景提供元数据。

③ 提供配置化的数据服务托管能力,就是数据中台的统一服务化建设。

④ 建设覆盖全生命周期的数据治理体系,对于大数据产生的价值以及成本，需要更细粒度的管制，所以要建立一个覆盖全生命周期的数据治理体系。

⑤ 制定数据生产和采集标准,数据生产和采集的过程是业务和用户接触数据中台的第一个环节，如何把数据生产标准化，如何把数据的采集和输入标准化对用户来说是节省成本的一个关键环节。

⑥ 建立一个数据湖,数据仓库及周边体系,把数据作为一个中心化的组织形式来为公司或者各个业务的产品使用场景提供环境。

⑦ 推动数据中心化,传统的数据结构往往是 A 依赖于 B,B 依赖于 C，C 可能依赖于 A 的网状引用结构,这个过程会带来很多沟通的成本以及使用上的理解偏差，包括各自维护自己的数据，导致存储成本和管理方面成本相对较高.对此如何加快数

据交换,需要运营中心化的建设，来帮助数据的生产方和使用方降低使用和维护的成本，并作为一个数据交换的中心。

⑧ 通过 AI 能力替代人工的反复性工作,通过 AI 技术的融合建设一个自动化平台，让用户可以方便快捷地使用这种 AI 能力，同时需要把 AI 能力赋能到我们的数据平台中，比如数据质量的监测、数据使用的分析，包括数据仓库建设的健康度，都需要 AI 能力去覆盖。

02

爱奇艺数据中台介绍

1. 爱奇艺数据中台定位

爱奇艺数据中台主要服务于业务前台和业务中台,数据中台主要由数据的生产接入，数据的处理加工，数据资产,数据治理，以及最终对外提供数据服务组成。数据中台主要的作用分以下四个方面展开：

① 将数据的生产收集处理存储和服务等环节进行封装，面向于不同层级的用户和业务，提供不同的服务形式。可以解释为，面向不同层级且具备一定的数据开发能力的用户，可能需要写 SQL 对数据表进行直接的查询，或者做更深度的数据开发，比如比较复杂的数据处理流程，数据开发平台支持用户通过拖拉拽的方式构建复杂工作流去 DAG。数据中台在对接业务前台时，如果直接使用数据表的成本会比较高，因此需要将数据封装成数据服务，并提供数据服务能力去帮助用户通过这种配置化的能力达到业务系统的对接能力。

② 在数据标准化的过程中，防止数据的重复建设，以及避免口径问题，来提高数据的使用效率，防止大家在从各种口径问题上花费过多的精力，或者避免因为口径问题带来一些决策上的错误。

③ 对于数据进行全链路的治理，来保证数据的生产使用，使得对资源的利用，有比较好的保障。

④ 最终的目的，屏蔽数据处理的复杂性，让用户可以更方便更高效地使用和发现数据，满足业务快速发展需求。

2. 爱奇艺数据中台组成

接下来介绍爱奇艺数据中台组成，这个分层组成的粒度较粗，但完全能覆盖到数据中台应该具备的能力。

架构最底层是大数据基础设施，结合云技术，可提供标准化、可弹性高、可用的统一云服务的能力。云服务之上有两部分，一个是统一数据生产和接入，另一个是统一数据的开发平台。往上是统一的数据组织形式，主要是数据湖,数据仓库以及其他的一些数据组织形式。统一数据层上方是本文主要的分析方向——统一数据服务层。统一数据服务层有以下几个特性，分别是可弹性、可配置化、可监控、可组合。这其实是一个高阶应用,高阶使用的方式，把一些原子的数据服务能力进行二次或者三次组合，来完成相对复杂的数据服务。

3. 爱奇艺数据中台特点

爱奇艺数据中台有以下六个特点：

① 平台化，以平台化的形式对用户展现能力，比如数据开发平台、数据服务平台、数据治理平台、以及一些数据接入工具等。

② 标准化，可以体现在多个方面，一方面是流程的标准化，包括如何采集数据，如何存储数据，然后如何管理对外交换的数据。另一方面，是对数据资产本身的标准化，比如数据表的命名、库的命名、字段的命名，还有数据仓库相关的，比如数据模型、指标系统、维度系统的标准化建设。打造全公司标准的统一的存储平台以及指标系统和维度系统，所有的数据体系可能都依赖于此。

③ 中心化，数据中台相当于把公司数据放入中转站，把数据汇总和分发，然后让数据得以统一管理，进而高效管理，同时对数据使用和安全情况做后续的审计。

④ 智能化， 体现在两方面，一方面是提供一个平台，智能化平台（AI 平台），让用户可以通过拖拉拽的方式快速地获得一些简单的 AI 机器学习的能力或者深度学习的能力。另一方面是在中台内部体现智能化能力，比如把智能的预测能力用于数据监测、数据分析上。

⑤ 服务化，是指把数据中台的能力通过服务的形式对系统推进，展现给业务，同时在组织形式上更像公司内部 toB 的一个公司，去服务于各个业务线，帮助售前、售中、售后实施数据定制方案。

⑥ 价值化，数据中台的建设与业务目标的关系相对模糊，所以希望能够寻求一些合理的方式来衡量建设数据中台的价值。

03

数据中台统一服务层

1. 统一服务面对的问题

接下来介绍一下爱奇艺数据中台的统一服务层，统一服务面对的问题主要分为以下几点：

① 数据和接口的复用性。由于传统的数据使用场景更多的是直接暴露数据表或者分配权限，往往这种情况下表的改动或者迁移，都会对于下游的服务造成特别大的影响。另外，数据表本身的流通性比数据接口的流动性差，因为对接业务或对接前台的部门，可能存在大家对于接口理解远高于对数据表的理解。

② 发现和理解数据。过去，爱奇艺通过各种形式维护元数据，比如数据表的含义、数据表字段的定义、字段类型等描述，但是这些数据在长时间运转下来，这些数据的信息其实逐渐的落后于实际情况，就造成了信息的缺失和不准确。其次是沟通成本问题，更多的还是需要人和人沟通，这种沟通一方面沟通效率会比较差，另一方面因为人与人沟通会产生理解的偏差。

③ 标准和统一管理。对于数据接口，过去总是各自依赖于自己所需要的数据，然后自己定义自己开发，导致出现各式各样的接口，在流通或者管理过程中的成本是很高的。而且往往对于一个数据资源，大家开发不同的数据接口，它的重复性会比较多，重复的概率会比较大，从而造成资源浪费严重。

④ 数据接入效率。过去给业务去提供一个数据表或者一个数据库业务，需要根据自身的情况去做相应的开发，然后评估服务的 QPS 和部署形式，以及申请域名的接口、安全网关等，但是这些其实都可以通过通用化的能力去解决，把效率提升起来。

⑤ 服务使用审计。以往提供的一个数据接口，可能就是 A 传 B、B 传 C 就扩散地使用起来了，但是往往这种情况会对于数据血缘的信息收集带来特别大的影响，导致后续升级一些数据表或者升级数据服务的时候，缺失部分下游的信息，从而导致一些操作对于某些线上业务带来额外的影响，而且有一些高精密性的数据，可能也会由于这种分享式的方式导致安全隐患。

2. 数据服务介绍

对于数据服务的定义以及它所具备的能力有了一个初步的概括后，开始介绍爱奇艺数据服务内容，主要有几下六点：

① 一站式的开发和运维的能力，它可以通过 SQL,可以通过配置来定义输入输出，并且可以和元数据中心打通，通过一些可选的方式去定义自己的数据服务。

② 全链路打通，因为有了数据接口到数据之间的血缘，并且依赖于现有数据和数据之间的血缘关系。其实从数据的生产到数据的加工到最终数据的使用，是一个全链路打通的一个状态，我们可以有效地去评估这个数据对于下游的影响情况，并且去衡量数据的价值。

③ API 集市，过去的使用背景往往是大家的数据表可能是基于各自的需求去开发各自的数据接口，这种复用性很难得到保障。通过 API 集市的方式，把所有基于某些表的数据接口展现出来，以及它所对应的输入输出，一个接口的元信息以更

友好的形式体现出来。这样，用户再去新建或者再去寻找数据服务的时候，有可靠的统一的入口，可以有很好的达到接口复用的目的。

④ PULL 和 PUSH 的这两种能力，也是业务关注的两种服务模式。PULL 很容易理解，用户通过发送数据访问到数据接口，数据接口对请求进行解析和优化，通过各种数据源计算数据，以秒或者毫秒级的响应速度返回数据结果，但这种场景往往是面向小型的数据量。而在数据服务面向的广大的业务当中，有一些场景下数据的时效性要求不是极高高，不需要到秒级或者毫秒级，但可以退而取其次可以达到一个分钟级，从而用以换取可以获得更大数据量的结果。这种情况下， 靠 PULL 的形式就很难以实现，所以需要通过 PUSH 回调的形式去通知调用数据服务的业务，去拉取这种大数据量的数据来满足后续业务的需求。

⑤ 逻辑模型，可以给业务或者用户一个更低门槛的或者更容易理解的一种展现形式。数据表往往有一些局限性，所以需要通过一种模型的概念，也就是大家都能理解的一个文字性的描述的东西，去支持数据接口的一个定义来解决数据复用的能力。

⑥ 数据网关，其实一个很通用的能力，对于这种数据服务，一定要提供网关的集成能力，以及支持认证权限，然后限流和监控的这一整套的服务能力。

3. 数据服务架构

关于数据服务架构：

自上往下，最上层是最终对外提供的 API 集市，大家可以通过 REST API 的形式去访问，查询数据以及获取数据。下一层是查询引擎，产品群里基本上是 API 的接口，更多的是以一种协议的形式存在，所以在查询引擎的最上层是有一个解析的过程。根据协议标准将数据请求进行解析，获取将要查询的数据源，根据数据源信息获取对应的数据模型，数据模型会通过底层元数据信息映射出对应的数据表;根据请求中的字段列表以及 filter 条件,最终将请求解析成一个逻辑执行计划，并进一步产生一个物理执行计划，计算出最终结果封装成响应返回。这种调用形式其实分为两种，一种是同步的接口形式，也就是接口 API，另外一种就是异步。异步就是说定义一个异步的时候，可能要比同步的方案要定义的信息更多一些，比如说给业务方提供的一个数据接口，数据的业务方需要去定制自己的回调接口，以及制定适合自己业务后续去处理的数据存储地址，然后填写到数据服务的定制化接口配置界面上。当数据请求过来之后，数据服务会把整个的接口请求转换成

一种 DAG 工作流的形式。因为这个数据量比较大，靠一个本地的计算已经难以满足，或者说是内存上可能会存在一些瓶颈，所以把它翻译成一种离线的 DAE 形式来去计算，或者是判断其他的覆盖能力,计算完的数据，会存到用户指定的地方，并且调用户指定的回调接口来告知用户，数据已经准备好，可以去某某地方拉取。这个数据存储的最终形式就是按照用户定义的那种结果形式去存储，这样供业务前台可以快速的去拿到数据去进行后续的处理，这些产品其实都是通过统一的查询能力去完成。

查询引擎的下一层是 API 的配置层。对 API 配置功能的拆解，首先是接口定义，接口的名字是什么，接口的描述以及传入的参数,输出的结果，包括 filter 的条件。其次是协议的管理，不仅支持 AGP 的协议，还可以支持 RPC 的各种协议。还有异步的形势下，需要用户填写自己的回调地址，或者说指定一下数据存储的位置。

再往下是对于整个数据服务的管理模块，主要分为数据源管理、版本管理、资源管理、流量管理等。数据源管理是对数据接口的数据服务自身的一个管理。对于资源的管理能力，体现在数据服务常常会消耗服务器资源，然后对接公司的 QAE 的这套体系，就是说一套虚拟化的一个容器。流量管理就是对于每一个服务，可能都需要有一定的流量的管理措施去衡量以及动态调整服务的副本数。

左边就是网关，一个数据服务或者是一个服务接口所具备的能力，比如说一些安全认证及权限访问的问题，包括数据服务本身运行的稳定性的监控，还有数据接口调用分析，包括当接口并发量突然有激增的情况发生时，需要有限流的能力。

最底层是数据源，为了后续对数据服务做一个更深层次分析，我们需要对日志进行统一采集，统一管理。

最右边是整个数据中台里面很重要的一块——元数据中心，因为现在看无论是任何一个模块，任何一个数据的分层，对元数据的依赖都是相当重的。

4. 元数据服务组成

元数据的概念比较难理解，其实元数据就是数据的数据。对于元数据服务，现在提供了两种服务形式。一种是搜索服务，就是大家可以通过已知的一些信息去进行搜索，拿到数据资产的一些更详细的说明。比如可以通过搜表名、搜维度，搜业务线的名称、搜指标，就可以拿到跟搜索词相关的数据资产，并且进一步查看它的详细信息。另外一种形式可能比较偏向导性的或者结构化的一种展现形式，

也就是业务图谱。我们可以从业务的角度出发，一层一层地圈定更细的范围来查找我们想要看到的数据资产。

元数据中心给用户展现的信息主要是包括几种，一种是基础信息，也就是说数据的定义，包括任务的定义、数据的生产者、安全责任人、数据的样例以及变更的历史。另一种是数据资产本身的特点，首先是数据资产等级，我们需要对不同的资产做分级，以保证不同等级的资产有不同的保障机制，然后更多的精力放到重要资产上。其次是对数据的健康度和质量的体现，我们会对于所有的数据资产分级地检测质量，包括它的产出时间来对数据资产进行定级。最后是数据流行度,主要是为了体现数据在下游使用当中的使用次数，以此来表明数据的重要程度。我们也会把数据的流行度作为数据价值的一个重要衡量指标。

除了这些元信息之外，我们可能也需要对于整个数据生态的一数据标准，通过元数据中心去对外去体现。比如业务的信息，包括业务的所属部门、负责人的信息，以及业务相关的一些指标维度和数据模型，把元信息以这两种服务形式对外提供，其实是为了可以让使用方可以更快速更高效地去找数据，把数据能理解和使用起来，并且可以指导用户去快速地开发自己的数据需求。

5. 元数据服务架构

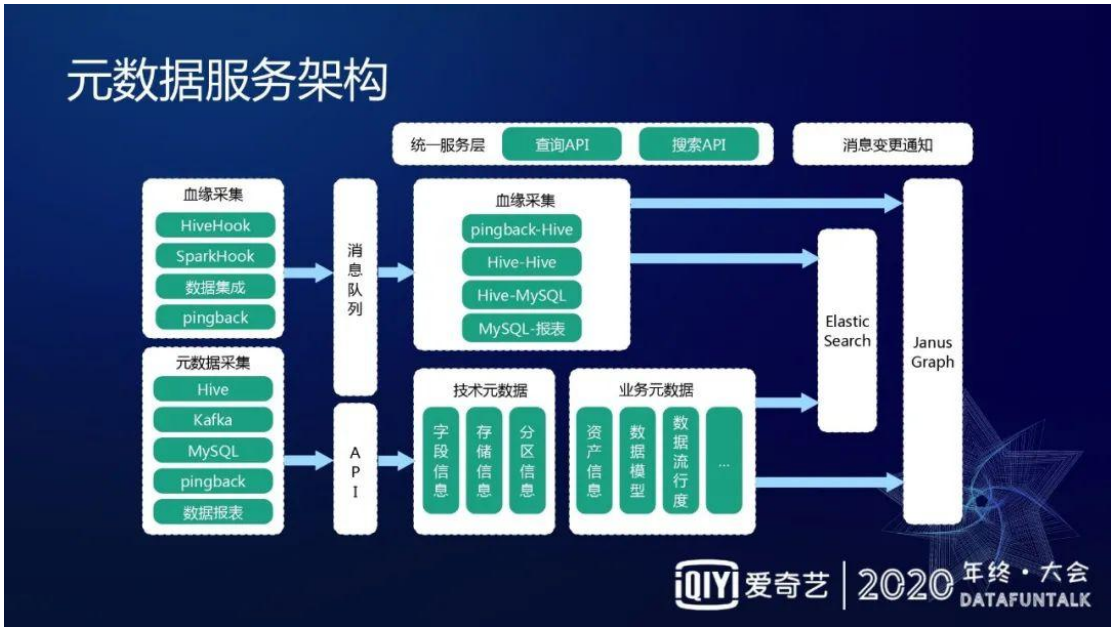

关于元数据的服务架构，左侧是相当于元数据的采集员,血缘采集其实是把数据资产由血缘形式体现出来，让每一个数据知道其的上下游是谁，然后在一些变更的时候能及时通知，并且如果数据上有一些变化，也可以及时的通过数据血缘的能力去找到自己的上游来排查数据变化的原因。血缘采集主要是分以下几部分：

一是通过 HiveHook 采集，Hive 表之间的血缘，然后 sparkhook 采集 spark 的生产数据，就是发个任务生产的数据，以及它的数据源之间的关系。接下来是数据集成，是对数据异构数据源的同步能力，我们把这种导入导出的一种血缘管控起来。最后是 pingback，因为 pingback 是很多数据产生的一个源头，所以这一块是说我们从数据产生最源头到最终数据的使用，全链路渲染的采集的方式。

下边是对于非关系型数据的元数据采集,比如说 Hive、Kafka、MySQL,pingback，还有数据报表。这些更多的是对于数据资产的原始信息的采集方式。然后通过消息队列和 API 的这两种形式实现离线或者是实时的元数据采集流程。元数据中心

可以通过 JanusGraph 去对血缘进行一个整体的管理。我们现在的血缘其实支持 pingback 到 Hive,Hive 到 Hive,Hive 到 MySQL，然后 MySQL 到报表的整体的血缘关系。这样我们所有的数据资产，正常的来说应该都在这整个的血缘网当中，而且通过 JanusGraph 我们可以通过这种图结构的数据库去快速查找一些数据资产，包括它的上下游关系以及相互依赖关系。

然后技术元数据和业务元数据，主要是包括一些字段信息、存储信息、分区信息、资产信息、数据模型、数据流行度等等。为了快速查找，把索引信息存到了 ES 里，用于实现快速的搜索能力，并且这种详细信息我们可以通过 JanusGraph 或者其他的这种数据库存储形式去获取。

最后，元数据中心对外的体验形式主要有两种，一种叫查询 API，它可以对接到各种的业务系统上。另一种叫搜索 API，搜索 API 就是现在平台的展现形式，后面展现数据库的搜索 APIDE 能力。

6. 推理服务介绍

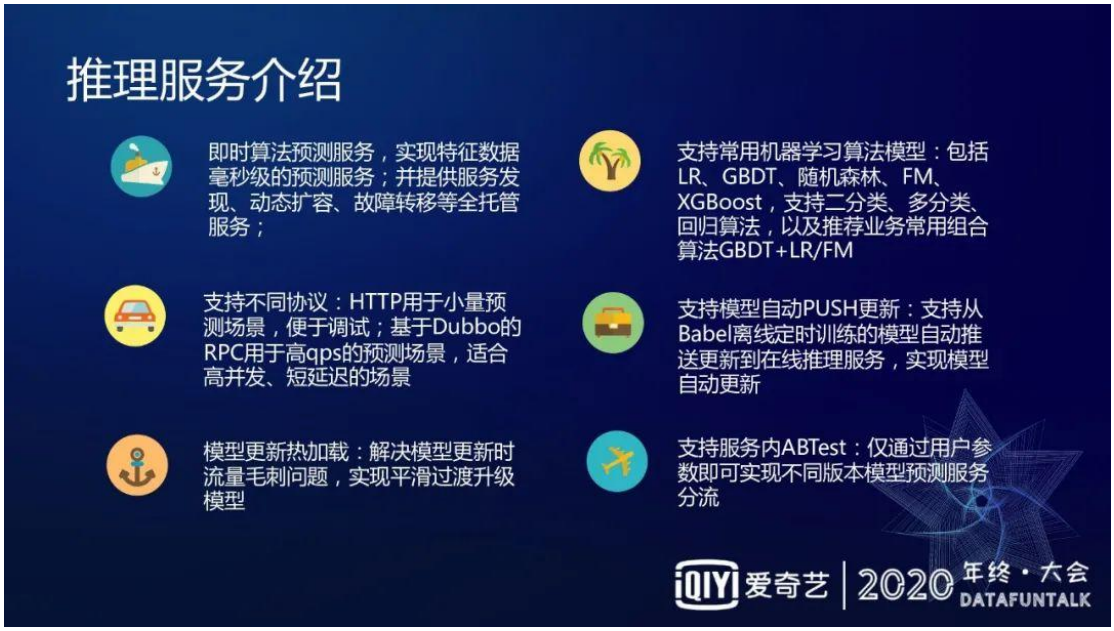

接下来对推理服务作一个简单的介绍，前面花了很大篇幅讲了数据服务和元数据服务，而推理服务其实是基于我们现在智能化建设的角度提出的。我们在离线部分有一个叫机器学习平台，它可以通过和我们现有的数据开发平台打通去做一些离线的特征管理、样板管理、特征训练，然后通过和数据服务打通，能支持模型的自动复制。推理服务还可以可以对外提供 AGTP 或者 RPC 的接口服务，对各种前台应用提供实时在线的一个预测服务能力，并且它可以支持预加载或者热更新，以及支持 ABTest。

7. 推理服务架构

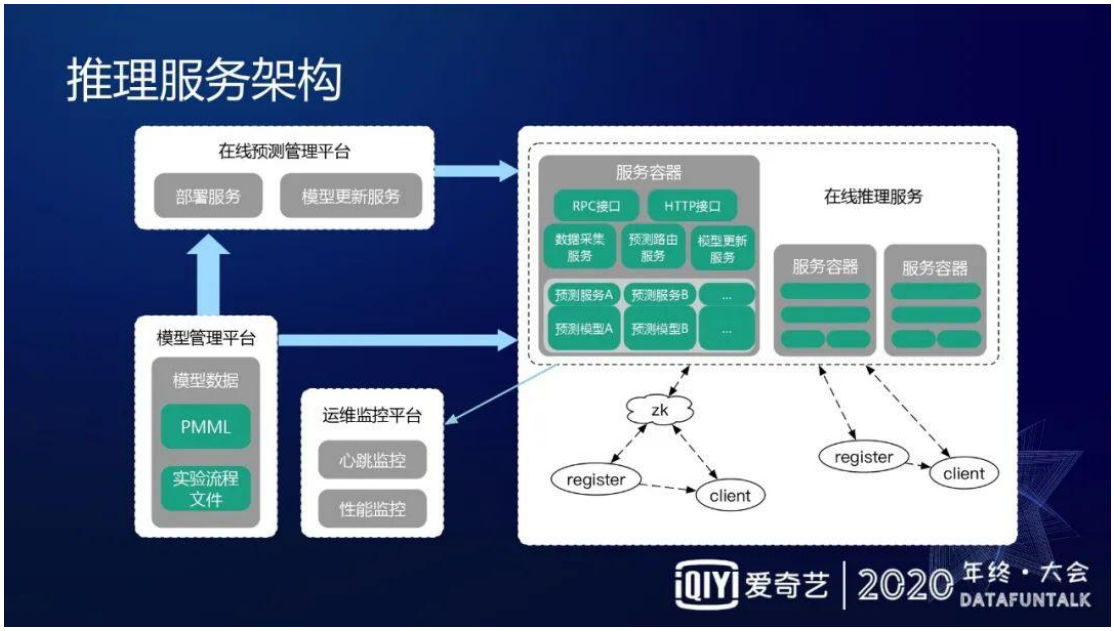

推理服务的架构，它主要分为几个模块。其中，模型的管理平台，通过离线训练，把一些模型数据通过 PMML 的形式来管理起来，然后输出到在线预测管理平台上。再通过预测管理平台去部署推理服务，同时运维监控平台对于线上的推理服务做一些性能或者心跳方面的监测。

03

场景应用

1. 数据服务案例

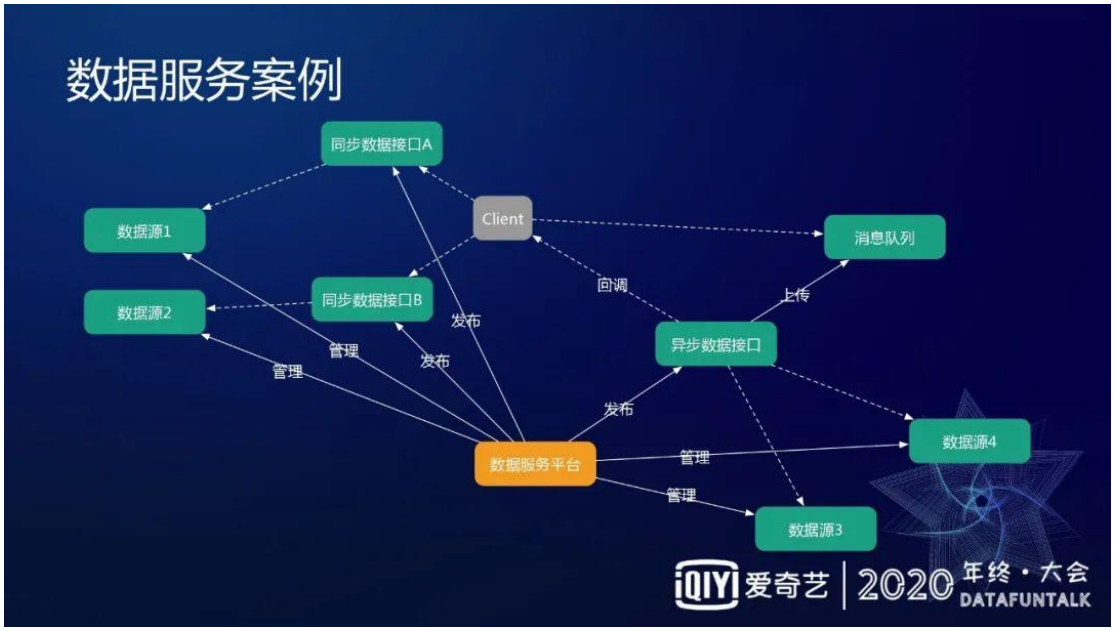

数据服务平台其实是数据平台和业务前台以及数据源之间的关系，可以说是管理各种数据源发布同步数据的接口，然后提供给 Client。Client 其实很多时候是业务前台来提供同步的调用法。右侧的异步的交流能力是通过发布一个异步的数据接口来把数据源做一些 DAG 的管理和处理，把最终的数据发布到消息队列上，同时去回调业务前台的回调接口，再通知业务前台去消息队列获取结果数据。

2. 数据服务平台

上图所示是数据服务的应用场景，左图是数据服务的 API 集市。上面有数据服务的简单介绍、创建人、创建部门以及上线时间。右侧是接口的详细信息，比如上线时间、有效期、紧急程度、接口的地址说明、接口描述和一些列的解释，这个列的解释就是最终的输出的结果。

3. 元数据服务案例

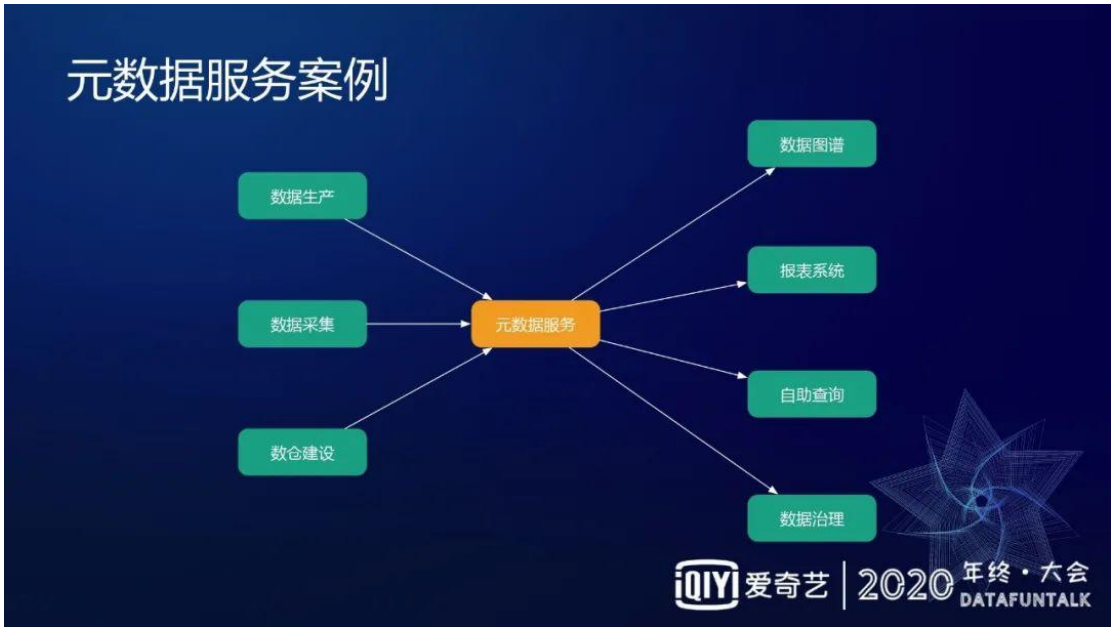

云数据服务就是数据源和数据使用方进行打通。上游的数据生产、数据采集和数仓建设来对元数据进行生产，然后通过元数据服务，把元数据的输出到比如数据图谱报表系、自助查询系统以及后续的数据治理体系当中。

4. 数据图谱

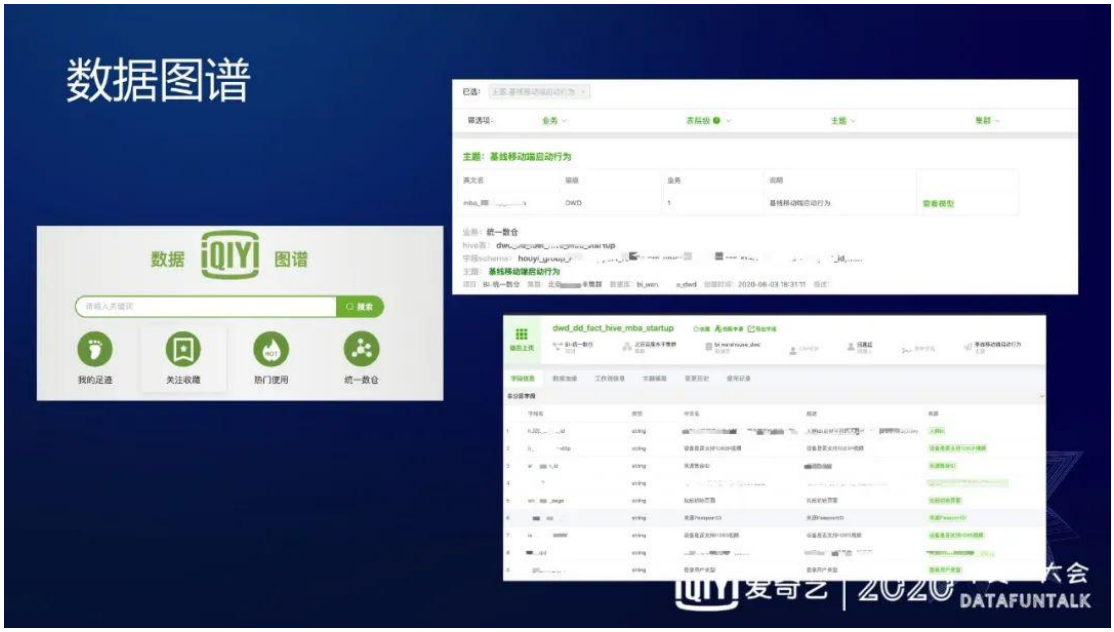

这是数据图谱的界面，其实是元数据一个体现形式。通过搜索可以快速地查找到一些表，然后再进一步去看右下方表的详细信息，包括所属于的项目、集群、库名、owner、创建人，以及相关的字段信息等。除此之外还会有一些血缘数据、血缘关系，包括所关联的模型、变更历史以及使用记录。

04 未来展望

未来展望

最后是对数据服务未来的展望。在数据服务上我们其实还有很多事情要去完成，主要为以下四个方面：

① 第一块是需要做一些跨数据源的合并，目前虽然我们做到了一些小数据量的跨数据源合并，但是大数据量的跨数据源合并能还需要再深挖升级。

② 第二块是服务接口组合，也是说我们如果有了一些原子接口，怎么去把它组合成更复杂更灵活的服务接口也是未来要解决的。

③ 第三块就是服务模型化，就是如何通过数据模型去构建服务，让使用方不去关注表的底层表的概念，或者底层表的信息，就能创建出符合自己预期的模型。

④ 最后一块是自动化管理，目前主要是人为地定义接口，后续需要把接口定义的各个环节尽可弱化，通过生成一个接口，然后内部的 request 模板或者 response 的字段说明，可以通过接口自动解析，然后以更灵活的方式体现出来，不需要每一个接口都事先定义才能使用。

今天的分享就到这里，谢谢大家。

金融资管数据中台体系探索实践

分享团队：熵简 Airworks 团队
编辑整理：王建新
出品平台：DataFunTalk

导读：数据中台是熵简科技数据智能业务的核心部分。引入数据中台可以打破数据与数据的界限、技术与业务的界限，为业务层的迭代提供更快的数据响应，真正做到业务数据化、数据资产化。熵简科技在长期的实践过程中总结出了一套适用于资管机构的数据中台架构方案。本文将从熵简数据中台体系和行业落地案例两方面展开详细介绍。

主要内容包括：

- 熵简科技及其数据中台的总体架构
- 数据接入：多源异构数据采集平台
- 数据中台：AirWorks 数据智能平台

- 实践案例：金融资管数据中台体系

01

熵简科技及其数据中台的总体架构

1. 熵简科技简介

熵简科技是一家 toB 的金融科技企业，定位于以技术和业务导向为核心的数据智能服务商，熵简科技中的熵是热力学中描述系统混沌程度的度量，熵简寓意着希望利用大数据人工智能的技术去帮助客户简化业务决策、投资研究中的复杂度。

2. 数据中台总体架构

在公司的数据中台部分，其整体架构自下而上分为三层，分别是数据层、中台层和应用层。在数据层，基于公司起家的另类数据，既提供了数据采

集的工具集，也提供了包括宏观数据、另类数据和资讯数据的数据集。平台还可以为金融机构客户提供采集配置服务和结构化定制等定制化数据服务。

在中台层构建了数据中台、算法中台和知识中台三大中台，在这三个中台的基础上，为给客户提供聚合搜索，舆情监控，知识管理等商品面向业务的应用系统。本次分享主要介绍的是数据层的工具集部分和中台层的数据中台部分。产品比较独特的核心优势是一方面提供了从数据采集到存储、处理和展示的一站式解决方案，另一方面，可以依托公司内部业务专家和技术专家的紧密配合，实现技术对业务的整体赋能。同时，参考海外的成熟架构和国内金融托管机构，量身定制了一套原厂架构。为了满足金融机构的私有化部署需求，产品的技术组件采用开源架构，支持公有云和私有云两种部署方式。

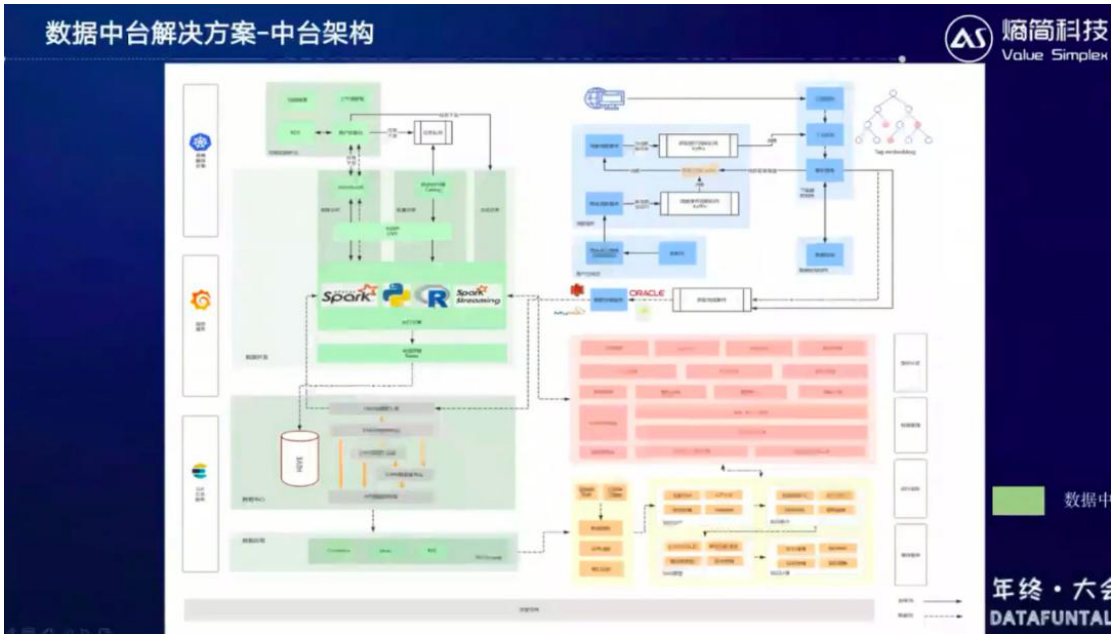

上图为中台的架构图，其中的数据平台包含三个部分，从下而上分别是数据开发，数据中心和数据应用。在数据开发部分，统一了批量任务、实时任务和信息查询，进行了统一封装；在数据中心部分，以 hive 做为元数据存储，进行了中心化的数仓建设；在数据应用部分，提供交互性探索的编译工具和供上层应用调用的 API 服务，技术实现也经历了从关系数据库到 druid 再到 clickhouse 的转变。

02

数据接入：多源异构数据采集平台

1．海量异构数据采集

金融竞争的本质是来源于信息不对称，因此有参考价值的数据都需要纳入到系统中。针对这样的需求，熵简科技自研了一套数据生产平台，实现海量异构数据源的采集和监控，能够采集研究资讯，宏观经济数据，互联网公开等数据。该工具目前在内部目前已经监控了 2000 多个数据源，每天新增的数据量超过了数个 TB。数据生成平台中最核心的任务是构建一个可以兼容数千种不同数据源类型，并且每日处处理数量在 TB 量级的一个大数据采集系统。实际应用中需要解决三方面的挑战，一方面是如何能够实现一个来源异构网站的数据抓取，二是如何能够以比较低的成本快速拓展新的数据源，三是在数千个数据源的情况下，如何保证数据采集的实时性和稳定性。

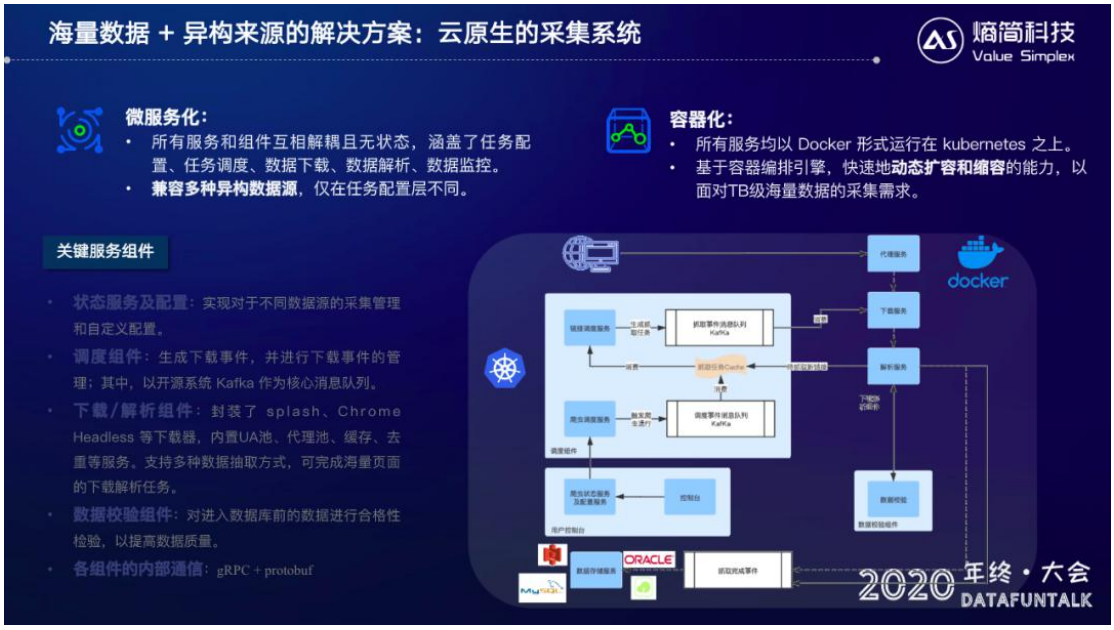

为了解决海量数据异构来源的问题，平台采用了云原生架构来构建大数据采集系统，整个系统是以 Kafka 作为消息中心，采用事件驱动的模型构建在 k8s 集群上。整个系统分为四个大模块，分别是用户控制台，数据采集引擎，数据存储服务和监控与认证服务。云原生架构有两个非常重要的特点，一个是微服务化，一个是容器化。上图右下角可以看出平台将采集系统中的所有服务和组件相互结耦进行了独立部署，涵盖了从任务配置、调度、数据下载再到解析、校验入库的全部的服务流程。平台的容器化体现在整个服务都是以容器的形式运行在 k8s 上的，通过容器编排引擎的快速动态伸缩扩容，可以满足海量数据的采集需求。

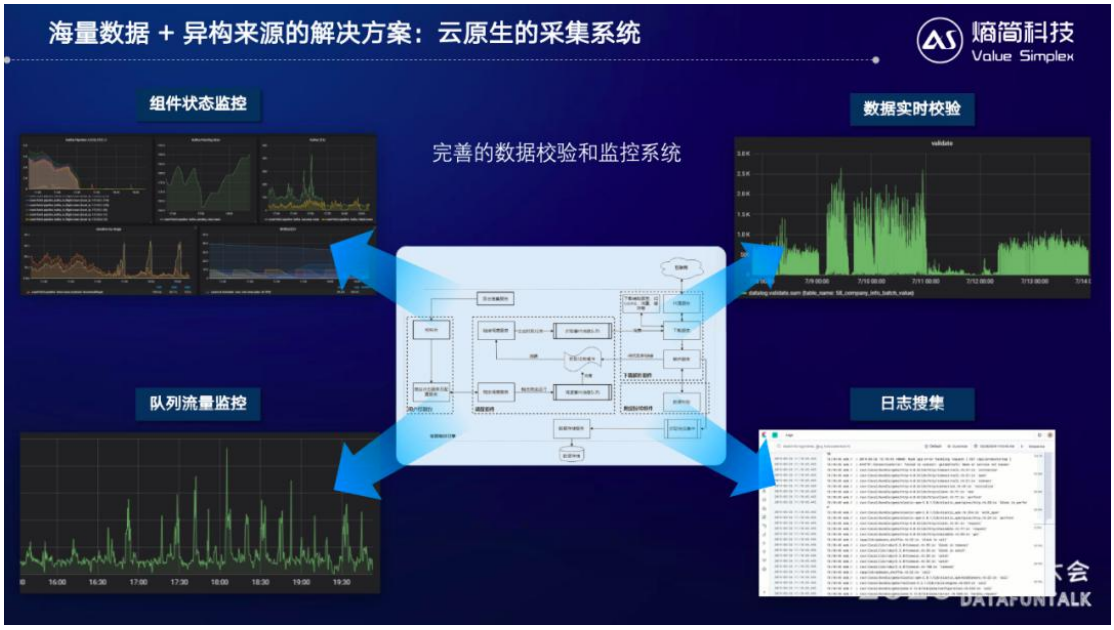

为了能够保证系统能够稳定、高质量的进行数据的采集和监控，系统也构建了一套完备的监控和报警体系，从三个层面对系统进行监控，包括基础设施/内存、组件和数据层。平台也有自己的数据交易规则，很多数据交易规则综合起来，成为监控异常报警的来源，在任何一层发现问题之后，都会第一时间向采集负责人进行报警，以保证系统的稳定性。

2. 数据源快速拓展

关于数据源的快速拓展部分，熵简科技的采集团队和算法团队一起合作，研发了一套智能化的网页抽取系统，这一套信息抽取引擎能够从网页中抽取出特定的区域、特定含义的文本片段。比如对于资讯数据来说，通常会关心哪一部分是新闻正文，哪一部分是新闻标题。对这个系统，提供了网页的 url 后，能够自动识别出网页中哪个字段是标题，哪个字段是正文，哪个字段是日期等，不需要一个页面一个面的去配置。其背后的实现原理也比较简单，每一个网页都是一个 HTML 文档，可以将它等价为一棵树，网页中的这些文本、图片链接都是树上各个节点和所携带的信息，所以想从原始网页提取核心字段，第一步将不属于提取内容的节点进行删除操作，第二步是根据这各个节点在树上的位置将节点中的信息序列化。

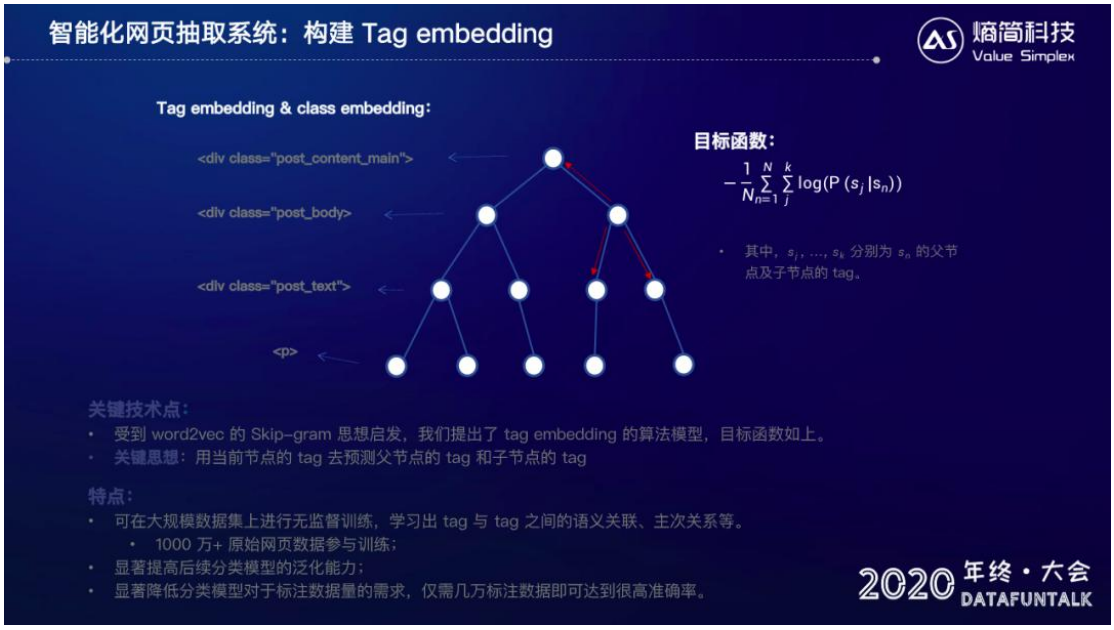

这里重点看一下第一步怎么样高精度的去剔除数上面的无用节点。这一步解决的其实是如何将网页上的标签和属性进行数字化表示的一个问题。公司算法团队 word2vec 的 Skip-gram 模型思想的启发，提出了 tag embedding 的模型.它的关键思想就是用当前节点的一个 tag 去预测 HTML 文档中父节点的 tag 和子节点的 tag。上图中右上角展示了算法的函数。该算法的优势是可以在构建的大规模数据集上进行无监督的训练，学习出 tag 与 tag 之间的语义关系。通过这个方法可以不依赖于人工标注就可以实现 HTML 标签的分布式展示。

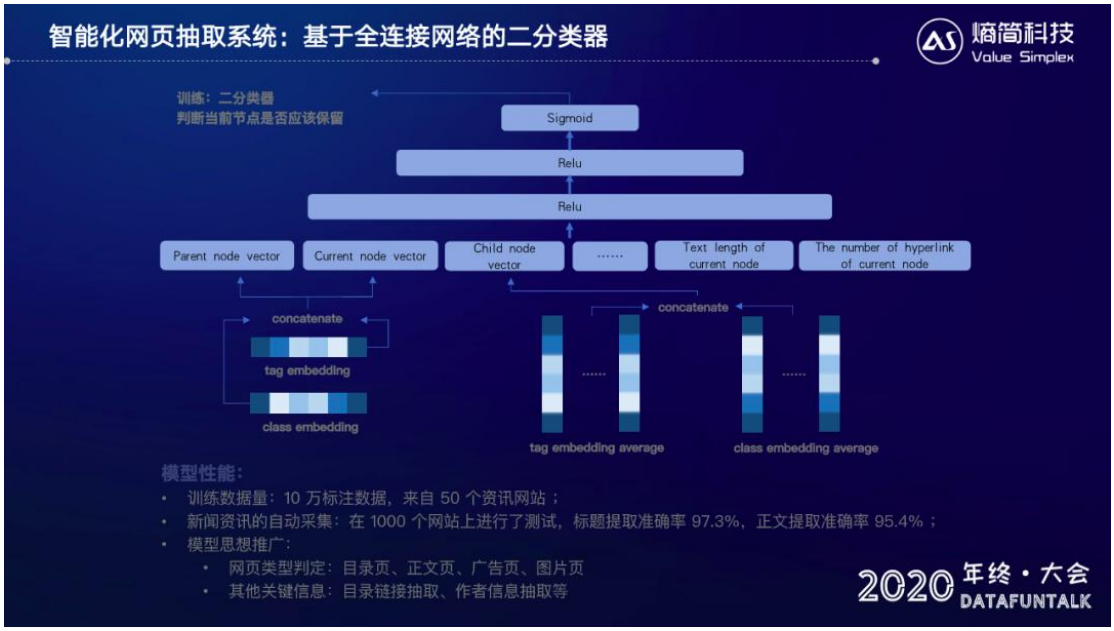

基于上述数据结果，算法人员利用基于三层前馈神经网络的二分类器，用来判断这个节点是否需要保留，输入的节点信息主要包括三大类，第一类是父节点的标签信息，第二类是子节点的标签信息，第三类是当前节点的标签信息以及当前节点其他特征。实际应用中整个模型在来自于 50 多个咨询网站十万的标注数据上进行训练，标题的准确率能够达到 97%左右，正文的准确率能够达到 95%左右。

03

数据中台：AirWorks 数据智能平台

1. AirWorks 简介

熵简科技在资管数据中台中实践中用到的核心组件在内部称为 AirWorks，数据中台本身和所使用的工具技术是解耦的，但是在实践过程中会发现自

研的核心组件对于自己和客户进行数据中台的建设都起到了很关键的一个作用。熵简对于数据平台的定义是面向于资管场景的业务数据平台，其本质是让前台人员都能够高效的、低成本的、更全面的用到业务数据。数据中台的价值主要体现在一方面可以提高数据管理和利用的效率，方便数据治理；另外一方面，通过数据分层，能够作为相对稳定的 IT 后台架构和快速迭代的前台业务需求之间的变速齿轮，使业务人员的需求能够更及时的被响应。其中的核心环节就是将数据层多源异构的数据进行融合，形成投研可用的知识。

熵简内部对 AirWorks 的定位即是一个低代码、可视化的数据 ETL 平台，同时也是一个科学建模系统和一个中心化的数据仓库和统一分发的数据服务。该工具集的目标是帮助编程经验较少或没有编程经验的用户完成数据清洗和数据分析工作。

2. AirWorks 功能架构

AirWorks 的功能架构自下而上分为四个部分，别是数据源接入、数据开发运维、数据资产管理和数据服务。在数据源接入部分既会接入数据采集系统采集的互联网公开数据，也会接入数据服务商提供三方数据，同时还会接入内部业务系统产生的数据。数据开发运维部分，统一了离线开发和实时开发，同时把算法团队提供的算法能力封装在整个平台中，使人人都可以成为算法工程师。数据资产管理相对于整个体系来说，是相对比较核心的部分，产品在中心化的数据仓库中提供了数据治理的功能。对外的数据服务部分一方面提供了一个 BI 可视化分析,另一方面提供了对接上层应用的 API 服务。

3. AirWorks 技术架构

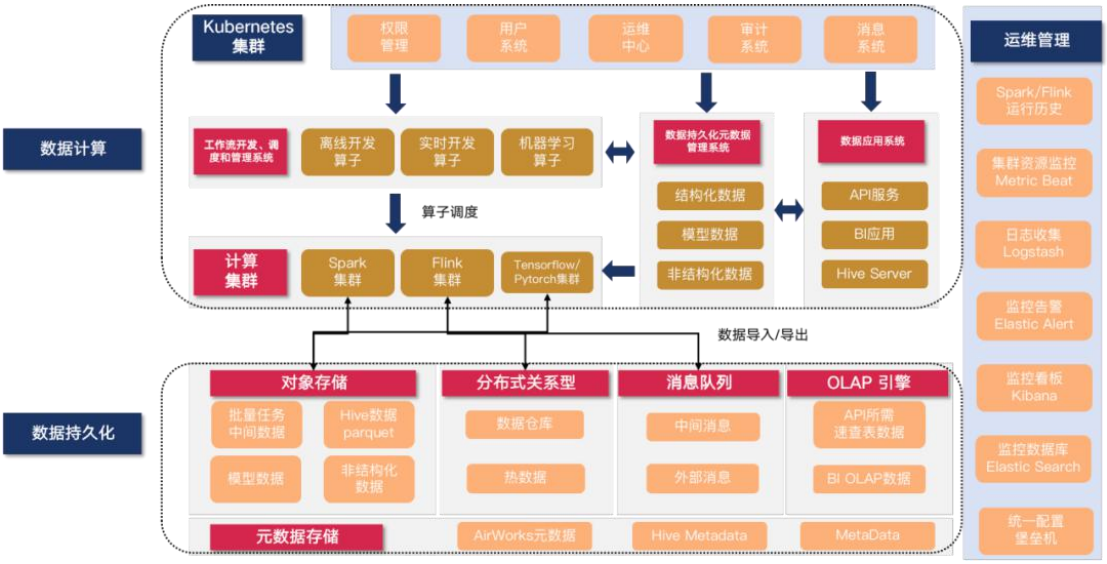

AirWorks 的技术架构在底层是数据持久化，上层是数据计算。数据持久化是深度依赖了对象存储，不管是批量任务的中间数据还是结构化和非结构化数据。构建数据中台的工具集面临的核心技术挑战包括五点，第一点是通过资源的计算引擎，把主流的这种开源框架都纳入进来，然后包括 spark、python 和 R 等对用户来说其实是透明的，用户在界面上进行可视化的数据配置的时候，不需要关心底层资源引擎是什么；第二点是对于异构数据量级，实现智能调度和监控管理，实现小数据和大数据统一分配。第三点是基于底层的开源的分布式架构，支持突破单机限制，实现资源的横向扩容，第四点是平台中集成了 NLP 的算法中台，通过算法团队提供的这样一个算法能力，让数据分析师都能够利用到已经训练好的模型，第五点是将整个采集据中台应用打通成一个全链路统一的基础组件，能给客户提供一站式的原生体验。

4. AirWorks 技术特点

对于用户透明下的异构任务处理这个问题，采用的是多引擎协同和多租户管理的方案，通过不同计算引擎的引入，让最合适的引擎去做最合适的任务。比如说在平台上，大部分的大数据相关的 ETL 操作是通过 Spark 批任务的引擎去处理的；对于科学建模的算子，其中的数据科学分析是通过 R 算子来进行的，背后的 NLP 的任务是通过 tensorflow 集群实现的。其中有两个核心点，第一个是各个算子之间是需要进行松耦合的，各自能够独立运行，第二个是算子本身是无状态的，算子之间只能通过数据进行驱动，这也就意味着在中间层组上，我们希望会将数据 ETL 的每一步都进行存储，所以背后也利用了对象存储这样相对稳定并且低成本的一个存储架构。在多租户管理方面，平台的核心目标是最大化资源的利用效率。

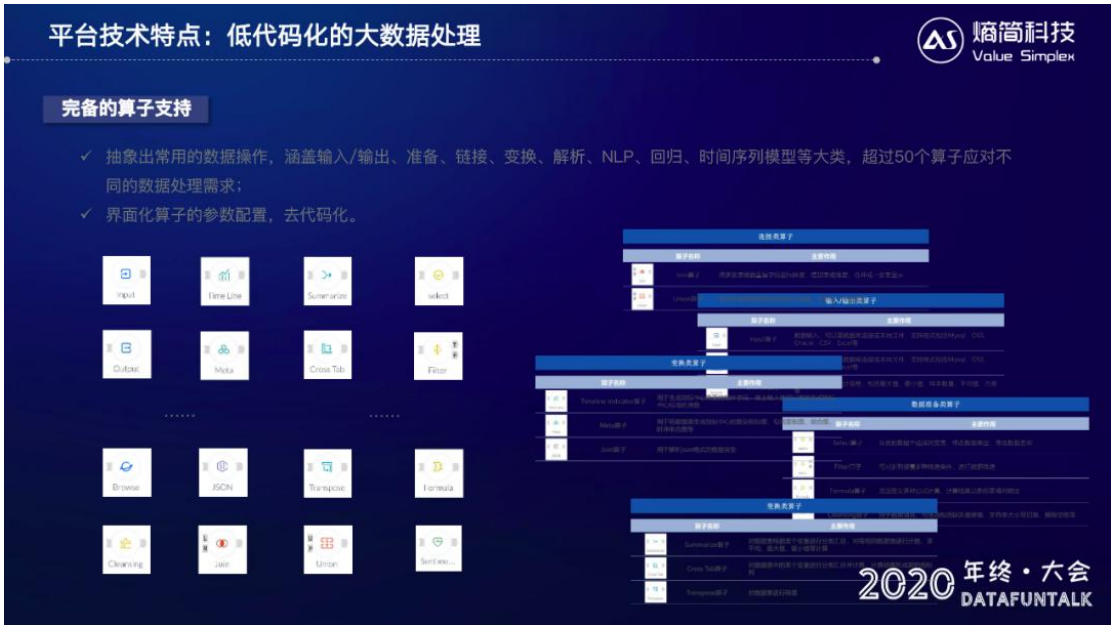

低代码化方面，整个系统提供了比较完备的原子化的算子支持，涵盖了从输入、输出到预处理和变换解析几大类。目前的算子数量已经超过了 50 个。从上百个应用案例的实践中发现，这些算子能够覆盖绝大部分的数据操作需求。

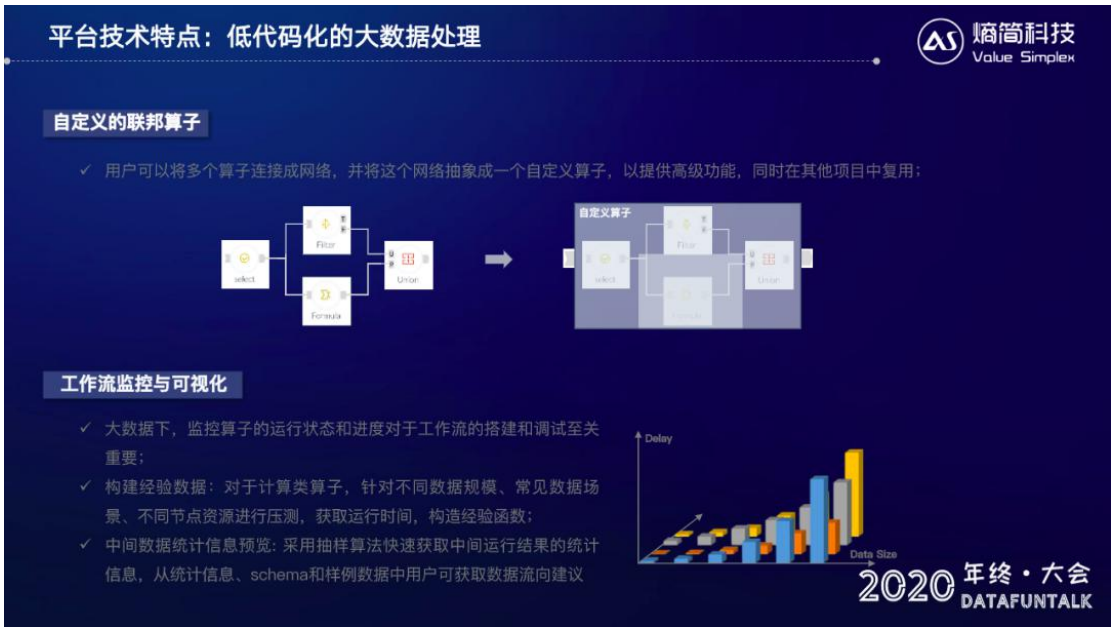

除了原子化的算子之外，系统也提供了自定义的联邦算子。具体来说就是用户可以将多个算子连接成网络，并且将网络抽象成一个自定义算子，在其他项目中进行复用。相对于系统本身的原子化算子来说，这类联邦算子可以提供更加高级的功能，支撑更快搭建工作流。在大数据的前提下，想要快速搭建工作流，算子的运行状态和进度监控是很重要的，因此系统也提供了工作流监控和中间状态的可视化。在实践过程中，很多金融机构都有相同的三方数据源，所以系统也提供一些相对高层的算子，比如资管机构基本上都会用到万得数据财务数据，系统会提供针对这种特定数据源的联邦算子。

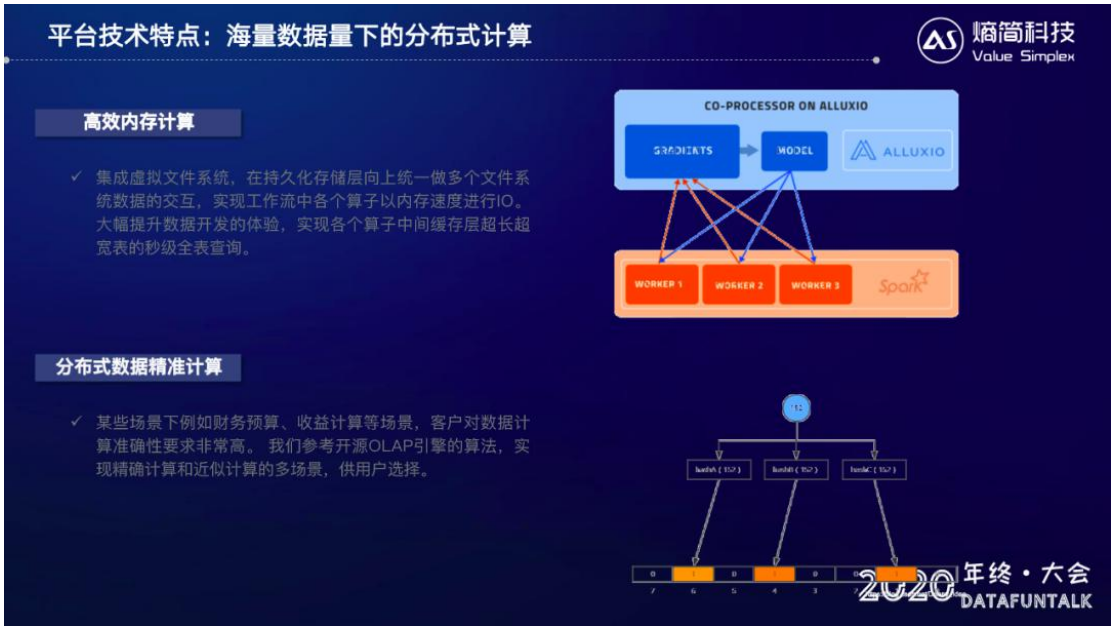

在海量数据处理的性能优化上，一方面引入 alluxio 虚拟文件系统提高系统的 IO 速度，提供高效的内存计算。同事参考开源 OLAP 引擎的算法，实现精确计算和近似计算的多种场景供用户去选择。

在大数据和小数据的均衡处理这个问题上，系统主要是通过采样预估加数据倾斜的策略去进行均衡，具体方式是在单元计算节点的资源选择上，采用最小规格的单个节点，这样在大数据下其实可能会存在问题，可能会由于比如说数据倾斜造成整个节点崩溃，为了解决这个问题，会在关键节点上，比如说 join 算子进行数据采样，根据采样的结果进行数据倾斜的预估，对于倾斜度较高的数据进行拆分处理，处理完之后再进行自动合并。

一个常见的案例就是在对公开的电商数据处理的过程中，经常需要将销售表和店铺表关联起来，但是由于不同店铺的销量会存在比较大的差异，所以其中可能有一半的数据都来自于比如说某一个旗舰店，通过采样的方式发现了数据倾斜的情况后，通过自动化的策略将数据的前缀随机打散，实现数据的负载均衡。

整个数据中台组建中，提供了一个数据全链路的服务，既能为客户提供一站式的原生体验，也可以根据客户实际的需求进行基础设施的对接和改造。

最后在整个大数据平台中，对接了 NLP 算法中台，一个实际案例是根据线上销售的数据和口碑数据去进行基本业绩的衡量，从客户的电商平台用户评论中去抓取评论数据，然后利用情感分析算子对每条评论进行情感分析，横向对比多个产品型号的用户的 NPS 指数，可以分析产品的口碑趋势，这也是投资研究中一个比较常见的案例。

04

实践案例：金融资管数据中台体系

最后简单介绍一下在某头部上市公司的实践案例，该案例是公司与某头部券商进行研究业务数据中台和智能投研应用系统的搭建。基于 AirWorks 数据智能平台搭建的内部研究业务数据中台，为上层的智能投研应用提供了有深度的分层次的数据服务。

对于资管数据仓库而言，和传统的数仓一样需要构建元数据模型，通过数据规范的定义和引入来全面准确的描述客户的资管业务。实际的做法和传统数仓的元数据建模是类似的，只不过抽象出来的实体包括环境过程，金融实体，实际行为等跟客户的实际业务紧密耦合。

抽象出这些元数据模型之后，整个数据处理过程分为四步，分别是数据输入、数据清洗、数据聚合和数据输出。从逻辑上看，整个过程并不复杂，前面提到的数据的均衡、多种计算引擎的协作已经交给 AirWorks 系统来完成了。整个数据中心的分层架构其实和大部分数仓是类似的，缓冲层和天然层基本按照原数据系统的数据结构进行存储，只进行非常基本的数据质量核验。指标会根据数据标准加工存储成各类数据指标，上层的整合会将所有的数据拿到一套逻辑模型中，最上面集市层面向具体的应用，但实际实践中，资管客户的大部分三方数据主要是以指标的形式存在，所以对应到明细层、汇总层再到集市层，分别定义了这样一套模式即一个 onedata 到 one indicator 再到 one entity 这样一个规范和模型，最后对外提供一个统一的 API 服务和交互探索的面板。从券商研究所的实际场景来说，依托 AirWorks 可以高效地打造一个精品的行业数据库，将研究员日常整理涉及到的研究底稿，做到自动化和线上化，实现一个数据的深加工和标准化封装，供给我们下游的一个应用系统。

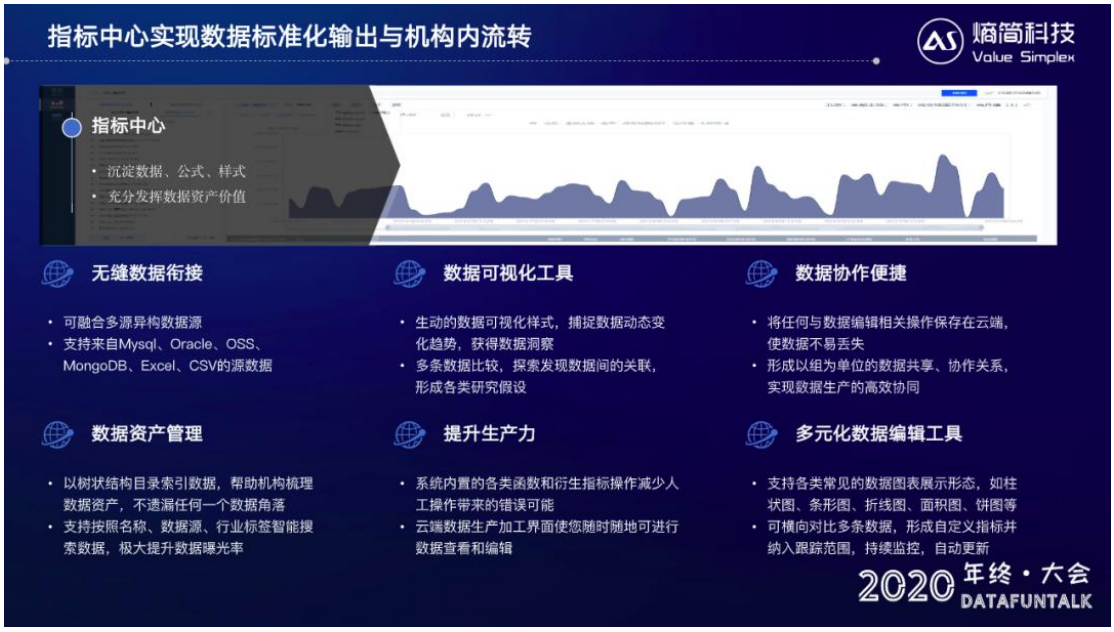

合作项目的第一部分是通过建设标准化指标中心的方式实现数据资产的沉淀，通过导入客户采购的各类第三方数据库，实现数据融合和面向业务场景的聚合搜索，打通研究所内部不同行业、公司内外部数据的使用边界。

在前端建立的应用上，研究所内部成员可以同时进行数据加工和生产，分析师能够从前端进行本地数据的上传和线上的数据编辑，生成个性化的指

标。前端的应用上，还提供了指标中心、在线编辑和智能研报等多种场景的应用形式。

项目的第二部分是将分析师的底稿进行线上化，通过 AirWorks 数据融合工具加上自动化脚本导入的方式，结合前端用户上传和自定义维护，将研究员非结构化的研究素材通过技术手段整理为归一化的业务指标，最后在前端应用中通过知识图谱的方式实现知识沉淀。研究所内核心的研究逻辑和模型框架可以用可视化的方式进行图形化的绘制和结构化的存储。结构化的知识一方面可以帮助券商作为卖方对外输出为特色的研究产品，另外一方面也可以对内为智能投资提供结构化的专家支持。

今天的分享就到这里，谢谢大家。

增强分析技术原理与实践

文章作者：马玥、丁建栋 阿里巴巴
编辑整理：Hoh
内容来源：作者授权
出品平台：DataFunTalk
注：欢迎转载，转载请留言。

导读：去年，增强分析（Augmented Analytics）与人工智能、量子计算、和区块链等技术一起被 Gartner 评选为十大战略趋势之一，高调走入公众的视线。Gartner 认为，增强分析将颠覆目前的数据分析模式，代表了数据和 BI 能力的第三大浪潮。在 Gartner 的分析与商业智能技术成熟度曲线上，增强型分析傲视群雄的处在"期望膨胀期"的最高点上，其热度可见一斑。

图 1 Gartner 相关研究

那么，这大热的增强分析到底是什么？与传统 BI 有何差别？将为业务带来怎样的影响？现在市场有哪些相关的解决方案？我们有没有相关技术布局？我们查阅了相关文献资料，并尝试通过这篇文章去回答这些问题，希望能抛砖引玉，与大家一起学习、探讨。

01

什么是增强分析

增强分析的概念由 Gartner 在 2017 年提出，在 Gartner 当年的报告《Augmented Analytics Is the Future of Data and Analytics》中，给出了增强分析的定义：

"Augmented analytics is a next-generation data and analytics paradigm that uses machine learning to automate data preparation, insight discovery and

insight sharing for a broad range of business users, operational workers and citizen data scientists.——增强分析是下一代数据和分析范式，它面向广泛的业务用户、运营人员和民间数据科学家，利用机器学习将数据准备，洞察发现和洞察共享等过程自动化。"从 Gartner 这个定义看来，在概念提出之初定义还是很模糊和宽泛的，在之后的两三年，Gartner 也在不同的报告中围绕这一概念做了许多的讨论。我们对其中的观点进行了总结，从三个角度来看增强分析相较于传统数据分析到底"增强"在哪里。从数据分析的流程而言，数据分析的过程可以抽象为三个阶段：

- 数据准备
- 洞察发现
- 结果共享

增强分析的重点在于提高这一流程的易用性（无代码化）和自动化程度。如下图所示，在数据准备，增强分析通过自动化帮助我们加速一些耗时耗力的工作；在洞见发现阶段中，自然语言查询将优化人机之间的交互方式，而自动化洞察能够帮助我们及时的发现数据中的规律和变化，原本复杂的建模也被自动化建模过程取代；此外，在结果的展示方面，自然语言生成、自动化报表等技术也大大降低了数据分析的门槛，催生出更多的"民间数据科学家"。

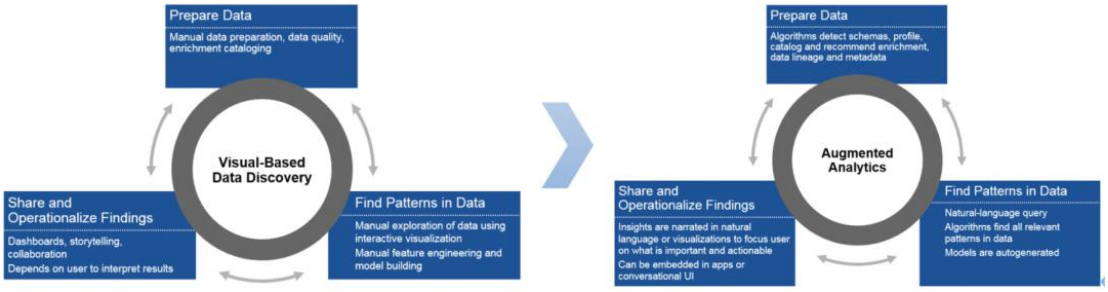

图 2 数据分析流程变化[1]

从数据分析中各角色的分工而言，增强型分析带来的变化非常显著。从下图可见，增强分析在赋能数据分析人员，从而为 IT 人员减压。数据分析人员可以把控的事情变得更多，以前可能需要 IT 技术人员提供的支持，现在数据分析人员自己就能按具体需求操作。这样的变化将带来业务流程的效率大幅提升，也避免了需求传递造成的信息偏差。

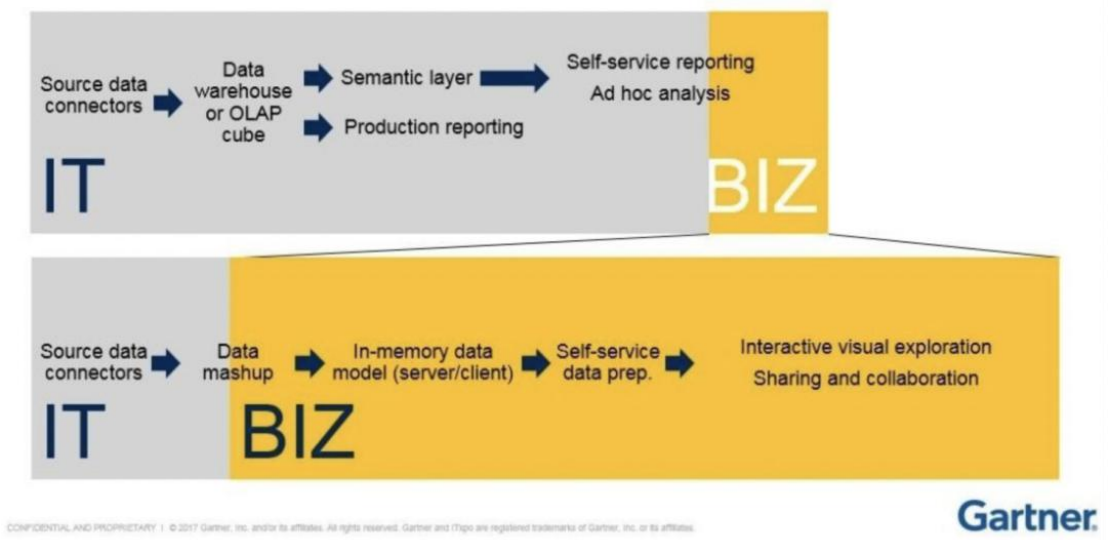

图 3 数据分析角色任务变化

从数据分析的层次而言，之前 Gartner 曾定义了数据分析的四种能力，如图 4。传统的数据分析主要关注于利用统计学方法给出描述性分析和诊断性分析。而对于预测性和处方性分析，之前则必须在数据科学家的帮助下才能完成。随着数据建模的过程不断自动化，基于数据挖掘模型的数据分析能力将越来越普及，也就是说我们能够轻松的做更多的预测性分析和处方性分析，企业对数据认识的整体能力也将不断加强，数据的价值也将被更大程度的释放。

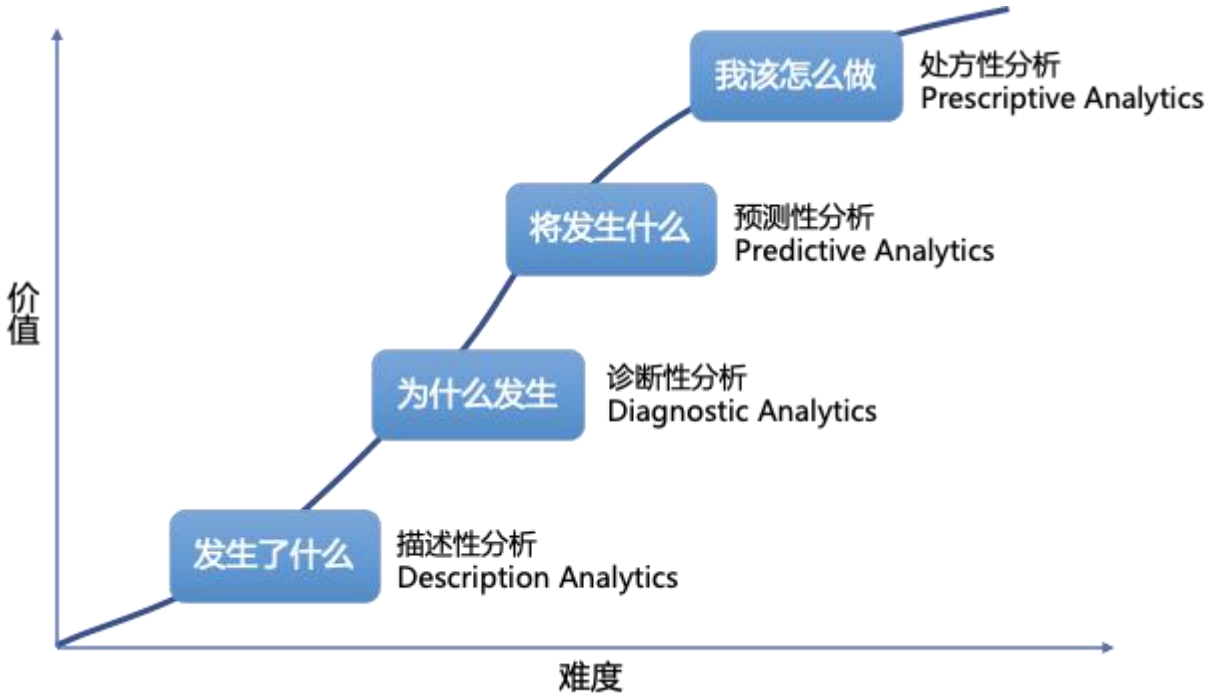

图 4 数据分析的四种能力

总结而言，增强分析并不是一种技术或是一个产品，而是一系列的技术和方法，其目的就是为数据分析提效和降低数据分析的门槛。这其中包含的很多技术其实已经问世多年，而 Gartner 为他们取了个酷炫的名字以后，就成功将他们推向了风口浪尖。值得一提的是，"商务智能"这个古老的概念也是由 Gartner 提出的。

02

关键技术能力

对增强分析的概念有了基本的认知之后，我们来看看增强分析具体包含了哪些技术能力。结合 Gartner 的分类，我们可以将增强分析相关的技术分为了三类：增强数据准备、增强数据分析和增强数据挖掘。

1. 增强数据准备

准备数据通常是最耗时的工作。这里的数据准备不仅包含所谓的 ETL 或者 ECTL，通常包含有数据探查、数据质量、数据协调、数据模型、数据清洗、数据聚合，元数据管理以及数据编目等工作，涵盖了数据管理的各个方面，甚至向前延伸到数据集成和数据湖的管理。增强数据准备通常从两个方向着手加速以上过程：

- 可视化交互：通过类似 Excel 的界面以及托拉拽式的操作方式实现可视化的数据配置、数据源的混合以及数据清洗工作，让数据准备变得"无代码化"。

- 算法辅助：利用机器学习和 AI 技术来自动化上述的部分流程。例如，自动的查找数据之间的关系，对数据质量进行评估，推荐用于连接、丰富、清洗数据的最佳方法，还有自动查找元数据和血缘关系等功能。例如下图中，Paxata 平台自动找到了两张表最佳的 join 方式。

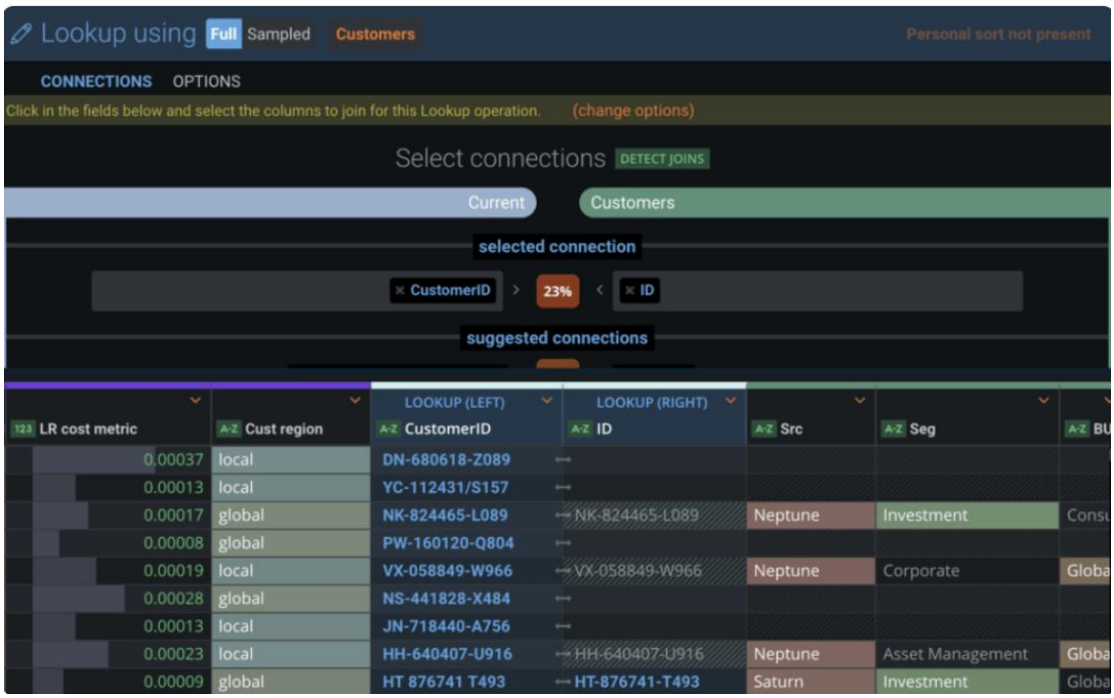

图 5 Paxata 提供智能数据连接

显然，攻克数据准备这一瓶颈将大大提升分析的效率，从 2012 年前后，市场上开始出现专注于数据准备的供应商，包括 ClearStory Data、Datawatch、Paxata、Trifacta 等公司。近两年，许多 BI 平台和数据科学平台厂商也都在将增强数据准备作为重点提升方向。2018 年，CAE 仿真平台厂商 Altair 宣布收购 Datawatch；2019 年，专注于 AutoML 的数据科学平台 DataRobot 将 Paxata 纳入麾下；除了资本运作，更多的大厂也在优化自己产品的数据准备功能，例如 Tableau 推出的 Tableau Prep（如下图），PowerBI 推出的 Power BI Premium 都提供了简单直观的自助式数据准备功能。

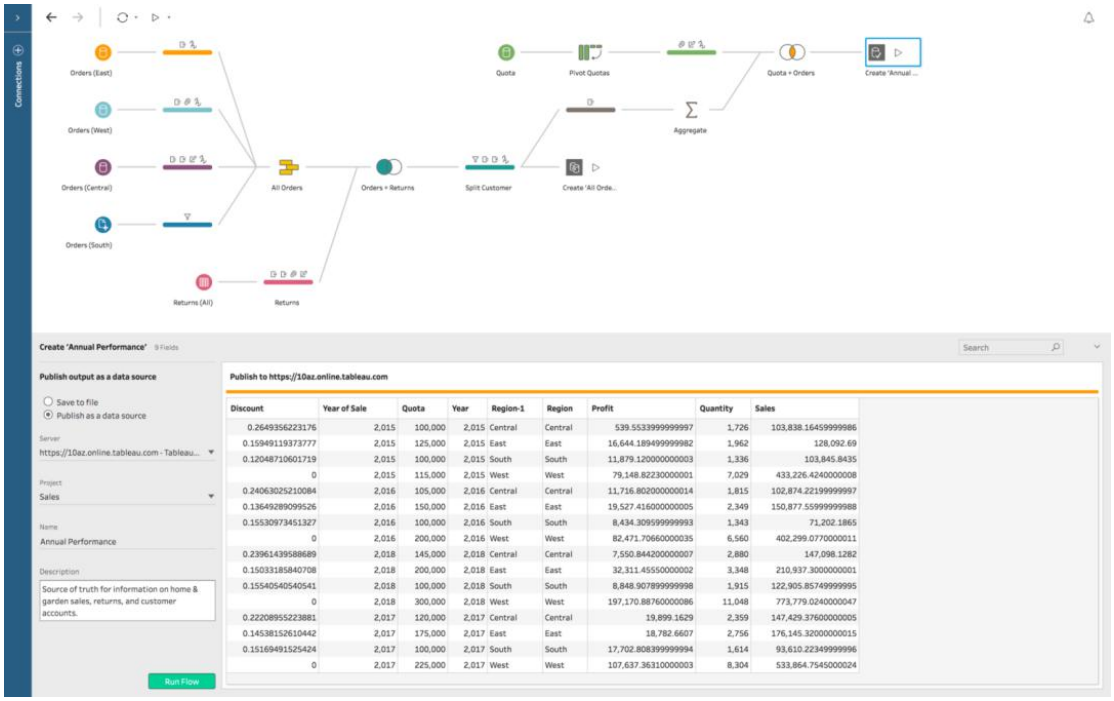

图 6 Tableau Prep 图形化界面

目前，图形化的操作界面似乎已经被习以为常了，但是，针对数据准备目前能够提供的算法辅助功能还是散点式的，虽然交互式界面使得用户操作数据不再依赖代码，但整个过程仍需要人工大量的参与，相信这一领域仍有很大的发展空间。

2. 增强数据分析

与数据准备思路类似，我们也可以将增强数据分析相关的技术按照其业务应用目标划分为了易用和智能两类。易用类技术帮助数据分析的用户无需建模和编写算法，而是通过可视化和对话界面来研究数据，大大提高了数据分析的可用性；而智能类技术在帮助用户自动寻找数据规律，将相关结果自动的转化为可视化表达，提高分析的效率。

① 易用性

易用类技术主要包含了自然语言查询（Natural Language Query，NLQ）和自然语言生成（Natural Language Generation，NLG）两个方向。

自然语言查询（NLQ）：自然语言查询是指用户直接在搜索框输入或通过对话的方式查询数据。想要将用户的问题与数据表中的数据对应上，NL2SQL（Natural Language to SQL）技术就是其中的关键。举个例子，用户可能会问「特斯拉的车总共卖了多少辆？」，通过 NL2SQL 就会将其转化为相应的 SQL 表达式是「SELECT SUM(销量) FROM TABLE WHERE 品牌=="特斯拉"；」。NL2SQL 这一任务的本质，是将用户的自然语言语句转化为计算机可以理解并执行的规范语义表示，是语义分析（Semantic Parsing）领域的一个子任务。在深度学习方法流行之前，这一领域的解决方案主要是通过高质量的语法树和词典来构建语义解析器，再将自然语言语句转化为相应的 SQL，例如 Google 2017 年提出的 Analyza 方法[2]，Sen 等人提出的 NLIDB 方法[3]。这类方法都具有类似的框架，以 NLIDB 为例，通过 Evidence Annotator 按照规则对查询语句进行分解，而后通过多步的"组装"拼接成 SQL 语句。现在的解决方案主要是深度学习与 SQL 特征规则相结合的方法。

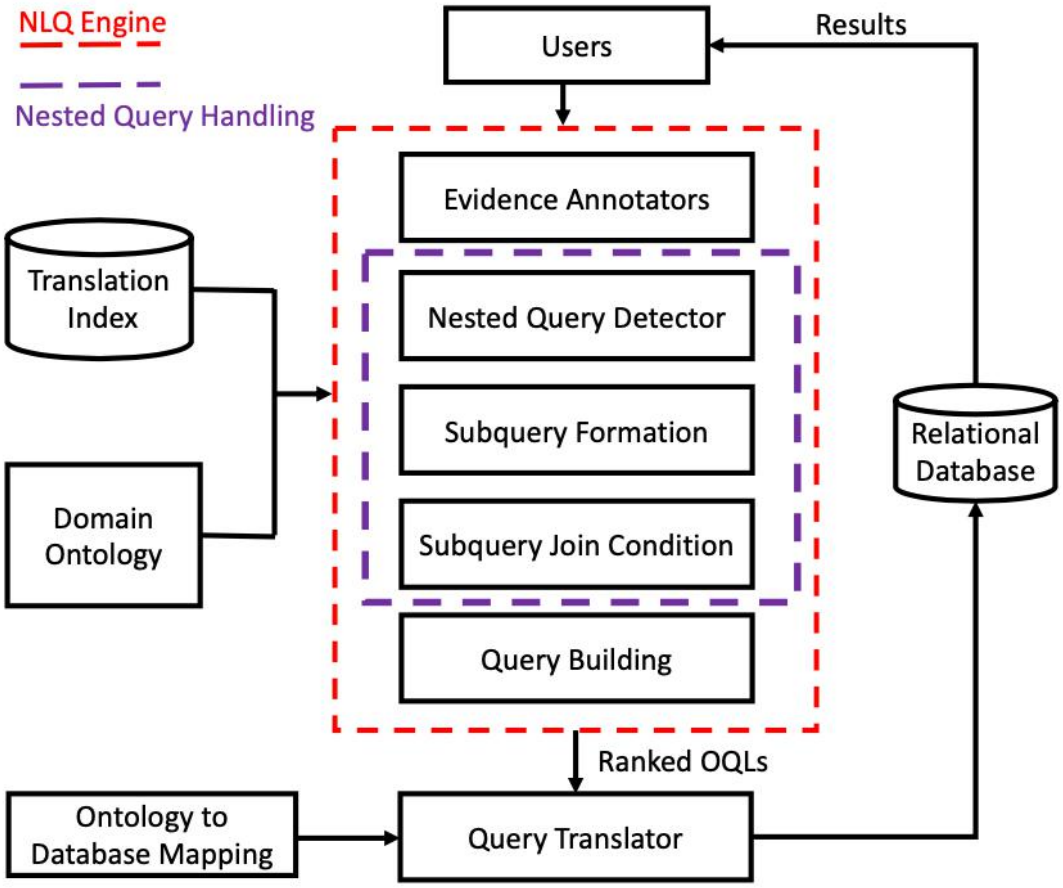

图 7 NLQ 方法 NLIDB[3]系统框架

近几年在学术界和业界这一领域都得到了广泛的关注，Salesforce、斯坦福、耶鲁等机构提出了 WikiSQL、WikiTableQuestions、Spider、SParC 等大规模数据集，并得到多次评测结果的提交。其中，Salesforce 于 2017 年提出的 WikiSQL 数据集是目前规模最大的有监督数据集。在这个数据集上，SQL 执行结果的准确率目前已经突破 90%。但 WikiSQL 数据形式过于简单，只支持最基础的 SQL 语句，而聚组、排序、嵌套等其它众多常用的 SQL 语法都不支持。这样的数据集并不符合真实的应用场景。相比之下，Spider 等数据集更贴近于真实应用场景，支持几乎所有 SQL 语法的用法，而相关的评测各项指标还都很低。如何应对复杂的 SQL 语句仍是非常值得探索的方向。NLQ 技术在产品形态上主要有两种，搜索式和对话式：

搜索式类似于搜索引擎，用户输入感兴趣的分析目标，系统将辅助用户进行查询条件的细化，而后自动将结果进行图形化展示。搜索式的代表产品就是 2019 年闯入 BI 魔力象限 Leader 梯队的黑马 ThoughtSpot，它的 slogan 就是"Search & AI-Driven Analytics"，从 2012 年诞生之初，它就是使用搜索作为访问数据的主要界面，这种设计就意味着其面向的最终用户是普通业务人员而不是分析师，较低的使用门槛为它快速积累了大量客户。目前主流 BI 大厂都基本能够支持搜索式的数据分析。

对话式数据分析主要是数据分析与对话机器人的结合形成的数据机器人，Qlik Insight Bot、QuickBI 的智能小 Q、我们团队开发的数小蜜都是此类的典型产品。数据机器人不仅可以以独立产品存在，而且可以提供 PaaS 能力与其他机器人相结合，例如阿里数小蜜机器人的能力就输出到了阿里店小蜜、阿里内外小蜜、钉钉智能助理等诸多的场景。

自然语言生成（NLG）：NLG 技术是将语义信息以人类可读的自然语言形式进行表达。根据输入信息的不同，NLG 又可分为：数据到文本的生成、文本到文本的生成、意义到文本的生成、图像到文本的生成等。在数据分析中应用 NLG 主要是数据到文本的生成，它能够将分析结果转换为人类理解的清晰叙述，以帮助用户更好的理解数据，讲好数据故事。与其他 NLP 领域类似的，在 NLG 技术发展的历史过程中，主要包括基于模板的 NLG 和基于神经网络的 NLG 方法两个阶段。Reiter 等人[4]将基于模版的系统进行了归纳总结，将 NLG 系统划分为文本规划、句子规划、句法实现 3 个模块。其中，文本规划决定文本要说什么（what）；句法实现决定怎么说（how）；句子规划则负责让句子更加连贯。在该框架下，针对不同模块，若干基于统计的模型被提出。

图 8 典型的三阶段式 NLG 架构[4]

近几年，基于深度学习的 NLG 方法也层出不穷。在今年 2 月份，微软公布了史上最大的语言生成模型，Turing-NLG，拥有 170 亿参数量，可以说是超级庞然大物。基于神经网络的方法又分为基于神经机器翻译（Neural Machine Translation）的方法和基于神经语言模型（Neural Language Model）的方法。前者将基于结构化数据的文本生成任务视为一个翻译任务，即输入的源语言是结构化数据，输出的目标语言是文本[5]；后者则主要是将以 bert 为首的大量预训练模型应用到了 NLG 任务中。对比基于模板的方法和基于深度学习的 NLG 方法，基于模板的更可控，但是结果较为生硬、死板，而且后期扩展对初期规划依赖较大，常用于天气预报、财报、新闻等场景；而基于深度学习的端到端方法可以更好的生成创意性、个性化、娱乐性等文本，但是效果不可控或者难以控制，目前的研究方向主要是将两者进行融合。这一领域的另一个挑战来自于数据，一方面，不同应用场景中的文本要求差异很大，现在能够用于训练的数据集仍然不够丰富；另一方面，data2text 任务的训练数据需要大量数据到文本的映射，收集成本很高。这就限制了需要大量训练数据的深度学习模型发挥出更好的效果。而在产品应用方面，BI 平台目前对 NLG 的应用还比较简单，例如下图 Tableau 的 Expain Data 中的 C 区域，就是对结果的简单解释。想必其背后应该是一套基于模板的方法，随着分析人员对自动化报告的要求越来越高，这一领域 NLG 的应用也会不断深入，不知道未来 BI 能不能自己帮董秘们写出一份慷慨激昂的董事会发言稿。

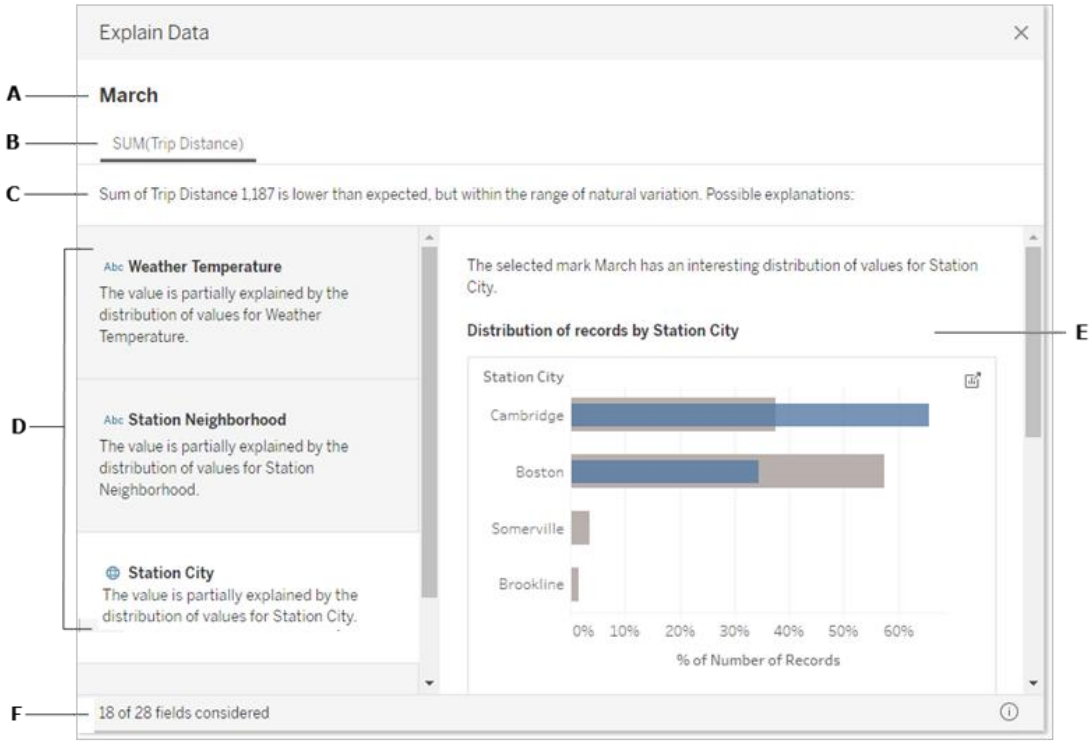

图 9 Tableau Expain Data 界面

② 自动化

另一个方向就是自动化，自动的帮助用户完成数据分析中的一些过程。这里典型的技术包括自动洞察（automated insights）和自动可视化（automated visualization）。

自动洞察：自动洞察，也叫主动洞察，是增强分析的核心功能，但同样也是一个宽泛的概念。现在大部分的主流 BI 平台都有自动洞察的相关功能推出，且方向各有不同。自动洞察的目标就是代替一部分分析师的工作，从数据中发现潜在信息和价值。从任务目的的角度划分，主流的技术有以下几个方向：

发现关联：比如分析 GMV 关联因素，可能涉及到订单量、金额、人数、产品类型等多种因素，通过自动洞察可以在分析高费用收入时，找出哪项因素对高费用影响最大。传统的指标解释常常需要数据分析师依靠业务理解和经验对数据指标进行拆解，找出影

响因素。而自动洞察则能够自动完成这一过程。图 9 中的 Tableau 的 Expain Data 就是通过构建贝叶斯模型评估各个数据项对目标值的影响大小，而后通过图表的方式给出了对目标值影响最大的数据项分布，引导用户进一步探查。

发现异常：自动的发现数据异常，不再依赖于规定固定的阈值。这个领域在学术界应该是个古老话题了，在此就不做赘述。

自动聚类：聚类是一种典型的无监督学习，可以自动的将样本分成若干组，因此也被认为是一种自动洞察能力。

现在学术界和 Google、微软等大型科技公司都在自动化 insight 推荐方面走的比较远，且方向各有不同。以微软的 PowerBI 为例，其推出的"快速洞察"（Quick Insights）功能能够自动对于源数据做出各种交叉的一阶或者多阶计算（百分比，排序，同环比），从而挖掘数据内部各种趋势，显著点等洞察，同时发现数据之间的相关性、数据内的异常点、时序数据的趋势以及周期性变化规律等等，并进行可视化呈现。

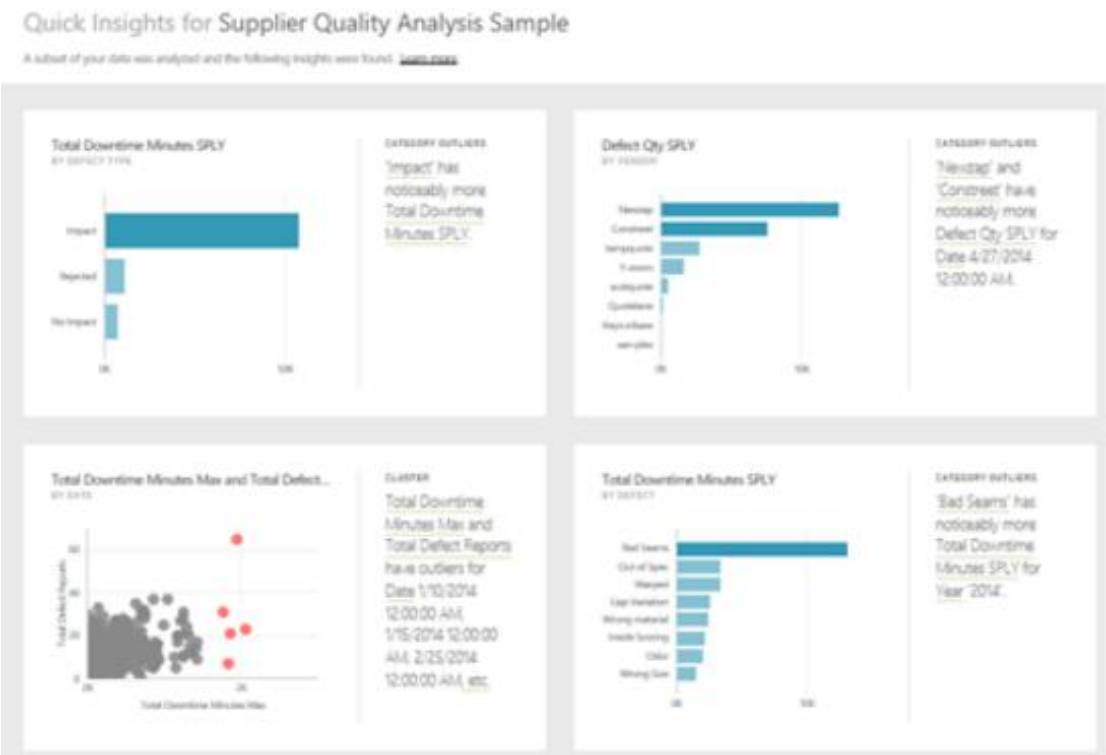

图 10　PowerBI 快速洞察功能

自动可视化：自动可视化的概念就非常直观了，就是根据你的数据结果自动的选择可视化的方式进行展示，以清晰的展现数据分析结果。自动化报表与自然语言查询、自然语言生成等技术配合，将大大加快整个分析流程，对前台业务人员十分友好。但这同样是个很大的话题，数据可视化毕竟不是选择用柱状图还是折线图展示这么简单。它大概可分成两个层次：

自动化图表：无需用户操作直接生成图表，根据图形语法、图表配置映射等方式将图表渲染出来

自动化报表：自动生成报表，参考分析目的和图形样式等方面来生成报表布局、配置控件、图表联动等

如果把可视化比作是一种数据到设计的翻译，那么好的可视化也需要做到"信达雅"。生成的数据表不仅要能被看懂，还要美，还要能交互，更高的要求是能够帮助用户讲好故事（storytelling），比如直接生成 deck 或者海报。在学术领域，自动化图表技术可以分为两类，基于规则的方法和基于机器学习的方法[6]。基于规则的方法依赖于预先设置好的规则库，这种方法的效果非常依赖于规则库的质量，也缺少灵活性。另一类方法则是将问题转化为了分类或排序问题，而后训练相应的模型，例如将一种可视化方案分类为"好"或"坏"。这其中，如何刻画源数据的特征和可视化图表的特征是相关研究重点讨论的问题。在产品方面，基础的自动化图表已经有许多主流 BI 厂商提供，一些开源的软件也有着不错的支持，例如 AVA，Rath 等等。感兴趣的同学可以关注一年一度的可视化领域顶级会议 IEEE VIS，每年都会有有意思的方法、工具出现。

3. 增强机器学习

既然前面已经谈过了数据准备，这里谈到的机器学习就更加纯粹的关注于模型本身，比如特征工程、模型训练、模型部署、模型解释以及最后的模型监控和管理。与增强数据分析相比，增强机器学习面向的更多是数据科学家，通过算法将特征工程、模型选择与超参数优化，以及深度神经网络结构搜索等机器学习过程中的关键步骤自动化，帮助数据科学家更高效的得到满意的模型。许多 BI 平台都提供嵌入的机器学习模型，例如预测、聚类等，其中将许多之前必须数据科学家来做的工作变成了自动的流程，使得数据分析师或者业务人员也可以通过图形化界面完成，这就大大释放了数据科学家的精力。这部分的核心技术就是近几年大热的自动机器学习 AutoML。早期的 AutoML 研究起源于 Meta Learning，早在上个世纪八十年代就被提出，数十年间在机器学习领域的相关研究主要集中在超参优化。近年来随着深度学习的广泛应用，Meta-Leaning 领域

在学术界又一次升温。同时，自动化特征工程、自动化模型评价等技术的研究和商业化也使得 AutoML 的概念覆盖到了机器学习的全流程。

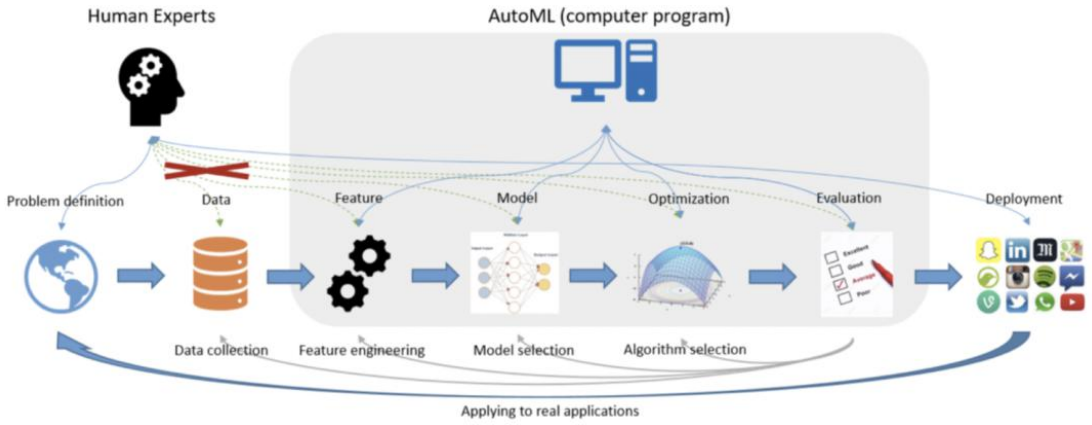

图 11 AutoML 应用于机器学习全流程[7]

AutoML 要解决的问题主要是释放机器学习过程中的人力投入。从提升技术生产力的核心环节角度看，AutoML 覆盖的领域可以分为三个方向：

① **特征工程：**特征工程在机器学习中都有着举足轻重的作用，同时也非常考验数据科学家的能力。在 AutoML 中，自动特征工程的目的是自动地发掘并构造相关的特征，使得模型可以有最优的表现。特征工程可以分为特征生成、特征选择、特征编码等步骤，而其中的小步骤是非常繁杂的（做过的人应该深有体感~），因此这部分的策略和技术方法也是非常多样的，在此就不做赘述了。常用的工具包括 Tsfresh、Trane、Categorical Encoding、boruta_py、Featuretools 等等。

② **机器学习（模型选择与超参优化）：**这部分主要面向传统的机器学习，在训练过程中需要选择模型，设定模型的参数，这是早期的研究重点，也是当前产品化的主要方向。现有的平台基本上都是预定义一系列模型，比如预定义 20 种不同的模型，在试每个模型的过程中给这些模型选择参数。选择参数比较常见的做法是将调参和训练分离开，调

参过程给训练过程建议一组或多组参数，训练过程反馈结果，然后调参过程根据反馈结果产生下一组建议的参数。这个过程一直迭代直至满足了终止条件。调参过程中比较常见的算法为网格搜索，随机搜索和贝叶斯优化等。

③ 深度学习（网络架构）：对深度神经网络结构搜索（NAS）问题的探索是近几年最热的研究方向。T.Elsken 等人[7]将该问题的研究归纳为三个方向：**搜索空间、搜索策略和评价预估。**

搜索空间问题旨在找到了一组网络架构参数和对应的超参数，深度学习模型的性能由这组参数来控制和决定的，那么问题就转化成了对复杂模型的架构参数和对应的超参数进行优化。

搜索策略旨在设计更优的算法快速、准确找到最优的网络结构参数配置。搜索策略主要包括了增强学习、进化算法、基于梯度的算法等。

评价预估类的策略是使用近似评估的思路解决大规模数据上训练和评价过于耗时的问题，常用策略包括低保真数据集训练模型，代理模型和参数级别迁移等。

2018 年 Google 推出了一系列 AutoML 商业化产品（AutoNLP，AutoCV，AutoTranslation，AutoTable），这一概念在业界也开始受到广泛关注，之后 Amazon、Microsoft、Facebook、Uber 及很多创业公司都纷纷推出了自己的自动机器学习库或产品。国内互联网公司同样推出了相关产品。阿里云机器学习平台 PAI（Platform of Artificial Intelligence）是阿里巴巴推出的机器学习服务平台，其中 PAI AutoLearning 自动学习是 PAI 推出的全新自动机器学习平台，支持在线标注、自动模型训练、超参优化以及模型评估，在平台上只需准备少量标注数据，设置训练时长即可得到深度优化的模型。

03

数据机器人实践

阿里机器智能技术-智能服务事业部于 2017 年推出了创新产品数据机器人，以对话机器人形式提供多维数据查询、智能分析、预警推送、数据可视化等多项数据智能服务。该项目开始之初，增强分析的概念还远没有现在这么火，而现在看来，数据机器人正是增强分析的一个典型案例。数据机器人于 2017 年 10 月在钉钉上首次上线，最初通过机器人平台的会话流和意图配置提供客户体验领域的指标查询。经过两年多的业务发展，数据机器人已接入阿里集团 20 多个 BU、100 多块子业务的数据，并且以 PaaS 化服务的形式接入到阿里小蜜、钉钉智能助理、内外小蜜、云小助等机器人实例中，提供个性化的数据查询和分析服务。

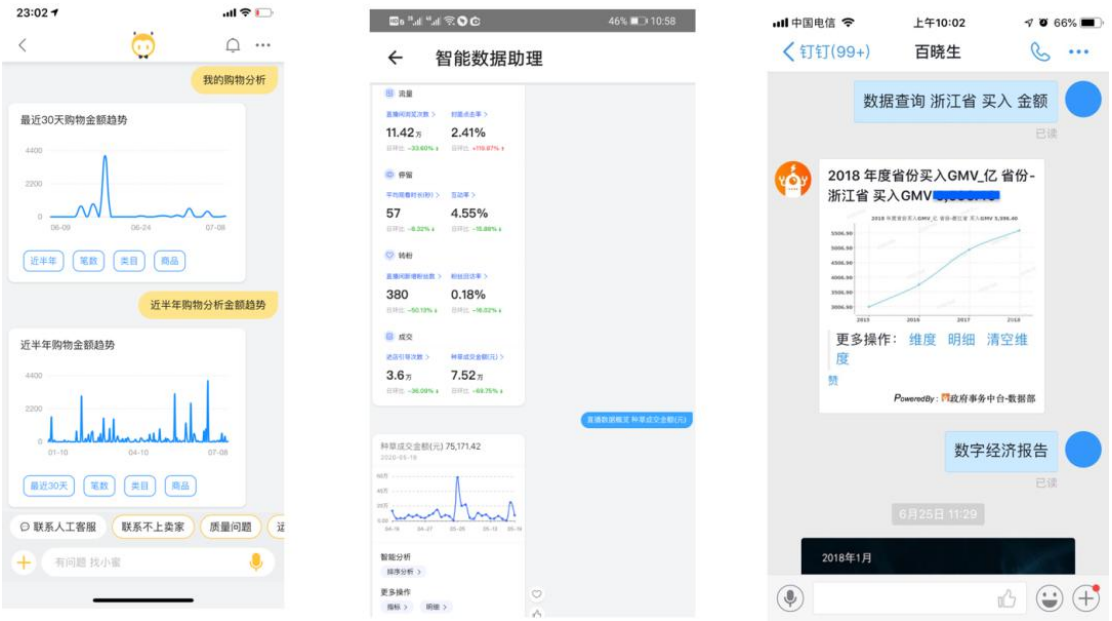

图 12 数据机器人应用实例

从功能而言，数据机器人主要功能特性都完美契合了增强数据分析的能力方向：

对话式分析：基于分析意图模型和多轮对话管理能力，实现灵活便捷的对话式分析请求和丰富数据展现。这一过程实质将 NLQ 和自动化报表串联起来，自然语言转 SQL，再将 SQL 结果集转图形，形成了"NL2SQL2Graph"的完整链路，同时利用 NLG 技术形成机器人对话能力。

动态预警：借助数据机器人的动态预警能力，实现数据自动找人，将业务数据的异常波动主动推送到相关人和钉钉群，帮助业务部门及时发现问题并采取有效措施。

智能分析：数据分析算法化，支持归因、TopN、维度下钻、时序预测等等算法，以及动态的操作推荐。

智能洞察：具备时序异常检测、因果关联、波动归因等主动洞察能力，自动的发现有用结论。这些都是自动洞察技术的典型应用，同时叠加 NLG 过程，为用户自动的生成智能洞察报告。

数据机器人对业务场景的支持，有 PaaS 和 SaaS 两种形式。通过开放的数据接入和机器人实例定制，可以高效实现业务定制的数据机器人。目前，数据机器人上公有云的准备工作也在紧锣密鼓的进行，不久后就能在云上与更多的用户见面，数据机器人的增强能力实践，也将以系列文章对外发表。

04

结论：未来已来，将至已至

在 2019 年初，Gartner 在分析和商业智能平台魔力象限报告中曾作出预测：

到 2020 年，增强分析将成为用户部署数据分析、数据科学、机器学习以及嵌入式分析平台的主要推动力。

到 2020 年，50%的分析查询将通过搜索、自然语言处理或语音生成，或者将由平台自动生成。

而身处 2020 年的我们，似乎并没有对预测的结果有深切的体感。而在今年初，Gartner 做出了对增强分析最新的预测：

到 2022 年，增强分析技术将无处不在，但只有 10%的分析师将充分发挥其潜力。

到 2022 年，40%的机器学习模型开发和评分将在没有把机器学习作为主要目标的产品中完成。

到 2025 年，数据故事将成为最广泛的消费分析方式，75%的故事将使用增强分析技术自动生成。

从字里行间可以感受到 Gartner 对这一方向的信心。着眼主流 BI 平台和数据科学平台，近几年的确都在这条赛道上蓄力，相信这些预测必然会实现。正如前面提到的，增强分析旨在为数据分析提效和降低数据分析的门槛，而提升数据分析平台的易用性和自动化程度成为了发力的两个主要方向。从三类增强分析的关键技术来看：

增强数据准备，主要通过可视化交互实现全程的无代码化，提升易用性，同时通过算法为部分流程提供操作的提示或建议。但由于数据准备的过程往往非常灵活且繁琐，当前的算法辅助功能仍比较初级，距离真正的自动化仍有一段距离。而数据准备往往是整个数据分析流程中最耗时的工作，增强数据准备能力将成为未来 BI 平台吸引客户的亮点之一。

增强数据分析，正在不断降低数据消费者使用数据的门槛，以提升企业使用数据的广度。用户通过自然语言进行查询，系统自动的为其呈现图表化的数据结果和文字的"数据解释"。更进一步的，只需选择数据源，系统就能够自动的产生一些有价值的洞见。这些能力将为企业普及数据思维，提升决策质量提供有力的工具。

增强机器学习，则是将原本复杂的建模过程变得自动化，很大程度上帮助了机器学习从业人员将想法快速便捷的应用、落地，将机器学习模型应用到更多的场景，以提升企业使用数据的深度。但这一领域仍面临着算力要求高、优化时间较长等挑战，加速整个学习过程将是增强机器学习进一步普及的关键。

当然，和诸多从技术成熟曲线上跌落的名词一样，当增强分析无处不在的时候，我们肯定也不再觉得它有什么"增强"之处了，而是一种理所当然的存在，这个名词也就会随之消失。但值得一提的是，虽然增强分析一定程度上改变了目前的数据分析模式，让我们离"人人都是分析师"的共产主义又近了一步，但是并不意味着数据分析师和数据科学家变得不再重要。相反，更多"民间数据科学家"的出现，将对数据科学家的专业能力提出更高的要求，既要站的高，更多的着眼于企业数字化转型的大局对数据价值变现的体系进行设计，又要钻的深，毕竟简单题目别人的都会做了，留下来肯定都是硬骨头了。所以，诸位数据分析和数据科学的小伙伴，前路漫漫，任重而道远。

文章作者：马玥，博士，阿里巴巴解决方案架构师。

丁建栋，博士，阿里巴巴高级数据技术专家。

今天的分享就到这里，谢谢大家。

贝壳商业化算法中台架构实践

分享嘉宾：彭克炼 贝壳 资深工程师

编辑整理：马瑶

出品平台：DataFunTalk

导读：随着贝壳流量的日渐增长，贝壳商业化细分场景越来越丰富，公司对业务迭代和效果优化的效率有了更高的要求，贝壳商业化策略算法中台的架构也在不断的进行调整和升级。本文将围绕贝壳商业化策略算法中台的架构演进过程，介绍贝壳在商业化策略算法中台架构方面的探索和实践。重点探讨贝壳商业化算法模型落地、架构设计、服务治理以及性能优化方面的问题，以及如何增强系统的稳定性和扩展性。

01

贝壳商业化简介

1. 业务场景

首先我们看一下业务场景，用户通过贝壳找房 APP 可以找到自己想买的房子，或者想要租的房子，在进入房源详情页的时候，房源详情页会有一个房源经纪人的展示，这个经纪人在后台实际上是通过实时竞价之后才会出现的，而实时竞价是各种经纪人，通过金贝平台，购买商业化产品的平台，去进行小区的投放，以及进行出价，形成订单，这个过程会由商业化这边会做一个定向推荐，出价建议，以及订单投放之后的投放诊断，当用户和经纪人发生 IM 对话时，也就是想要咨询房子的情况，我们就会对贝壳经纪人的贝壳币进行扣费，所以大家可以看出来，我们和一般互联网公司不一样的地方是广告主是经纪人。

2. 竞价排序

接下来我们看一下竞价排序的方法，这个和计算广告类似的，通过 eCPM 进行经纪人的排序的，eCPM 是通过经纪人的出价和 CVR 的转化进行预估，两者相乘得到一个 eCPM，这里 CVR 的话是预估未来 7 天商机转委托的概率，相信同学在之前的分享中听过商机这个词，用户和经纪人进行一次对话，我们称为一个商机，发生对话后，用户会把自己的电话委托给经纪人，让经纪人帮他/她找房子，这个过程我们称之为委托。所以我们预估就是未来 7 天商机转委托的概率。

3. 贝壳的商业化场景

为了让大家更好的理解贝壳的商业化场景，我这里举例来做一个对比。我们通过门户网站和贝壳进行对比：

从流量角度来看，门户网站针对用户浏览页面，用户发生点击行为称为流量，而贝壳是用户点击 IM（商机）称为是流量。

从用户定向来看，一般的互联网公司在做用户定向的时候，对用户做各种分析，比如他/她的年龄、性别、地域等，而贝壳主要是针对用户感兴趣的房源进行定向，用户一般会看某套房子才会咨询经纪人，所以证明用户对这套房子是非常感兴趣的，用房源来做定向的话，可以说是非常精准的。

从支付方式来看，广告主就是各区域的经纪人，支付方式的话，我们用的不是金钱，而是贝壳币，贝壳币是我们牵引经纪人完成任务的抓手，平时我们会给经纪人下发各种任务，经纪人完成任务之后会获得贝壳币，有了贝克币之后就可以购买我们的商业化产品了，对于经纪人来说，获得贝壳币来说就是获得商机，通过这种方式我们可以牵引经纪人去完成各种任务，更好的服务我们的客户。

从结算方式来看，很多门户网站都是通过 CPM/CPC 的方式进行结算的，而我们是通过 CPA 方式进行结算，我们对 CPA 也进行了加强，必须是用户和经纪人发生三次有效对话之后才会进行扣费，这样也是更好的保证经纪人的权益。

4. 商业化展示

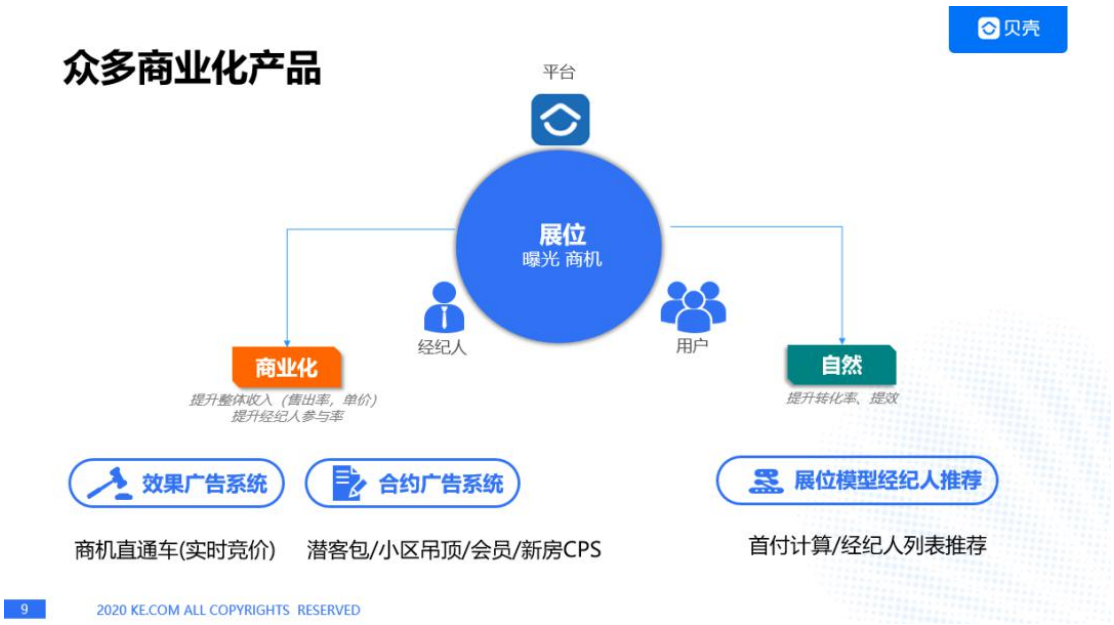

目前我们已经有了众多的商业化产品，因为我们最重要的一个展位就是在贝壳 APP 里面会有很多的曝光，曝光之后就会产生商机，我们重要的两个商业化产品：

- 效果广告，也称为商机直通车，其实跟淘宝直通车是非常类似的，也是通过实时竞价的方式进行投放，

- 合约广告系统，目前是有潜课包/小区吊顶/会员/新房 CPS 等。

当然了，我们也推出了自然流量，就是通过展位模型的方式给经纪人推荐，比如在首付计算/经纪人列表推荐等等，所以众多商业化产品的话，总结一点就是我们是给用户推荐经纪人的。

02

贝壳商业化架构演进历程

1. 贝壳商业化历史进程

2018 年，贝壳找房成立，启动 CPT 等合约广告产品开发。

2019 年，随着流量增大，对流量进行精细化分类，探索效果广告。

2020 年，我们已经有了众多的商业化产品，结算方式也有了 CPA/CPM/CPT/CPS 等等。

2018 年架构产品的业务形态

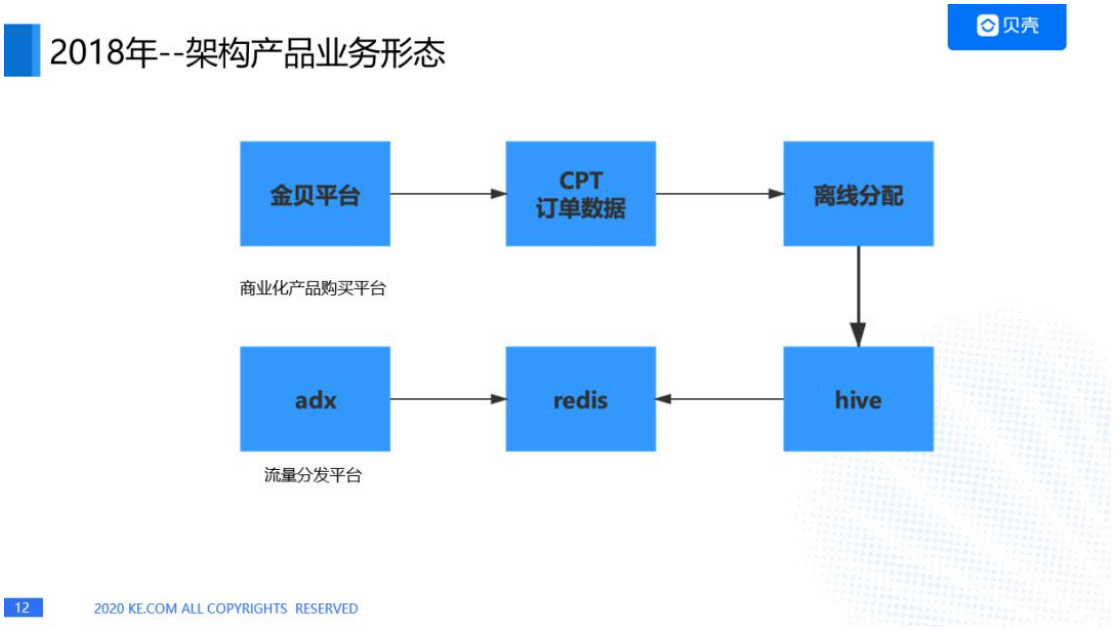

这时的架构是非常粗犷的，对接方主要有两个，一个是金贝平台，这是一个商业化产品购买平台，

另外一个是 adx,这是一个流量分发的平台，经纪人在金贝平台购买了商业化产品之后，会在 CPT 上产生订单数据，通过 mysql2hive 的方式进入 hive 表，然后就进行离线分配了。而 adx 的话，是通过 redis 数据库进行一个流量的获取，经纪人的推荐。

2019 年架构产品的业务形态

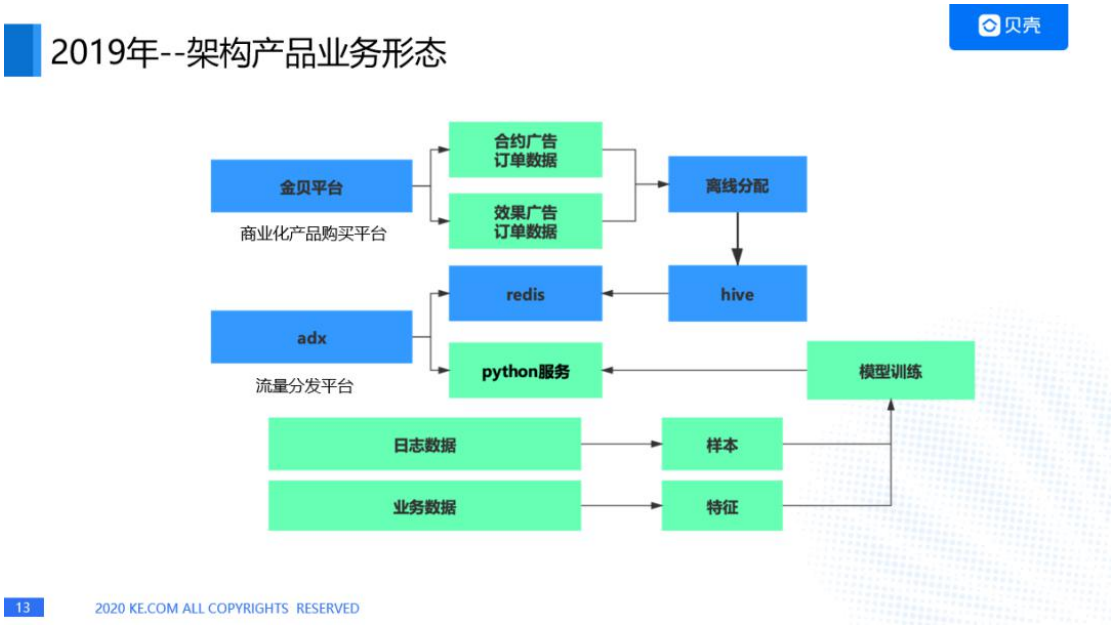

2019 年金贝平台开始售卖效果广告，所有金贝平台形成效果广告的数据，而 adx 的话，不仅对接到合约广告，还有实时竞价，所以我们起了一套 python 服务，这项服务因为需要对 CVR,也就是刚才提到的 eCPM 进行预估，因此我们要进行一个模型的训练，会去收集到日志数据，业务数据，形成样本和特征，经过模型训练，进行在线预估。Python 服务的话，我们考虑到开发效率，所以直接用了 python 的 tornado 来进行线上的 web 服务。

2020 年架构产品的业务形态

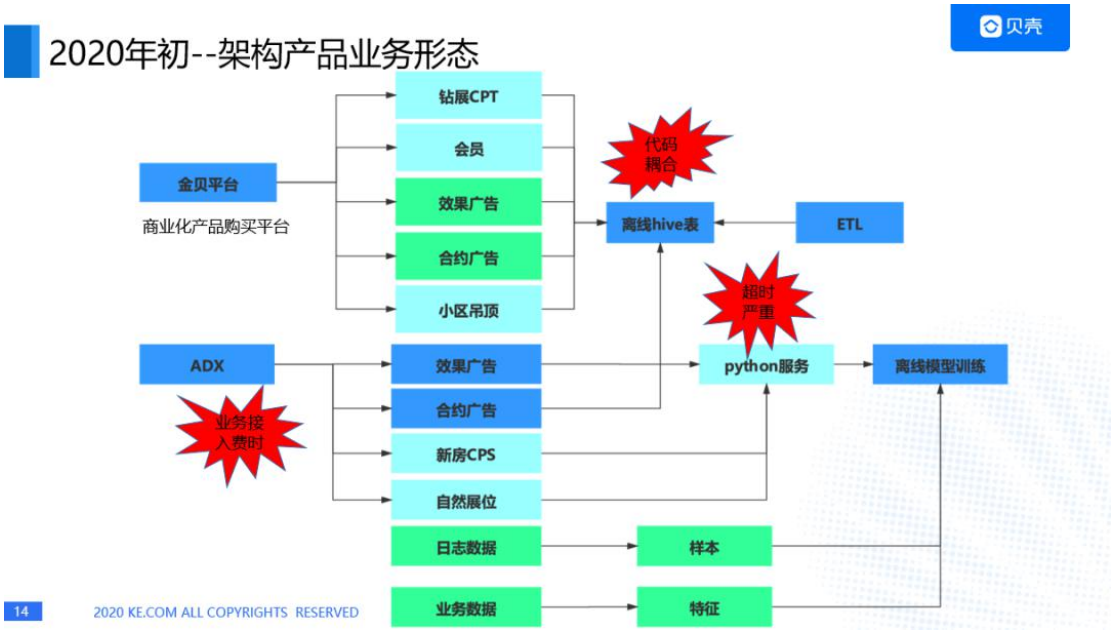

等到 2020 年的时候，我们的产品就已经非常多了，钻展 CPT，会员，效果广告，合约广告等等都接入我们的平台，ADX 不仅接入了效果广告，合约广告，也接入了新房 CPS，自然展位等众多的平台接入进来，还是通过 python 进行一个在线服务的提供，这时就暴露出几个问题，一个是 python 服务出现超时，而且超时越来越严重，第二个是 hive 表在进行离线计算的时候，代码都是耦合在一起的，第三个是我们在承接新的业务时，会出现业务接入费时的情况，我们算法的小伙伴都在进行业务的接入，而没有沉下心来对模型进行深入的探究。

2. 过程中的问题与解决方法

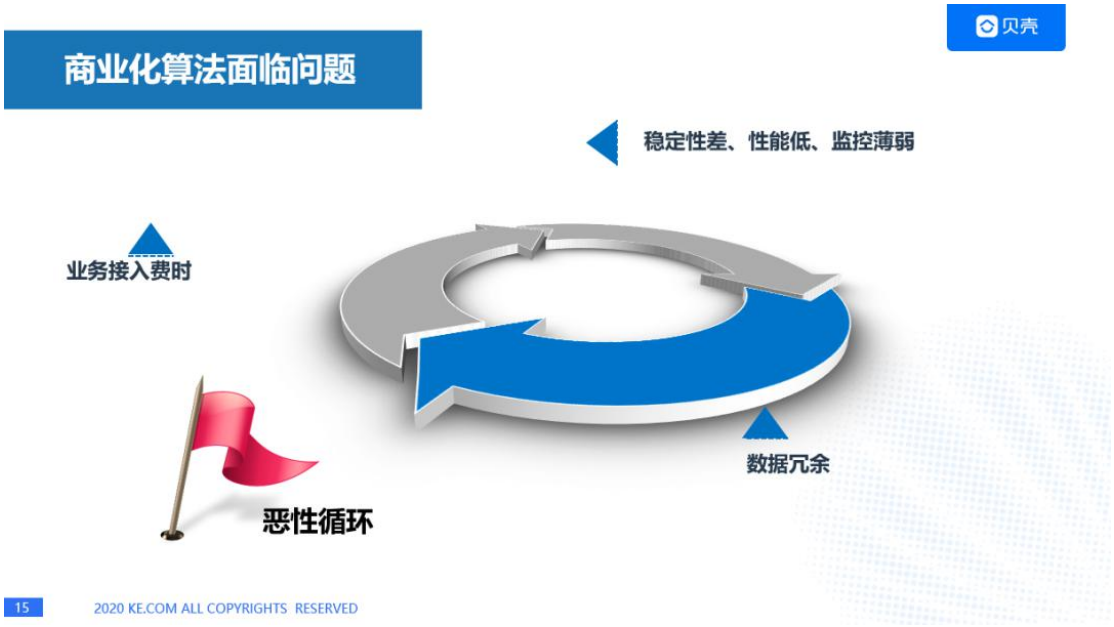

第一个是稳定性差，性能低，监控薄弱的问题。

第二个是数据冗余的问题。

第三个是业务接入费时的问题，随着这三个问题越来越严重，我们的产品接入方也越来越多，整个过程就形成了恶性循环。

这时系统重构迫在眉睫，于是，在年初的时候，我们就诞生了一个想法，对整个的系统架构进行重建，出现了商业化策略算法中台的架构。

03

贝壳商业化策略算法中台架构

1．设计过程

既然要设计一个新的架构，肯定要把老的问题都解决掉：

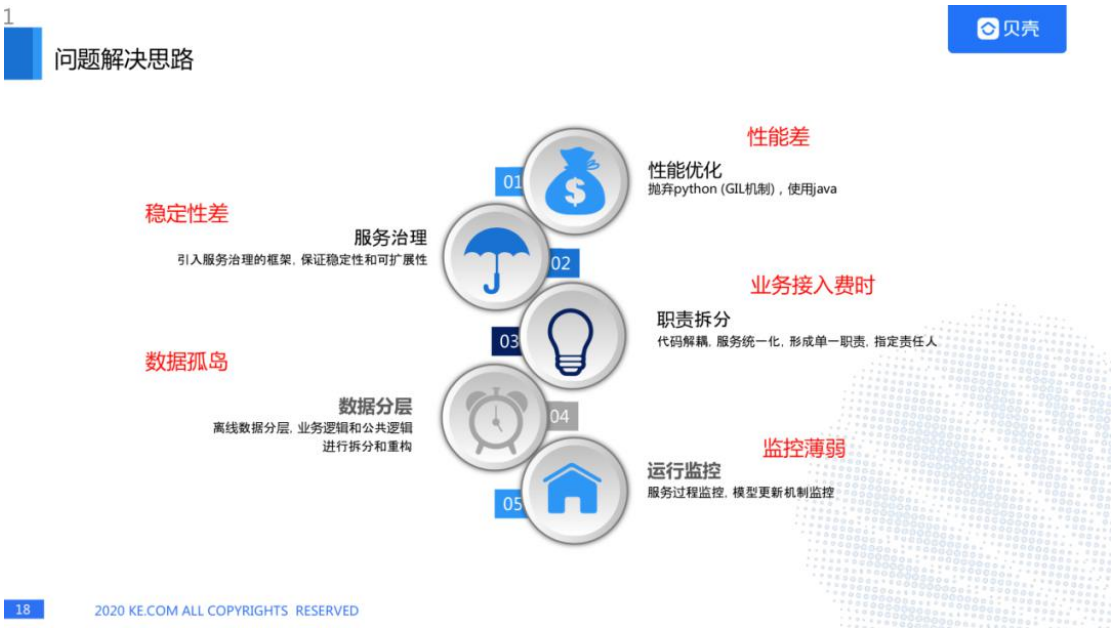

针对性能差的问题，我们抛弃了 python 的代码，而是使用 java 进行服务的构建，python 的 GIL 机制，导致 python 的多线程是一个伪多线程，而使用 python 进行多进程，我们知道进程的切换也浪费 CPU 资源的，所以我们干脆用 java 来进行服务的重构。

针对稳定性差的问题，我们打算引入服务治理的框架，引入服务治理的框架，保证稳定性和可扩展性。

针对业务接入费时问题，我们是对微服务拆分，代码解耦，服务统一化，形成单一职责，指定责任人。

针对数据孤岛问题，我们对离线数据分层，业务逻辑和公共逻辑进行拆分和重构。针对监控薄弱的问题，由于我们引入了服务治理的框架，因此可以对服务过程进行监控，模型更新机制监控。

2. 架构分层：

解决的以上这些问题之后，我们需要对架构进行分层，分层的好处就是各层次之间相互独立，通过接口调用。我们是把架构分成了三层：

在线服务层，主要是根据业务实际场景提供实时、高效、稳定的 http 接口，并灵活的进行 AB 测试。

近实时层，主要是进行模型训练、数据存储、订阅用户行为数据等，从而做到秒针级别用户兴趣捕捉和线上效果反馈。

离线计算层，从原始业务和日志数据进行 ETL，形成用户画像、经纪人画像、房源信息、训练数据等。

3. 各层特点与适合任务的相关规定

实时层，也就是在线服务层主要使用的是实时+非实时的数据，实时性是秒级，特点是响应速度快，数据实时性敏感，计算复杂度低，稳定性高时延低，适合的任务是在线请求。

近实时层使用的数据是实时+非实时，实时性是分钟级，特点是基于实时数据，计算复杂度适中，队列可缓冲数据，适合的任务是特征实时计算与更新，实时算法计算（相关性），模型在线更新，指标统计和计算，日志收集和分析。

离线计算层使用的数据是非实时的，实时性是小时级，特点是大数据批量计算，计算复杂度高，大容量存储，适合的任务是 ETL 任务（规则特征样本），模型的训练。

4. 各层架构的特点：

我们来看一下整体的架构情况，每个层都会有详细的模块与特有的特征。

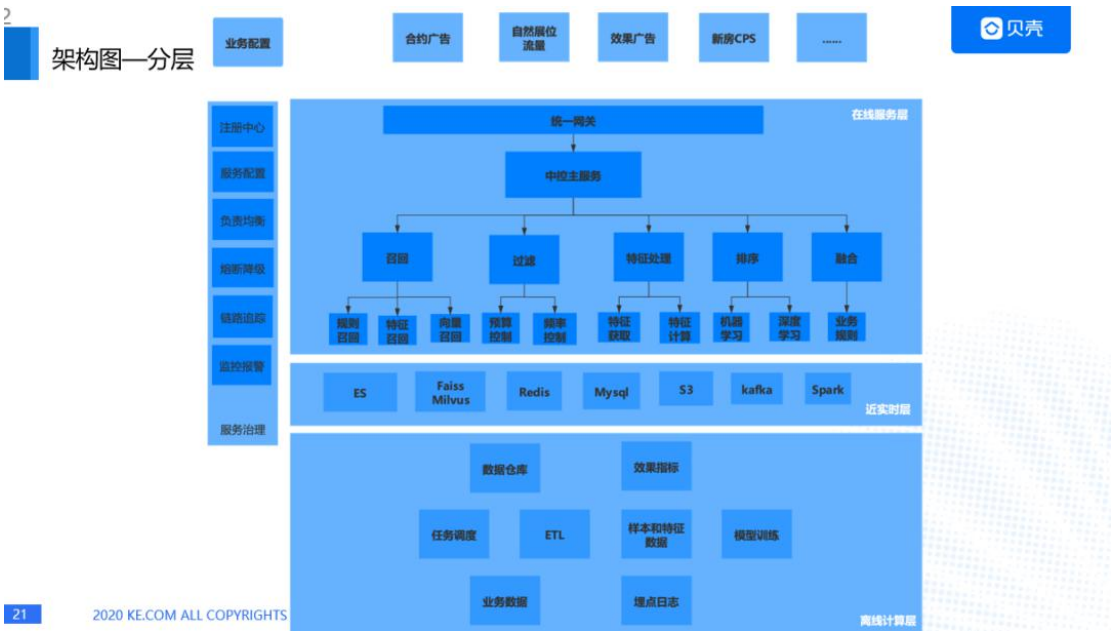

下面我们将为大家详细介绍下各层：

在线服务层

1. 在线服务层架构

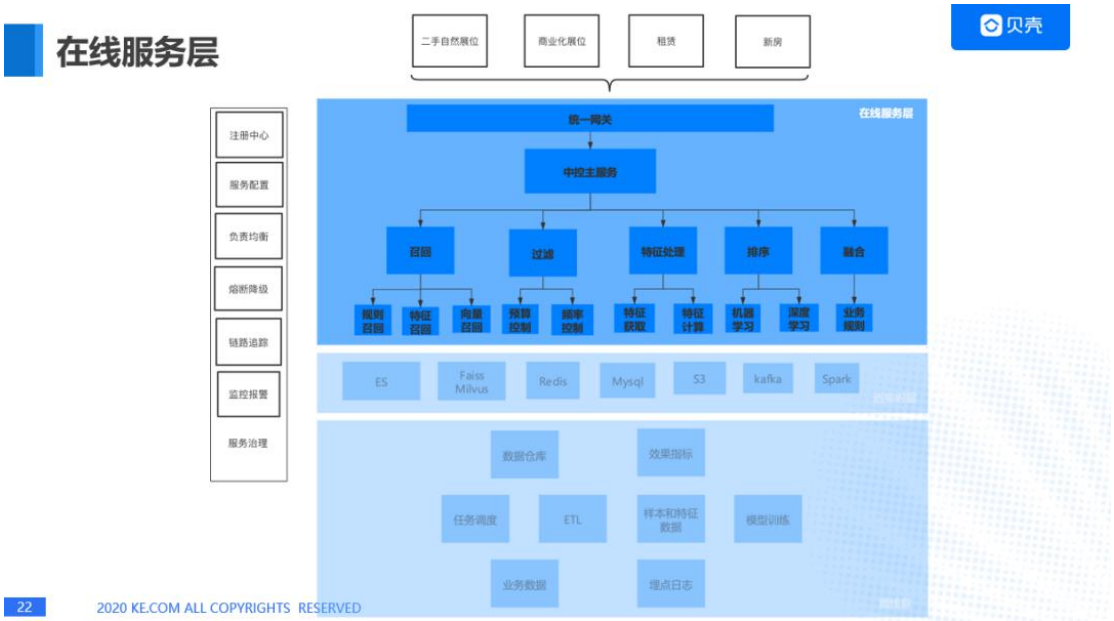

2. 在线服务层拆分

在线服务层我们要对业务进行拆分，引入服务治理的框架，不可避免的要对服务进行拆分，拆分主要有两个原则：

- 横向拆分，按照不同的业务域进行拆分，我们这里是拆分成了效果广告，合约广告和自然展位三个业务域。

- 纵向拆分，把一个业务功能里的不同模块或者组件进行拆分，从多个业务角度找共性，将服务进行抽离，确定各个服务边界，清晰职责。

这里我们看一个例子，这是两个主要的业务。一个是不走商业化流量的自然展位经纪人推荐，另外一个是商业化经纪人推荐。

自然展位经纪人推荐是要经过一个召回模块，规则过滤，特征处理，排序模型，兜底规则。商业化经纪人推荐是不走召回模块，因为它的业务主要是从前端传过来的，就是这个经纪人有订单了，就会直接召回，因为整个过程越激烈，对我们来说是越有好处的，召回完成之后，会进行预算控制，这是比较特殊的一点，后面会讲，其实就是对经纪人做一层过滤，然后进行特征处理，排序模型，融合规则，融合的话，会计算 eCPM。

这两个过程有很多相似的地方，所以我们对这两个过程其中的一些部分进行了抽离，比如说规则过滤和预算控制过滤，我们抽离成过滤模块，特征处理我们抽离成了特征处理模块，排序模型我们抽离成了模型模块，兜底规则和融合规则我们抽离成了融合层的服务。

在线服务层拆分原则：

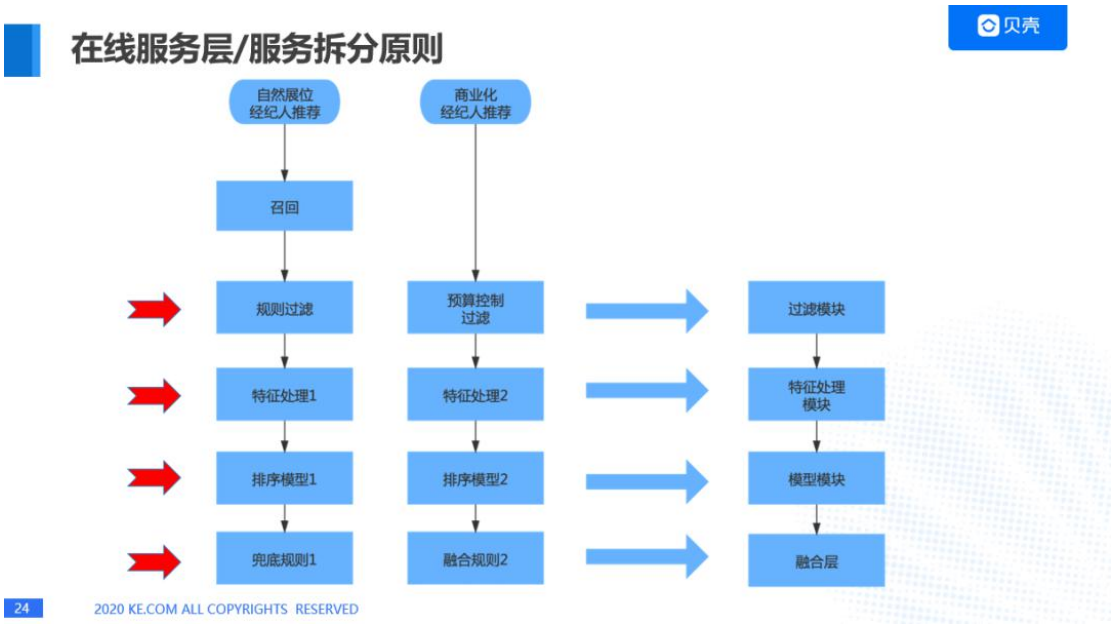

我们来看一下在线服务层拆分前和拆分后的状态。中控主服务主要包括策略配置，召回阶段，特征处理，排序阶段，融合阶段。

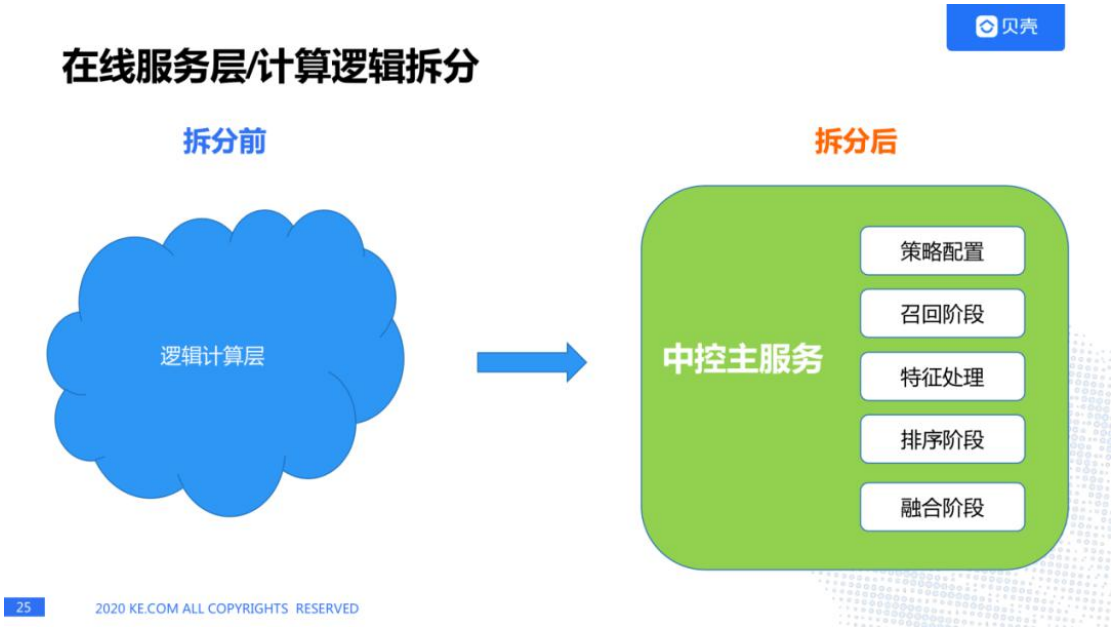

在线服务层拆分形态和调用流程：

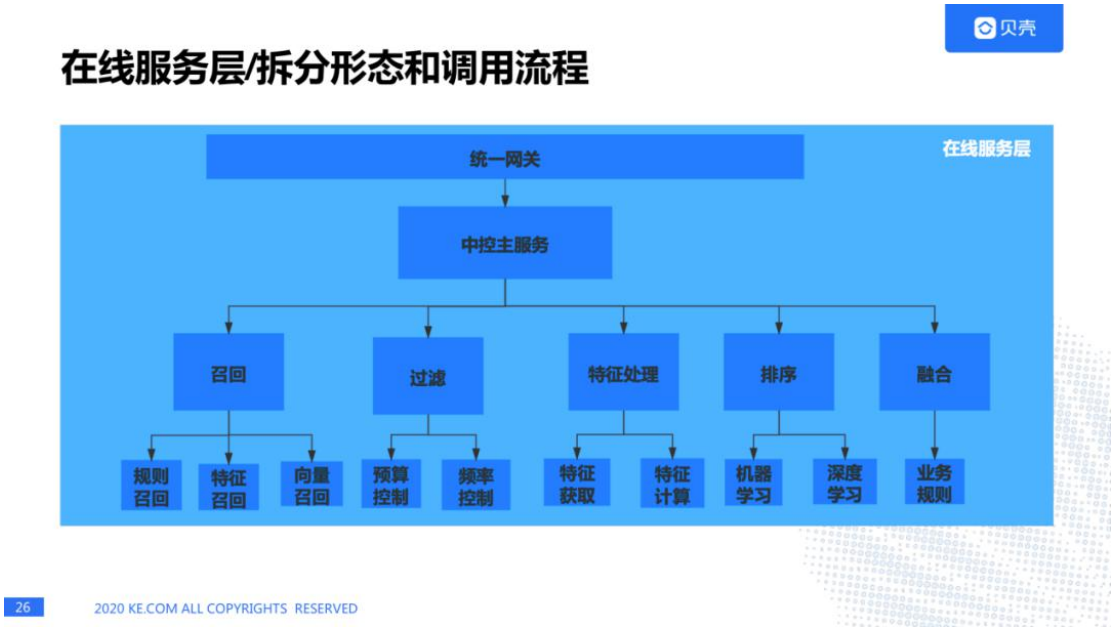

我们来详细看一下在线服务层的各个部分。请求会通过统一网关进入中控主服务，中控主服务会调用下面的各个子服务，比如召回，过滤，特征处理，排序，融合。召回里面有很多召回的方式，过滤里面也会有很多过滤的方式。接下来我会介绍一下每个服务里面设计的特点。

3.中控主服务，主要功能：

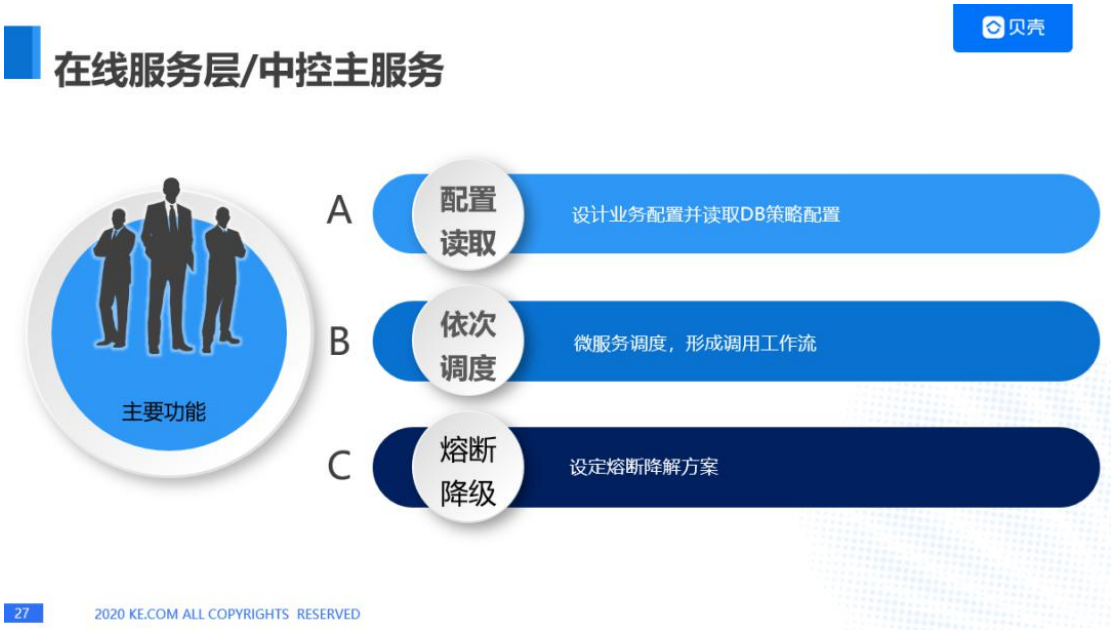

- 配置读取，我们会对每个要调用的服务进行配置化，有些业务需要一种召回方式，有些业务需要多种方式进行召回，我们都可以通过配置的方式进行更新。

- 读取配置后，需要对微服务进行依次调度，形成调用工作流。

- 会对熔断降解方案的设定。

4. 策略配置设计的过程

左边是一张 mysql 的表，我们可以看到这里的字段有召回策略，过滤策略，排序策略，融合策略等，针对每个策略，我们都可以设定召回策略的参数，排序策略的参数等等。举个例子比如这里有个展位，我们可以设定它的召回策略，过滤策略，排序策略以及融合策略。

5. 中控主服务的特点：

- 对外提供 HTTP 服务，对内微服务调用使用 RPC 或者 HTTP。

- 各微服务调用时间使用动态设置，一般各模块实际超时时间=Min（该模块最大超时时间，剩余时间）。

- 尽量不包含业务逻辑，减少迭代。

6. 在线服务层中召回模块

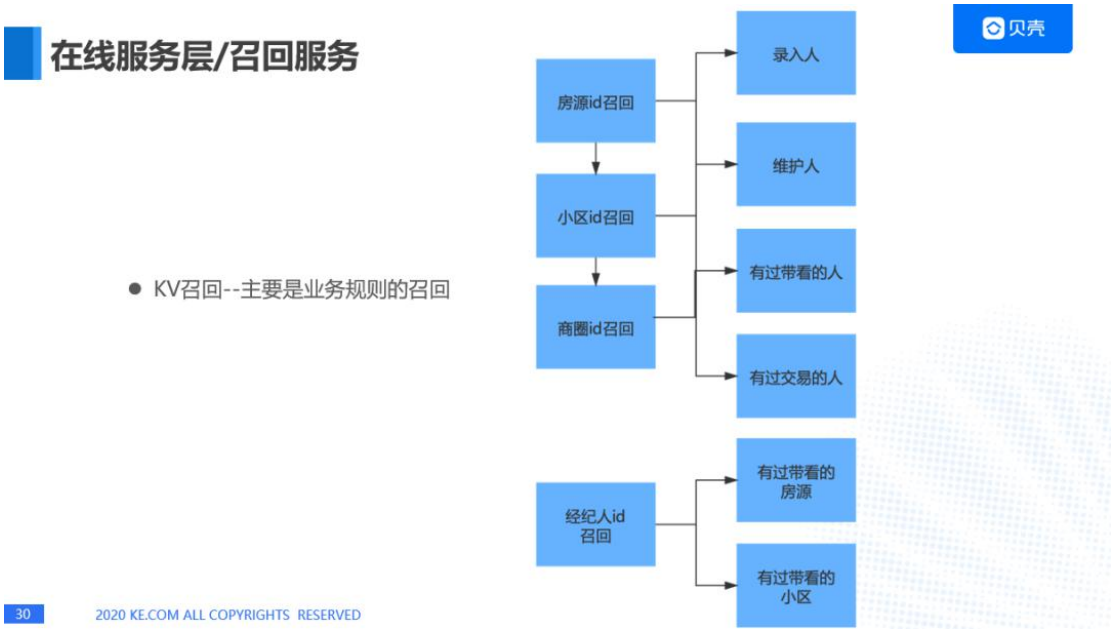

第一个我们会做 KV 召回—主要是业务规则的召回。把计算好的数据放在 KV 数据库里面，比如用户来了之后，点了某一套房子，然后我们通过房源召回录入人，维护人，有过带看的人，有过交易的人，这样就可以把经纪人召回来，如果这个小区没有数据的话，就再往上一层，分别来做兜底，小区没有的话就从商圈的维度去召回经纪人。还有一种就是从经纪人 id 进行召回，这个主要是金贝平台，我们需要给经纪人推荐他/她感兴趣的小区，她/他（经纪人）肯定会选择看有过带看的房源，有过交易的房源。

ES 召回

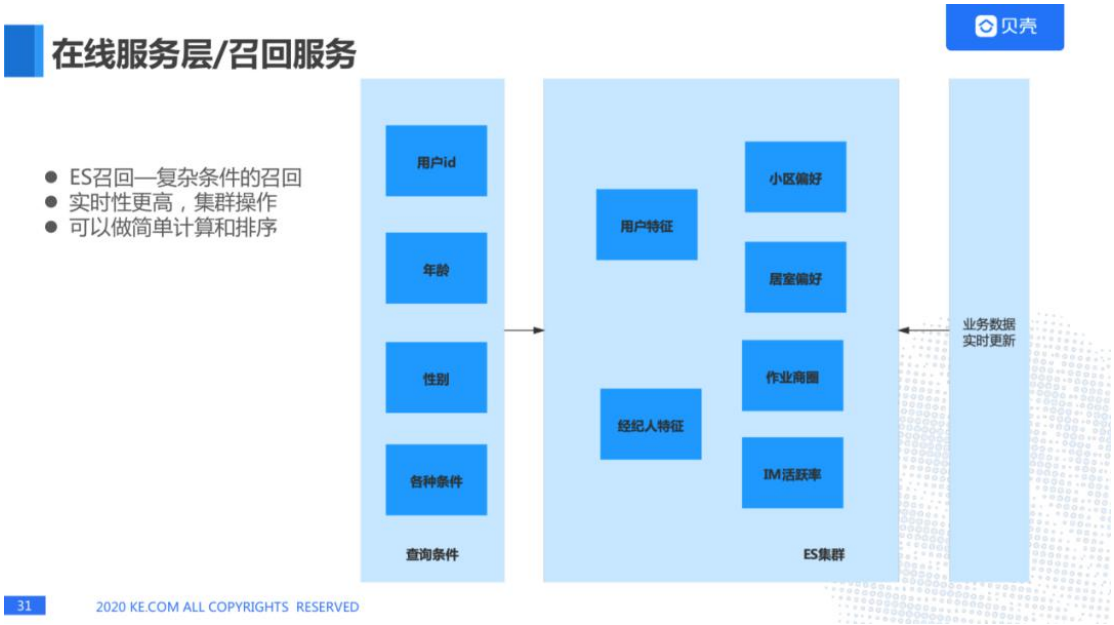

ES 召回有一些复杂的召回，比如用户 id,年龄，性别，各种条件的查询条件适用于冷启动的问题。ES 集群还有一些用户特征，经纪人特征，是从 DMP 平台获取的。ES 的好处是实时性更高，集群操作，可以做简单计算和排序。ES 里面也支持向量召回，效果也不错，我们有一些场景用到了 ES 的向量召回。

向量召回

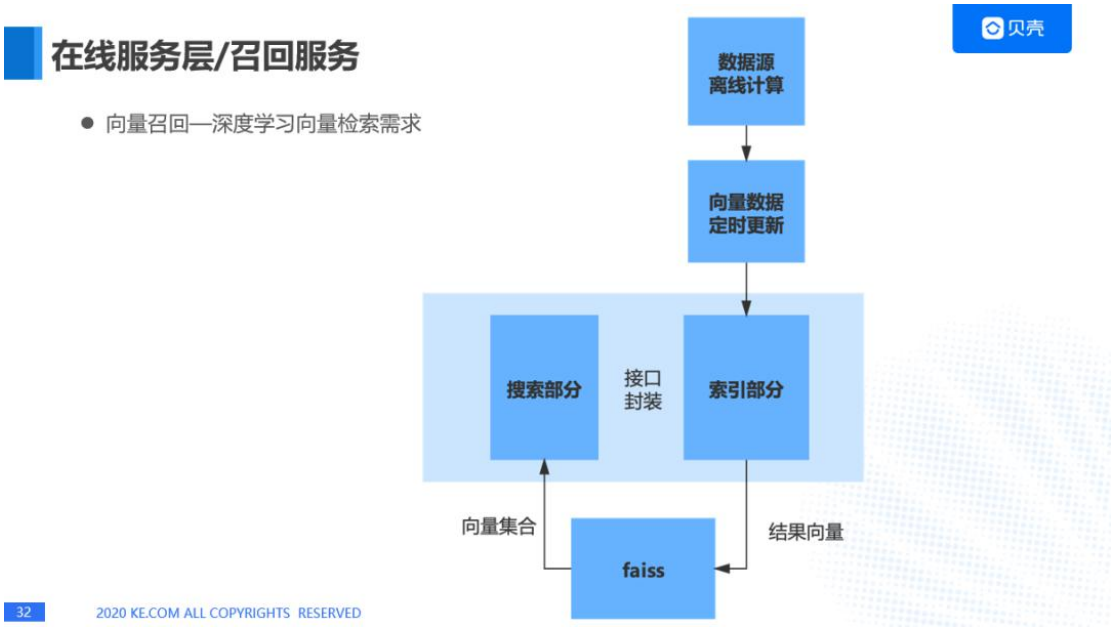

这个在深度学习向量检索的需求非常大，我们之前使用的 Facebook 开源的一个工具 faiss. 将数据源离线计算后，向量数据定时更新，通过一个接口索引部分，将结果向量送入 faiss. 另外一个接口是通过 faiss，把向量集合送入到搜索部分。

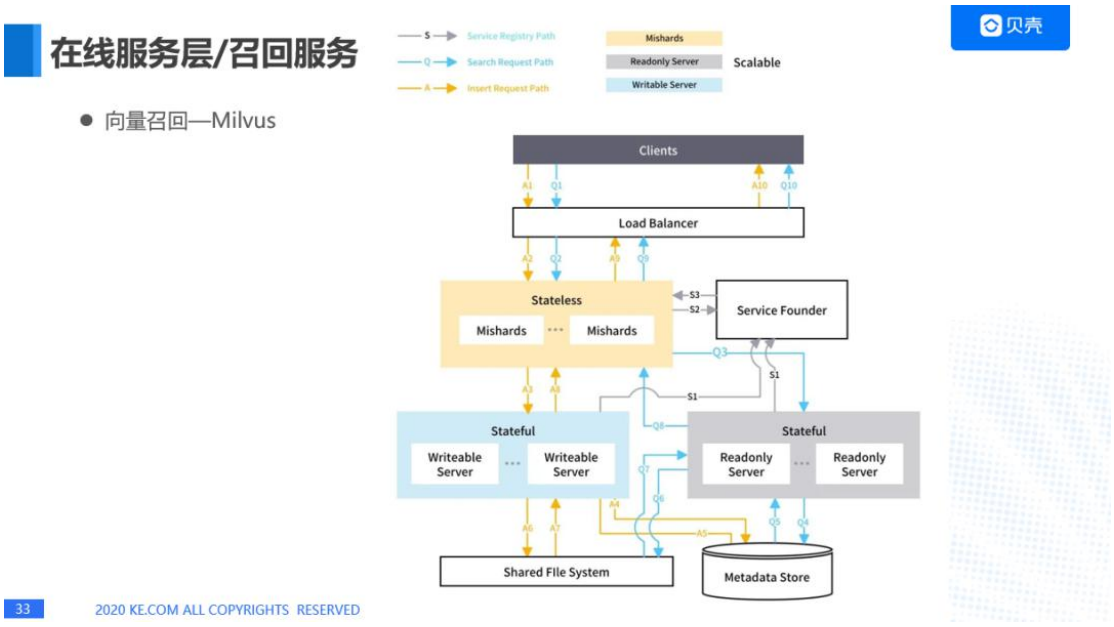

但是 faiss 有一个缺点它是单机部署，没有分布式，所以我们使用了另外一个比较火的向量召回的框架叫 Milvus，上面这个是我从官网上截的一张图，它的底层

架构也是基于 faiss 的，它是使用了负载均衡，服务发现，对底层的数据进行分片，来保证稳定性和高性能。

embedding 向量生成的原理

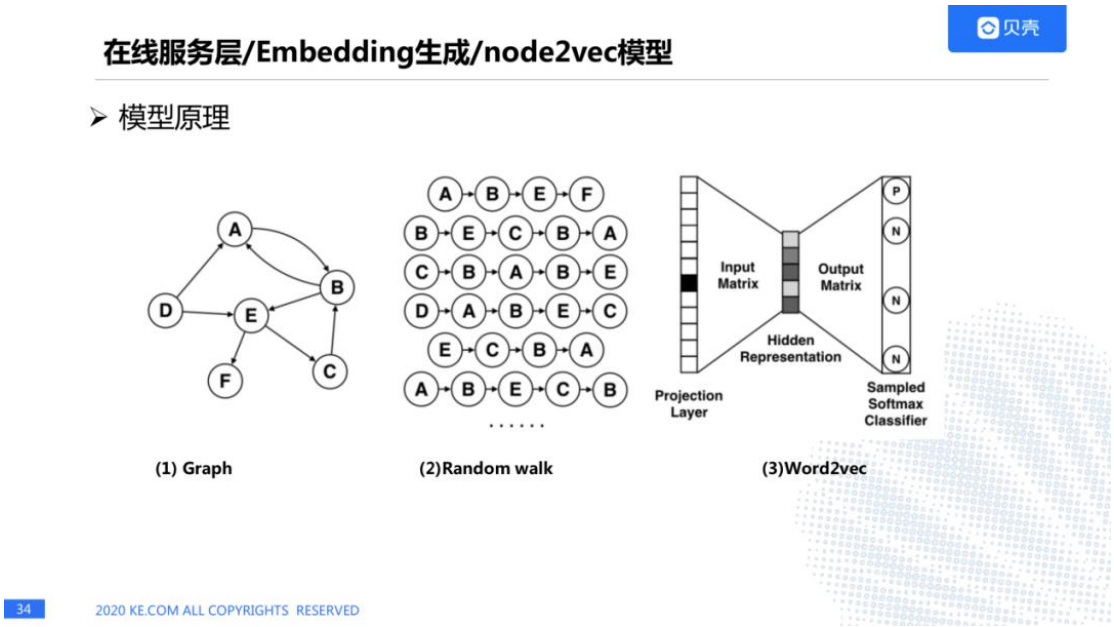

这里我们有多种模型生成 embedding,主要是通过 node2vec。也就是说用户在浏览 APP 的时候，会生成很多的房源序列，根据房源序列我们可以抽象出一张图，这跟我们使用的 word2vec 是非常类似的，生成一张图之后，会做随机游走，之后将结果输入到 word2vec，生成 embedding 的向量。

7. 如何去做线上的 serving

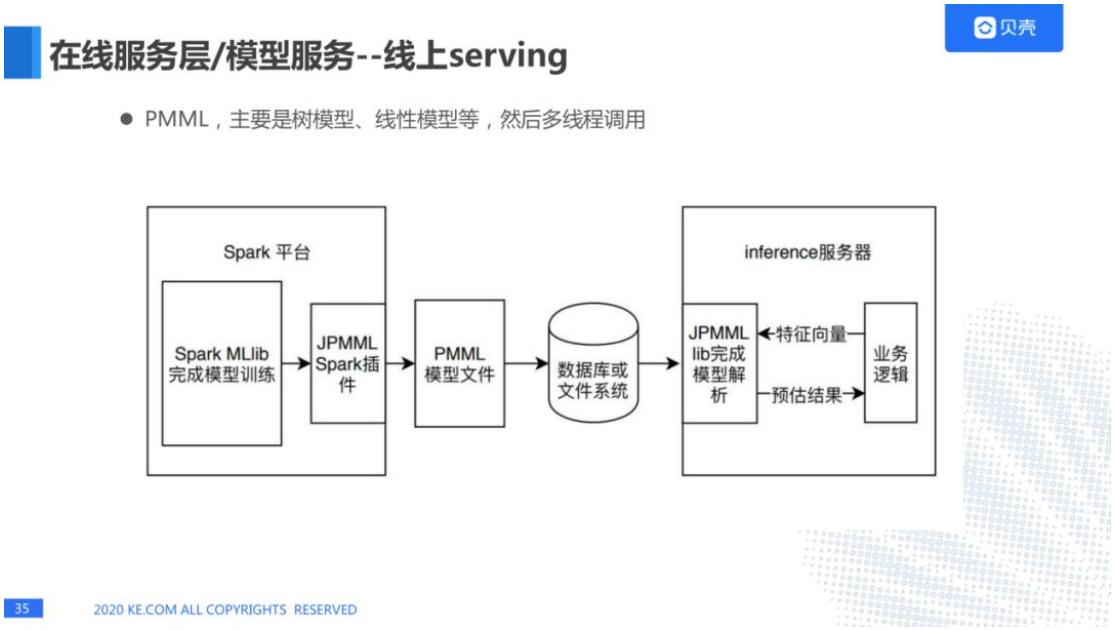

线上 serving 目前没有比较好的开源的解决方案，公司都会有一套线上自己的 serving 服务。而我们主要有两种方式，一种是 PMML 格式的文件进行线上 serving，这个主要用在一些比较简单的模型，比如树模型、线性模型进行多线程的调用，这里主要是用 spark 平台，python 平台，我们可以通过模型训练之后，使用 JPMML 插件，形成 PMML 模型文件，然后把这种文件放在数据库或文件系统中，最后可以通过 java 服务进行线上推断。

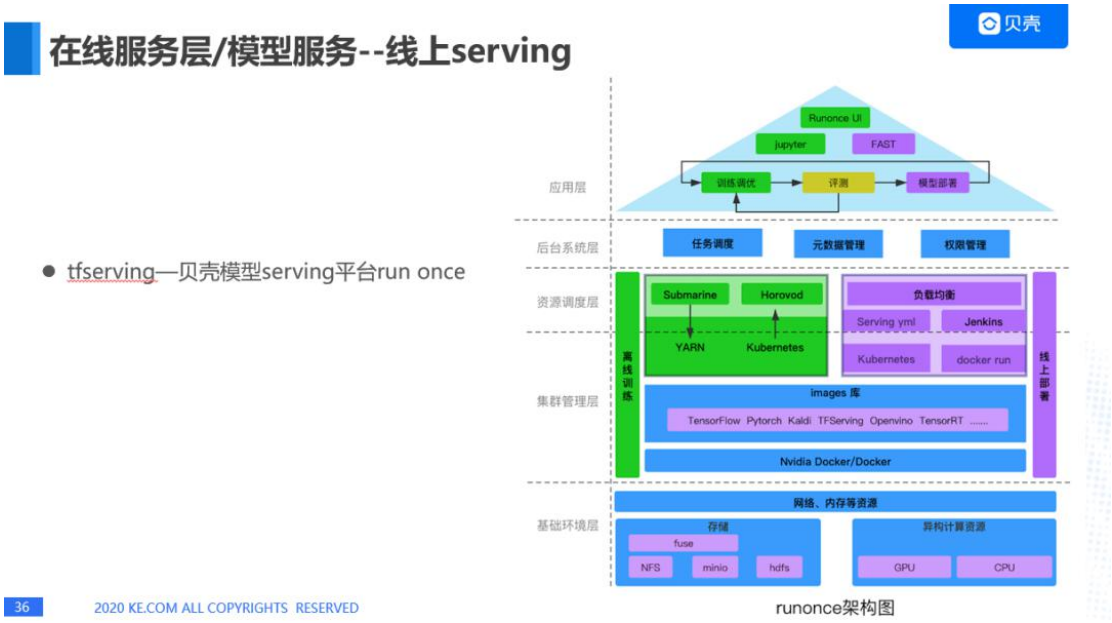

runonce架构图

另外一种在线服务的方式，tfserving---贝壳模型 serving 平台 run once。上面是一个架构图。支持比如说 Tensorflow, Pytorch 等一些在线 serving。

过滤服务

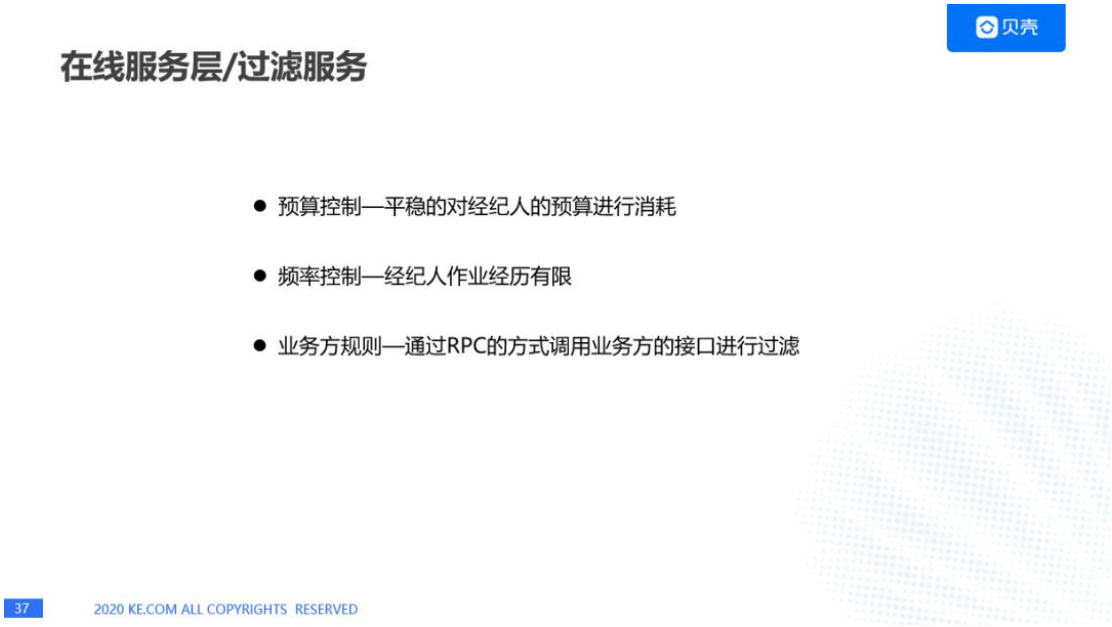

- 预算控制，经纪人会在金贝平台生成订单，然后他/她会先把钱充到账户里面，那么我们肯定需要平稳的对经纪人的预算进行消耗。

- 频率控制，我们不想让用户看到同样的广告次数太多，我们会对这些广告进行过滤，但是我们这里会对广告主进行频率控制，也就是经纪人作业经历有限，如果我们一次给他/她的商机也就是用户太多的话，她/他会处理不过来，所以我们会对经纪人的频率进行控制。

- 业务方规则，可以通过 RPC 的方式调用业务方的接口进行过滤。

微服务的技术选型

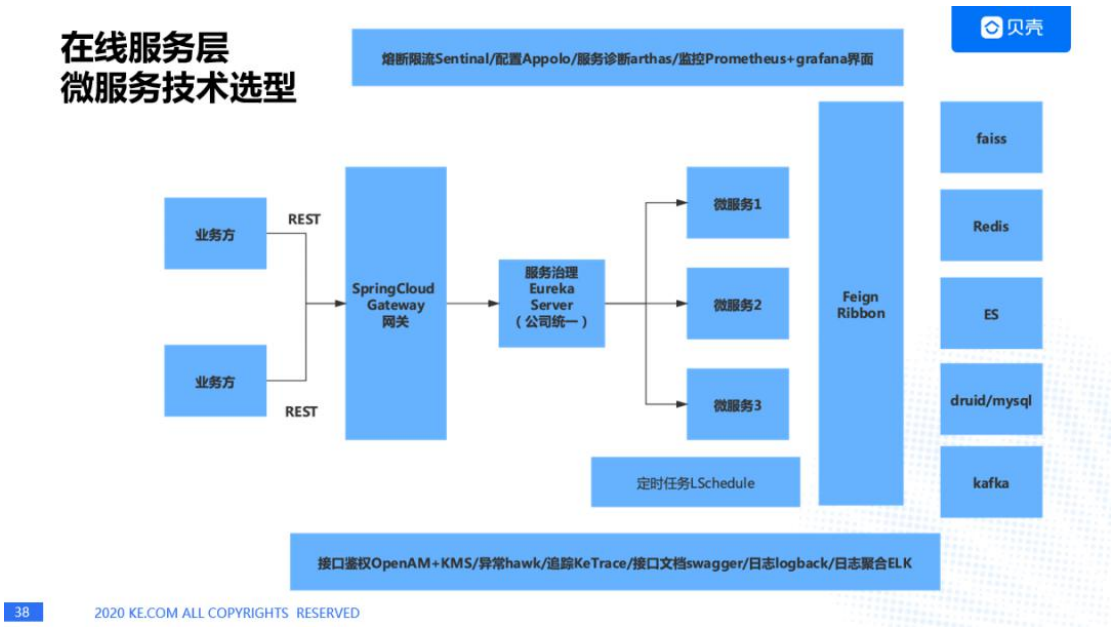

业务方会通过 SpringCloud Gateway 进入到服务里面，公司的服务会统一到 Eureka 平台进行注册，每个微服务是通过 Feign 进行通信，通过 Ribbon 进行服务的负载均衡，中间也用到很多开源的组件，比如接口鉴权(OpenAM)，异常

诊断（hawk），链路追踪（KeTrace）,熔断限流（Sentinal）,配置（Appolo），服务诊断（arthas）,监控 Prometheus+grafana 界面来实时监控。

05

近实时层

1. 近实时层架构图

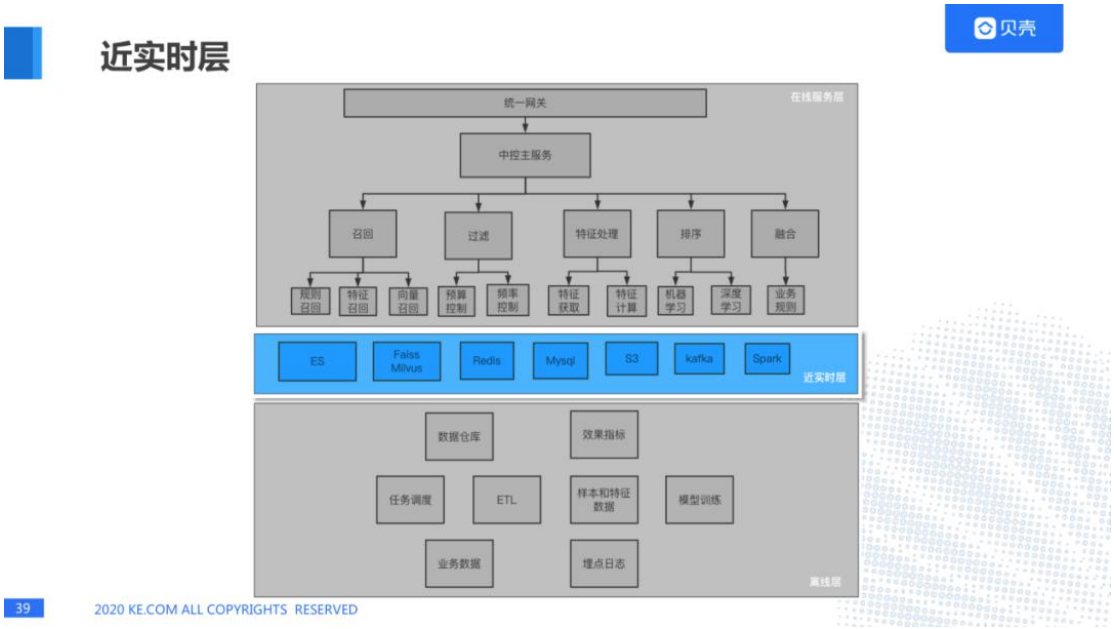

2. 近实时层数据收集

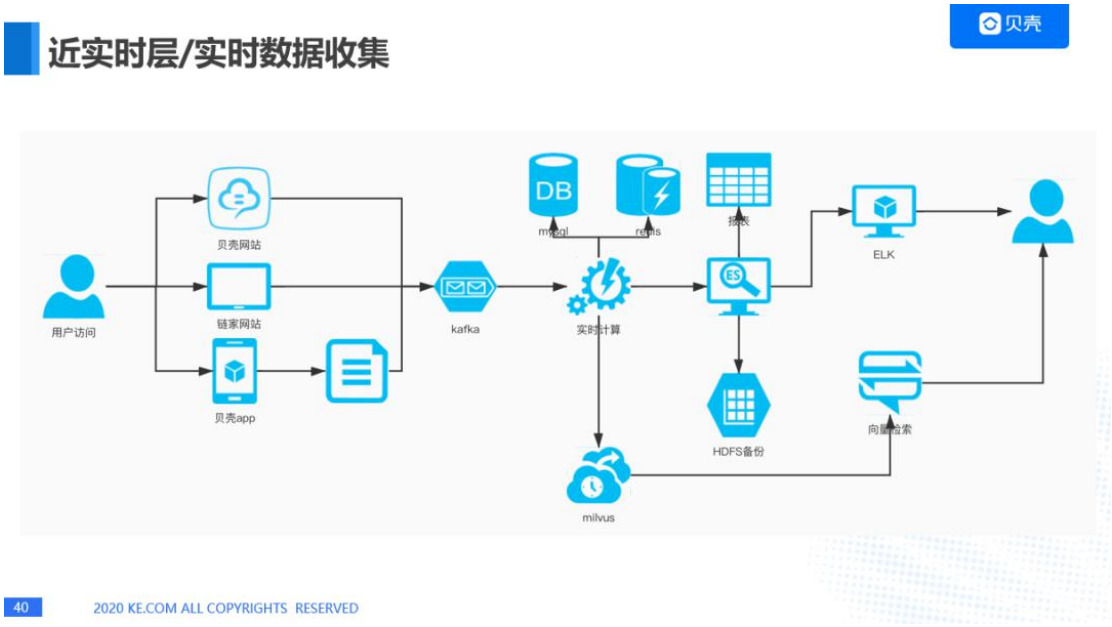

近实时层大多数公司的架构可能差不多。我们这里主要是会存储各种各样的数据，比如 mysql 数据，redis 数据，向量数据，另外一个就是会对实时数据进行收集，比如用户访问贝壳网站，链家网站，贝壳 App 之后，会留下数据，后台会进行埋点，然后通过 kafka 进入实时计算的模块，最后会计算出一些规则的数据，记录到 mysql,redis,进行一些向量的计算，进入 milvus,进行向量搜索，我们也会把数据进入到 ES 里面做一些报表，还有做一些 ELK 的分析，以及 HDFS 的备份。

06

离线层

1．离线层架构图

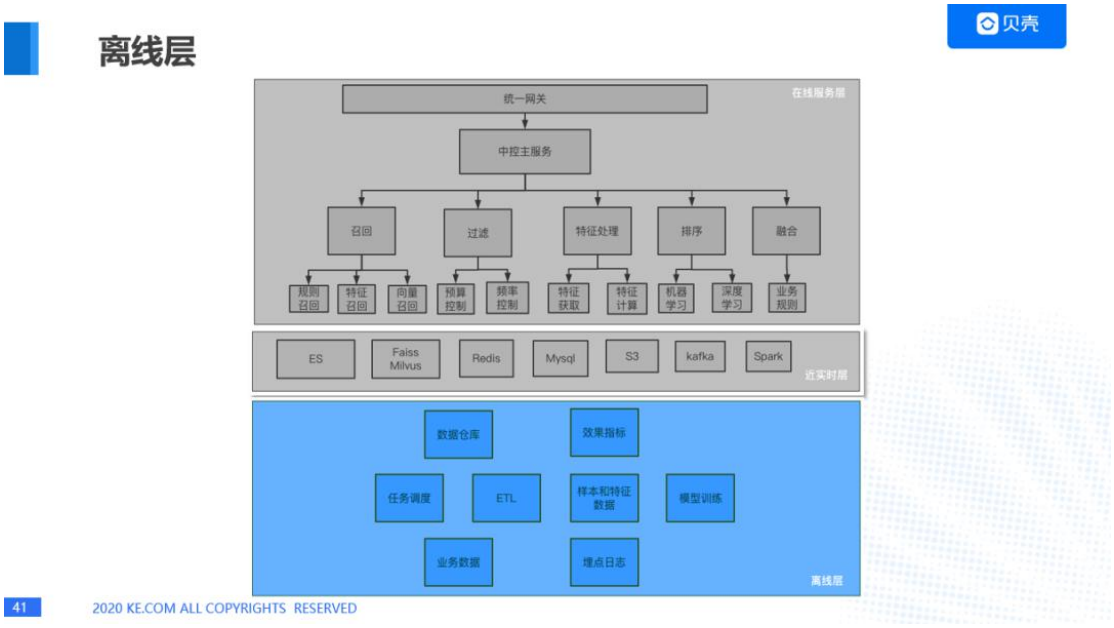

2.离线层分层：

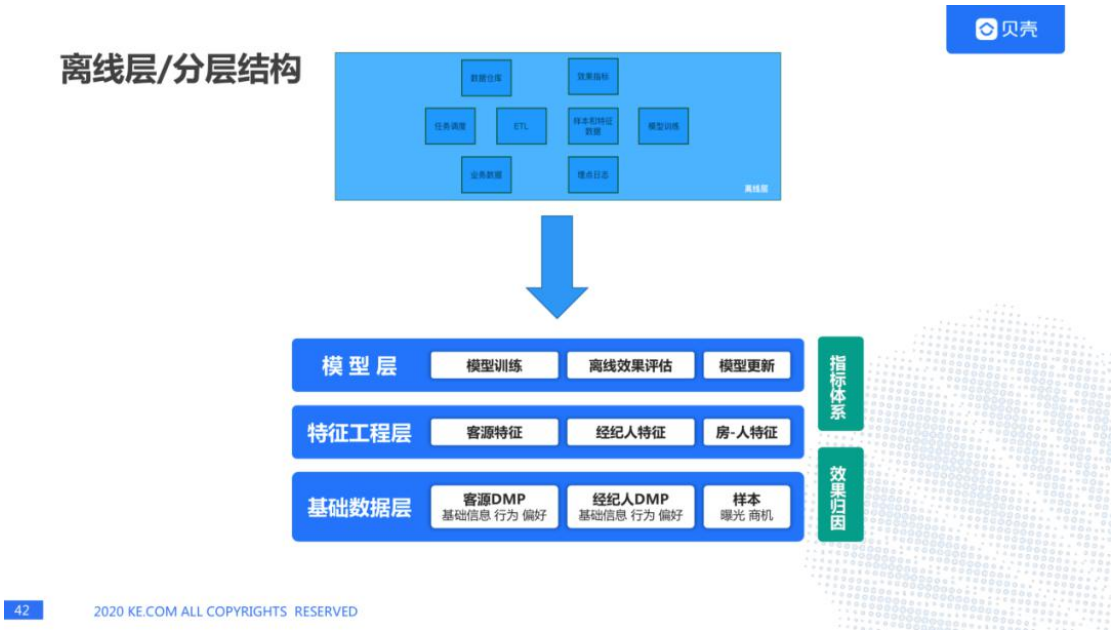

离线层在这个框架里面是一些功能，但是我们也对离线层进行了分层：基础数据层、特征工程层、基础数据层。

基础数据层，我们会从 DMP 平台获取到用户的画像，经纪人画像和业务数据（样本，曝光，商机等），在这之上会生成客源特征，经纪人特征，房-人特征，我们这里主要是给用户推荐经纪人，所以在使用的过程中我们发现使用房的特征做推荐对房的成交量作用并不大，我们就弱化了房的特征，关注经纪人特征和人的特征，因为我们发现用户在看这套房子，和最后成交的房子关系并不大，而经纪人和用户建立联系之后，经纪人会给用户推荐各种各样的房子，最后成交的并不一定是这个用户看的，再上面一层是模型层，包括模型训练，离线效果评估，以及模型更新。

3. 离线训练部分

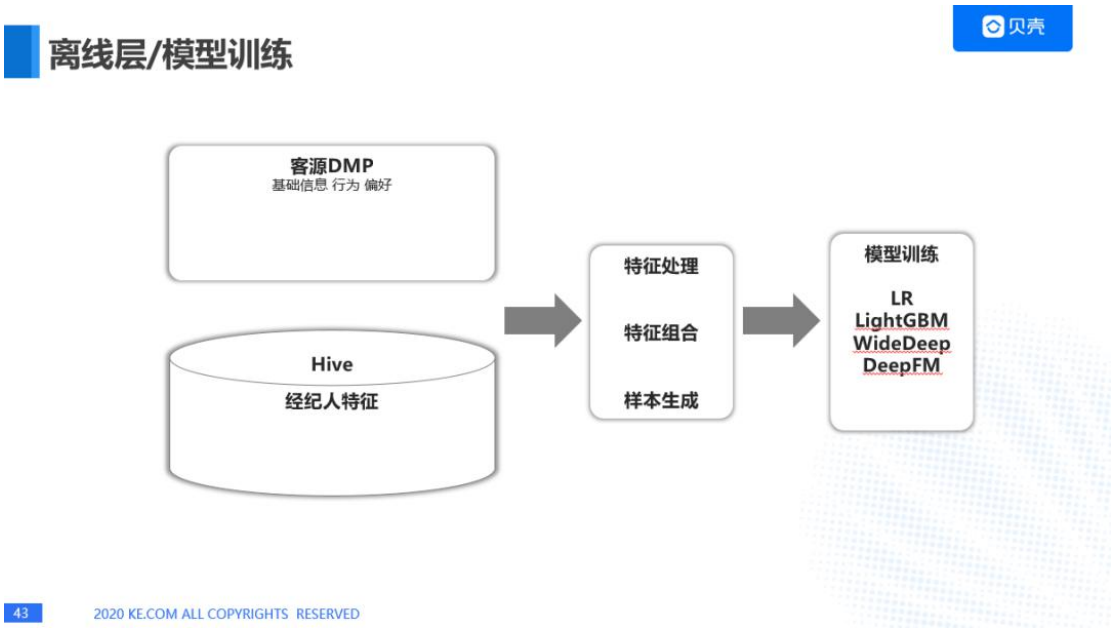

这是离线训练的部分。主要是使用特征进行离线模型训练，我们用到了 LR，LightGBM, WideDeep, DeepFM 等等。

4. 架构重构之后的效果：

- 稳定性，由 97%升高到 99.99%。

- 性能提升—满足同样 QPS 情况下，机器由原来的 36 个 8 核 12g 实例减少到 24 个 4 核 6g 实例。成本上有了大的减少。

人效方面的提升，可以通过 hawk 随时查看访问数据，异常实时报警，通过 IM 告知给具体的责任人，通过界面化方式配置微服务的熔断降级方案。

这里是我们通过界面的方式配置熔断限流策略，微服务的熔断策略，之前要修改这些配置需要改代码，现在需要界面就可以了。

当有新的接入方，我们可以打开城市、策略配置，做 AB 实验/各模块策略的配置，也可以对业务进行召回，过滤，排序等一些策略的设定，策略灵活设置，分钟级上线、生效。

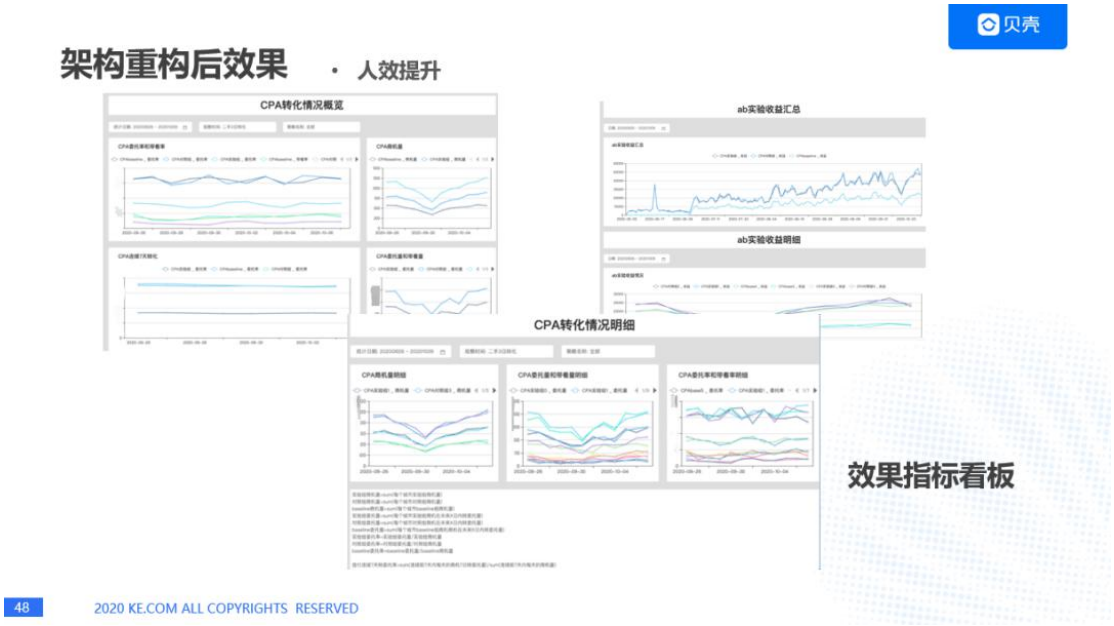

这是一个效果的指标看板。可以看到 CPA 转化情况，商机的情况，转委托的情况，也能看到 AB 实验的结果，就是具体每个策略的转化结果是什么样的，这里也能看到详细的情况。

07

总结与展望

主要有四个方面：

- 贝壳商业化平台计划要打造 AI 算法中台，容纳更多业务。不局限于商业化的业务，还会有图像，估价之类的。

- 兼容多语言。之前有些系统可能是 python, go 语言，我们都可以去对接他们的业务。

- 服务性能优化，使用性能更高的 RPC 框架，进一步提升内部性能。

- 探索更多模型。比如在深度学习方面更多的模型以及线上的部署。

今天的分享就到这里，谢谢大家。

网易大数据用户画像实践

分享嘉宾：张长江 网易 大数据技术专家
编辑整理：黄乐平
出品平台：DataFunTalk

导读：网易大数据生态数量级巨大，且产品线丰富，覆盖用户娱乐、电商、教育等领域，并且 APP 活跃度高，积累了多维度的用户行为数据。通过集团数据资产构建全域用户画像，旨在服务于域内众多业务场景，同时也在探索外部商业化方案。今天借此机会，同大家分享下网易在大数据用户画像中的实战应用经验。

今天的介绍会围绕下面三点展开：

- 网易生态数据介绍
- 用户画像中心分类
- 网易用户画像实战案例

01

网易生态数据介绍

整个用户画像实践经验，都依赖于网易易数中台，所以首先给大家介绍下网易生态数据情况。

1. 网易数据总览

网易数据总览特征如下：

- 数据量超亿级，每日上亿级账号活跃，可触达同人；
- 服务场景多，生态较为复杂，覆盖多行业产品线，包括游戏、教育、电商、泛娱乐等；
- 优质用户平均标签覆盖率达 70%以上；

- 提供包括但不限于参与人、流量域、位置域、关系域等主题域解决方案，即能够封装用户画像在主题域的通用化模块。

2. 网易产品线丰富

网易产品线丰富，覆盖从用户娱乐、电商购物、教育、新闻资讯等各个维度用户行为数据，APP 活跃度高，涵盖用户群广。项目组整体目标是通过集团数据资产构建全域资产用户画像，已应用于网易生态圈内众多业务场景，同时探索产品化及方法论，服务于生态圈外部合作机构，进行商业化操作。

3. 全链路数据中台产品矩阵

全链路数据中台产品矩阵，包括底层日志等数据源层，数据平台加工层，整体标签的离线或实时加工、挖掘算法及监控，以及上层业务应用，如智能分析、增长运营、推荐搜索等一系列业务层应用，组成了网易数据中台产品矩阵。网易易数产品矩阵，为网易用户画像起着极为关键的支撑作用，尤其是数据标准体系、数据治理平台等模块，很好的承载着用户画像落地和质量保障。

02

用户画像中心分类

首先介绍下杭研用户画像整体数据架构及落地情况，主要分为三部分：其一为基础的用户画像，基础标签（如性别、年龄）、行为统计（如活跃）、兴趣偏好及预测等标签；其二为关系库部分，即 IDMapping；其三为主题域部分，即对地域、社交、搜索关键词等相关方面的工作。

1. 网易数据架构

网易整体数据架构底层与各个业务方进行数据交换合作，共同建立公共数据中心，以数仓为蓝本进行架构。

中间层为用户画像中心：

- 用户标签的分类包括基础标签、行为标签、偏好标签以及预测标签等，不同公司分类方法略有不同，如根据更新周期，分为静态标签（性别等）和动态标签（年龄等）；偏好标签包括用户的长中短期偏好等，预测标签主要应用于广告投放部分，例如游戏达人，高价值用户群等。

- 关系库主要是 IDMapping，目前已经有较多的方案论和解决方案，例如多账号的归一用于后续的业务数据挖掘工作，提升对用户的识别能力。典型场景为两个手机号对应只有其中一个有过注册行为信息，另

一个没有注册行为信息，但对于上层而言，应该打通他们作为同一个行为主体。关系库主要包括同机网络（同一设备多个 ID 的关系）、同人网络（同一个人多个设备信息）以及社交关系（人与人之间的关系）等。

- 主题域主要包括地域数据、广告数据、关键词和知识库方向，其中知识库和图谱数据，主要应用于网易域内外内容知识打通。

顶层的应用场景包括增长运营、推荐搜索、广告变现、营销系统、用户反欺诈及内容运营等方面，对业务方提供全方位的服务，不局限于单一应用场景。还有数据规范和数据管理部分，作为数据标准化，沉淀经验方法论。

2. 网易用户画像构建流程

用户画像整体构建流程依托于网易易数中台，搭建起完整的业务数仓体系，融合多方业务数据源。经过多年的探索实践，已经形成完整的用户画像体系，从数据层面到产品层面，逐渐打磨，提供标签管理、监控、报表、算法、开发及权限管理，融合在各业务产品体系。诸如关系图谱形成 API 的接口服务输出各业务方；数据服务包括人群圈选、人群分析等运用于市场及运营团队；特征库方面描述了用户向量化的特征相比标签粒度更为细腻，适用于算法团队迭代开发。在此基础上沉淀了多种数据应用，包括增长运营、广告 DMP、智能风控等方面。

3. 网易用户标签

目前整体总标签数达 1000+，其中不包含单一业务行为数据。标签分类如下：

基础标签，即对用户的自然属性描述，例如性别、年龄、教育背景、生活习惯（早起晚起）、地理位置（POI 信息）、职业状况（所属行业）、经济情况（有车有房）、设备信息（手机、运营商等）、会员信息（各业务方会员等级）、衍生信息。其中衍生标签，如评估是否已婚，在原有的标签体系下没有此类标签，但可以通过对多个标签进行组合生成新的标签，包括是否有小孩、30 岁满足某个条件等。

行为标签包括地域、广告、搜索、全域、播放、点击、评论、关注、收藏、购买等维度。

偏好标签包括出行购物、手机数码、家装家居、教育公益、文化娱乐、新闻资讯、金融理财、游戏竞技、动漫影视、明星艺人等维度。

预测标签包括利用算法等进行预测生成的标签，包括是否出行，是否买车等等。

另外，标签的枚举值也相当重要，业务分析过程中很容易出现枚举值的偏差，不符合实际业务逻辑。除此之外还包括标签间的冲突，例如年龄 15 岁，学历却是博士或者有小孩，策略类标签是标签领域较为有挑战性的地方。

用户标签案例：性别。主要包括三种方案，其一为标签传播，根据用户在各个业务场景，例如母婴商品点击行为标签等进行 item 标记，构建 User-Item 的兴趣网络进行 Graph Embedding，最后进行分类预测用户的性别；其二为利用 NLP 算法对用户的昵称进行语义分析；其三为利用业务属性自行填写的内容进行判断，此处需要对数据质量进行过滤，排除诸如出生为 1990-01-01 的参数异常值信息。基于上述的三类算法特征结果集进行模型的融合，然后对用户的性别进行预测，同时判断该用户性别的准确率，大部分准确率在 0.6+以上可以应用于实际业务场景中。当然除了常见的算法融合，还包括数据融合、特征融合等等。其中需要突破的地方包括特征的稀疏性，因为 IDMapping 打通后的数据覆盖率仅 20%左右，这个严重影响了模型的整体效果。

4. IDMapping

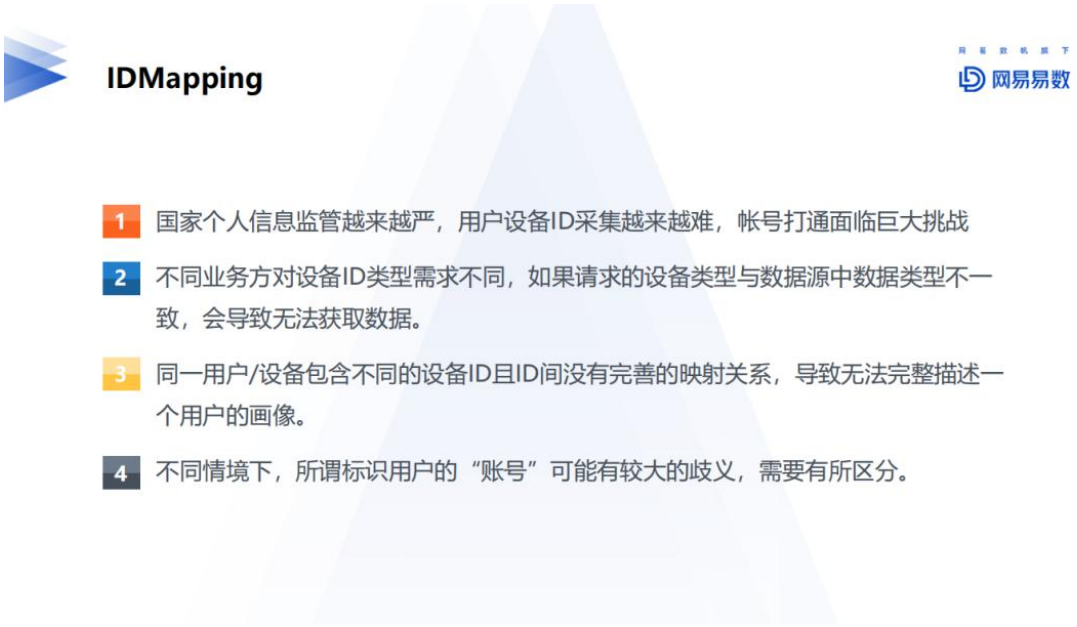

IDMapping 主要指用户设备的打通，用于识别用户的唯一性，现今采用的手段有两种，其一通过工程层面打通，如 SDK 埋点，优点是准确率较高，缺点是还会存在一人多机等现象，导致了不能够较好地完整描述一个用户画像；其二指数据层面打通，通过 ID 关系网，采用规则和算法结合的方法，进行同人识别，优点是很好解决一人多机现象，缺点是准确率难以评估。本次分享，主要指数据层面打通。

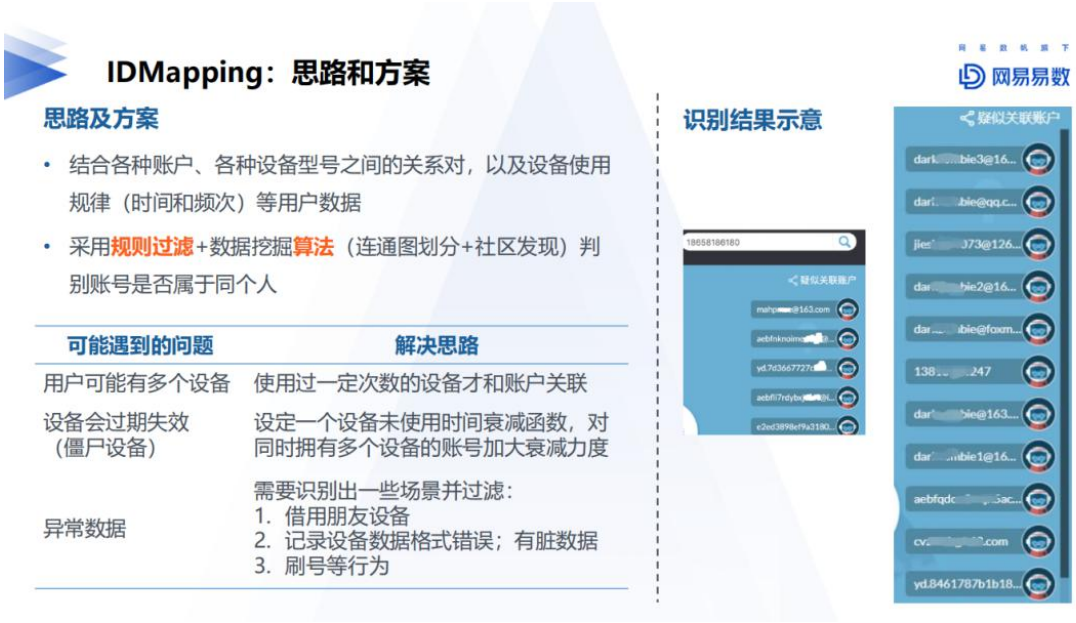

IDMapping 整体的思路及方案，具体要结合各种账户、设备之间的关系对，以及设备使用规律等用户数据，利用规则过滤+数据挖掘算法（连通图划分及社区发现）判断账号是否属于同人。在 IDMapping 过程中，常遇到的问题及对应解决方案如下：

- 用户有多个设备信息，定义相应的阈值进行关联。当然，社区发现当前应用于营销场景，暂没有用于风控或用户运营等场景，因为会把一些异常的账号关联在一起，且会存在仅登录使用过一次的设备信息。

- 设备过期（一般在 2 年半左右时间），设定衰减系数，对单用户多设备加大衰减力度。

- 当然也会存在一些异常数据信息，通过算法识别出包括但不限于以下场景，诸如借用朋友设备、设备脏数据、刷号等行为轨迹。

IDMapping 的存储方式包括两个 ID 类型（关系对）、最近采集时间、最早采集时间、采集源数据、采集源列表、采集的频次和周期。其中共线关系的部分增加了时间衰减系数，同步递减应用于结果，同时也增加了某些参数的权重部分用于提高业务的可选性和高可性。

5. 地域主题域

地域主题域可以挖掘用户的需求信息，包括是否有车，是否经常去 4S 店，通过 WIFI、设备等信息获取亲戚、同事等关系，通过 IP 可以捕获学校的学生信息，根据作息规律进行统计。当然除此之外，地域主题域还用于反欺诈领域，针对黄牛等用户群进行修改地域参数信息，规避系统检测。

6. 用户画像管理与存储

用户画像管理与存储在网易大数据经历了多次迭代，包括前期字符串的拼接、手工标签命名、明文关联维表，再到现在利用 JsonArray 格式进行标签类型管理，这种有个比较大的缺点，就是存在冗余严重，正在尝试新的方案设计。

7. 质量校验与保障体系

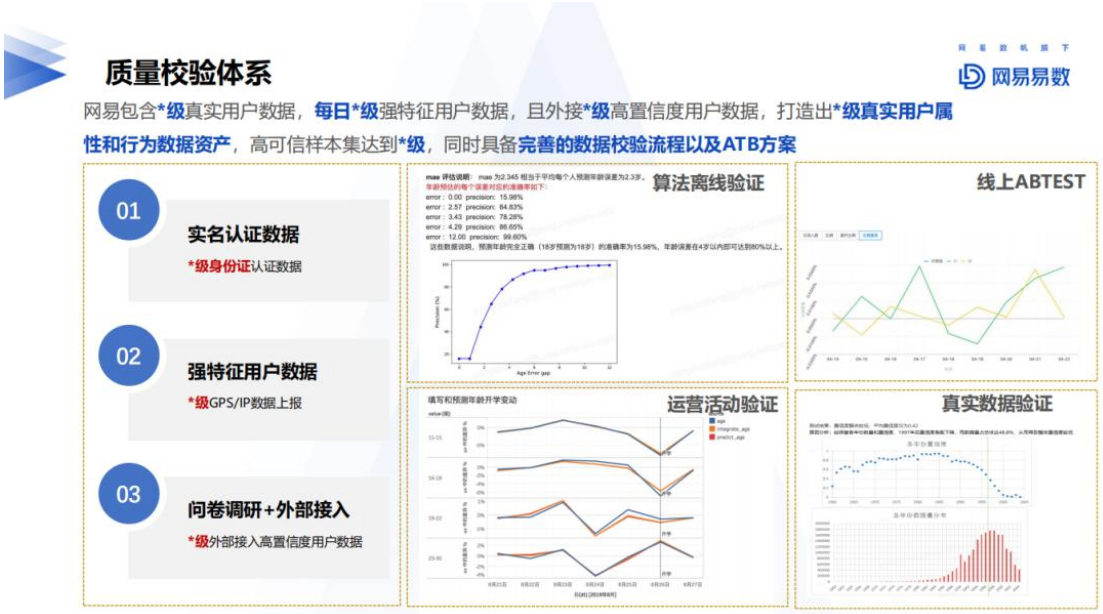

网易标签包含真实的用户数据及特征用户数据，利用无监督的算法模型预测姓名、年龄、有车、有房等，利用有监督进行提升数据质量，提升标签的整体效果。主要包括三方面的工作：

- 利用实名认证数据，作为高可信的样本集；
- 利用强特征用户数据，通过 GPS\IP 等用户行为数据；
- 利用外部数据，增加高置信用户数据质量。

除此之外，还包括利用一些常见的算法，例如交叉验证准确率和召回率，线上 ABTest、算法离线验证、运营活动验证、真实数据验证等等方案。

质量保障标签管理方法论，包括以下四点：

每个标签定义第一责任人，用于快速响应业务需求，同时处理标签异常问题；

流程优化，标签的流程较为漫长，需要了解业务、算法、开发的全流程，利用端到端的模式，通过快速响应增加标签规范化的评审工作；

测试监控方面，测试在标签上线前对标签规范和质量输出测试报告，预测则是针对规范、枚举值等范围，建立监控预警机制；

管理平台化，则是标签生产、加工、处理、应用全流程体系化、标签化、工具产品化，不断迭代升级。

03

网易用户画像实战案例

最后和大家介绍下网易用户画像实战案例。

1. 应用场景丰富

网易用户的多元化数据，能够精准定位用户，覆盖范围广，包括但不限于以下业务目标场景：

市场营销：为人群圈选、人群洞察等提升营销价值；

推荐搜索：为网易算法团队提供数据输入；

增长运营：为用户研究、数据运营等提供数据支撑；

广告投放：为广告主提供人群定向投放功能；

智能风控：为营销反欺诈，诸如薅羊毛、资金风险、异常用户识别提供特征算法服务。

这里重点讲解下营销反欺诈薅羊毛案例，此类用户资源池有限，通过频繁地切换 IP、WIFI 等设备信息，规避风险。利用用户画像及其特征，切入智能风控，能够提升 6%的风险用户识别率，同时结合知识图谱、IP 黑名单、异常设备等方面的数据信息，能够较好地扩大数据价值。

2. 用户画像案例

通过覆盖用户出行、娱乐、设备、购买、地址等维度数据，基于基础标签、事实标签以及预测标签等标签，应用于上述提及的多个业务场景中。通过用户画像，可以知道用户偏好，购买相关等偏好信息。

3. 实时全链路推荐案例

网易用户数据服务实时方案，打通各个业务场景的数据孤岛信息，实时融合用户的数据资产，深度洞察分析用户属性信息，支撑各个业务间数据打通和服务，实现了"采集+计算+调用"的实时全链路体系。例如，在冷启动新客阶段，利用用户画像能力，将离线特征放进 HBase 中进行实时计算，在多业务场景进行交叉，全链路支撑各业务数据打通和服务，为业务方提供二次服务。另外，利用实时用户画像结合知识图谱捕获用户行为轨迹，避免用户流失后造成的无购买、点击等行为，进行二次触达，增加业务转化效率。

4. 总结

网易数据用户画像中台显著提高了数据生产力，逐步沉淀方法论和产品，赋能域内众多业务场景，探索外部商业化解决方案。

今天的分享就到这里，谢谢大家。

用户画像在阅文的探索与实践

分享嘉宾：陈炜于 阅文集团 高级总监
编辑整理：李沛欣、马宇峰
出品平台：DataFunTalk

导读：阅文作为国内最大的网络文学公司，我们在实践过程中，总结了一套适合自身业务特点的用户画像方法论，及实践经验。本文将介绍为什么需要用户画像，以及如何做用户画像，并结合在阅文场景下所面临的问题，为大家分享下我们在用户画像上的探索与实践。

01

背景介绍

1. 关于阅文

阅文集团是国内最大的网络文学公司，有很多原创文学品牌，包括起点中文、创世中文、起点海外、以及云起书院等；也有几款用户量很大的阅读类 APP，包括

起点读书、QQ 阅读、红袖读书等。另外还有自己一些上下游的企业，如影视制作发行公司新丽传媒。这些都是我们用户画像的应用场景。

2. 阅文智能业务中心

阅文智能业务中心的整体架构主要分为：数据层、大脑层和应用层。

① 数据层

包含了智能业务中心可以采集到的各种带有数据属性的数据。这里 AGC 数据是作家创造的网文内容，UGC 数据是观众或读者，在评论区、书评区、书单等产生的 UGC 内容。

② 大脑层

是智能业务中心的基础，主要解决对用户的洞察，以及对文本内容的挖掘和理解。今天要分享的用户画像就处在这一层。

③ 应用层

赋能给各处的应用，主要包括两类：

一类是助力用户找书：助力用户更好的找到想看的书，助力用户浏览阅读体验的提升。主要包括推荐、搜索、精细化运营等。

一类是助力内容衍生：助力实现整体内容延伸，包括内容理解和内容风控等。

下面给大家详细介绍下我的一些思考和做用户画像整体的方法论，以及在阅文的探索和实践。

02

思考和方法

1．思考：画像为何存在

① 需求：

精细化：

互联网时代已经走过了原来的野蛮增长过程，大家手机上虽然装了很多 APP，但可能很多 APP 是不会打开的。这导致如果 APP A 想要获取流量，会找 APP B 把流量给获取过来，而不是因为流量红利的存在，有很多用户会主动安装一些新的 APP。所以我们从增量时代，来到了精细化时代。这时，用户画像显得非常重要，如何能够更好的洞察用户意图，理解用户背后隐藏的意图以及对用户标签的洞察，可以很方便的助力整体业务的发展。

用户价值：

另外，现在用户的价值越来越细分也越来越多维。在精细化时代，C 端的用户价值往往会偏向于 B 端的应用场景。比如下面这个问题：

有很多的内容要改编成电视剧、游戏、电影、动漫。那么，什么样的内容适合改编？这些内容到底能够带来多少价值？价值如何定义？这时，我们发现用户价值往往起到了决定性的因素。

比如一部网文吸引的读者，都是年轻化的读者，如在校学生或者初入职场的毕业生等。那么，这部网文就适合改编成励志剧或者校园情景剧，它的想象空间和受众的广度，就可以提前洞察到，便于在改编时有一定的用户基础。杜绝了"直接拍脑袋改编剧集，再去看市场反映"情况的发生。这就是用户画像在用户价值方面的体现，可以很好的帮助网文的改编。

② 能力

有了需求以后，在我们的业务场景，能够把用户画像建起来么？早在我 10 年加入百度时，百度已经开始做用户画像的整体建设了，由于百度是做精准广告出身的，这就需要精准的用户洞察。这时，外面很多的小公司还没有对用户画像进行建设，一是因为数据量可能没有那么大，二是因为自身的算法模型还没有完备。随着阅文业务的数据量越来越大，结合算法模型能力的提升，可以精准的挖掘出背后隐含的用户意图。

③ 发展

数据资产：

用户画像是公司对未来发展的重要基础。用户画像聚集了"上帝"，因为我们做所有的 APP 都是为用户服务的，希望给用户提供更好的体验。这些"上帝"形成的画像，无形中成为了公司的资产，这在每个公司都是适用的。

潜在壁垒：

在资产之上可以衍生出更多的产品，这就形成了潜在的壁垒。对于阅读领域，我们有自己对画像的提炼，可以对国内用户的阅读倾向，有更深刻的洞察和理解，这样就形成了公司的壁垒。我们再以字节跳动为例，字节跳动一开始只有今日头条一个主 APP，但在主 APP 的发展过程中，他们积累了很多用户的精准画像，如用户 A 喜欢车，用户 B 喜欢短视频，在这基础上，使得字节跳动孵化出了抖音短视频和懂车帝，这背后都跟用户的精准洞察是息息相关的。

这就是我们为什么要做用户画像的一个原因。

2. 思考：画像如何来做

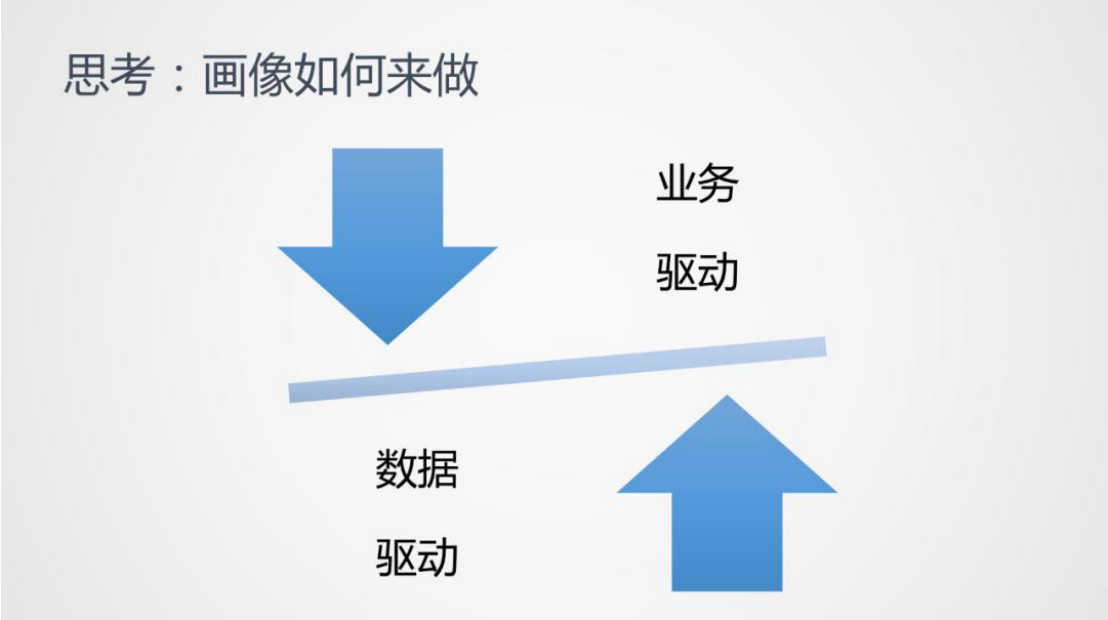

我们知道了为什么要做用户画像，那如何来做用户画像？如何构建用户画像标签体系？是数据驱动？还是业务驱动？

① 数据驱动

从 Bottom to Up，也就是自底向上（ 自下而上 ）。那么底是什么？底是公司所有的数据资产，是由数据驱动，可以发现用户有哪些规律，找到用户画像的隐含标签。这是一种方法，从数据驱动去解决，可以看到用户有哪些标签。

② 业务驱动

所有的业务对用户画像都有一定的导向性。因为技术总归要应用到某些特定的场景，如某些 B 端场景应用价值的评估。这时要看业务想要聚合哪一类型的用户，需要找到这些用户。这就是以业务为驱动，来找到下游要做怎样的标签体系。

3. 方法：数据驱动+业务驱动

一般来说，用户画像是业务驱动或者数据驱动的。而在做阅文整体的用户画像时，考虑的是业务和数据相结合。

基础数据驱动的用户画像洞察，当提炼出一些标签以后，会决定业务行动的效率。比如对流失了 3 天的用户，要做一些促活的活动，先会通过数据提炼出流失 3 天的一些用户，去做用户激活，比如 push（ 消息推送 ），进行 push 之后可以拿到基础数据反馈的结果，从而更好的驱动用户画像标签的优化。

进一步，如果最终画像标签是为了促活而使用的，那么我们可不可以预测下，哪些用户有存在流失的可能性，而不仅仅只是从基础数据得到自己流失 3 天的、被定义为将要流失的用户。这样就形成了正向的闭环，可以有效的提升画像标签的精准性，并提升用户画像的价值，可以更好的解决业务面临的一些问题。

03 探索和实践

前面讲述了对用户画像整体的总结与思考，也就是总的纲领，现在展开讲一下我们的一些探索和实践。

1．背景

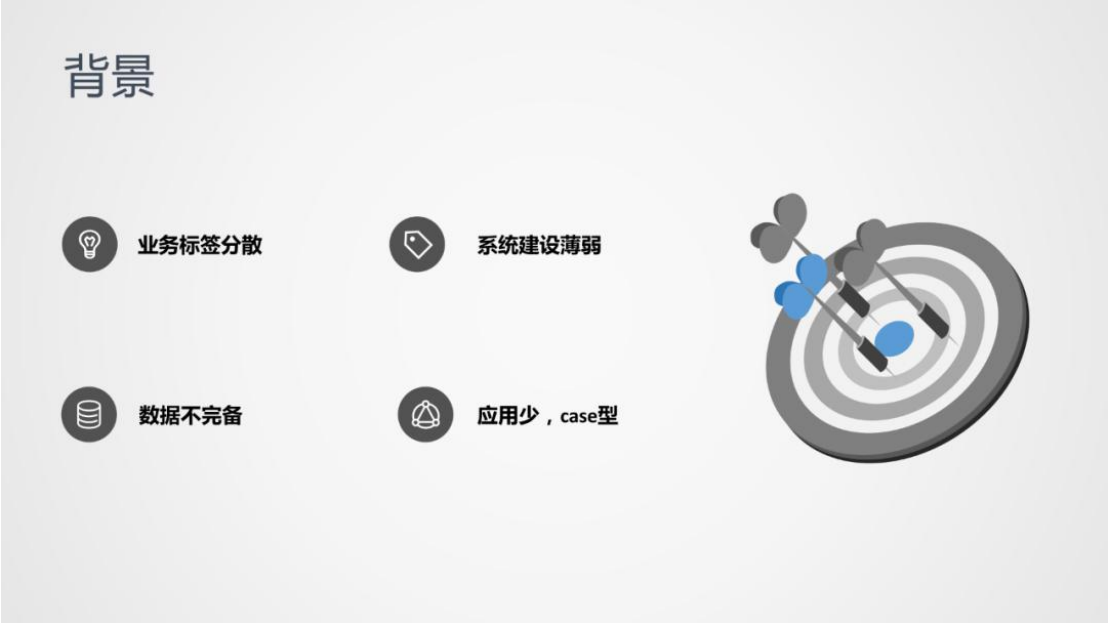

阅文用户画像建设的背景：阅文集团旗下有多款阅读类 APP，虽然在国内网络文学领域占了绝对的领先位置，但有很多独立的 APP，导致标签无法单独成为统一的、独立于 APP 而存在的体系，这导致了以下几个问题：

业务标签分散：每个 APP 都有自己定义的业务标签体系和业务表现。可能都存在自己业务线的用户标签或用户画像，没办法形成合力。

系统建设薄弱：在之前所有的系统建设上，存在着很多薄弱的环节，很多大数据的组件都是没有的，如实时数据的整体实时数据流、离线的挖掘系统等，都是一种算力的缺失。

数据不完备：做用户画像时，考虑更多的是全局，但割裂的数据会导致信息都是不完备的，没办法学习整体用户画像。

应用少，case 型：用户画像的应用较少，以 case 型为导向。

2. 方法：收敛，基建，应用，反馈

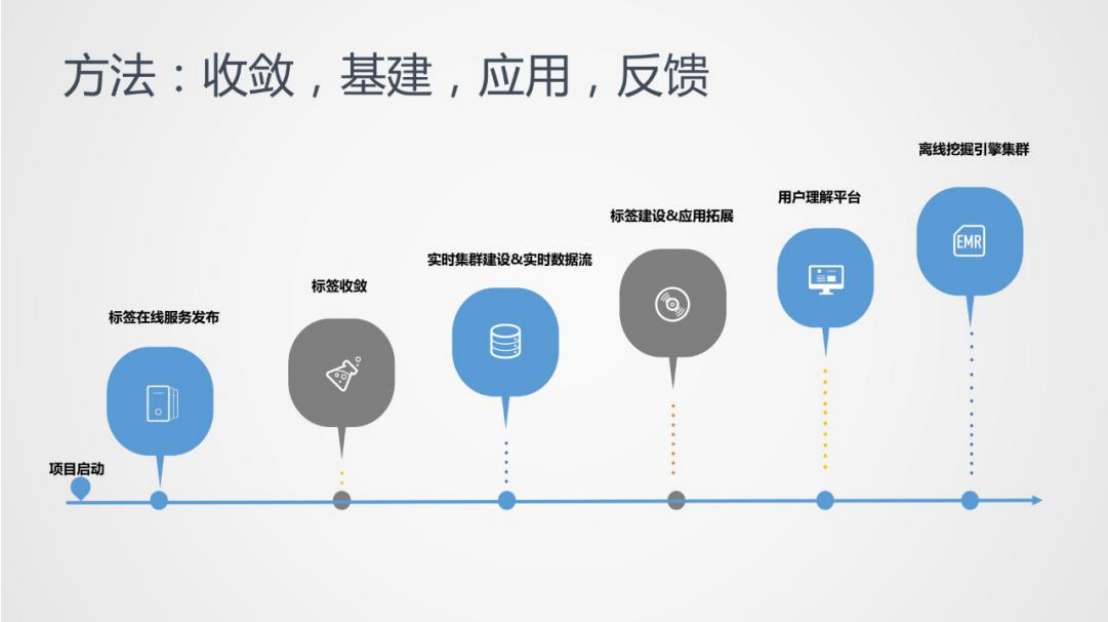

具体如何解决这些问题，更好地建设和应用用户画像，我们在此做了一些关键节点的罗列：

标签在线服务发布：我们发现标签最主要的应用是在推荐场景中，且更多是标签在线服务的应用，这时就需要发布整体的标签在线服务，以便对所有标签的在线调用进行统一收口。以前对 A 的推荐可能会调底层 Cache Redis 中的一些表边或线上的接口，导致所有的调用是比较混乱的。于是我们采用了先把用户画像的在线服务接口发布出来，让所有的标签推荐、后端应用，所调用的接口都进行统一收口。

标签收敛：因为业务标签都分散在各个方面，因此我们希望整合这种标签。有调用的收敛以后，我就可以把事情整合起来，因为有上游的日志来圈，到底哪些标签是被调用的，哪些标签没有被调用。底层的标签可以跟业务口有一道屏障，能够把东西给屏蔽掉，只对底层的标签来做一些收敛工作。

实时集群建设&实时数据流：接下来，我们解决了工程实践上的一些短板，比如刚才讲到的实时集群和对实时数据流的诠释。我们引入了外部的一些开源的大数据实时流系统，建立了自己的一套实时数据流。

标签建设&应用拓展：在有了实时数据流后，我们可以建立实时类的标签，当有了标签的收敛后，就可以扩展到更多的应用，来调用我们的接口，这里主要体现在精细化运营上的一些拓展。

用户理解平台：有了整体的系统以后，我们搭建了自己的用户理解平台，何为理解平台？一是为了更好的追踪数据质量，二是在这上面能够做一些简单的应用，

或者简单的用户整体分析，供给 B 端进行使用，直接在我们的用户理解平台上解决问题。

离线挖掘引擎集群：这块是今年上半年主要做的，我们原来所有的数据流都是以 Kappa 架构来解决问题，也就是以实时数据累加的形式来解决标签的建设。从今年开始逐渐把架构改成了 Lambda 结构，希望引入离线挖掘引擎的集群，获得大规模计算的能力，解决更复杂的模型挖掘与数据挖掘工作。

3. 用户画像系统全貌

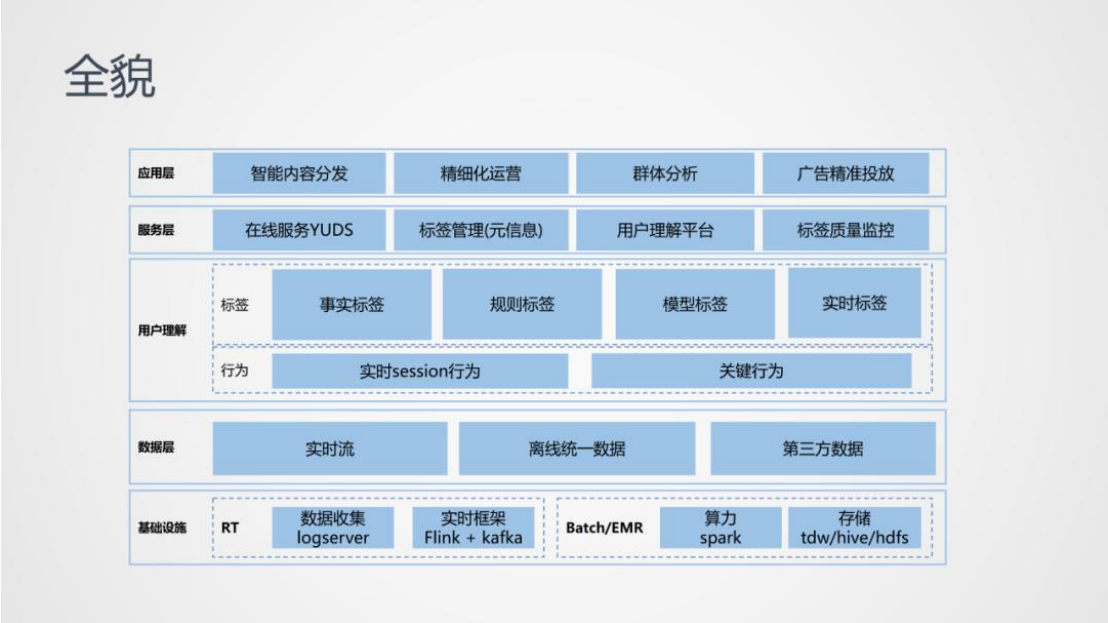

简单看一下用户画像系统的全貌：

① 基础设施

基础的算力依赖，主要包括：

实时依赖。主要是我们自建的数据采集框架和 Flink Kafka 实施框架。

离线依赖。主要采用了 spark 集群，并复用了腾讯 tdw 的存储资源。

② 数据层

包括实时流、离线统一数据、第三方数据。这里说一下离线统一数据：

以前更关注的是离线数据，但是当 APP 越来越多以后，各个端的离线数据口径和埋点是不一致的，有非常大的挑战，特别对于成熟的公司做用户画像时，会发现这一块最耗费精力，因为要对所有的数据口径进行梳理。所以这块未来希望有一套统一的离线数据来支持上层整体的用户画像应用。

③ 用户理解层

在数据层上面，再会构建自己的用户理解层，基于数据去理解用户。主要包括行为和标签。

行为：

因为有些行为是有强意图的，我们希望把强意图的行为也能够直接积累起来，并在上游直接应用。行为主要包括实时 session 行为和关键行为。

实时 session 行为：基于 session 可以挖掘到上游更多的意图，还可以基于 session 进行线上调整，应用于精细化运营和推荐等。

关键行为：需要累积好，对上游的应用或者精细化运营有非常大的应用场景。有业务需要调用时，可以直接复用这种关键行为。基于这种行为以后，我们才会去挖掘标签体系或者挖掘用户画像。

标签：

对于标签，主要包含了 4 类：

- 事实标签：一些更偏事实类的标签，比如用户是什么等级的用户
- 规则标签：就是通过一定的规则计算出来的标签
- 模型标签和实时标签：通过模型挖掘的标签，以及可能服务于具体业务的实时标签。

④ 服务层

在用户理解的基础上，我们可以提供各种服务：在线服务 YUDS（ 统一收口服务)、 标签管理 （ 很多标签业务用过以后，下次再用时不知道标签是什么含义了，希望有一套标签元信息的管理，能够很好的管理起来，达成标签的更强复用)、用户理解平台以及标签质量监控 （ 监控标签的质量，调优标签的结果)。

④ 应用层

这里不再细讲，在后面会展开一下。以上，就是我们用户画像系统的全貌，下面再详细为大家介绍下：

4. 基础：不可忽视的数据建设

万丈高楼平地起，没有数据，画像都是无根之草。对于数据建设会强调几个方面：

数据质量：如何保证数据的覆盖面和准确率？这需要一套完整的数据监控体系，通过数据监控体系完善数据的覆盖面和准确率。比如能够通过数据监控体系看到每次发版灰度流量时，数据有没有变少，覆盖面有没有降低，准确率有没有降低等。

数据时效：线上延时可能会导致采集的数据延迟。我们希望能够尽量解决，而不是像以前一样小时级别来导一次数据，数据时效性无法满足线上的需求。这块重点在于实时数据流的建设。

数据平台化：对于集团类公司，有很多类型 APP 时，这一点是非常重要的，要解决数据的统一问题。再就是 ID 的贯通，在很多的业务、场景、APP 都需要 ID 贯通，需要有一定的手段解决 ID 贯通的问题。

这些都需要对数据体系进行统一，我们从 19 年开始，就一直在做数据收敛和埋点的统一。只有数据的统一，形成整体的平台化以后，用户画像才能更好的解决集团整体的一些问题。

5. 支撑：架构建设

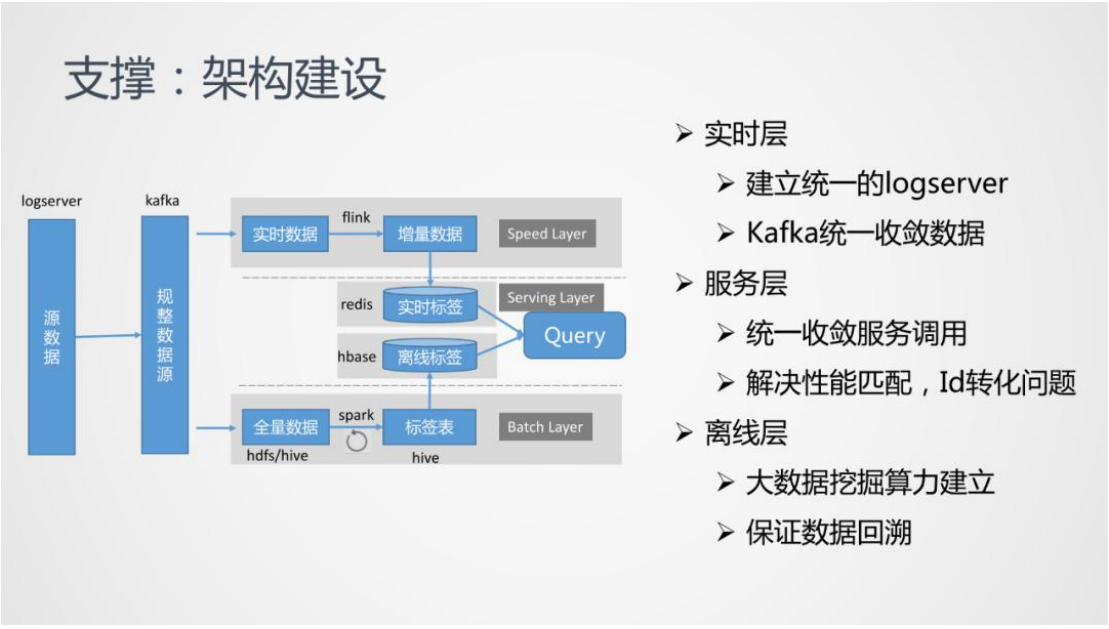

有了数据的基础后，就是对工程架构的建设。在业内主要有两种工程架构：

Lambda 架构：包括实时层、服务层和离线层

Kappa 架构：没有离线层，所有的数据都是从实时层进行累积，再通过 Server 层直接出去

我们的架构是从 Kappa 架构过渡到 Lambda 架构的：

- 离线层：我们希望有离线的大数据挖掘能力，因为在线时，发现很多模型类的标签没办法通过在线直接挖掘来。另外，我们希望保证数据回溯。有时标签会改掉一些定义或者手段，我们希望对所有的数据进行重刷，这时在开发架构中，重刷会遇到很大困难，但在 Lambda 架构，可以比较方便的做整体的重刷。

- 实时层：主要是在工作时建立统一的 Logserver，收敛整体数据流的采集，当采集完以后到 Kafka 做一层规整，由 Kafka 分别导给实时层、离线层等。在实时数据流中，主要采用的是通过 Flink 框架来解决实时数据的挖掘。

- 服务层：主要解决统一收敛服务的调用，所有外界的服务调用都统一通过这个调用口进去，这样可以很好地屏蔽上层业务层和底层标签建设，不会影响业务工作。另外，我们还会解决 ID 转换、性能匹配等工作。

6. 内容：标签建设

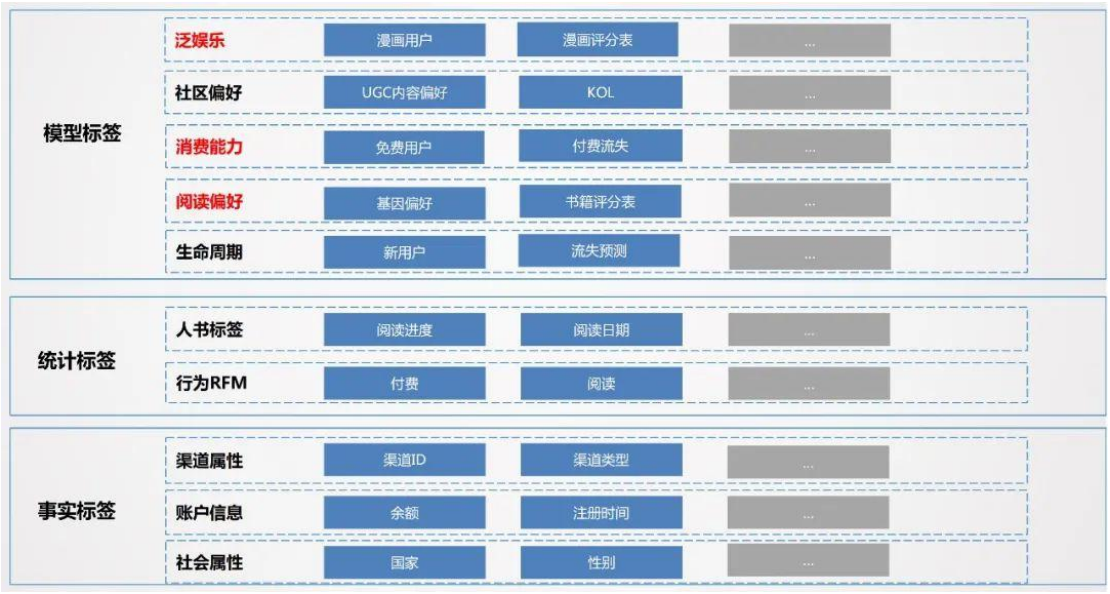

有架构以后，要填充内容，内容其实就是标签。刚才在全貌中大家也看到了，有事实标签，规则标签（统计标签），还有模型标签和实时标签。这里重点展开讲一下阅文特有的模型标签，阅读偏好。因为我们是属于阅读业务领先的公司，主要解决的是用户阅读类型问题。

阅读内容偏好：比如用户是喜欢阅读历史类、文娱类、搞笑类的书，还是庆余年这种架空历史类型的书，这就是阅读内容偏好

阅读时间偏好：比如用户在什么时间点经常会来看书

阅读习惯偏好：有些用户在看书时，只看连载完结书，觉得完结书看起来比较爽，不需要追连载。

阅读字数偏好：有些老用户可能当网文积累到一定字数才会看，因为这样老用户会觉得这本书写的还可以，是被验证过的。

阅读行为偏好：有些用户在阅读时，会先翻一翻，挑到最后几章、最新的几章看一看，再来决定看不看这本书。这种都是用户阅读行为上的习惯，这需要我们通过数据挖掘的手段来掌握用户的阅读行为偏好。

付费阅读偏好：是消费能力的一些积累。后面还有一些泛娱乐的标签，是因为我们的内容形态不仅有网文还有漫画等。

7. 价值：应用

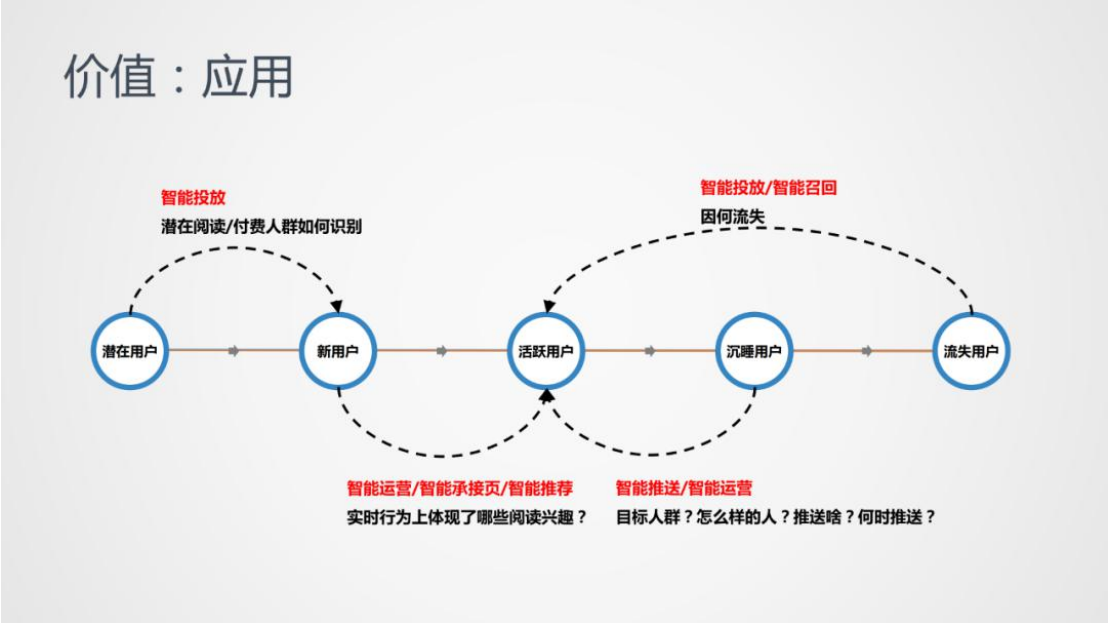

用户画像的应用价值在哪里？我们通过整体的用户生命周期就可以很容易看出用户画像的价值。从潜在用户到新用户，可以识别潜在阅读/付费人群，来进行智能投放；从新用户到活跃用户，可以通过实时行为看出用户的阅读兴趣，来进行智能运营、智能承接页、智能推荐等；还包括未来的流失召回，以及自己用户的激活都跟用户画像息息相关。

8. 反馈：验证+闭环

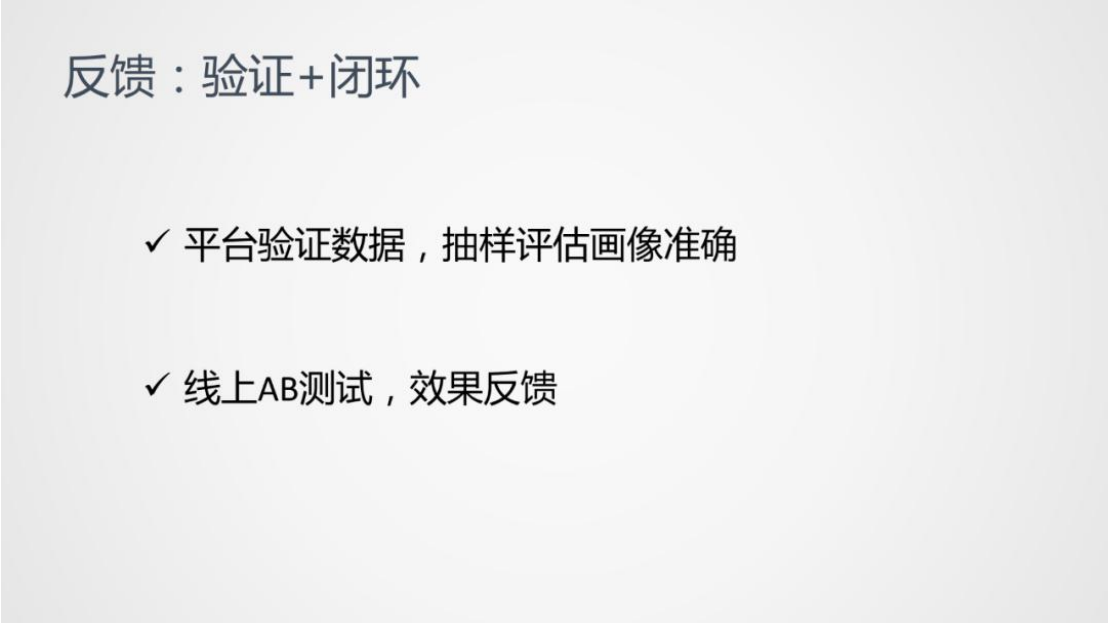

对于建设整体的标签体系，反馈是非常重要的一环，用来保证用户画像的准度。

主要方法有：

平台验证数据，从用户理解平台抽样评估数据、画像到底准不准

线上的 AB 测试，得到数据效果，可以更好的验证模型标签打的是否准确

04

未来展望

未来展望分为两点：

1. 技术突破，奠定泛娱乐的用户画像之基

对基础技术进行突破，奠定泛娱乐的用户画像之基。什么是泛娱乐的用户画像之基？除了网文，我们还有游戏、漫画、动画、影视，是否有一种整体的用户画像基础，可以承接整体泛娱乐场景的用户洞察，这是技术上会考虑的问题。

2. 业务赋能，打造用户全生命周期的赋能

刚刚在应用价值中，有讲到把用户整体生命周期串起来看，用户画像能在某个点、某个场景中进行进一步的赋能。在这里，我们希望可以跟业务有强绑定，通过推荐、精准的精细化运营等手段，解决线上的用户全生命周期的管理及赋能问题。

今天的分享就到这里，谢谢大家。

用户画像实践：神策标签生产引擎架构

分享嘉宾：王琛@神策数据
编辑整理：冯露
出品平台：DataFunTalk

导读：用户画像是建立在数据基础之上的用户模型，是产品改进、精准营销等业务场景中不可或缺的重要基础。而构建用户画像的过程就是要给用户打上各种维度的标签，并基于标签进行定性或定量分析。这其中，建设灵活、全面、高效的标签体系是工作的重中之重。本文就从标签体系建设的需求出发，阐述神策数据在设计标签生产引擎过程中所做的思考和实践。主要内容包括：

- 用户标签及其应用场景
- 标签生产平台的需求
- 批流一体的标签生产架构
- 总结

用户标签及其应用场景

1. 什么是用户标签

简单说，就是对用户的某个维度特征的描述。对一群用户而言，我们为了能让业务做的更好，就想知道他们的很多特征。比如说，我现在有个 10 万块钱的活动预算，那这个钱应该集中花在哪里呢？针对这个问题，我们希望对给定的用户群体，能知道他们的商业价值，对他们的商业价值有一个很好的描述。知道里面哪些人才是我们重点要服务的对象。

2. 用户标签的应用价值

用户标签的应用主要是四种场景：

用户特征洞察：

辅助用户分析和用户洞察，用户标签可以帮助业务人员快速的对用户有一个认知，然后发现里面显著的特征，获得一些商业灵感。

增强数据分析：

标签还可以丰富数据的维度。对我们的业务数据，有更深层次的对比分析，而分析洞察得到的灵感以后，可以辅助业务落地。

精细化运营：

一方面，可以将用户群体，切割成更细粒度的群组，使得运营从粗放化到精细化，用多种不同的手段，不同的渠道去触达，比如说短信、推送、邮件等等，对于用户进行驱动或召回，从而达到事半功倍的效果。

数据产品应用：

另一方面，除了驱动人工的业务以外，用户标签还可以成为其他数据产品的基础，比如个性化推荐系统，广告系统，CRM 等这些系统。自动化的业务系统能更有效的利用这些用户标签，从而发挥更巨大的威力。

3. 为什么常见的标签体系用不起来？

用户标签其实已经不是新概念，十几年前，就已经有各种各样的标签系统，但是在我们这几年的实践过程中，其实发现，很多的标签系统在实际落地的过程中，都会多多少少的遇到一些问题。这里面主要是两大类问题。

难全面覆盖：

在创建标签的过程中，数据的提供方希望尽可能满足各种各样业务的需求，就会有一些发散性的构思，但是实际上在操作中很难覆盖特别的全面，业务是一直变化的，不能预知一年以后这个业务发展成什么样子，所以很难覆盖全。

难落地应用：

另外一大类问题，业务方在使用的时候，面对的是成百上千的甚至上万的标签，他们也比较懵，不知道怎么使用，也不知道标签的统计口径是什么，用户分层的切割规则等等这些，从而导致了不会用或者不好用，用不起来。

02

标签生产平台的需求

1. 应用驱动的标签构建

我们的解决方案其实是基于标签的应用流程，去反向去反推这个标签体系的构思和建设。

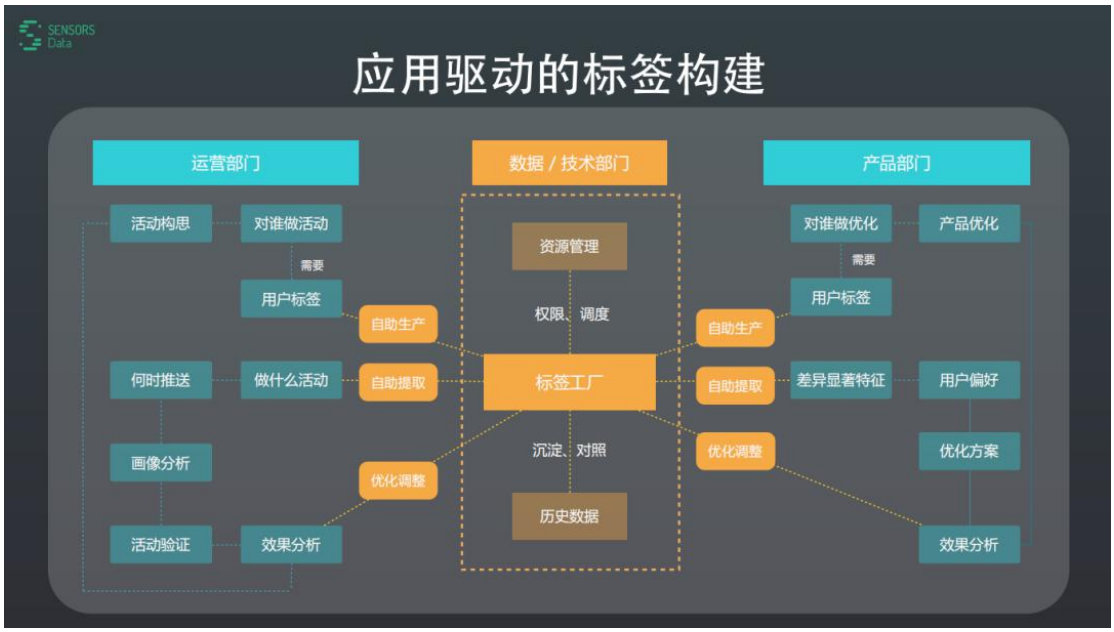

这个反推，其实是一个比较需要业务经验的事情，根据我们的经验，大部分情况下，产品部门和运营部门，都会有一些不同的标签使用方式。比如运营部门，一般是用于做活动，他们关心的问题是，怎么样做一个活动才能够提高客户的转化。而产品则是负责对某一个问题提供解决方案，他们需要观察的是客户的特征，去决定如何设计才能解决大多数的问题。

2. 根据标签的使用目的，体系化梳理标签

总体来说，无论是产品还是运营，我们都把它叫做业务部门，他们应用标签的流程实际上一般来讲就分三步。

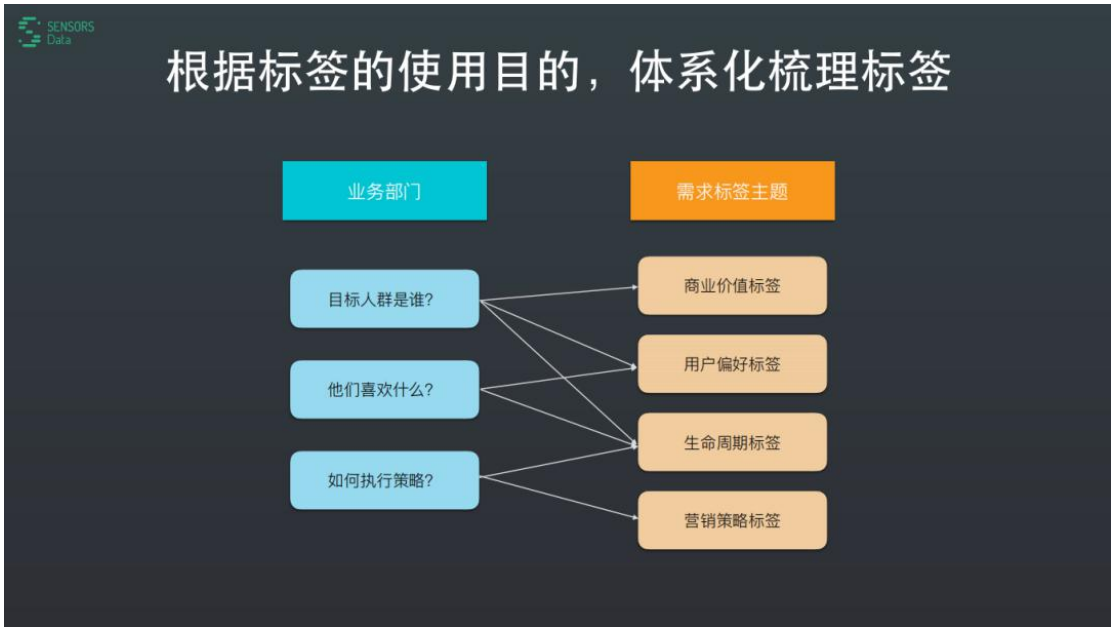

目标人群是谁？

其实是一个战略性的问题，定位的目标人群，这里其实往往应该先看，比如说商业价值类的标签，然后去帮助我们的业务人员发现商业价值最大的那个人群。

他们喜欢什么？

如果目标人群是有比较明确的行为数据的，比如说他们是活跃用户，这时候应该去看他的用户偏好类型的这个标签，比如他喜欢做什么，然后他的兴趣爱好是什么等等这些。

如果目标人群行为数据比较少，比如说他是新用户，或者是一些静默用户，那这个时候就应该从他们所属的生命周期标签出发，去计划构建促进转化或者是召回的策略。

如何执行策略？

就是我们应该做什么，做一个什么样的策略，这个策略怎么落地？然后当策略方向有了以后，还需要一些具体的参考信息，比如推送什么时间发这种问题，需要有一些具体的营销时机类的标签，比如说用户一般的活跃时间段，然后来帮助整个计划的这个落地。

3. 标签类型

回到整个我们的标签平台本身，我们认为首先作为一个标签平台，它需要具有非常灵活的标签创建的能力，从而才能适应不断变化的业务需求。

具体来说，我们是把需要创建的这个标签分成了三个大类。

数值聚合型标签：

这类的标签就是主要是在用户维度的数值计算，主要是弥补在数据采集当中未能及时补全的一些信息。如：每个用户最近半年消费次数、最后一次消费时间、近一周消费的商品类别

还有一种数值聚合是实时标签，类似这种标签一般都是用于运营活动的受众的筛选。如：某活动开始时间到当前时间，用户的下单金额

分群标签：

顾名思义就是给一群人，给他们打上一个标签。

如：将累计充值金额超过 10000 元的用户标记为 「高价值用户」

如：X 运营活动开始后，通过运营页注册下单的用户，则标记为 「X 活动转化用户」

状态转化标签：

这个是我们在我们定义里面是逻辑相对来说比较复杂的一类标签，这类标签通常来说都是实时标签，对于实时性的要求都会比较高，要求是秒级分钟级的。如：通过行为来标记新用户是否为羊毛党。

另外一类呢就是还有一些比较复杂的运营活动，或者是从控制成本的角度来做一些运营活动。如：在规定时间内，完成运营活动中的至少 3 项任务，并完成领券下单转化的，则标记为「价格敏感型用户」。

4. 标签平台的技术需求

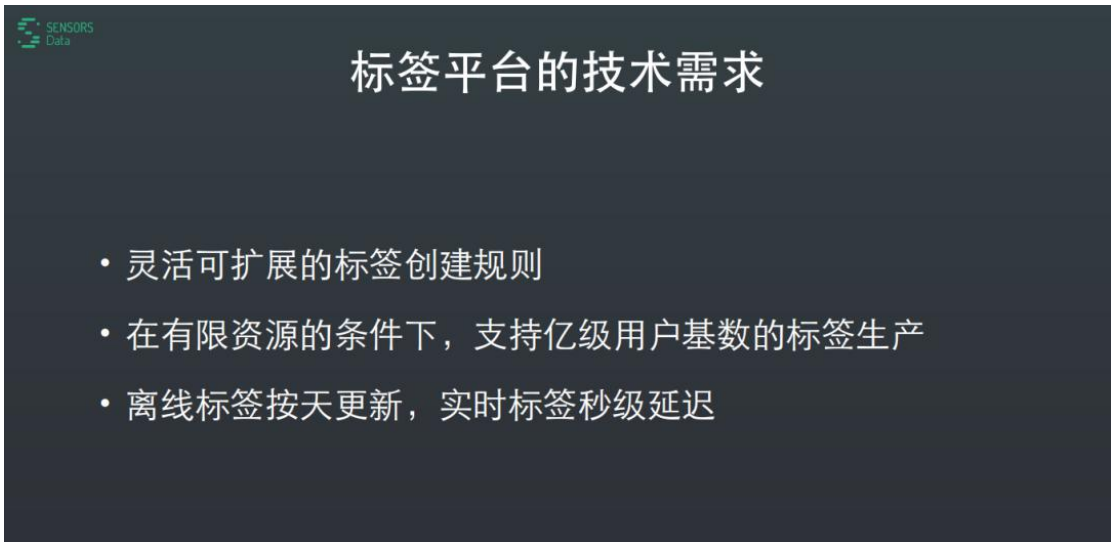

灵活可拓展的标签创建规则：我们需要有非常灵活可扩展的标签的规则的定义。

在有限的资源条件下支持亿级用户基数的标签生产：在相对比较有限的条件下，能够支持相对比较大的用户基数的标签生产，需要对计算或者存储方面有比较高的优化，对于系统架构来说，平台的伸缩性和这种适应性都会要求相对高一些。

离线标签按天更新，实时标签秒级延迟：对于业务，我们一般的标签可能是按天更新的，例行标签。另外有一种就是实时活动，计算的响应要求比较高，实时标签的计算要在秒级之内完成，可能秒级之内还要后面做推送，然后触达到用户。

03

批流一体的标签生产架构

1. 基础数据流

下面主要讲讲技术问题，首先，在我们的理解当中，标签平台是一个中间层的服务，为前台服务提供一个数据支持，然后另外一方面，标签平台它所用到的数据其实是依赖于底层的基础数据平台的原始数据。

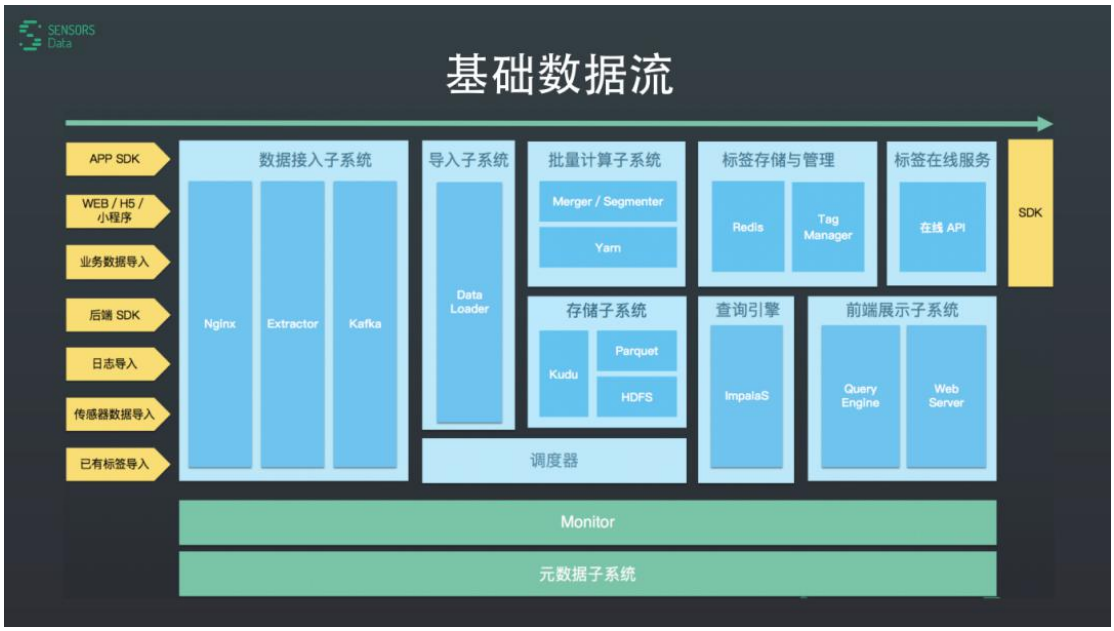

这张图就展现了神策基础数据流平台的架构。数据流是从左到右的，最左边是所有的采集的方式，各种 SDK 采集了数据之后，经过数据接收系统、导入系统和存储系统，然后查询系统，最后展现。

2. 简化的数据模型

在这个流里，数据模型其实是非常简单的，基本会分成两大类：用户行为数据、用户属性数据。

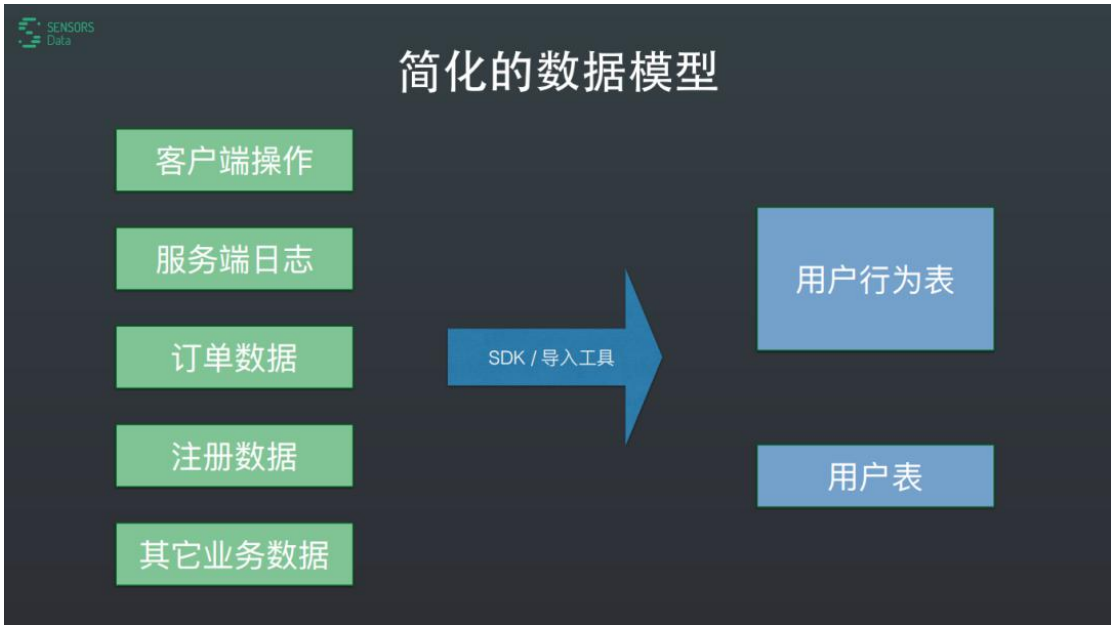

用户行为表：

其实是个宽表，它里面是几个常用的维度，主要描述了什么人在什么时间，做了一件什么事。所以主要字段就是：时间、用户 ID、事件、渠道、搜索关键词、商品价格等。

用户属性表：

用户属性表，主要描述用户的属性情况，相对变化不大。主要字段有：用户 ID、性别、注册渠道、会员等级等。

3. 基于有限流的标签计算

所以在我们的系统里面，首先会做一套批量离线的标签处理引擎，依赖的是我们底层比较稳定的数据结构。这个标签引擎一边读事件数据，一边读用户的属性数据，再配合上特定的标签规则，做一个批量计算，最后生成用户标签。

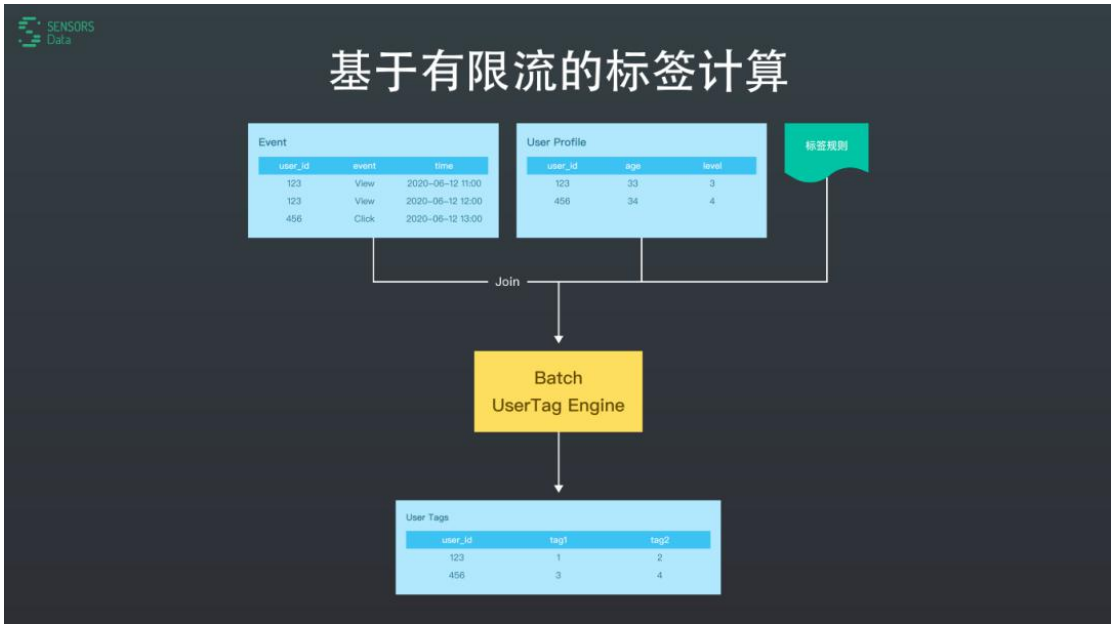

有限流：

Event-User 数据可以理解为永不停止的数据流。只要业务在用，就有不断的数据进来。

批量离线计算开始时，参与计算的数据已完全入库。不会有还没有入库的数据。

在有限流的情况下，数据是稳定的，计算具有幂等性，不会频繁变化。与之相对的就是基于无限流的实时计算标签，在计算启动的时刻，数据还在源源不断的进来，计算不具有幂等性。所以批量标签引擎实际上跟一些离线数据仓库和离线引擎一样，最核心的两部分，一个是调度器，一个是计算引擎。

实现方式：

- 使用 Impala + HDFS(parquet) 为底层计算引擎
- 标签规则引擎负责将标签定义翻译为高效 SQL
- 使用 impala 分析函数实现特定的规则
- 通用调度器负责例行任务的调度

4. 非实时标签数据存储格式

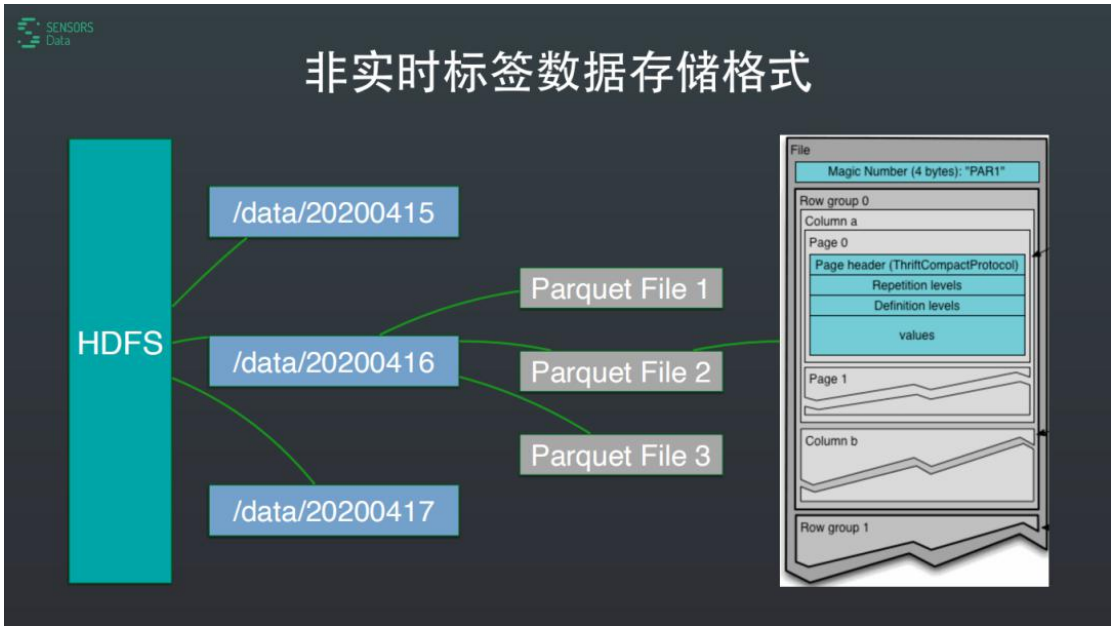

数据存储方面，我们采取的方式是每个标签都存一张物理的表，以时间作为分区，因为离线计算一般都是按天调度的，所以就按天存储，每日的结果存为一个 partition，然后这个 partition 下面存的都是 parquet 类型的文件，并且用 gzip 来压缩。我们这个单表里面每一行是一个用户的 ID，然后后面有一列跟的是它的这个标签的值，在这种结构下用 gzip 一压，其实压缩比还是比较高的，比较可观。

5. 标签宽表加速查询

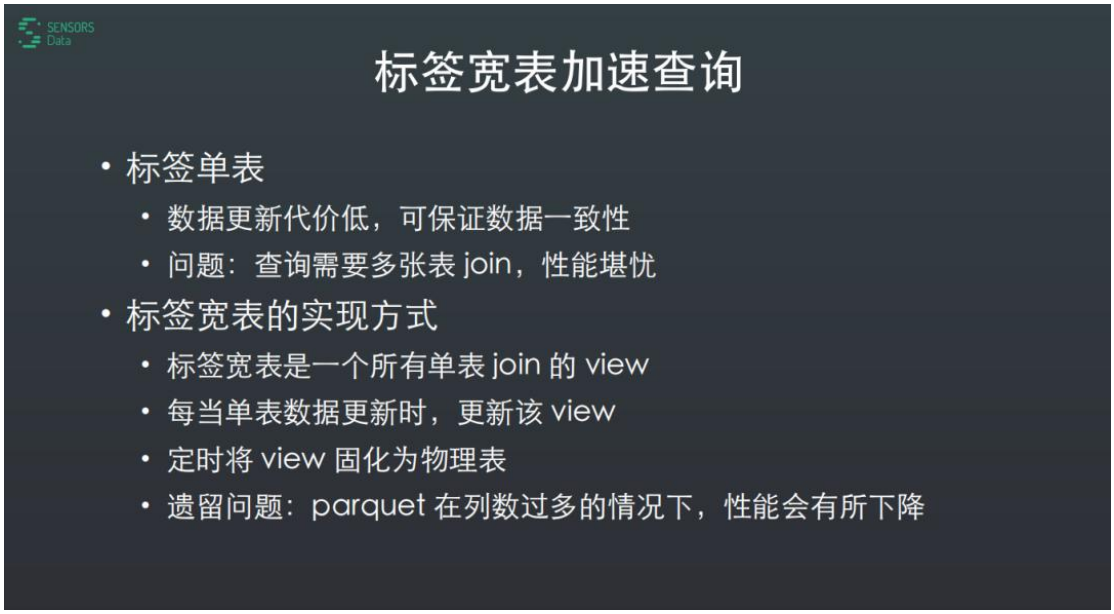

每个标签存一张物理表，其实也是有比较大的问题。这个表虽然在数据更新的时候很好处理，能够保持更新时的数据的一致性，但是对于查询端其实并不是很友好，尤其是在做多条件过滤的时候，需要将底层的多张表进行 join 操作，计算代价很大。为了提高性能，我们在后台会有一个例行任务，定时将这些已经固化下来的标签编号，把它合并成一张宽表，主要依据标签的离线计算，基本上每天都更新一次，更新完了以后这个数据基本上就固定保持稳定了。

标签单表：

数据更新代价低，可保证数据一致性

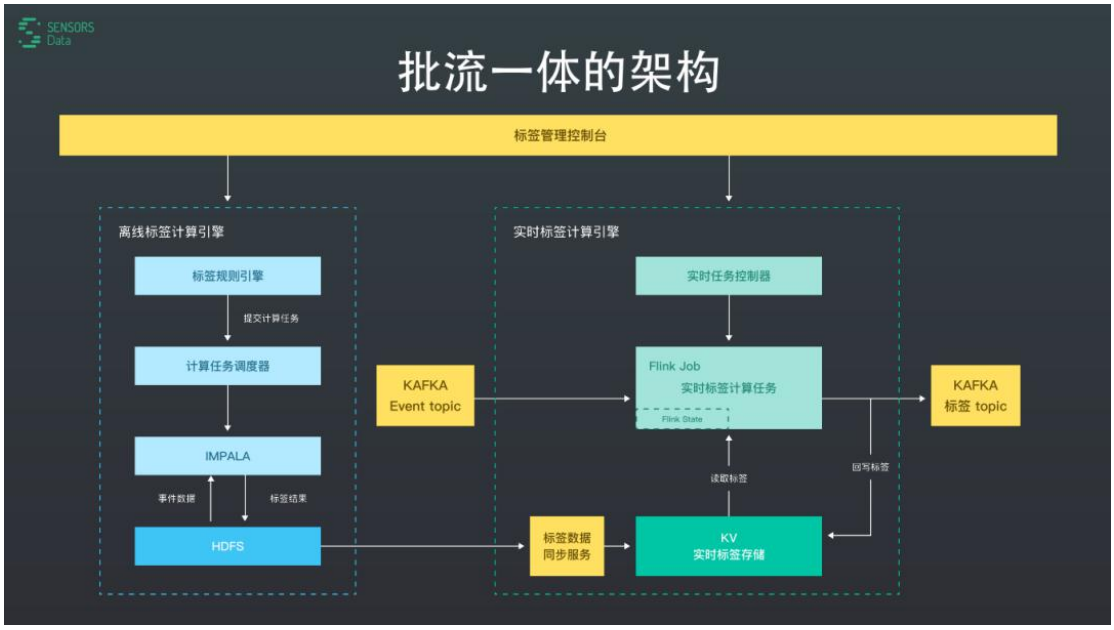

问题：查询需要多张表 join，性能堪忧

标签宽表的实现方式：

- 标签宽表是一个所有单表 join 的 view
- 每当单表数据更新时，更新该 view
- 定时将 view 固化为物理表
- 遗留问题：parquet 在列数过多的情况下，性能会有所下降

6. 用 bitmap 优化人群筛选

另外就是使用 bitmap 来做人群筛选优化，部分标签值所对应的人群使用频次更高，如「高价值用户」、「活跃用户」等。使用标签筛选用户，可以理解成针对人群包的集合操作。

bitmap 过滤的实现方式：

- 将标签值对应的人群包构建 RoaringBitmap
- 人群筛选时，先通过 bitmap 的交并差运算得到过滤用的 bitmap
- impala 使用 bitmap 做最终的过滤器，得到人群包（包含太多元素的 bitmap 体积太大，反而影响效率）

7. 基于无限流的标签计算

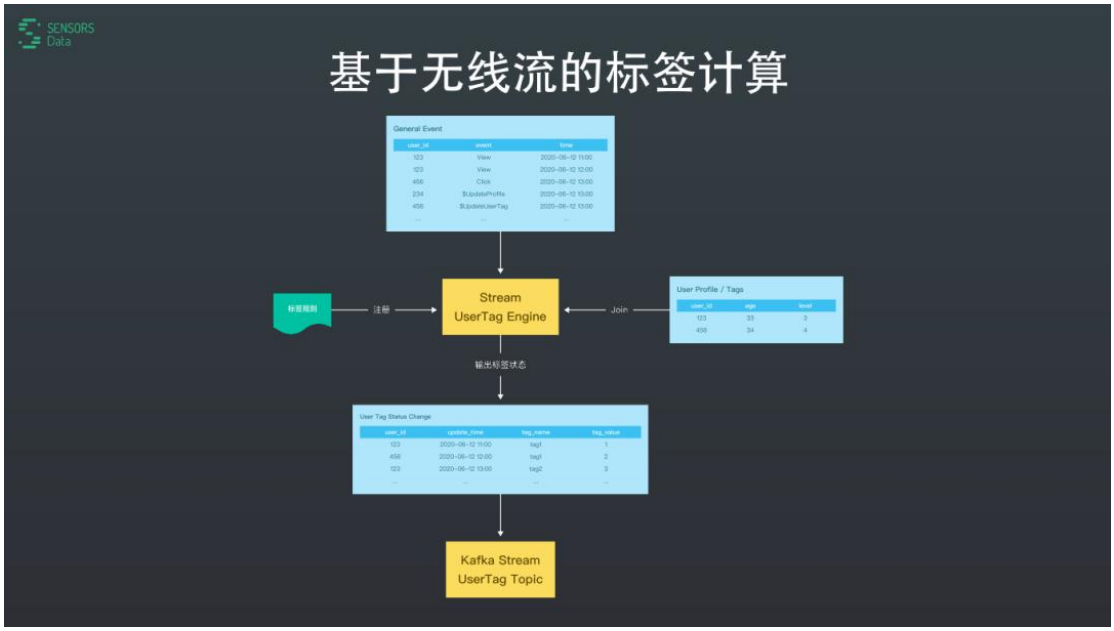

大部分业务场景实际上是离线的部分就能满足了，实时的部分主要是要满足一些运营活动的一些需求。我们这个实时标签引擎其实也并不复杂，输入的数据就是我们实时流的事件数据，根据标签规则，还有用户属性，用户标签对他做在线的一个计算，从而输出的是一个标签状态的变更，最后得到这个标签结果。

8. 实时标签引擎

实现方式：

- 实时标签计算使用 Flink
- Flink job 监听 Kafka 的 event topic，计算由事件触发
- 计算过程就是实现一个状态机
- 计算的中间状态存储在 Flink State 和 KV 存储中
- 实时计算能使用的离线标签，需要先订阅到 KV 存储中
- 标签结果输出到 Kafka 的 tag topic

9. 批流一体的架构

整体的架构就像这张图一样，在我们的标签管理控制台这一层，其实是对标签规则做了一个划分，在这里会识别当前要算的这个标签，到底是一个离线标签还是一个实时标签比较好？如果它是实时标签，它要对哪些离线标签进行订阅，也是在这里处理的。离线标签就做离线的计算，然后在最下面有一个数据同步服务，会把离线标签计算的结果同步到 kv 里面，这里面其实也不会依赖特别多，我们不会给他做一些特别复杂的计算，然后依赖特别多的数据，因为 kv 里面也会有性能问题。然后 Flink State 实际上是 kv 存储的半个缓存，实际上计算由 Flink Job 来进行。

04

总结

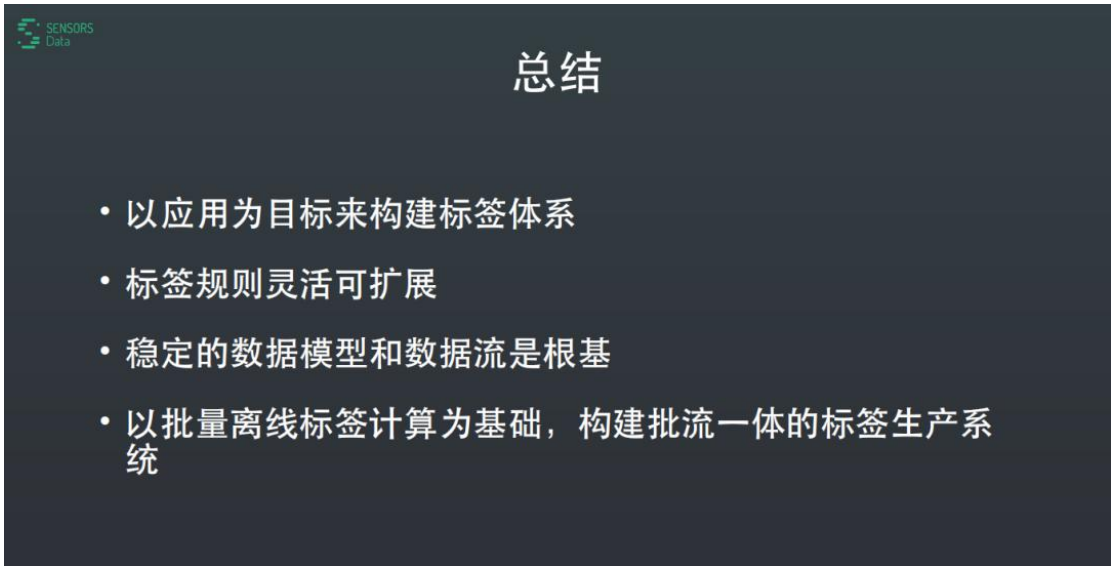

最后总结一下，我们所理解的标签平台，实际上是以应用为目标来构建的标准体系。我们认为在这个平台里面标签规则一定是要灵活的，要让真正做业务的技术小白，也能够灵活的自主配置，然后能够自己搭建这个标准体系，能够自己改规则。在技术层面，标签平台它是依赖于底层特别稳定的数据模型和数据流的，然后标签平台本身它的技术架构实际上是批流一体，因为批量相对来说计算性能更高，代价更小，然后流式是实时性更高，两边一起组合而成的标签生产体系。

今天的分享就到这里，谢谢大家。